第 3 讲笔记

定量数据分析

引言

- 今天我们将开始查看和分析数据。
- 首先，我们将学习如何使用一些简单的统计指标来描述数据。
- 在此过程中，我们还会进一步学习 R 语言。
- 我们先从因变量入手。

为什么要进行描述性统计?

- 初步的描述性统计有助于我们发现数据中的错误、离群值和其他异常情况。
- 这些数值合理吗？是否可能出现？有没有可以作为对照的参考值?
- 描述性统计有助于我们理解数据及其规律。
- 撰写定量研究报告时，需要描述所使用的数据，以便读者理解。
- 有时，对数据本身的描述就非常有价值，甚至可能成为研究最重要的部分。

集中趋势的度量

- 一个关键问题是：因变量的典型取值是多少?
- 这个问题可以通过不同方式来回答。
- 在统计学中，这些指标统称为“集中趋势度量”。
- 最常见的指标之一是算术平均数，通常简称为均值。
- 计算方法是将所有观测值相加，再除以观测值的数量。
- 既可以手动计算，也可以使用 mean 函数。
- 我们先计算 1、9、8、2、7、3、2 这七个数的平均值。

计算均值

- 样本 X 的均值计算公式为：

$$X = \frac{\sum_{i=1}^{n} x_i}{n}$$

- x_i 表示 X 的第 i 个观测值。
- n 表示样本量。

计算均值

```
(1 + 9 + 8 + 2 + 7 + 3 + 2) / 7
```

```
## [1] 4.571429
```

- 或者也可以这样计算：

```
mean(c(1,9,8,2,7,3,2))
```

```
## [1] 4.571429
```

平均小时工资

- 下面查看样本中的平均小时工资。
- 我们可以用几种方法实现。
- 这里使用 summarise 函数来调用 mean 函数并汇总计算结果。

```
summarise(lfs,mean(HOURPAY))
```

```
## # A tibble: 1 × 1
##   `mean(HOURPAY)`
##             <dbl>
## 1            20.8
```

- 因此，平均小时工资为 20.84 英镑。

数据分布

- 均值是可以用来代表数据的一个统计量。
- 但是，我们知道各个观测值之间可能存在很大的差异。
- “分布”是统计学中的一个重要概念。
- 我们可以先从最大值和最小值着手。
- 采用与前面类似的方法，使用 min 和 max 函数即可。

最大值和最小值

```
summarise(lfs,mean(HOURPAY),
              min(HOURPAY),
              max(HOURPAY))
```

```
## # A tibble: 1 × 3
##   `mean(HOURPAY)` `min(HOURPAY)` `max(HOURPAY)`
##             <dbl>          <dbl>          <dbl>
## 1            20.8            6.4           98.8
```

- 我们还可以为输出结果添加自定义名称。

最大值和最小值

```
summarise(lfs,mean_pay = mean(HOURPAY),
              minimum_pay = min(HOURPAY),
              maximum_pay = max(HOURPAY))
```

```
## # A tibble: 1 × 3
##   mean_pay minimum_pay maximum_pay
##      <dbl>       <dbl>       <dbl>
## 1     20.8         6.4        98.8
```

方差

- 我们还可以通过方差进一步衡量数据的分布特征。
- 顾名思义，方差用于衡量数据的离散程度。
- 其思路是考察每个观测值距离均值有多远。
- 我们可能会想到用 $\Sigma(x_i - x)$ 来衡量观测值与均值的偏差。
- 但正偏差和负偏差会相互抵消。
- 因此可以将偏差平方，即计算 $\Sigma(x_i - x)^2$，从而避免正负抵消。

方差

- 由此可得到样本方差的计算公式：

$$S^2 = \frac{\Sigma(x_i - x)^2}{n - 1}$$

- 平方处理会让结果的单位和含义变得不那么直观。
- 可以通过开平方来解决这一问题。
- 得到的就是标准差，它与原始变量具有相同的计量单位。

计算方差与标准差

```
summarise(lfs,
          wage_var = var(HOURPAY),
          wage_sd = sd(HOURPAY))
```

```
## # A tibble: 1 × 2
##   wage_var wage_sd
##      <dbl>   <dbl>
## 1     133.    11.5
```

分位数

- 研究变量分布的另一种有效方法是计算分位数。
- 我们可以指定将数据划分为多少组，不过具体是通过间接方式实现的。
- 分位数方法会找出能够将数据分成等比例组的切分值。
- 根据划分组数的不同，这些指标有不同名称。
- 常见的分位数包括：
    - 四分位数：将数据分为 4 组。
    - 五分位数：将数据分为 5 组。
    - 十分位数：将数据分为 10 组。
- 我们使用比例 / 概率指定切分点，还可以为输出结果添加标签。

分位数

```
reframe(lfs, quartiles = quantile(HOURPAY, probs = c(0.25, 0.5, 0.75)),
              q = c("First quartile","Second Quartile","Third Quartile"))
```

```
## # A tibble: 3 × 2
##   quartiles q
##       <dbl> <chr>
## 1      12.9 First quartile
## 2      17.3 Second Quartile
## 3      25.1 Third Quartile
```

解读四分位数

- 25% 的人时薪低于 12.86 英镑。
- 50% 的人时薪低于 17.3 英镑。
- 75% 的人时薪低于 25.09 英镑。

- 如果需要，还可以在分位数结果中同时显示最大值和最小值。

分位数

```
reframe(lfs, quartiles = quantile(HOURPAY, probs = c(0,0.25, 0.5, 0.75,
1)),
              q = c("Minimum","First quartile","Second Quartile",
                  "Third Quartile","Maximum"))
```

```
## # A tibble: 5 × 2
##   quartiles q
##       <dbl> <chr>
## 1       6.4 Minimum
## 2      12.9 First quartile
## 3      17.3 Second Quartile
## 4      25.1 Third Quartile
## 5      98.8 Maximum
```

中位数

- 第二四分位数具有特殊地位，因此有专门名称。
- 它叫做“中位数”，即将数据一分为二的数值。
- 将观测值从小到大排序后，中位数位于中间位置。
- 可以使用 median 函数计算。
- 与均值相比，中位数受离群值影响更小。
- 例如，3、5、9、10、12 的均值为 7.8，中位数为 9。
- 如果将最后一个数改为 1000，则均值变为 205.4，但中位数仍为 9。

工资中位数与均值的比较

```
summarise(lfs,mean_pay = mean(HOURPAY),
              median_pay = median(HOURPAY))
```

```
## # A tibble: 1 × 2
##   mean_pay median_pay
##      <dbl>      <dbl>
## 1     20.8       17.3
```

- 可以看到，中位数明显低于均值。
- 这说明少数高工资人群可能拉高了均值，使分布出现偏斜。

summary 汇总函数

- 可以使用 R 基础函数 summary 快速获得这些统计指标。
- 对整个数据框调用 summary，可以获得所有变量的汇总信息。
- 也可以只对某一个变量使用它。
- 这里我们稍微借用一下 Base R 的写法。

```
summary(lfs$HOURPAY)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    6.40   12.87   17.30   20.84   25.09   98.82
```

- 先写数据框名称，再通过美元符号 $ 指定其中的某个变量。

变量类型

- 小时工资是一个连续的比率尺度变量。
- 因此可以计算它的均值、中位数和分位数。
- 不同测量尺度的变量，需要采用不同的分析方式。
- 下面考虑一个有序分类变量。
- 数据中的 EMPLEN 变量就是一个很好的例子，它表示一个人已经工作了多长时间。
- 我们可以先制作频数表（这里也称列联表）。

频数表

```
count(lfs, EMPLEN)
```

```
## # A tibble: 8 × 2
##   EMPLEN                        n
##   <fct>                     <int>
## 1 Less than 3 months          196
## 2 Three months, less than 6   268
## 3 6 months, less than 12      425
## 4 1 year, less than 2         900
## 5 2 years, less than 5       1777
## 6 5 years, less than 10      1316
## 7 10 years, less than 20     1417
## 8 20 years or more           1048
```

有序分类变量的集中趋势

- 我们不能直接针对这种分类计算有意义的算术均值。
- 可以查看排序后位于中间的人属于哪个类别，从而确定中位类别。
- 不过，当人数为偶数时，确定中间类别会有一些困难。
- 一个更直接的指标是众数，即出现次数最多的类别。
- 由于众数不依赖类别顺序，因此也适用于一般分类变量。
- 常用做法是提供频数表，并附上各类别的百分比。

在表格中添加百分比

- 可以通过多种方式为表格添加百分比。
- 先沿用我们之前使用过的方法。
- 继续之前，先学习一个非常实用的 R 技巧。
- 在数据分析中，我们经常需要连续执行多个操作。
- 一些编程语言提供管道操作符，用来将多个函数连接起来。
- 数据从管道的一端进入，依次经过多个函数处理，最后输出结果。
- 先看一个简单例子。

补充：Base R 的管道操作符

- Tidyverse 的管道操作符非常流行，因此 R 4 版本也增加了原生管道。
- 它的写法是 |>
- 它与 Tidyverse 的管道操作符在行为上略有差异。
- 本课程不会使用它，但你可能在其他资料中看到。

计算频数表

- 在前一个频数表中，我们使用了 count(lfs, EMPLEN)。
- 下面这种写法可以得到完全相同的结果：

```
lfs %>% count(EMPLEN)
```

```
## # A tibble: 8 × 2
##   EMPLEN                        n
##   <fct>                     <int>
## 1 Less than 3 months          196
## 2 Three months, less than 6   268
## 3 6 months, less than 12      425
## 4 1 year, less than 2         900
## 5 2 years, less than 5       1777
## 6 5 years, less than 10      1316
## 7 10 years, less than 20     1417
## 8 20 years or more           1048
```

这是如何实现的?

- 首先写出数据框名称。
- 然后通过管道将它传递给 count 函数。
- 管道传入的数据会成为后一个函数的第一个参数。
- Tidyverse 函数通常以数据框作为第一个参数，并输出一个数据框。
- 可以利用这个机制串联多个操作。

为频数表添加百分比

```
lfs %>% count(EMPLEN) %>% mutate(percent = n / sum(n)*100)
```

```
## # A tibble: 8 × 3
##   EMPLEN                        n percent
##   <fct>                     <int>   <dbl>
## 1 Less than 3 months          196    2.67
## 2 Three months, less than 6   268    3.65
## 3 6 months, less than 12      425    5.78
## 4 1 year, less than 2         900   12.2
## 5 2 years, less than 5       1777   24.2
## 6 5 years, less than 10      1316   17.9
## 7 10 years, less than 20     1417   19.3
## 8 20 years or more           1048   14.3
```

代码的执行过程

1. 首先指定要使用的数据框。
2. 数据框被传入 count 函数。该函数统计 EMPLEN 变量每个类别中的人数，并生成一张表：表中列出 EMPLEN 因子的各个类别，以及记录相应人数的变量 n。

3. 再把这张新表传入 mutate 函数，计算一个名为 percent 的新变量。

数据中有多少男性和女性?

```
lfs %>% count(SEX) %>% mutate(percent = n / sum(n)*100)
```

```
## # A tibble: 2 × 3
##   SEX        n percent
##   <fct>  <int>   <dbl>
## 1 Male    3410    46.4
## 2 Female  3937    53.6
```

- 样本中的女性人数略多于男性。

受访者居住在哪里?

```
lfs %>% count(GOR9D) %>% mutate(percent = n / sum(n)*100)
```

```
## # A tibble: 12 × 3
##    GOR9D                        n percent
##    <fct>                    <int>   <dbl>
##  1 London                     581    7.91
##  2 Yorkshire and The Humber   761   10.4
##  3 South West                 747   10.2
##  4 West Midlands              555    7.55
##  5 South East                1121   15.3
##  6 East of England            602    8.19
##  7 East Midlands              654    8.90
##  8 North East                 290    3.95
##  9 North West                 664    9.04
## 10 Wales                      282    3.84
## 11 Northern Ireland           473    6.44
## 12 Scotland                   617    8.40
```

有多少人签订了零工时合同?

```
lfs %>% count(FLEX22W6) %>% mutate(percent = n / sum(n)*100)
```

```
## # A tibble: 2 × 3
##   FLEX22W6     n percent
##   <fct>    <int>   <dbl>
## 1 Yes        152    2.07
## 2 No        7195   97.9
```

全职与兼职的分布

```
lfs %>% count(FTPT) %>% mutate(percent = n / sum(n)*100)
```

```
## # A tibble: 2 × 3
##   FTPT          n percent
##   <fct>     <int>   <dbl>
## 1 Full-time  5762    78.4
## 2 Part-time  1585    21.6
```

学历分布

```
lfs %>% count(HIQUL22D) %>% mutate(percent = n / sum(n)*100)
```

```
## # A tibble: 6 × 3
##   HIQUL22D                    n percent
##   <fct>                   <int>   <dbl>
## 1 Degree or equivalent     3535   48.1
## 2 Higher education          565    7.69
## 3 A level or equivalent    1604   21.8
## 4 GCSE A*-C or equivalent  1102   15.0
## 5 Other qualitfication      331    4.51
## 6 No Qualification          210    2.86
```

按行业划分的人数

```
lfs %>% count(INDE07M) %>% mutate(percent = n / sum(n)*100)
```

```
## # A tibble: 9 × 3
##   INDE07M                                n percent
##   <fct>                              <int>   <dbl>
## 1 Agriculture, forestry and fishing     33   0.449
## 2 Energy and water                     155   2.11
## 3 Manufacturing                        636   8.66
## 4 Construction                         332   4.52
## 5 Distribution, hotels and restaurants 1026  14.0
## 6 Transport and communication          693   9.43
## 7 Banking and finance                  1311  17.8
## 8 Public admin, education and health   2858  38.9
## 9 Other services                       303   4.12
```

永久职位与非永久职位人数

```
lfs %>% count(JOBTYP) %>% mutate(percent = n / sum(n)*100)
```

```
## # A tibble: 2 × 3
##   JOBTYP                       n percent
##   <fct>                    <int>   <dbl>
## 1 Permanent                 7106   96.7
## 2 Not permanent in some way  241    3.28
```

工作场所的员工人数

```
lfs %>% count(MPNR02) %>% mutate(percent = n / sum(n)*100)
```

```
## # A tibble: 9 × 3
##   MPNR02                              n percent
##   <fct>                           <int>   <dbl>
## 1 1–10                             1173   16.0
## 2 11–19                             560    7.62
## 3 20–24                             279    3.80
## 4 Don't know but under 25           151    2.06
## 5 25–49                             875   11.9
## 6 50–249                           1681   22.9
## 7 250–499                           477    6.49
## 8 Don't know but between 50 and 499  312    4.25
## 9 500 or more                      1839   25.0
```

婚姻状况分布

```
lfs %>% count(MARSTA) %>% mutate(percent = n / sum(n)*100)
```

```
## # A tibble: 6 × 3
##   MARSTA                                          n percent
##   <fct>                                       <int>   <dbl>
## 1 Single, never married                        2699   36.7
## 2 Married, living with spouse                  3785   51.5
## 3 Married separated from spouse                 166    2.26
## 4 Divorced                                      546    7.43
## 5 Widowed                                        74    1.01
## 6 Currently or previously in civil partnership   77    1.05
```

按职业等级划分的人数

```
lfs %>% count(NSECMJ20) %>% mutate(percent = n / sum(n)*100)
```

```
## # A tibble: 7 × 3
##   NSECMJ20                                n percent
##   <fct>                               <int>   <dbl>
## 1 Higher managerial and professional  1836   25.0
## 2 Lower managerial and professional   2426   33.0
## 3 Intermediate occupations            1112   15.1
## 4 Lower supervisory and technical      423    5.76
## 5 Semi-routine occupations             728    9.91
## 6 Routine occupations                  662    9.01
## 7 Never worked                         160    2.18
```

常规基本工作时长汇总

```
summary(lfs$BUSHR)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    7.00   32.00   38.00   34.76   40.00   90.00
```

常规基本工作时长汇总

- 也可以用 Tidyverse 风格调用 summary 函数。

```
lfs %>% pull(BUSHR) %>% summary()
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    7.00   32.00   38.00   34.76   40.00   90.00
```

分组描述性统计

- 到目前为止，我们关注的是单变量统计指标，也就是一次只分析一个变量。
- 按不同群体进行统计汇总后，分析会更加有趣。
- 实现起来并不复杂。
- 我们将使用 group_by 函数。
- 它会改变 summarise 函数进行汇总时的行为，使结果按组计算。
- 下面计算我们最关注的指标：男性与女性的平均小时工资差异。

男性和女性的平均工资与工资中位数

```
lfs %>% group_by(SEX) %>% summarise(mean_wage = mean(HOURPAY),
                                    median_wage = median(HOURPAY))
```

```
## # A tibble: 2 × 3
##   SEX    mean_wage median_wage
##   <fct>      <dbl>       <dbl>
## 1 Male        22.5        18.5
## 2 Female      19.4        16.4
```

下一步分析什么?

- 可以看到，男女平均工资存在较大差异。
- 一种可能解释是，男女在影响工资的个人特征上存在差异。
- 例如，男女群体的平均受教育程度可能不同。
- 可以使用交叉列联表来检验这一点。
- 一个方便的方法是使用 Base R 的 table 函数。
- 由于 table 是 Base R 函数，使用方式与前面介绍的函数略有不同。
- 它不把数据框作为第一个参数，而是直接接收变量。
- 这可以通过之前学过的 $ 符号来实现。

性别与学历

```
table(lfs$HIQUL22D, lfs$SEX)
```

```
##
##                           Male Female
##   Degree or equivalent    1511   2024
##   Higher education         269    296
##   A level or equivalent    816    788
##   GCSE A*-C or equivalent  531    571
##   Other qualitfication     177    154
##   No Qualification         106    104
```

比例

- 仅靠绝对频数往往不容易进行比较。
- 使用比例或百分比更便于理解。
- 百分比可以按三种方式计算：

    - 单元格百分比：该单元格占整张表总数的比例。
    - 行百分比：该单元格占所在行总数的比例。
    - 列百分比：该单元格占所在列总数的比例。
- 可以用 prop.table 函数计算这些比例。
- margin 参数决定按行还是按列计算比例。
- 可以使用 round 函数控制显示的小数位数。

性别与学历：单元格比例

```
table(lfs$HIQUL22D, lfs$SEX) %>% prop.table() %>% round(2)
```

```
##
##                            Male Female
##   Degree or equivalent    0.21   0.28
##   Higher education        0.04   0.04
##   A level or equivalent   0.11   0.11
##   GCSE A*-C or equivalent 0.07   0.08
##   Other qualitfication    0.02   0.02
##   No Qualification        0.01   0.01
```

性别与学历：行比例

```
table(lfs$HIQUL22D, lfs$SEX) %>% prop.table(1) %>% round(2)
```

```
##
##                            Male Female
##   Degree or equivalent    0.43   0.57
##   Higher education        0.48   0.52
##   A level or equivalent   0.51   0.49
##   GCSE A*-C or equivalent 0.48   0.52
##   Other qualitfication    0.53   0.47
##   No Qualification        0.50   0.50
```

性别与学历：列比例

```
table(lfs$HIQUL22D, lfs$SEX) %>% prop.table(2) %>% round(2)
```

```
##
##                            Male Female
##   Degree or equivalent     0.44   0.51
##   Higher education         0.08   0.08
##   A level or equivalent    0.24   0.20
##   GCSE A*-C or equivalent  0.16   0.15
##   Other qualitfication     0.05   0.04
##   No Qualification         0.03   0.03
```

性别与行业：列比例

```
table(lfs$INDE07M, lfs$SEX) %>% prop.table(2) %>% round(2)
```

```
##
##                                      Male Female
##   Agriculture, forestry and fishing  0.01   0.00
##   Energy and water                   0.03   0.01
##   Manufacturing                      0.13   0.05
##   Construction                       0.07   0.02
##   Distribution, hotels and restaurants 0.15   0.13
##   Transport and communication        0.14   0.05
##   Banking and finance                0.19   0.17
##   Public admin, education and health 0.24   0.52
##   Other services                     0.05   0.04
```

其他实用函数

检查数据

- 到目前为止介绍的这些统计指标，都是你在研究报告中可能展示的内容。
- 另外还有一些用于查看数据的实用函数。
- 我们之前使用过 glimpse，它可以简要显示数据中各变量的类型。
- 也介绍过 View，它可以像电子表格一样打开数据。
- head 函数会在控制台打印数据框前五行。
- 可以通过 n 参数改变打印的行数。

head 函数

```
head(lfs)
```

```
## # A tibble: 6 × 14
##   SEX   HOURPAY   AGE GOR9D EMPLEN FLEX22W6 FTPT  HIQUL22D INDE07M JOB
TYP MPNR02
##   <fct>   <dbl> <dbl> <fct> <fct>  <fct>    <fct> <fct>    <fct>   <fc
t>  <fct>
## 1 Male     14.4    61 Sout… 6 mon… No       Part… GCSE A*… Other … Per
ma… 1-10
## 2 Male     11.6    60 Sout… Three… No       Full… GCSE A*… Public… Per
ma… 1-10
## 3 Fema…    10.4    63 Sout… 2 yea… No       Full… A level… Public… Per
ma… 1-10
## 4 Fema…    25.3    54 Sout… 1 yea… No       Full… Degree … Public… Not
p… 500 o…
## 5 Fema…    13.8    39 Sout… 2 yea… No       Full… Degree … Public… Per
ma… 1-10
## 6 Male     41.0    53 Sout… 10 ye… No       Full… Degree … Transp… Per
ma… 11-19
## # ℹ 3 more variables: MARSTA <fct>, NSECMJ20 <fct>, BUSHR <dbl>
```

tail 和 arrange 函数

- tail 与 head 类似，但它打印数据框的最后五行。
- 如果数据行的顺序是随机的，这种查看方式的作用可能有限。
- 可以使用 arrange 函数对数据排序。
- 指定某个变量即可按升序排列。
- 在变量名前加负号即可按降序排列。
- 下面查看收入最高的受访者。

排序并检查数据

```
lfs %>% arrange(HOURPAY) %>% tail()
```

```
## # A tibble: 6 × 14
##   SEX   HOURPAY   AGE GOR9D EMPLEN FLEX22W6 FTPT  HIQUL22D INDE07M JOB
TYP MPNR02
##   <fct>   <dbl> <dbl> <fct> <fct>  <fct>    <fct> <fct>    <fct>   <fc
t>  <fct>
## 1 Male     94.0    39 Lond… 2 yea… No       Full… A level… Transp… Per
ma… 1–10
## 2 Fema…    95.4    45 Sout… 10 ye… No       Full… Degree … Constr… Per
ma… 50–249
## 3 Male     96.1    56 Lond… 1 yea… No       Part… Degree … Public… Per
ma… 1–10
## 4 Male     96.2    58 East… 20 ye… No       Full… A level… Transp… Per
ma… 250–4…
## 5 Male     96.2    45 Scot… 2 yea… No       Full… Degree … Public… Per
ma… 500 o…
## 6 Fema…    98.8    51 Sout… 6 mon… No       Full… Degree … Bankin… Per
ma… 500 o…
## # ℹ 3 more variables: MARSTA <fct>, NSECMJ20 <fct>, BUSHR <dbl>
```

总结

- 查看并汇总数据非常重要。
- 既有助于你自己理解数据，也能帮助读者理解数据。
- 你可能会发现有趣的规律，并找到合适的展示方式。
- 下一讲我们将学习数据可视化。
- 这将进一步拓展今天所学的内容。