Lecture3_R语言零基础代码逐行教程

Lecture 3：R 语言描述性统计零基础逐行教程

> **适合读者**：从来没有写过程序、第一次接触 R/RStudio 或 VS Code 的同学。
> **对应材料**：`lecture3_notes.html`（Quantitative Data Analysis, Lecture 3 Notes）。
> **覆盖范围**：原讲义全部 **33 段可执行 R 代码** 与相应 **33 个输出示例**，严格按原文次序讲解。
> **阅读方式**：先理解概念，手动输入代码，再对照输出。本教程中附加的基础知识和练习为教学补充，不是原讲义新增要求。

0. 开始前：你需要知道什么?

0.1 R 是什么?

R 是统计计算语言。你可以把它想象成一台能处理整张表格的计算器：除了加减乘除，还能统计每一类有多少人、求平均工资、比较不同群体。RStudio 和 VS Code 是用来**编写**、**运行** R 代码的软件，R 才是真正执行代码的程序。

0.2 数据是什么样的?

讲义里一直使用一个叫 **`lfs`** 的数据框（data frame）。想象它是一张 Excel 表：**一行**对应一位受访者，**一列**对应一项属性，例如 `SEX`（性别）、`HOURPAY`（时薪）或 `BUSHR`（通常每周基本工作时长）。课程数据的某些输出显示共有 **7,347 条记录**；这是讲义示例中的人数，并非所有版本的数据都如此。

运行前提：需提前按课程前面的步骤把数据读入内存，并将结果命名为 `lfs`；同时加载提供 `summarise()`、`count()`、`mutate()`、`reframe()`、`group_by()`、`pull()`、`arrange()` 的 `dplyr` 包。这份第三讲原文没有提供完整的初始导入代码，因此下面为教学补充，而非原文：

```
# 只需第一次安装（联网时）
install.packages("dplyr")
# 每次重新启动 R 后加载
library(dplyr)
# 按自己的文件路径修改；这里仅为示例，文件需真实存在
# lfs <- readr::read_tsv("你的数据路径/文件名.tab")
```

如果你在前面课程已经创建 `lfs`，**不要重新随意覆盖它**。在 Console 输入 `ls()` 可以看见当前已创建的对象；`head(lfs)` 可以预览。

0.3 新手必读：R 的语法积木

符号	意思	示例
`()`	调用函数，括号里放需要的信息	`mean(c(1,2,3))`
`,`	分隔不同参数	`round(3.14159, 2)`
`=`	给函数参数命名，或在表达式中指定结果列名	`probs = c(0.25, 0.5)`
`<-`	把右边结果赋值给左边变量	`x <- 10`
`$`	从数据框取出某列	`lfs$HOURPAY`
`c()`	把几个值组合成一个向量	`c(1, 9, 8)`
`%>%`	将左侧结果交给右侧函数，叫作管道	`lfs %>% count(SEX)`
`+ - * /`	加、减、乘、除	`n / sum(n) * 100`
`"..."`	表示文本字符串	`"Female"`
`#`	本行后面为注释，R 不执行	`# 统计人数`

`R` **区分大小写**：`HOURPAY` 不等于 `hourpay`。英文括号与标点需用半角字符。换行只是为了易读，合理地放在括号或管道之间通常不影响运行。讲义输出中的 `##` 是文档打印输出的标记，**不是让你复制执行的代码**。

0.4 一张输出表要怎么看?

例如 `# A tibble: 1 × 3` 表示输出是一张 **1 行 3 列** 的表。`<dbl>` 表示数值型（双精度），`<int>` 表示整数，`<chr>` 表示文本，`<fct>` 表示分类变量（factor）。`[1]` 表示打印的第一个向量元素，不是算式的一部分。数据输出的小数位往往只为显示而四舍五入。

---

1. 按原讲义逐段讲解全部代码

以下 `代码 #` 仅标记原讲义的**实际可执行代码段**（共 33 段），每段附对应输出。运行输出**不要复制进 R Console**。

代码 01｜手算平均值

原讲义位置：Calculating the mean。

原代码：

```
(1 + 9 + 8 + 2 + 7 + 3 + 2) / 7
```

逐步拆解： 先把 7 个数字相加：`1+9+8+2+7+3+2=32`，再除以 `7`，得到约 `4.57`。`/` 是除法，`()` 保证先求和。

原讲义对应输出：

```
## [1] 4.571429
```

怎样理解结果： 这是均值（mean）：数据总和 ÷ 数据个数。

> 新手练习：把最后的 `/ 7` 改成 `/ 6`，猜测结果会怎样；再改回来。

代码 02｜用函数自动求平均

原讲义位置：Calculating the mean。

原代码：

```
mean(c(1,9,8,2,7,3,2))
```

逐步拆解： `c(1,9,8,2,7,3,2)` 把 7 个数字装成一个向量；外层 `mean(...)` 计算这个向量的平均值。

原讲义对应输出：

```
## [1] 4.571429
```

怎样理解结果： `mean()` 接受数字集合；它不会自动统计表格所有列。

代码 03｜计算所有人的平均时薪

原讲义位置：Mean hourly wage。

原代码：

```
summarise(lfs,mean(HOURPAY))
```

逐步拆解： `lfs` 是整张调查表，`HOURPAY` 是时薪这一列；`summarise(lfs, mean(HOURPAY))` 汇总成一行。

原讲义对应输出：

```
## # A tibble: 1 × 1
##   `mean(HOURPAY)`
##             <dbl>
## 1            20.8
```

怎样理解结果： `summarise()` 在 `dplyr` 中用于生成汇总结果；这里约为 20.8（与数据单位一致）。

代码 04｜一次求均值、最小值、最大值

原讲义位置：Maximum and minimum。

原代码：

```
summarise(lfs,mean(HOURPAY),
              min(HOURPAY),
              max(HOURPAY))
```

逐步拆解： `mean(HOURPAY)` 计算平均；`min(HOURPAY)` 找最小；`max(HOURPAY)` 找最大。三个函数都作用于同一列，逗号用来分开三个计算任务。

原讲义对应输出：

```
## # A tibble: 1 × 3
##   `mean(HOURPAY)` `min(HOURPAY)` `max(HOURPAY)`
##             <dbl>          <dbl>          <dbl>
## 1            20.8            6.4           98.8
```

怎样理解结果： 对比最小 6.4 与最大 98.8，可初步发现分布范围很宽，但不能只凭最大值断定其是错误数据。

代码 05｜为汇总列取容易理解的名字

原讲义位置：Maximum and minimum。

原代码：

```
summarise(lfs,mean_pay = mean(HOURPAY),
              minimum_pay = min(HOURPAY),
              maximum_pay = max(HOURPAY))
```

逐步拆解： `mean_pay = mean(HOURPAY)` 左边是**新输出列的名字**，右边是真正的计算；另两列相同。

原讲义对应输出：

```
## # A tibble: 1 × 3
##   mean_pay minimum_pay maximum_pay
##      <dbl>       <dbl>       <dbl>
## 1     20.8         6.4        98.8
```

怎样理解结果： 用 `mean_pay` 比默认列名 `mean(HOURPAY)` 更适合写报告或后续使用。

代码 06｜计算方差和标准差

原讲义位置：Calculating the variance and standard deviation。

原代码：

```
summarise(lfs,
          wage_var = var(HOURPAY),
          wage_sd = sd(HOURPAY))
```

逐步拆解： `var(HOURPAY)` 求样本方差（衡量围绕均值的离散程度）；`sd(HOURPAY)` 求样本标准差。`wage_var` 和 `wage_sd` 是结果列名。

原讲义对应输出：

```
## # A tibble: 1 × 2
##   wage_var wage_sd
##      <dbl>   <dbl>
## 1     133.    11.5
```

怎样理解结果： 标准差的单位与工资相同；方差的单位是工资单位的平方。标准差约 11.5，不等于工资平均差值 11.5。

> 新手提示：`var()` / `sd()` 默认计算样本统计量。若有缺失值 `NA`，可能需要 `na.rm = TRUE`，但是否删除缺失值需先考虑研究设计。

代码 07｜求三个四分位点

原讲义位置：Quantiles。

原代码：

```
reframe(lfs, quartiles = quantile(HOURPAY, probs = c(0.25, 0.5, 0.75)),
             q = c("First quartile","Second Quartile","Third Quartile"))
```

逐步拆解： `quantile(HOURPAY, probs = c(0.25, 0.5, 0.75))` 计算 25%、50%、75% 分位点；`reframe()` 允许生成多行；`q = c(...)` 给每一行配文本标签。

原讲义对应输出：

```
## # A tibble: 3 × 2
##   quartiles q
##       <dbl> <chr>
## 1      12.9 First quartile
## 2      17.3 Second Quartile
## 3      25.1 Third Quartile
```

怎样理解结果： 25% 分位数不是「工资总额的 25%」，而是排序后大约四分之一观测值不大于该数。

代码 08｜同时输出最小值、四分位数和最大值

原讲义位置：Quantiles。

原代码：

```
reframe(lfs, quartiles = quantile(HOURPAY, probs = c(0,0.25, 0.5,
0.75,1)),
              q = c("Minimum","First quartile","Second Quartile",
                  "Third Quartile","Maximum"))
```

逐步拆解： `probs = c(0,0.25,0.5,0.75,1)` 指定 0%、25%、50%、75%、100% 五个位置；标签向量也是五个元素，因此逐一对应。

原讲义对应输出：

```
## # A tibble: 5 × 2
##   quartiles q
##       <dbl> <chr>
## 1       6.4 Minimum
## 2      12.9 First quartile
## 3      17.3 Second Quartile
## 4      25.1 Third Quartile
## 5      98.8 Maximum
```

怎样理解结果： `reframe()` 在此产生五行。`probs` 的值应在 0 到 1 之间。

代码 09｜对照平均数和中位数

原讲义位置：Median pay compared to mean。

原代码：

```
summarise(lfs,mean_pay = mean(HOURPAY),
              median_pay = median(HOURPAY))
```

逐步拆解： `mean()` 求均值，`median()` 求中位数；`summarise()` 将二者排在同一行。

原讲义对应输出：

```
## # A tibble: 1 × 2
##   mean_pay median_pay
##      <dbl>      <dbl>
## 1     20.8       17.3
```

怎样理解结果： 原讲义平均时薪约 20.8，中位数约 17.3；均值较高可能受到高工资观察值影响，但具体原因需要进一步验证。

代码 10｜一行生成常见描述统计

原讲义位置：The summary function。

原代码：

```
summary(lfs$HOURPAY)
```

逐步拆解： `lfs$HOURPAY` 表示从数据框 `lfs` 取出 `HOURPAY` 列；`summary()` 自动计算最小值、第一四分位数、中位数、均值、第三四分位数、最大值。

原讲义对应输出：

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    6.40   12.87   17.30   20.84   25.09   98.82
```

怎样理解结果： `$` 右边必须是正确列名；这是基础 R 的写法，不依赖 `dplyr`。

代码 11｜按工作年限分类计数

原讲义位置：Frequency table。

原代码：

```
count(lfs, EMPLEN)
```

逐步拆解： `count(lfs, EMPLEN)` 根据 `EMPLEN` 的不同类别分组，计算每类人数；自动生成 `n` 列表示频数（人数）。

原讲义对应输出：

```
## # A tibble: 8 × 2
##   EMPLEN                        n
##   <fct>                     <int>
## 1 Less than 3 months          196
## 2 Three months, less than 6   268
## 3 6 months, less than 12      425
## 4 1 year, less than 2         900
## 5 2 years, less than 5       1777
## 6 5 years, less than 10      1316
## 7 10 years, less than 20     1417
## 8 20 years or more           1048
```

怎样理解结果： 类别变量适合用频数表描述；不是所有变量都适合直接算平均值。

代码 12｜用管道改写同一计算

原讲义位置：Calculating a frequency table。

原代码：

```
lfs %>% count(EMPLEN)
```

逐步拆解： `lfs %>% count(EMPLEN)` 与上一个例子的结果一样。管道 `%>%` 把左边 `lfs` 传给 `count()` 的第一个参数。

原讲义对应输出：

```
## # A tibble: 8 × 2
##   EMPLEN                          n
##   <fct>                       <int>
## 1 Less than 3 months            196
## 2 Three months, less than 6     268
## 3 6 months, less than 12        425
## 4 1 year, less than 2           900
## 5 2 years, less than 5         1777
## 6 5 years, less than 10        1316
## 7 10 years, less than 20       1417
## 8 20 years or more             1048
```

怎样理解结果： 记忆方式：**数据 → 操作 → 结果**。原文讲的是 `%>%`，R 新版本还有 `|>`，但二者并非所有情况下完全等价。

代码 13｜在频数表加百分比

原讲义位置：Adding percentages to our table。

原代码：

```
lfs %>% count(EMPLEN) %>% mutate(percent = n / sum(n)*100)
```

逐步拆解： 第 1 步 `count(EMPLEN)` 得到各类别人数 `n`；第 2 步 `mutate(percent = n / sum(n)*100)` 添加一列：本类别人数 ÷ 总人数 × 100。

原讲义对应输出：

```
## # A tibble: 8 × 3
##   EMPLEN                          n percent
##   <fct>                       <int>   <dbl>
## 1 Less than 3 months            196    2.67
## 2 Three months, less than 6     268    3.65
## 3 6 months, less than 12        425    5.78
## 4 1 year, less than 2           900   12.2
## 5 2 years, less than 5         1777   24.2
```

```
## 6 5 years, less than 10      1316   17.9
## 7 10 years, less than 20     1417   19.3
## 8 20 years or more           1048   14.3
```

怎样理解结果： `mutate()` 是**新增或修改列**，而不是像 `summarise()` 那样把每组压缩成一行。所有类别的百分比合计通常约为 100%，显示时可能因四舍五入略有偏差。

> 小练习：计算一个类别的百分比，比如 `196 / 7347 * 100`，对照表格是否一致。

代码 14｜男女样本人数占比

原讲义位置：How many men and women in our data?。

原代码：

```
lfs %>% count(SEX) %>% mutate(percent = n / sum(n)*100)
```

逐步拆解： `count(SEX)` 分别计算 Male 和 Female 的样本数，`mutate()` 计算各自的占比。

原讲义对应输出：

```
## # A tibble: 2 × 3
##   SEX        n percent
##   <fct>  <int>   <dbl>
## 1 Male    3410    46.4
## 2 Female  3937    53.6
```

怎样理解结果： 这个 46.4% / 53.6% 表示**该样本**的性别分布，不能未经加权或抽样论证直接推广为总体比例。

代码 15｜样本所在地区分布

原讲义位置：Where do people live?。

原代码：

```
lfs %>% count(GOR9D) %>% mutate(percent = n / sum(n)*100)
```

逐步拆解： 把上一段的 `SEX` 改成 `GOR9D`：现在不按性别，而是按地区类别统计。

原讲义对应输出：

```
## # A tibble: 12 × 3
##    GOR9D                        n percent
##    <fct>                    <int>   <dbl>
##  1 London                     581    7.91
##  2 Yorkshire and The Humber   761   10.4
```

```
##  3 South West                 747   10.2
##  4 West Midlands              555    7.55
##  5 South East                1121   15.3
##  6 East of England            602    8.19
##  7 East Midlands              654    8.90
##  8 North East                 290    3.95
##  9 North West                 664    9.04
## 10 Wales                      282    3.84
## 11 Northern Ireland           473    6.44
## 12 Scotland                   617    8.40
```

怎样理解结果： 读输出时先看地区名称，再看 `n` 和 `percent`。同一段管道可以复用到许多分类列。

代码 16｜零工时合同占比

原讲义位置：How many on zero hours contracts?。

原代码：

```
lfs %>% count(FLEX22W6) %>% mutate(percent = n / sum(n)*100)
```

逐步拆解： `FLEX22W6` 在讲义中用于区分是否为零工时合同；`count(FLEX22W6)` 统计 Yes/No 数量。

原讲义对应输出：

```
## # A tibble: 2 × 3
##   FLEX22W6     n percent
##   <fct>    <int>   <dbl>
## 1 Yes        152    2.07
## 2 No        7195   97.9
```

怎样理解结果： 统计「Yes」所占比例时，分母是此表纳入的观测数；注意数据是否存在缺失值。

代码 17｜全职/兼职结构

原讲义位置：Full-time / part-time split。

原代码：

```
lfs %>% count(FTPT) %>% mutate(percent = n / sum(n)*100)
```

逐步拆解： `FTPT` 区分 Full-time 与 Part-time。先计数，再按总人数求百分比。

原讲义对应输出：

```
## # A tibble: 2 × 3
##   FTPT          n percent
##   <fct>     <int>   <dbl>
## 1 Full-time  5762    78.4
## 2 Part-time  1585    21.6
```

怎样理解结果： 输出的 78.4% / 21.6% 描述该样本的工作类型构成。

代码 18｜最高学历结构

原讲义位置：Education split。

原代码：

```
lfs %>% count(HIQUL22D) %>% mutate(percent = n / sum(n)*100)
```

逐步拆解： `HIQUL22D` 是课程里的教育资格类别变量；同样按类别计数并计算占比。

原讲义对应输出：

```
## # A tibble: 6 × 3
##   HIQUL22D                    n percent
##   <fct>                   <int>   <dbl>
## 1 Degree or equivalent     3535   48.1
## 2 Higher education          565    7.69
## 3 A level or equivalent    1604   21.8
## 4 GCSE A*-C or equivalent  1102   15.0
## 5 Other qualitfication      331    4.51
## 6 No Qualification          210    2.86
```

怎样理解结果： 学历是有类别意义的变量；如果要研究等级顺序，需要了解其 factor 的实际编码。

代码 19｜行业构成

原讲义位置：People by industry。

原代码：

```
lfs %>% count(INDE07M) %>% mutate(percent = n / sum(n)*100)
```

逐步拆解： `INDE07M` 表示讲义中使用的行业分类；结果给出每个行业的人数和占比。

原讲义对应输出：

```
## # A tibble: 9 × 3
##   INDE07M                                n percent
##   <fct>                              <int>   <dbl>
## 1 Agriculture, forestry and fishing     33   0.449
## 2 Energy and water                     155   2.11
## 3 Manufacturing                        636   8.66
## 4 Construction                         332   4.52
## 5 Distribution, hotels and restaurants 1026  14.0
## 6 Transport and communication          693   9.43
## 7 Banking and finance                  1311  17.8
## 8 Public admin, education and health   2858  38.9
## 9 Other services                       303   4.12
```

怎样理解结果： 例如小行业比例会很小，R 可能以更多有效数字展示；理解统计含义比小数位数更重要。

代码 20｜永久职位与非永久职位

原讲义位置：Number in permanent and temporary positions。

原代码：

```
lfs %>% count(JOBTYP) %>% mutate(percent = n / sum(n)*100)
```

逐步拆解： `JOBTYP` 分类计数；`percent` 是该类人数在样本中的比重。

原讲义对应输出：

```
## # A tibble: 2 × 3
##   JOBTYP                       n percent
##   <fct>                    <int>   <dbl>
## 1 Permanent                 7106   96.7
## 2 Not permanent in some way  241    3.28
```

怎样理解结果： `Not permanent in some way` 是数据中的类别标签，不能自行等同于所有形式的临时工而不看原数据定义。

代码 21｜单位员工规模

原讲义位置：Number of employees at work。

原代码：

```
lfs %>% count(MPNR02) %>% mutate(percent = n / sum(n)*100)
```

逐步拆解： `MPNR02` 是工作场所/雇员数量相关的分类变量；按其类别汇总人数。

原讲义对应输出：

```
## # A tibble: 9 × 3
##   MPNR02                                n percent
##   <fct>                             <int>   <dbl>
## 1 1–10                               1173   16.0
## 2 11–19                               560    7.62
## 3 20–24                               279    3.80
## 4 Don't know but under 25             151    2.06
## 5 25–49                               875   11.9
## 6 50–249                             1681   22.9
## 7 250–499                             477    6.49
## 8 Don't know but between 50 and 499   312    4.25
## 9 500 or more                        1839   25.0
```

怎样理解结果： 注意这是按**受访者所在的规模类别**统计人数，不是直接汇总了多少家企业。

代码 22｜婚姻状况分布

原讲义位置：People by marital status。

原代码：

```
lfs %>% count(MARSTA) %>% mutate(percent = n / sum(n)*100)
```

逐步拆解： `MARSTA` 为婚姻状况类别；输出每种状态的 `n` 和百分比。

原讲义对应输出：

```
## # A tibble: 6 × 3
##   MARSTA                                          n percent
##   <fct>                                       <int>   <dbl>
## 1 Single, never married                        2699   36.7
## 2 Married, living with spouse                  3785   51.5
## 3 Married separated from spouse                 166    2.26
## 4 Divorced                                      546    7.43
## 5 Widowed                                        74    1.01
## 6 Currently or previously in civil partnership   77    1.05
```

怎样理解结果： 不要把分类标签当成数字做算术；此处用 `count()` 最直观。

代码 23｜职业层级分布

原讲义位置：People by seniority。

原代码：

```r
lfs %>% count(NSECMJ20) %>% mutate(percent = n / sum(n)*100)
```

逐步拆解： `NSECMJ20` 为讲义的职业/社会经济层级类别变量；分类后计算占比。

原讲义对应输出：

```
## # A tibble: 7 × 3
##   NSECMJ20                                n percent
##   <fct>                               <int>   <dbl>
## 1 Higher managerial and professional  1836   25.0
## 2 Lower managerial and professional   2426   33.0
## 3 Intermediate occupations            1112   15.1
## 4 Lower supervisory and technical      423    5.76
## 5 Semi-routine occupations             728    9.91
## 6 Routine occupations                  662    9.01
## 7 Never worked                         160    2.18
```

怎样理解结果： 解释具体层级含义时以课程数据字典为准。

代码 24｜查看每周基本工作时长的摘要

原讲义位置：Summary of basic usual hours。

原代码：

```r
summary(lfs$BUSHR)
```

逐步拆解： `lfs$BUSHR` 选出工作时长列，再用 `summary()` 得出六项统计量。

原讲义对应输出：

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    7.00   32.00   38.00   34.76   40.00   90.00
```

怎样理解结果： 原输出显示中位数 38、均值 34.76；你需要分清哪一个是平均数、哪一个是中位数。

代码 25｜管道与 pull 的组合

原讲义位置：Summary of basic usual hours。

原代码：

```r
lfs %>% pull(BUSHR) %>% summary()
```

逐步拆解： `lfs %>% pull(BUSHR)` 从表中抽取一个向量；紧接 `%>% summary()` 对该向量做统计。

原讲义对应输出：

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    7.00   32.00   38.00   34.76   40.00   90.00
```

怎样理解结果： 它和 `summary(lfs$BUSHR)` 结果相同：一个是 `$` 提取列，一个是 `pull()` 提取列。

代码 26｜分别统计男女的工资

原讲义位置：Average and median wage for men and women。

原代码：

```
lfs %>% group_by(SEX) %>% summarise(mean_wage = mean(HOURPAY),
                                    median_wage = median(HOURPAY))
```

逐步拆解： `group_by(SEX)` 先把数据按性别分成组；`summarise(mean_wage = mean(HOURPAY), median_wage = median(HOURPAY))` 分别在每组内求均值和中位数。

原讲义对应输出：

```
## # A tibble: 2 × 3
##   SEX    mean_wage median_wage
##   <fct>      <dbl>       <dbl>
## 1 Male        22.5        18.5
## 2 Female      19.4        16.4
```

怎样理解结果： **先分组再汇总**与前面直接 `summarise` 不一样：前者每组一行，后者通常整表一行。男女均值不同是描述性发现，单凭此表不能证明因果关系。

> 小练习：把 `group_by(SEX)` 改为 `group_by(FTPT)`，比较全职与兼职的工资统计（前提是数据列可用）。

代码 27｜构造性别 × 学历的交叉表

原讲义位置：Sex and education。

原代码：

```
table(lfs$HIQUL22D, lfs$SEX)
```

逐步拆解： `lfs$HIQUL22D` 取学历列、`lfs$SEX` 取性别列；`table(A,B)` 把 A 放在行、B 放在列，统计每种组合的频数。

原讲义对应输出：

```
##
##                            Male Female
##   Degree or equivalent     1511   2024
##   Higher education          269    296
##   A level or equivalent     816    788
##   GCSE A*-C or equivalent   531    571
##   Other qualitfication      177    154
##   No Qualification          106    104
```

怎样理解结果： 如某行某列值 1511，意思是落入这两个类别交叉位置的观察人数。列联表可用于观察变量之间的分布。

代码 28｜单元格占总体比例

原讲义位置：Sex and education - cell proportions。

原代码：

```
table(lfs$HIQUL22D, lfs$SEX) %>% prop.table() %>% round(2)
```

逐步拆解： `table(...)` 先生成交叉频数表；`prop.table()` 默认除以**整个表的总人数**；`round(2)` 将比例显示为小数点后两位。

原讲义对应输出：

```
##
##                            Male Female
##   Degree or equivalent     0.21   0.28
##   Higher education         0.04   0.04
##   A level or equivalent    0.11   0.11
##   GCSE A*-C or equivalent  0.07   0.08
##   Other qualitfication     0.02   0.02
##   No Qualification         0.01   0.01
```

怎样理解结果： 例如 0.21 是总体约 21%，不是该学历群体内部的 21%。`round(2)` 在管道中等同于 `round(前一步结果, digits = 2)`。

代码 29｜行比例：同一学历内部比较男女

原讲义位置：Sex and education - row proportions。

原代码：

```r
table(lfs$HIQUL22D, lfs$SEX) %>% prop.table(1) %>% round(2)
```

逐步拆解： `prop.table(1)` 的 `1` 指按**行**归一化：每行的男女比例之和约为 1。

原讲义对应输出：

```
##
##                            Male Female
##   Degree or equivalent     0.43   0.57
##   Higher education         0.48   0.52
##   A level or equivalent    0.51   0.49
##   GCSE A*-C or equivalent  0.48   0.52
##   Other qualitfication     0.53   0.47
##   No Qualification         0.50   0.50
```

怎样理解结果： 回答的是「在某个学历类别的人中，男女各占多少？」；不是「男性中有多少人是这个学历」。

> 一句话记住：`prop.table(1)` → 每**行**总和为 1。

代码 30｜列比例：同一性别内部看学历

原讲义位置：Sex and education - column proportions。

原代码：

```r
table(lfs$HIQUL22D, lfs$SEX) %>% prop.table(2) %>% round(2)
```

逐步拆解： `prop.table(2)` 的 `2` 指按**列**归一化：每列不同学历的比例之和约为 1。

原讲义对应输出：

```
##
##                            Male Female
##   Degree or equivalent     0.44   0.51
##   Higher education         0.08   0.08
##   A level or equivalent    0.24   0.20
##   GCSE A*-C or equivalent  0.16   0.15
##   Other qualitfication     0.05   0.04
##   No Qualification         0.03   0.03
```

怎样理解结果： 回答的是「在男性（或女性）受访者内部，各学历占多少？」。这与上一段的分母不同，解释时一定说清楚。

> 一句话记住：`prop.table(2)` → 每**列**总和为 1。

代码 31｜按性别比较行业结构

原讲义位置：Sex and industry - column proportions。

原代码：

```
table(lfs$INDE07M, lfs$SEX) %>% prop.table(2) %>% round(2)
```

逐步拆解： 把交叉表的行变量从学历换成行业 `INDE07M`，保留列变量 `SEX`；`prop.table(2)` 比较男女各自内部的行业构成。

原讲义对应输出：

```
##
##                                        Male Female
##   Agriculture, forestry and fishing    0.01   0.00
##   Energy and water                     0.03   0.01
##   Manufacturing                        0.13   0.05
##   Construction                         0.07   0.02
##   Distribution, hotels and restaurants 0.15   0.13
##   Transport and communication          0.14   0.05
##   Banking and finance                  0.19   0.17
##   Public admin, education and health   0.24   0.52
##   Other services                       0.05   0.04
```

怎样理解结果： 这能描述行业结构差异，但不能直接说明性别导致某人进入某个行业。

代码 32｜预览数据框前几行

原讲义位置：The head function。

原代码：

```
head(lfs)
```

逐步拆解： `head(lfs)` 显示数据框的开头若干行；未提供参数时，默认通常显示**前 6 行**。

原讲义对应输出：

```
## # A tibble: 6 × 14
##   SEX   HOURPAY   AGE GOR9D EMPLEN FLEX22W6 FTPT  HIQUL22D INDE07M
JOBTYP MPNR02
##   <fct>   <dbl> <dbl> <fct> <fct>  <fct>    <fct> <fct>    <fct>
<fct>  <fct>
## 1 Male     14.4    61 Sout… 6 mon… No       Part… GCSE A*… Other …
Perma… 1–10
## 2 Male     11.6    60 Sout… Three… No       Full… GCSE A*… Public…
```

```
Perma… 1-10
## 3 Fema…    10.4    63 Sout… 2 yea… No       Full… A level… Public…
Perma… 1-10
## 4 Fema…    25.3    54 Sout… 1 yea… No       Full… Degree … Public… Not
p… 500 o…
## 5 Fema…    13.8    39 Sout… 2 yea… No       Full… Degree … Public…
Perma… 1-10
## 6 Male     41.0    53 Sout… 10 ye… No       Full… Degree … Transp…
Perma… 11-19
## # ℹ 3 more variables: MARSTA <fct>, NSECMJ20 <fct>, BUSHR <dbl>
```

怎样理解结果： 原讲义文字中有“前五行”的表述，但代码实际输出显示 6 行；以 R 的默认行为与输出为准。也可写 `head(lfs, 10)` 看前 10 行。

代码 33｜排序后查看最大值附近的记录

原讲义位置：Arranging and inspecting the data。

原代码：

```
lfs %>% arrange(HOURPAY) %>% tail()
```

逐步拆解： `arrange(HOURPAY)` 按时薪从小到大排序整张表；`tail()` 查看排序结果末尾的 6 行。

原讲义对应输出：

```
## # A tibble: 6 × 14
##   SEX   HOURPAY   AGE GOR9D EMPLEN FLEX22W6 FTPT  HIQUL22D INDE07M
JOBTYP MPNR02
##   <fct>   <dbl> <dbl> <fct> <fct>  <fct>    <fct> <fct>    <fct>
<fct>  <fct>
## 1 Male     94.0    39 Lond… 2 yea… No       Full… A level… Transp…
Perma… 1-10
## 2 Fema…    95.4    45 Sout… 10 ye… No       Full… Degree … Constr…
Perma… 50-249
## 3 Male     96.1    56 Lond… 1 yea… No       Part… Degree … Public…
Perma… 1-10
## 4 Male     96.2    58 East… 20 ye… No       Full… A level… Transp…
Perma… 250-4…
## 5 Male     96.2    45 Scot… 2 yea… No       Full… Degree … Public…
Perma… 500 o…
## 6 Fema…    98.8    51 Sout… 6 mon… No       Full… Degree … Bankin…
Perma… 500 o…
## # ℹ 3 more variables: MARSTA <fct>, NSECMJ20 <fct>, BUSHR <dbl>
```

怎样理解结果： 这有助于检查最高时薪附近的数据和对应属性。仅“排序并看最后几行”不能直接说明这些记录是异常值。

---

2. 你最容易混淆的 8 组概念

1. **`summarise()` 与 `mutate()`**：前者生成汇总行，后者为原来的每行添加或更改列；`count()` 专门做类别计数。
2. **`mean()` 与 `median()`**：前者对极端值较敏感，后者是排序后中间位置。
3. **`min()` / `max()` 与分位数**：极值是两端观测值，四分位数显示数据分布的内部位置。
4. **方差与标准差**：标准差等于方差的平方根；标准差保持原变量的量纲。
5. **频数与频率**：`n` 是人数，`percent` 是人数除以总人数乘 100。
6. **`$` 与 `pull()`**：两者都能从数据框提取某一列，写法不同。
7. **`table()` 与 `count()`**：前者常用于交叉列联表；后者返回易于管道后续处理的数据框。
8. **全表、行、列比例**：`prop.table()`、`prop.table(1)`、`prop.table(2)` 分母分别是**全表总数、对应行的总数、对应列的总数**。

3. 新手自检与报错排查

报错或现象	常见原因	如何处理
`object 'lfs' not found`	尚未导入数据，或对象名称不是 `lfs`	用 `ls()` 查看对象，检查导入步骤
`could not find function "count"`	未加载 `dplyr`	先执行 `library(dplyr)`
`object 'HOURPAY' not found`	列名拼写/大小写不一致或不在 `lfs` 中	`names(lfs)` 核对列名
结果是 `NA`	存在缺失值	先查 `sum(is.na(lfs$HOURPAY))`，再决定是否使用 `na.rm = TRUE`
`%>%` 不识别	没有加载相应包	执行 `library(dplyr)`
`reframe()` 不存在	`dplyr` 版本较旧	查看 `packageVersion("dplyr")`；按课程要求更新
`prop.table(1)` 的比例不符合预期	把“行”与“列”搞反了	再看 `table()` 的行名和列名，明确分母
输出结果和笔记有小差异	数据清洗、版本、缺失值或打印精度不同	核对数据来源、样本量和列类型

> **重要**：上述排错语句属于本教程补充，原始 Lecture 3 并未逐一演示。

4. 完整练习：你自己从头做一遍

假设你已准备好讲义中的 `lfs`，运行以下教学补充代码，分别体会“摘要、计数、分组、交叉表”：

```
library(dplyr)

# A. 了解整体工资水平
lfs %>% summarise(
  mean_pay = mean(HOURPAY),
  median_pay = median(HOURPAY),
  sd_pay = sd(HOURPAY)
)

# B. 看男女数量和占比
lfs %>% count(SEX) %>% mutate(percent = n / sum(n) * 100)

# C. 对比男女工资
lfs %>% group_by(SEX) %>% summarise(
  mean_pay = mean(HOURPAY),
  median_pay = median(HOURPAY)
)

# D. 学历与性别的行比例、列比例
tab <- table(lfs$HIQUL22D, lfs$SEX)
prop.table(tab, 1)  # 每个学历组内，男女各占多少
prop.table(tab, 2)  # 每个性别组内，各学历占多少
```

思考：为什么「学历群体中女性的比例」与「女性群体中某学历的比例」通常不同？关键在于两个问题的**分母**不同。

5. 一页速查表

你想做什么	直接使用
算平均数	`mean(x)`
算中位数	`median(x)`
求最小与最大	`min(x)` 、 `max(x)`
算方差、标准差	`var(x)` 、 `sd(x)`
求分位数	`quantile(x, probs = c(0.25, 0.5, 0.75))`
查看连续变量摘要	`summary(x)`
计算各类数量	`lfs %>% count(SEX)`
在计数表添加比例	`... %>% mutate(percent = n / sum(n) * 100)`
分组汇总	`lfs %>% group_by(SEX) %>% summarise(...)`

你想做什么	直接使用
两个分类变量交叉	`table(lfs$HIQUL22D, lfs$SEX)`
总体比例	`prop.table(tab)`
行内比例	`prop.table(tab, 1)`
列内比例	`prop.table(tab, 2)`
查看前六行	`head(lfs)`
查看后六行	`tail(lfs)`
排序	`lfs %>% arrange(HOURPAY)`

说明：代码和示例输出按上传的 `lecture3_notes.html` 顺序保留。教程解释、故障排查和附加练习是帮助初学者理解的补充说明。所有统计结果均属于原课程所用样本，不应在没有权重或抽样依据的情况下直接解释成英国总体估计。