第四讲课堂笔记

定量数据分析

引言

- 上节课，我们检查并描述了数据。
- 今天，我们将在此基础上进一步学习如何将数据可视化。
- 数据可视化是任何分析过程中至关重要的一步。
- 至少，它有助于我们理解数据并发现规律。
- 有时，一幅制作精良的可视化图表就足以清楚说明问题。
- 这时可能不需要进一步分析。

图形语法

- 理解统计图形的一个实用思路是威尔金森提出的“图形语法”。
- 它提供了一套规则，帮助我们理解和构建图形。
- 这一语法包含若干组成部分，是各种统计图形的基础。

图形语法的组成部分

- 数据以及一组映射关系，用于说明如何将变量映射到可感知的视觉属性。
- 图形中出现的几何对象，例如点、线和多边形。
- 统计变换，可用于变换数据或对数据进行汇总。
- 刻度：将数据空间中的数值映射到视觉属性空间中的值，例如形状、颜色和大小。
- 坐标系统：决定数据坐标如何映射到图形平面。
- 分面：把数据拆分为不同子集，分别作图。

R语言中的图形

- R语言具有多种绘图系统。
- 部分属于基础R，另一些由lattice等扩展包引入。
- 如今，ggplot2事实上已成为R语言绘图的通用标准，也是R语言最大的优势之一。
- 它也是tidyverse的一部分，因此与我们采用的数据处理方式能够很好地配合。
- 名称中的gg代表“图形语法”（grammar of graphics）。
- 这种方法通过逐层叠加，让我们能够构建几乎任何类型的统计图形。

- 本讲将参考Hadley Wickham的《ggplot2：优雅的数据分析图形》。

能做到不代表就应该这样做

- 就像语言一样，一个句子可以语法正确，却毫无意义。
- 考虑下面这个句子：

> 愤怒的石头像逗号一样吠叫。

- 这个句子在语法上正确，但并没有实际意义。
- ggplot2的方法旨在让你能够构建想要的各种图形。
- 始终要思考自己试图展示什么，以及展示方式是否合理。
- 图形语法本身不会替我们精细调整外观，但值得花时间做好这些细节。

ggplot2

- 必须先加载ggplot2；不过，如果使用library(tidyverse)，它也会随tidyverse一起加载。
- 编写绘图代码有好几种方式。
- 我们选用一种常见的方法（也是我自己使用的方法）。
- 图形通过不断添加元素来构建。
- 我们从调用ggplot()函数开始创建图形。
- 注意：函数名是ggplot，而软件包名是ggplot2。
- 此时并非一定要指定参数，但我建议指定。

ggplot函数的参数

- 第一个参数是将要使用的数据。
- 数据可以通过管道传入，也可以直接写在函数中。
- 我更喜欢通过管道传入数据。
- 在ggplot函数中，可以使用aes函数指定美学映射（视觉属性映射）。
- 我们从x变量开始，它显示在横轴上。
- 也可以指定y变量，它显示在纵轴上。
- 还可以指定其他映射，不过暂时先不讨论。

添加几何图层

- 指定数据和视觉映射后，就可以选择绘图使用的几何对象。

- 具体使用哪一种，取决于我们想展示什么。
- 今天我们将探索几种类型。

我们的因变量

- 一个很好的起点是查看我们的因变量。
- 仅使用一个变量时，能制作的图形类型相对有限。
- 我们将先学习两个重要示例：直方图和密度图。
- 它们都可以帮助我们检查变量的分布。
- 分布本身就值得研究；之后我们还会看到它对其他分析也很重要。

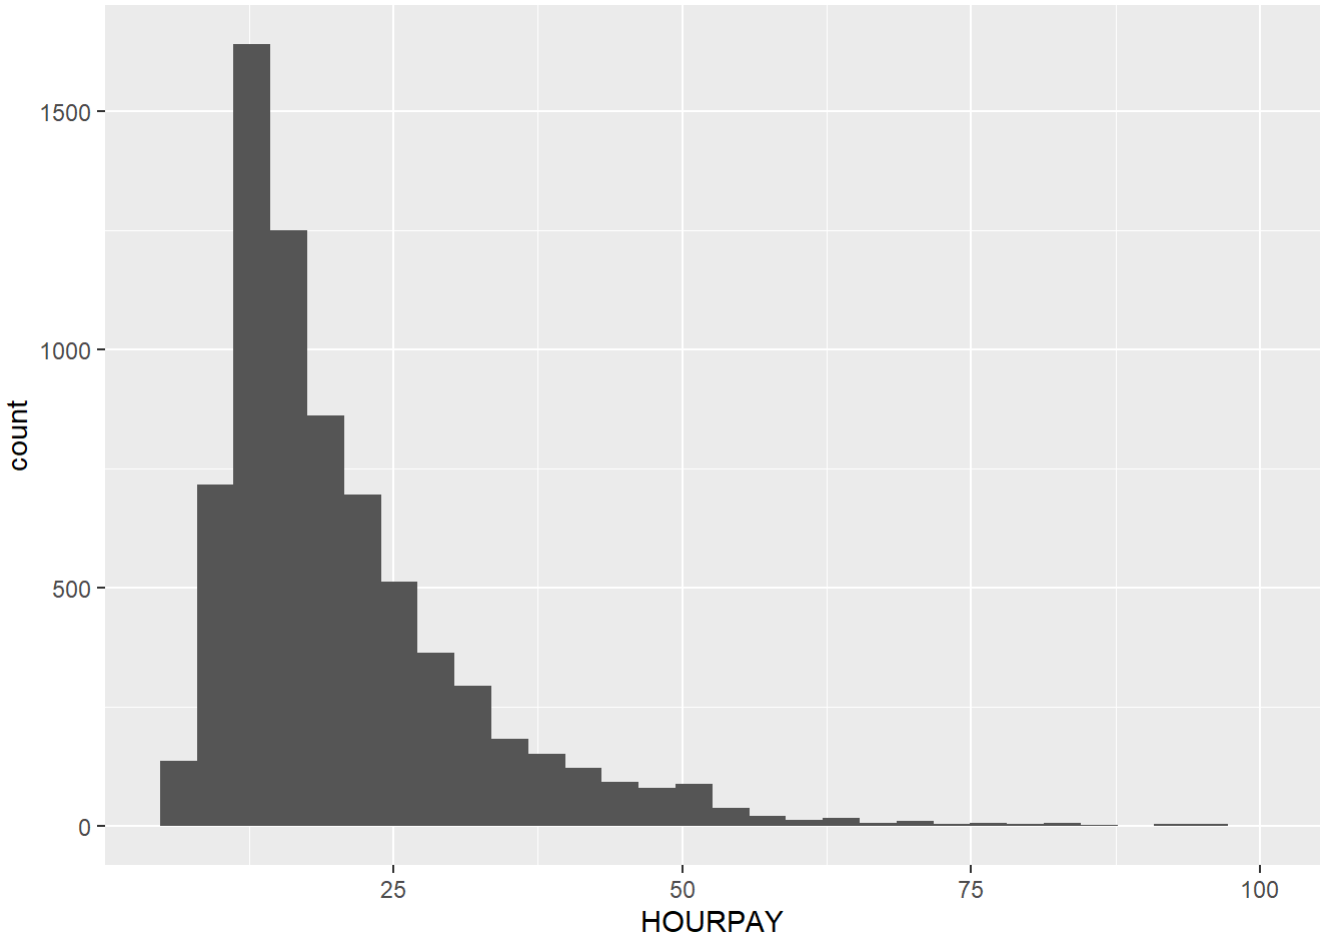
直方图

- 直方图将连续变量划分成若干离散的区间（组）。
- 统计每个区间内的观测数量。
- 用柱形表示每个区间内的观测数量。
- 我们可以自行选择组距，虽然多数软件也会提供默认设置。
- 我们打算用柱形来展示数据，但通常必须先将数据按区间聚合。
- 由于直方图非常重要，ggplot提供了一个快捷方法。
- 可以通过使用直方图几何图层来实现。
- 这样就会自动完成分组统计和图形展示。

小时工资的分布

```
lfs %>% ggplot(aes(HOURPAY)) + geom_histogram()
```

```
## `stat_bin()` using `bins = 30`. Pick better value `binwidth`.
```



我们能从直方图中看出什么?

- 首先可以看出，这个分布呈右偏（正偏）状态。
- 大多数观测集中在较低数值一端，而极少数高收入者出现在最右侧。
- 我们可以通过多种方式改善图表外观。
- 尤其值得注意的是，受数据分布影响，图形中有很大面积是空白的。
- 在解决这个问题前，先学习几种改善图表的方法。

标签

- 呈现给他人的每一幅图都必须有恰当的标签。
- 不要直接使用原始变量名，尤其当变量名本身不够清晰时。
- 图表有多种添加标签的方法。
- 我建议在图中加入labs函数。
- 通过这个函数，可以指定要添加标签的图形元素。

labs函数的部分参数

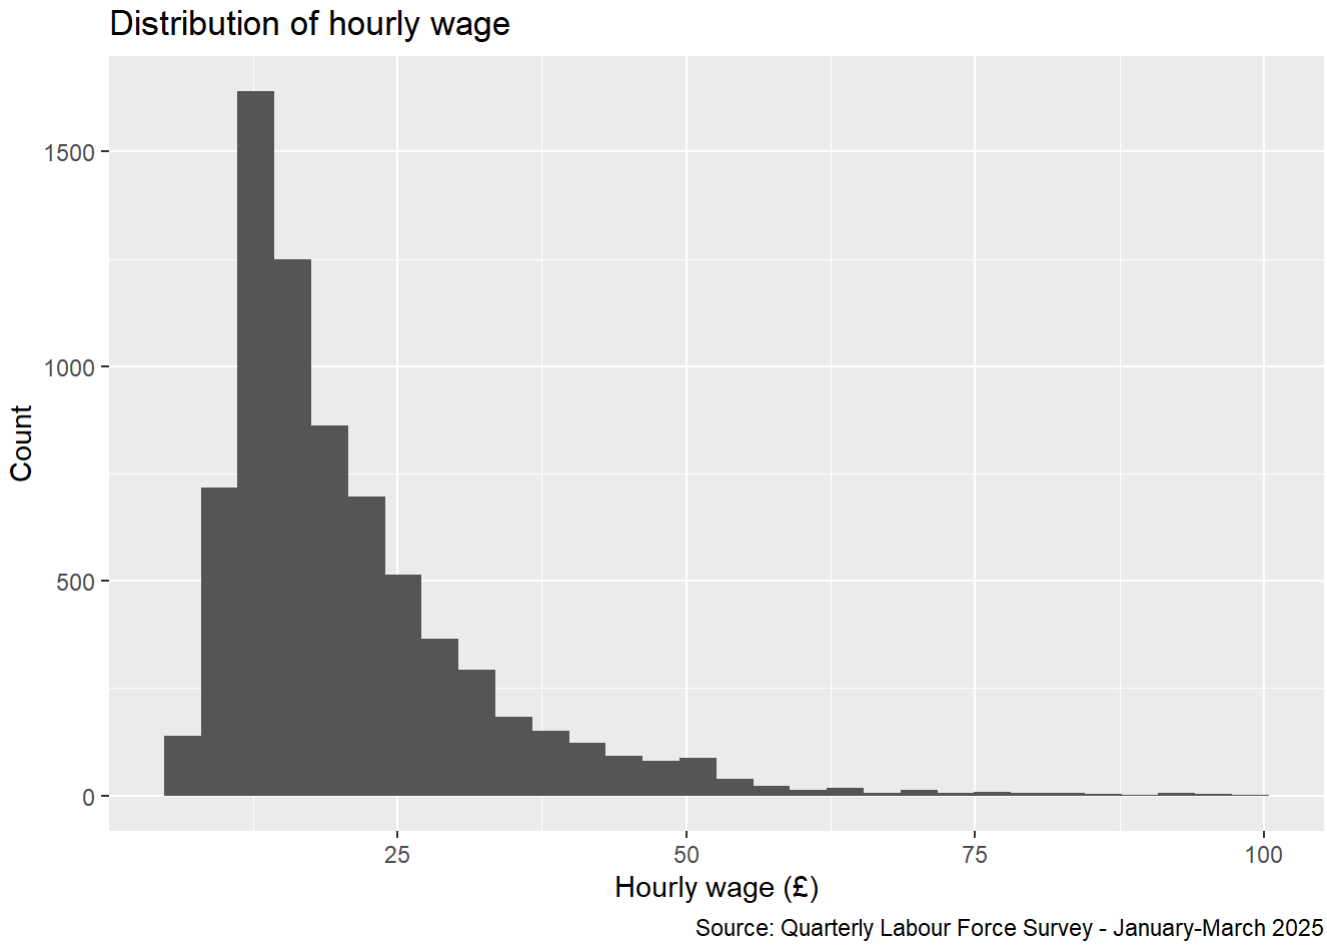
- title：放在图表上方的标题。

- subtitle：放在主标题下方的副标题。
- x：横轴标签。
- y：纵轴标签。
- caption：出现在图形右下方的说明文字，可以写明数据来源等信息。

为直方图添加标签

```
lfs %>% ggplot(aes(HOURPAY)) +
  geom_histogram() +
  labs( title = "Distribution of hourly wage",
        x = "Hourly wage (£)",
        y = "Count",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025")
```

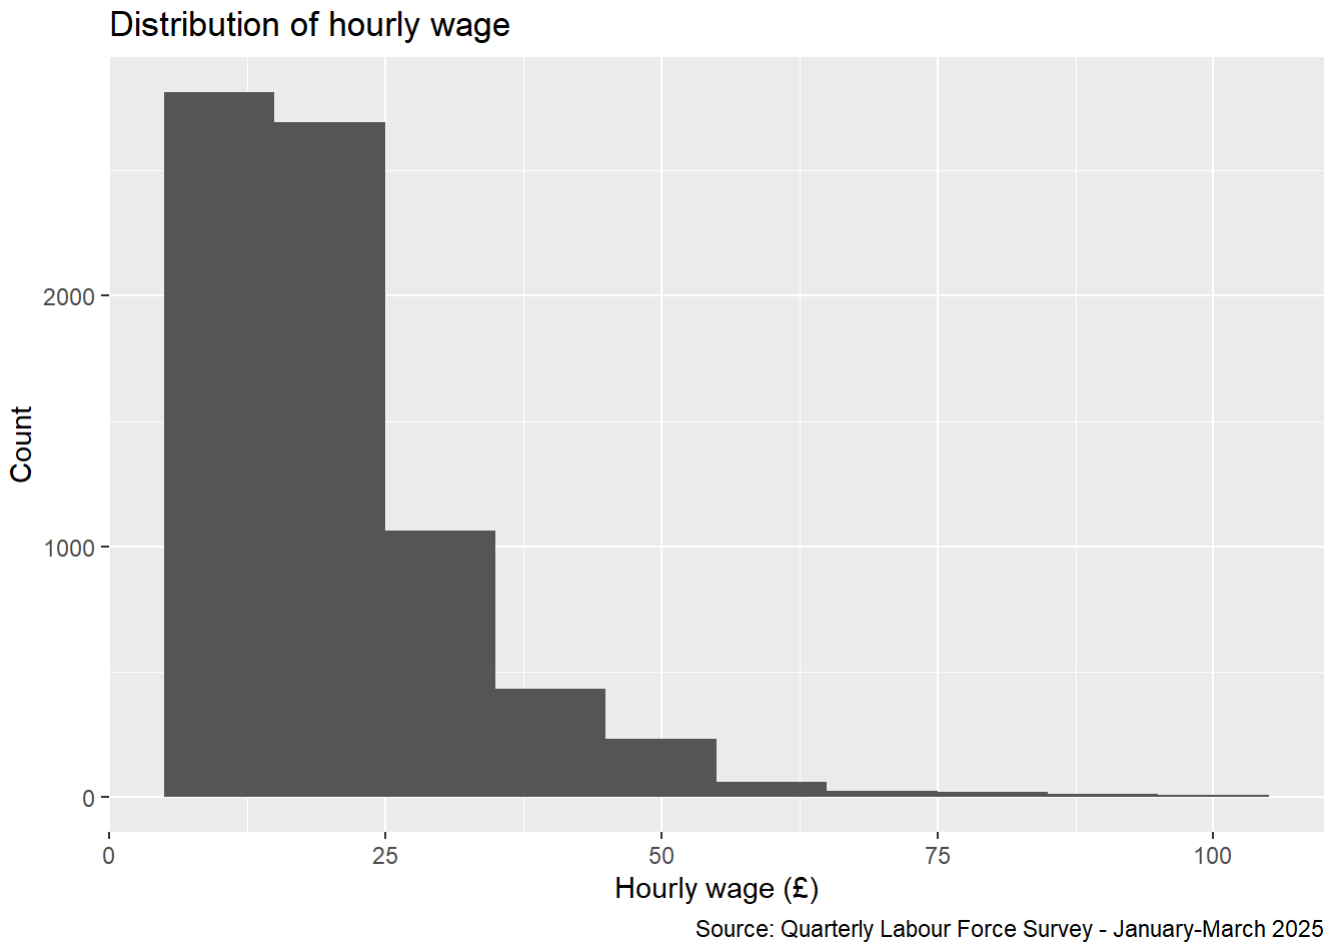
添加标签后的直方图



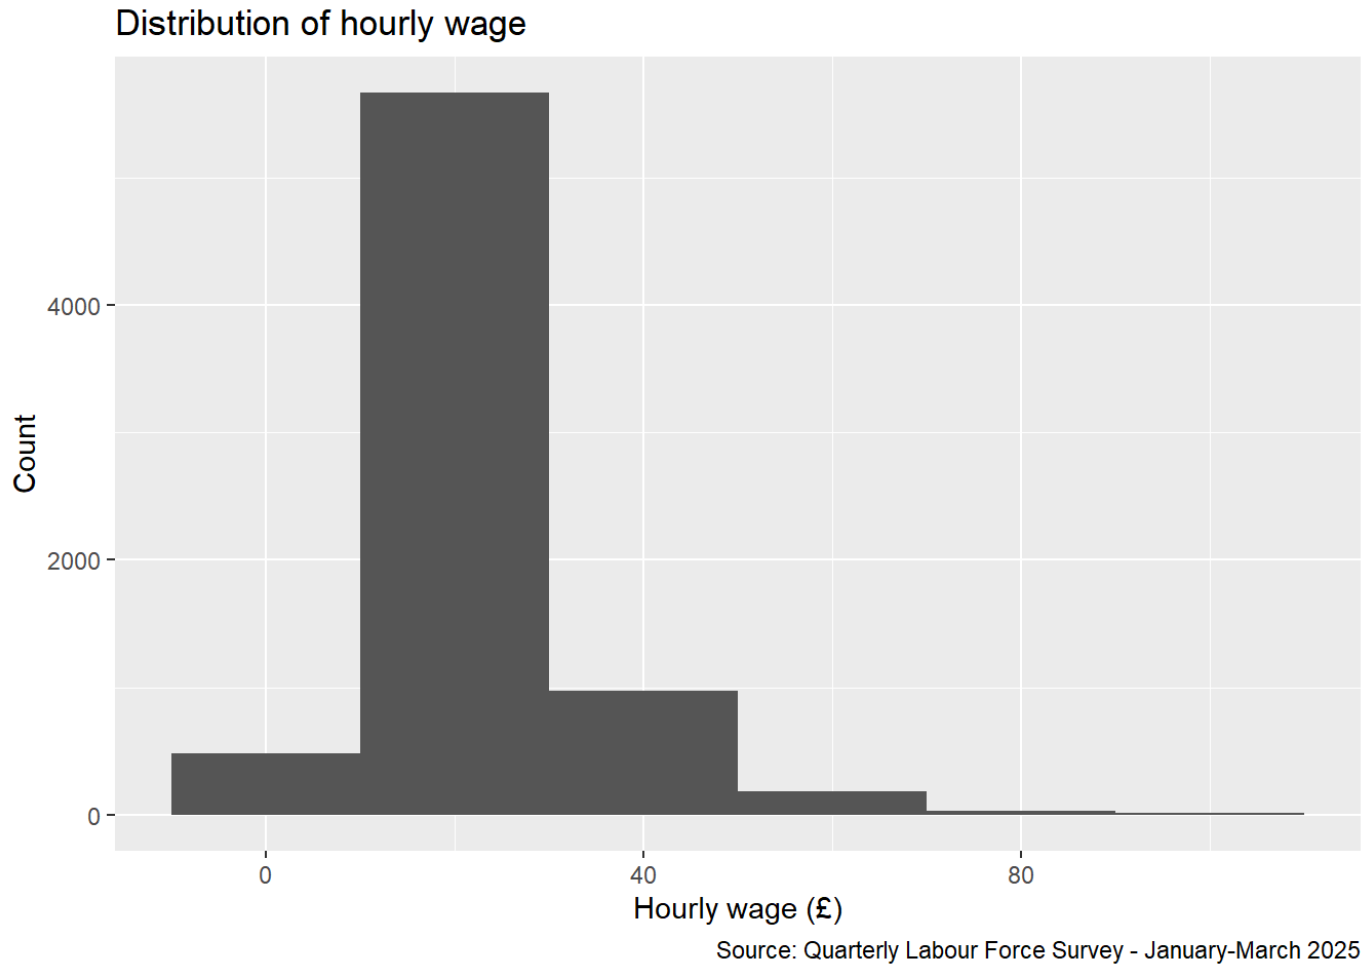
组距为10英镑

```
lfs %>% ggplot(aes(HOURPAY)) +
  geom_histogram(binwidth = 10) +
  labs( title = "Distribution of hourly wage",
        x = "Hourly wage (£)",
        y = "Count",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025")
```

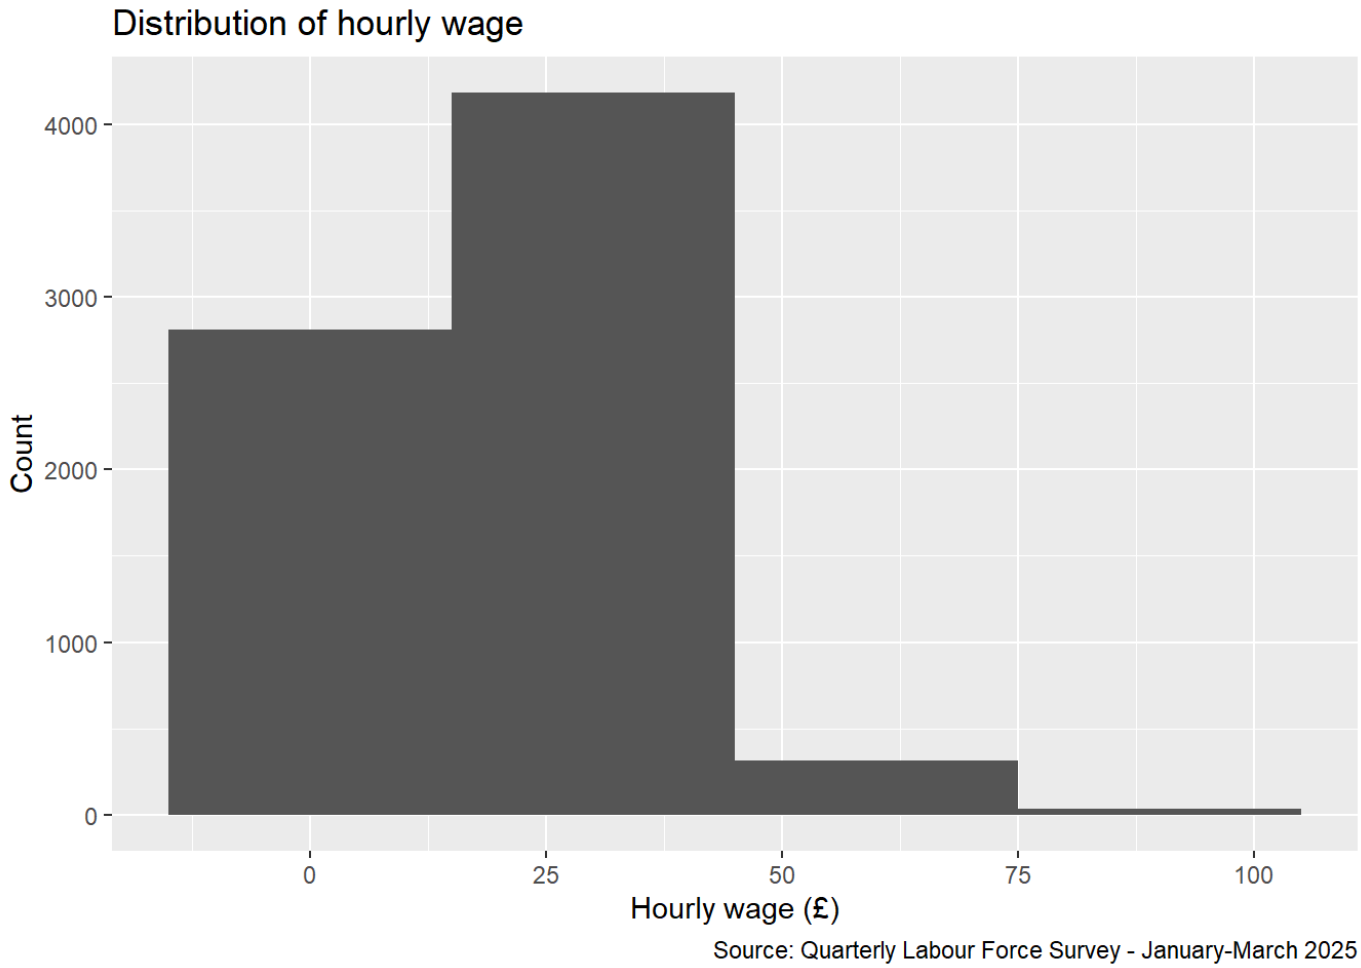
组距为10英镑



组距为20英镑


Distribution of hourly wage
Count
4000
2000
0
0
40
80
Hourly wage (£)
Source: Quarterly Labour Force Survey - January-March 2025

组距为30英镑

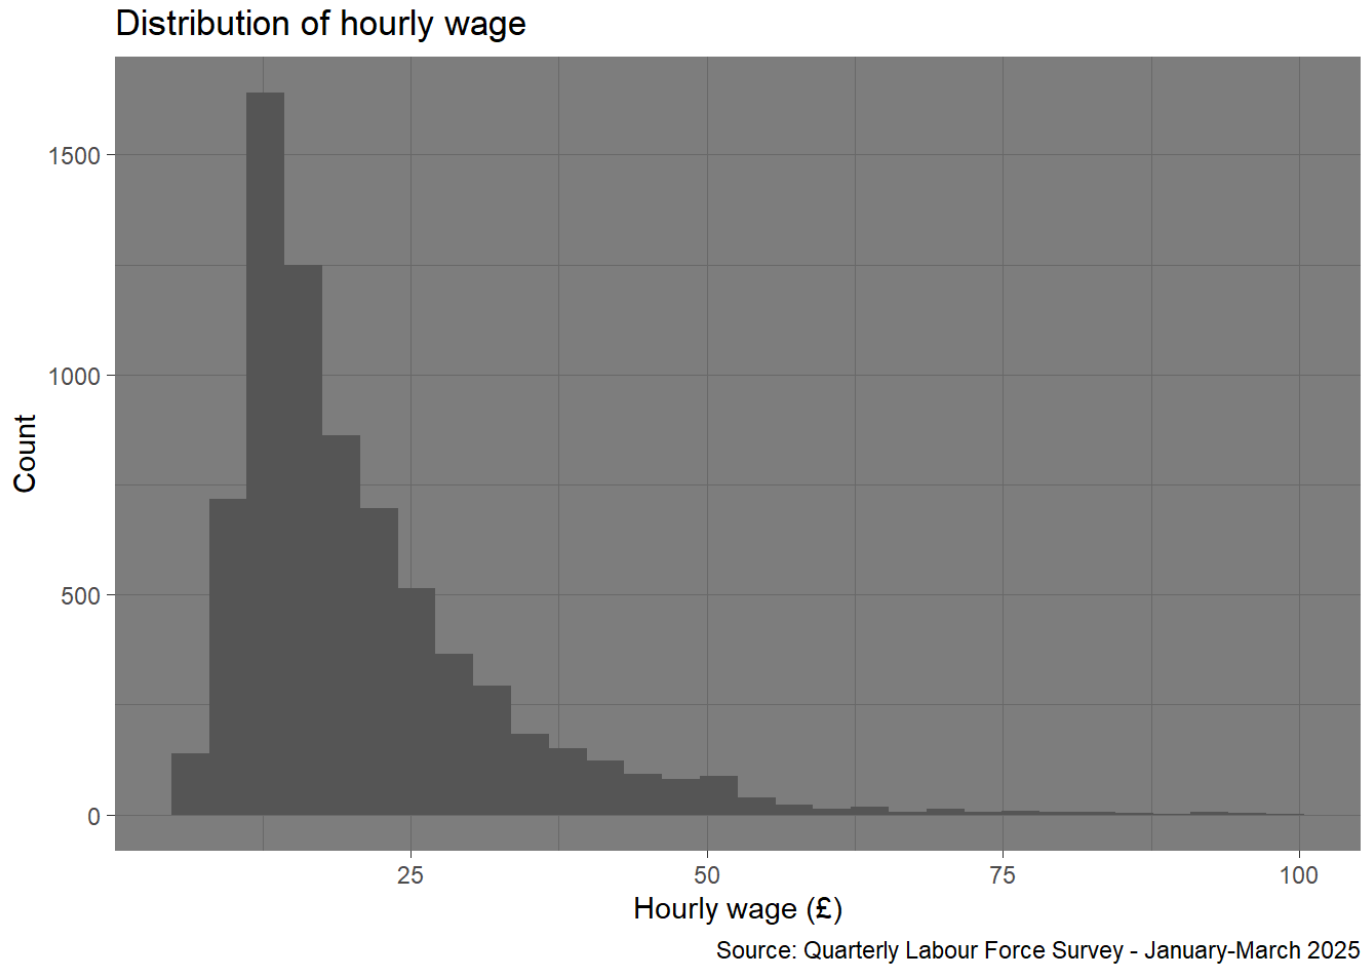


其他选项

- 几乎可以自定义图形外观的任何部分。
- 还可以选择一个绘图主题，利用别人已经完成的部分设计。
- 例如，可以选择theme_dark()、theme_bw()或theme_void()。
- 也可以查看ggthemes扩展包，获得更多选择。
- 还有其他提供各种主题的扩展包。（原讲义此处还提到了“添加主题”。）

```
lfs %>% ggplot(aes(HOURPAY)) +
  geom_histogram() +
  labs( title = "Distribution of hourly wage",
        x = "Hourly wage (£)",
        y = "Count",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_dark()
```

采用深色主题的直方图



处理偏态分布

- 图表中的大量空间都是空白。
- 这可能是少数极高数值造成的。
- 如果认为这些值是错误的，我们可以考虑排除它们。
- 但若没有充分理由，删除观测值并不明智。
- 可以考虑只在图形中不显示这些值。
- 既可以筛选数据，也可以限制图形的显示范围来实现。

检查高收入群体

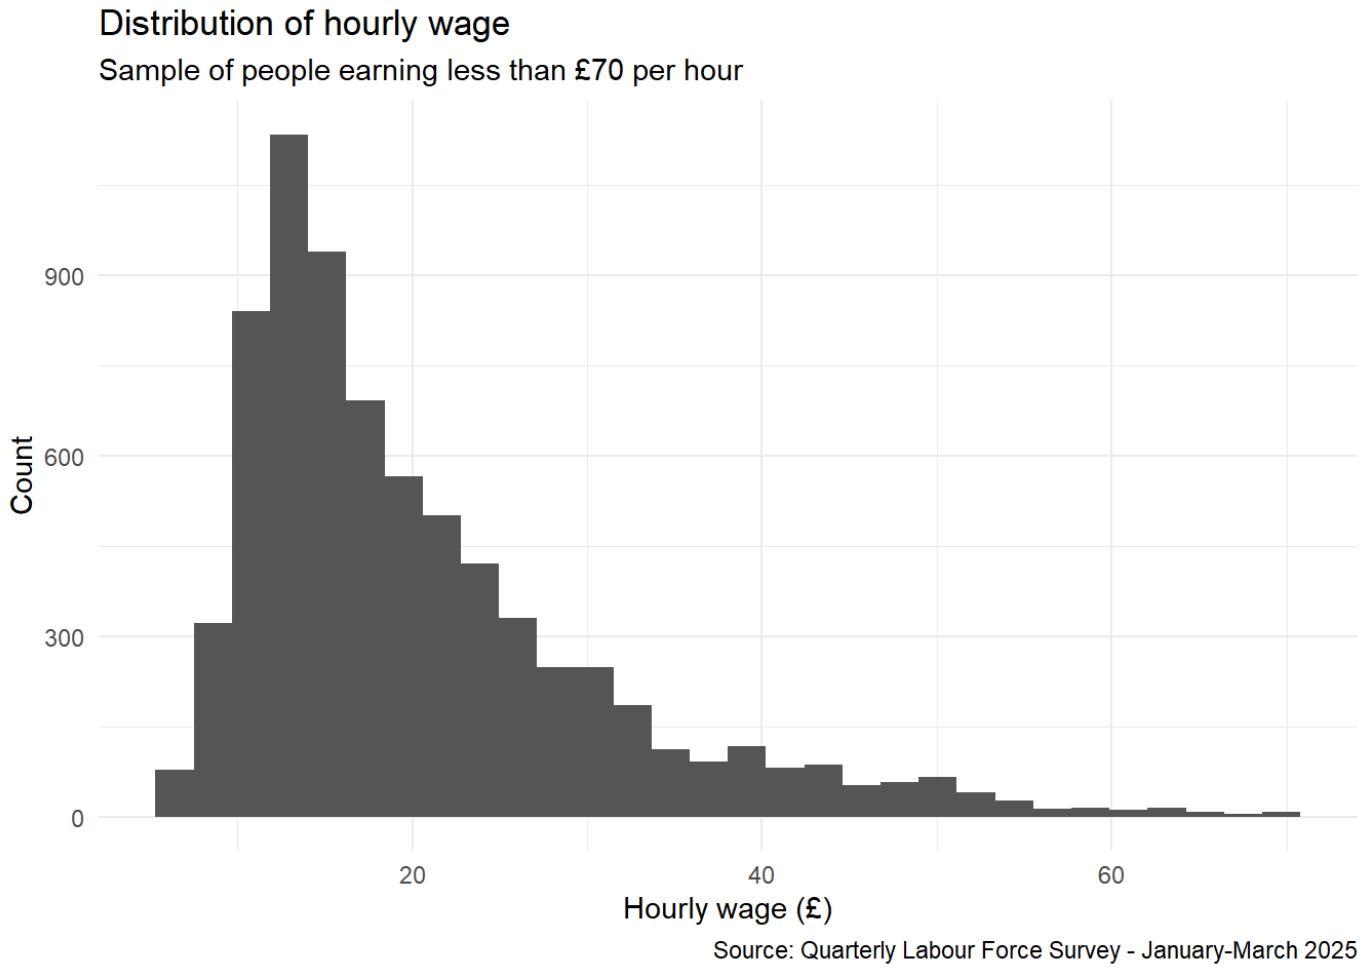
```
lfs %>% arrange(-HOURPAY) %>% select(HOURPAY) %>% head(n=10)
```

```
## # A tibble: 10 × 1
##    HOURPAY
##      <dbl>
##  1    98.8
##  2    96.2
##  3    96.2
##  4    96.1
##  5    95.4
##  6    94.0
##  7    93.8
##  8    93.6
##  9    92.3
## 10    91.4
```

时薪低于70英镑的人群直方图

```
lfs %>% filter(HOURPAY<70) %>%
   ggplot(aes(HOURPAY)) +
  geom_histogram() +
  labs( title = "Distribution of hourly wage",
        subtitle = "Sample of people earning less than £70 per hour",
        x = "Hourly wage (£)",
        y = "Count",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal()
```

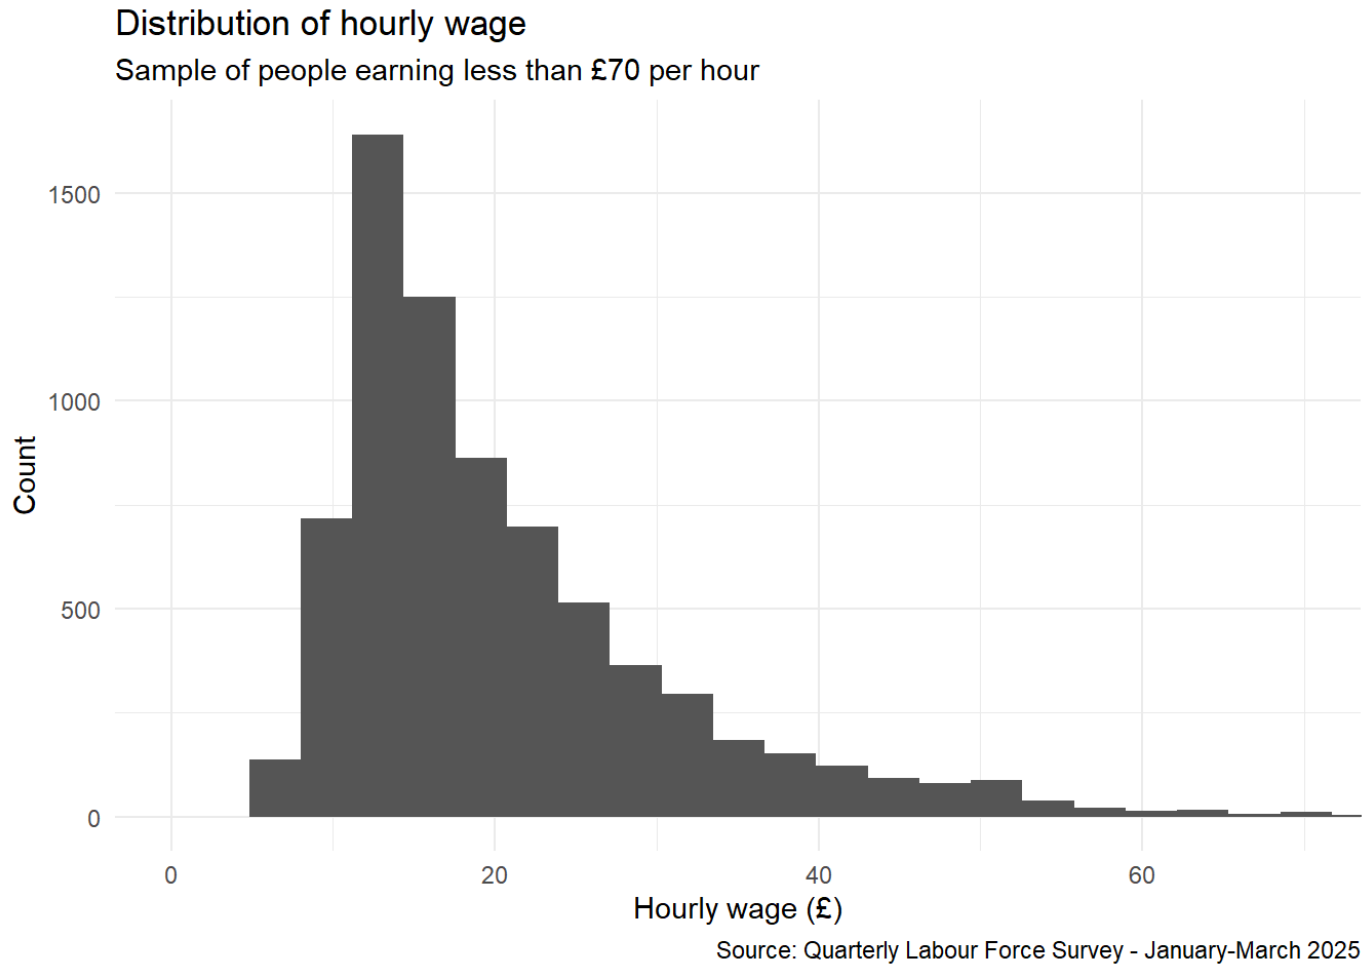
时薪低于100英镑的人群直方图



另一种方法

```
lfs %>%
   ggplot(aes(HOURPAY)) +
  geom_histogram() +
  labs( title = "Distribution of hourly wage",
        subtitle = "Sample of people earning less than £70 per hour",
        x = "Hourly wage (£)",
        y = "Count",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  coord_cartesian(xlim = c(0,70))
```

另一种方法



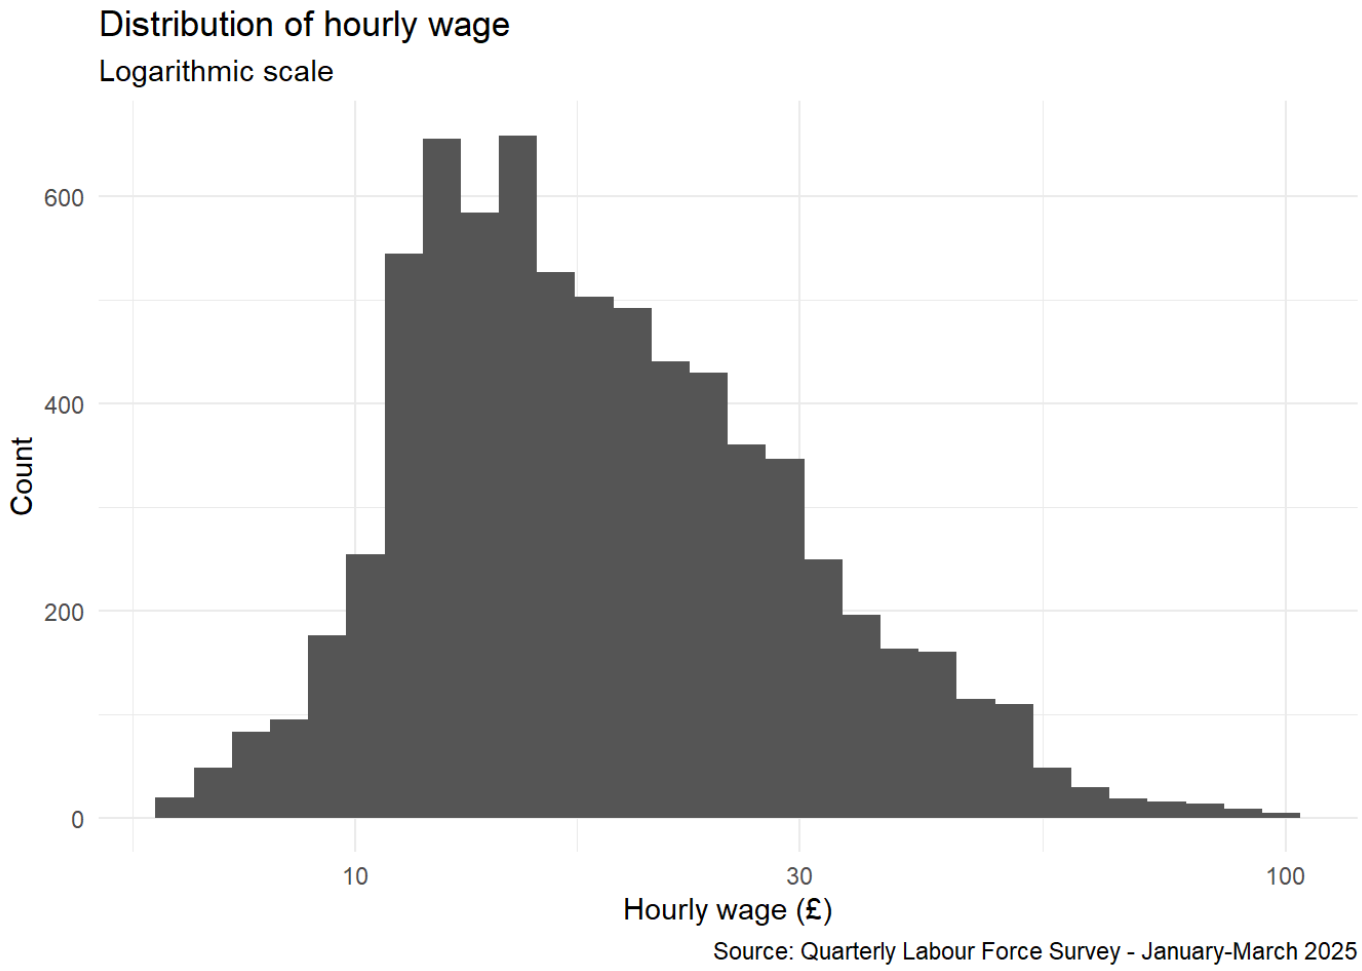
线性刻度与对数刻度

- 我们的横轴使用线性刻度。
- 沿着坐标轴移动时，数值按固定的幅度增加。
- 当最大值远大于最小值时，这种刻度未必合适。
- 在对数刻度上，数值沿轴的增长幅度会越来越大。
- 1到10的距离等于10到100的距离，也等于100到1000的距离。
- 这样可以在较小的图形范围内展示跨度很大的数值。
- 注意：数据中存在零值时，对数变换不能直接应用，因为0的对数不存在。

采用对数刻度的直方图

```
lfs %>%
   ggplot(aes(HOURPAY)) +
  geom_histogram() +
  labs( title = "Distribution of hourly wage",
        subtitle = "Logarithmic scale",
        x = "Hourly wage (£)",
        y = "Count",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_x_log10()
```

采用对数刻度的直方图



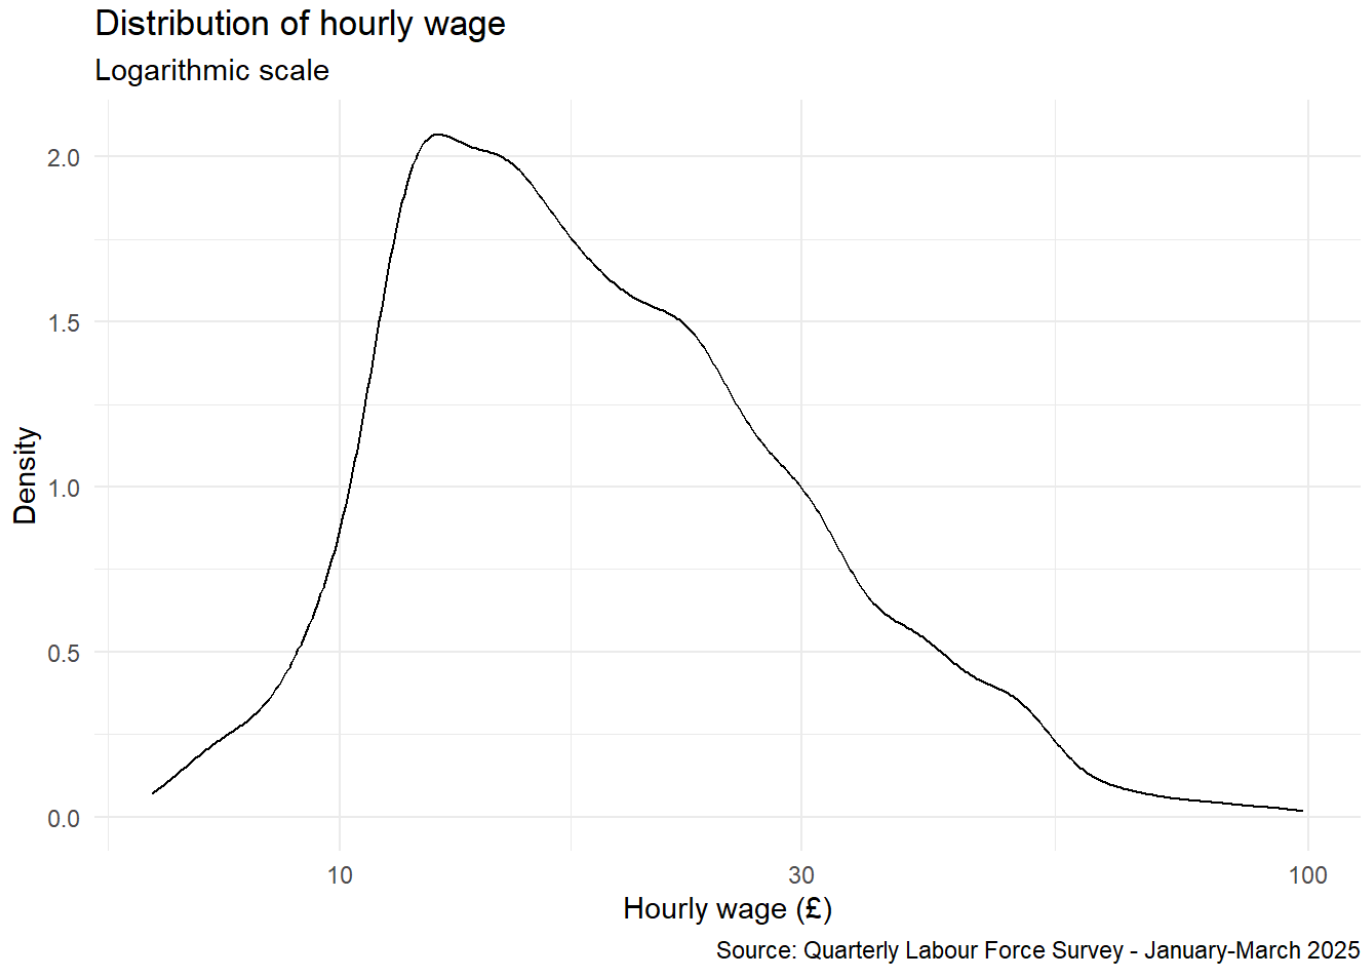
密度图

- 密度图与直方图密切相关，能告诉我们许多相似的信息。
- 它不将数据分到不同区间，而是使用核平滑方法来减少噪声。
- 这有助于观察潜在的数据分布。
- 也可以避免直方图由于区间数量选择不当而引发的一些问题。
- 密度图的绘制方式与直方图非常相似。

采用对数刻度的密度图

```
lfs %>%
   ggplot(aes(HOURPAY)) +
  geom_density() +
  labs( title = "Distribution of hourly wage",
        subtitle = "Logarithmic scale",
        x = "Hourly wage (£)",
        y = "Density",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_x_log10()
```

采用对数刻度的密度图



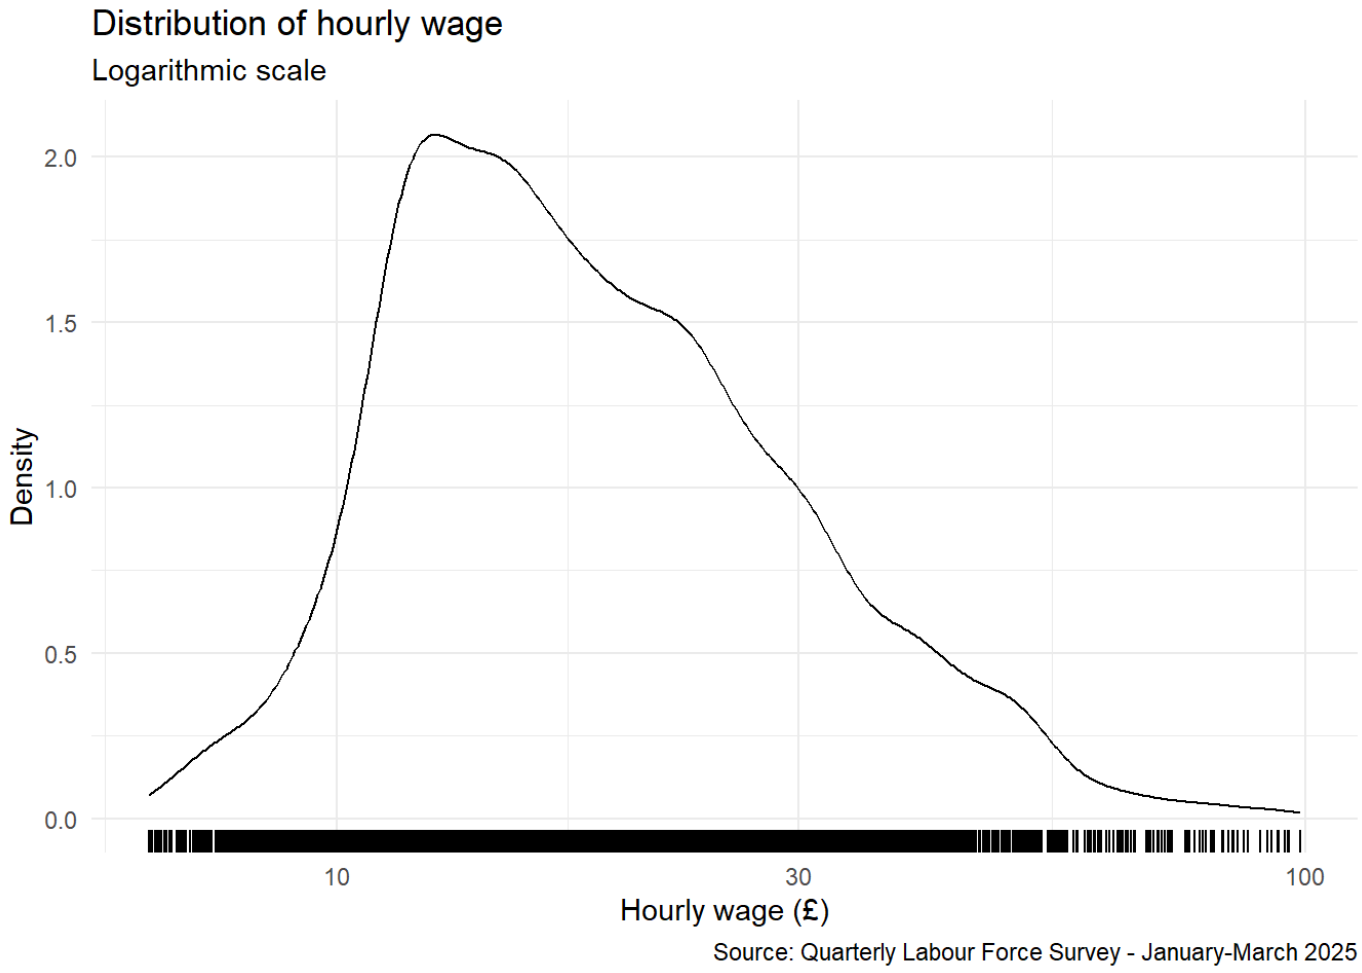
在图中添加地毯图（rug）

- 在图中添加rug（地毯图），会在图形底部添加一排短线。
- 其中的竖线表示每一个数据点所在的位置。
- 它不占用太多额外空间，却能够提供分布的附加信息。
- 通过添加geom_rug图层，就能得到这种图形。

采用对数刻度的密度图

```
lfs %>%
   ggplot(aes(HOURPAY)) +
  geom_density() +
  labs( title = "Distribution of hourly wage",
        subtitle = "Logarithmic scale",
        x = "Hourly wage (£)",
        y = "Density",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_x_log10() +
  geom_rug()
```

采用对数刻度的密度图



我们应该关注什么？

- 直方图和密度图呈现的信息非常相似。
- 均值附近存在较为集中的一组观测。
- 这个分布只有一个峰值。

- 有时也可能出现多个峰值，这时我们需要研究其原因。
- 也要留意任何不合理的异常现象。
- 分布高度右偏，也就是说，一部分人的小时工资非常高。

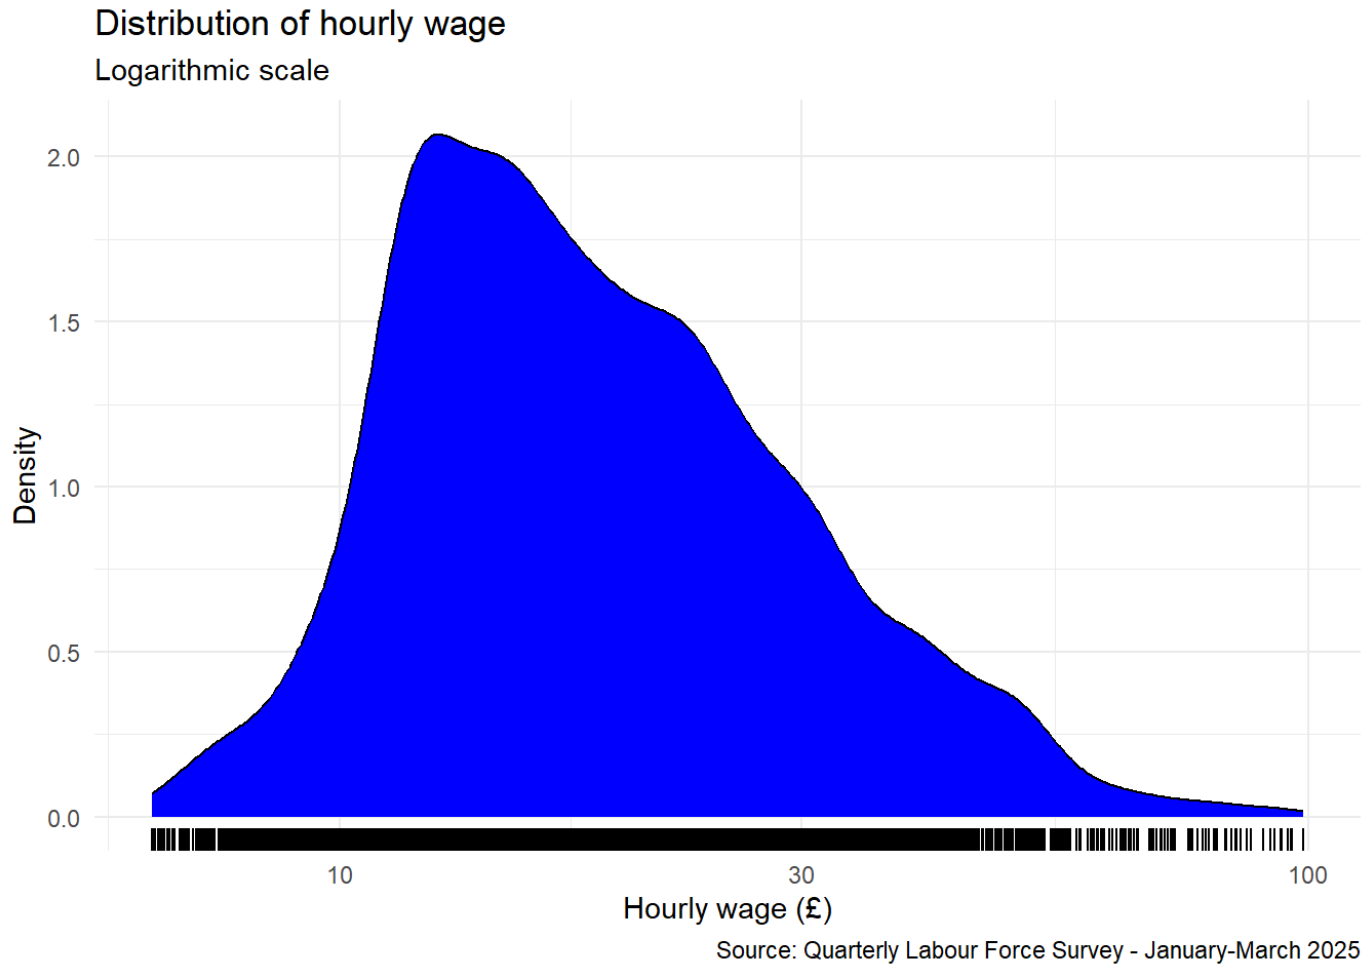
进一步完善密度图

- 如果愿意，可以为密度曲线下方的区域填色。
- 假设我们想把它填成蓝色。

采用对数刻度的密度图

```
lfs %>%
   ggplot(aes(HOURPAY)) +
  geom_density(fill="blue") +
  labs( title = "Distribution of hourly wage",
        subtitle = "Logarithmic scale",
        x = "Hourly wage (£)",
        y = "Density",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_x_log10() +
  geom_rug()
```

采用对数刻度的密度图



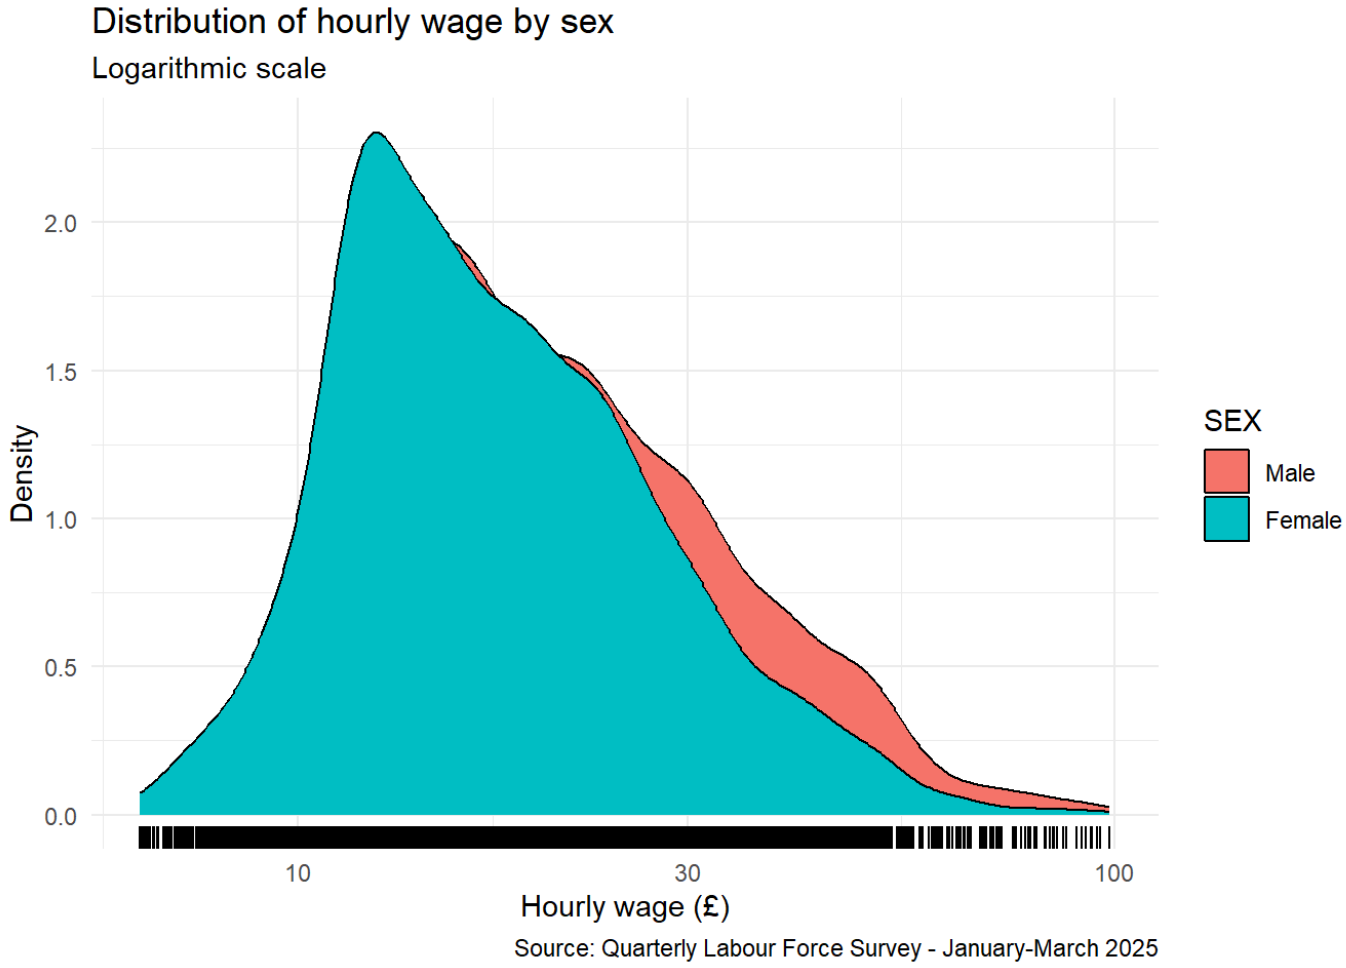
添加另一个变量

- 仅仅填上颜色虽然美观，却不能提供更多信息。
- 可以绘制不止一条密度曲线。
- 然后根据观测所属的组别分别填色。
- 在这里，可以使用SEX变量进行分组。
- 需要将这一信息加入美学映射中。
- 既可以在ggplot调用中设置，也可以在geom_density调用中设置。

采用对数刻度的密度图

```
lfs %>%
   ggplot(aes(HOURPAY)) +
  geom_density(aes(fill=SEX)) +
  labs( title = "Distribution of hourly wage by sex",
        subtitle = "Logarithmic scale",
        x = "Hourly wage (£)",
        y = "Density",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_x_log10() +
  geom_rug()
```

采用对数刻度的密度图



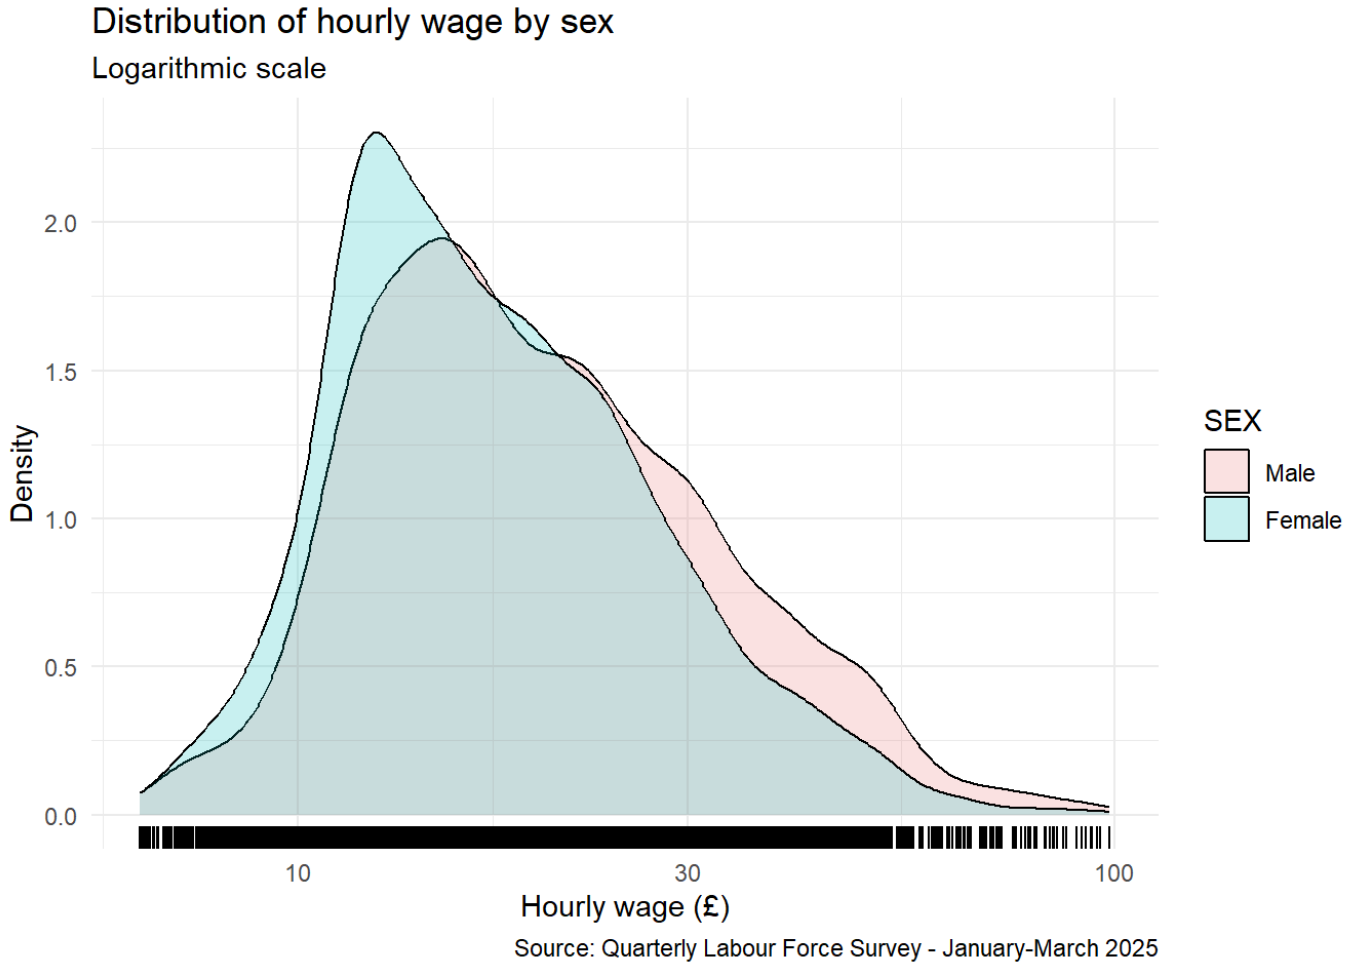
改进图表

- 这幅图已经很有信息量，但多条曲线彼此重叠。
- 降低填充区域的不透明度，可以缓解这一问题。
- 通过设置alpha参数即可实现。

采用对数刻度的密度图

```
lfs %>%
   ggplot(aes(HOURPAY)) +
  geom_density(aes(fill=SEX), alpha=0.2) +
  labs( title = "Distribution of hourly wage by sex",
        subtitle = "Logarithmic scale",
        x = "Hourly wage (£)",
        y = "Density",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_x_log10() +
  geom_rug()
```

采用对数刻度的密度图



图例

- 图例帮助读者理解图中展示的内容。
- 如有需要，可以自行定制图例。
- 一幅图中的分组数量应有所限制。
- 通常最多只有约8种颜色能被清楚地区分。

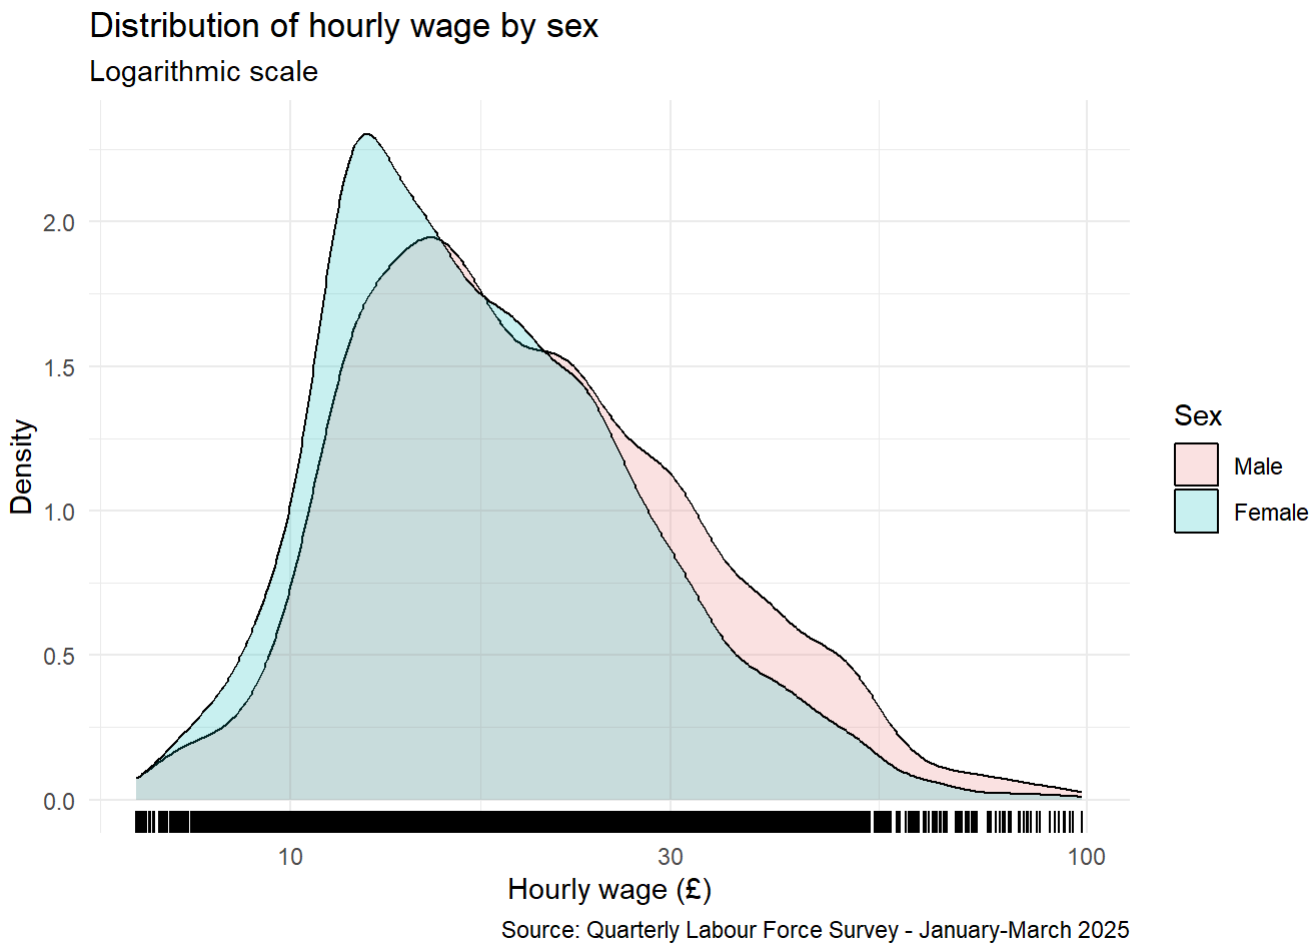
- 颜色选择很重要，ggplot2会尝试默认使用合适的颜色。
- 还有许多扩展包提供不同的调色方案，例如viridis或ggthemes。
- 也要考虑色觉辨识存在困难的人群（讲义称约占英国人口的4.5%，其中多数为男性）。

图例

- 当前图例直接使用变量名SEX作为标题。
- 虽然这个名称至少有明确含义，但不应该全部大写。
- 在这个例子中，图表标题和类别标签已足以说明图例内容。
- 因此，可以考虑取消图例标题。
- 图例可以通过labs()函数自定义。
- 也可以使用theme函数。

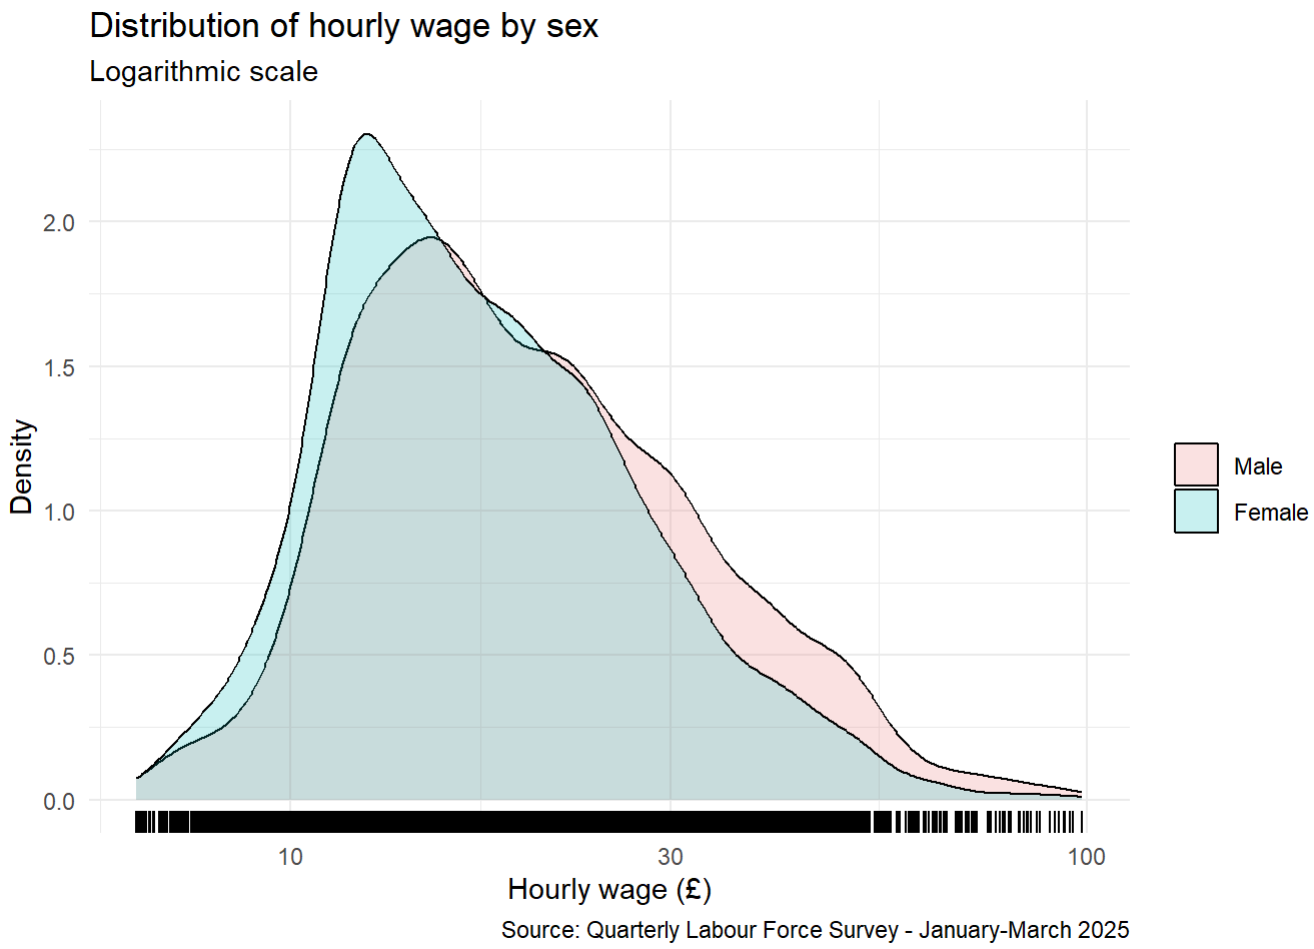
修改图例标签

```
lfs %>%
  ggplot(aes(HOURPAY)) +
  geom_density(aes(fill = SEX), alpha = 0.2) +
  labs( title = "Distribution of hourly wage by sex",
        subtitle = "Logarithmic scale",
        x = "Hourly wage (£)",
        y = "Density",
        fill = "Sex",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_x_log10() +
  geom_rug()
```



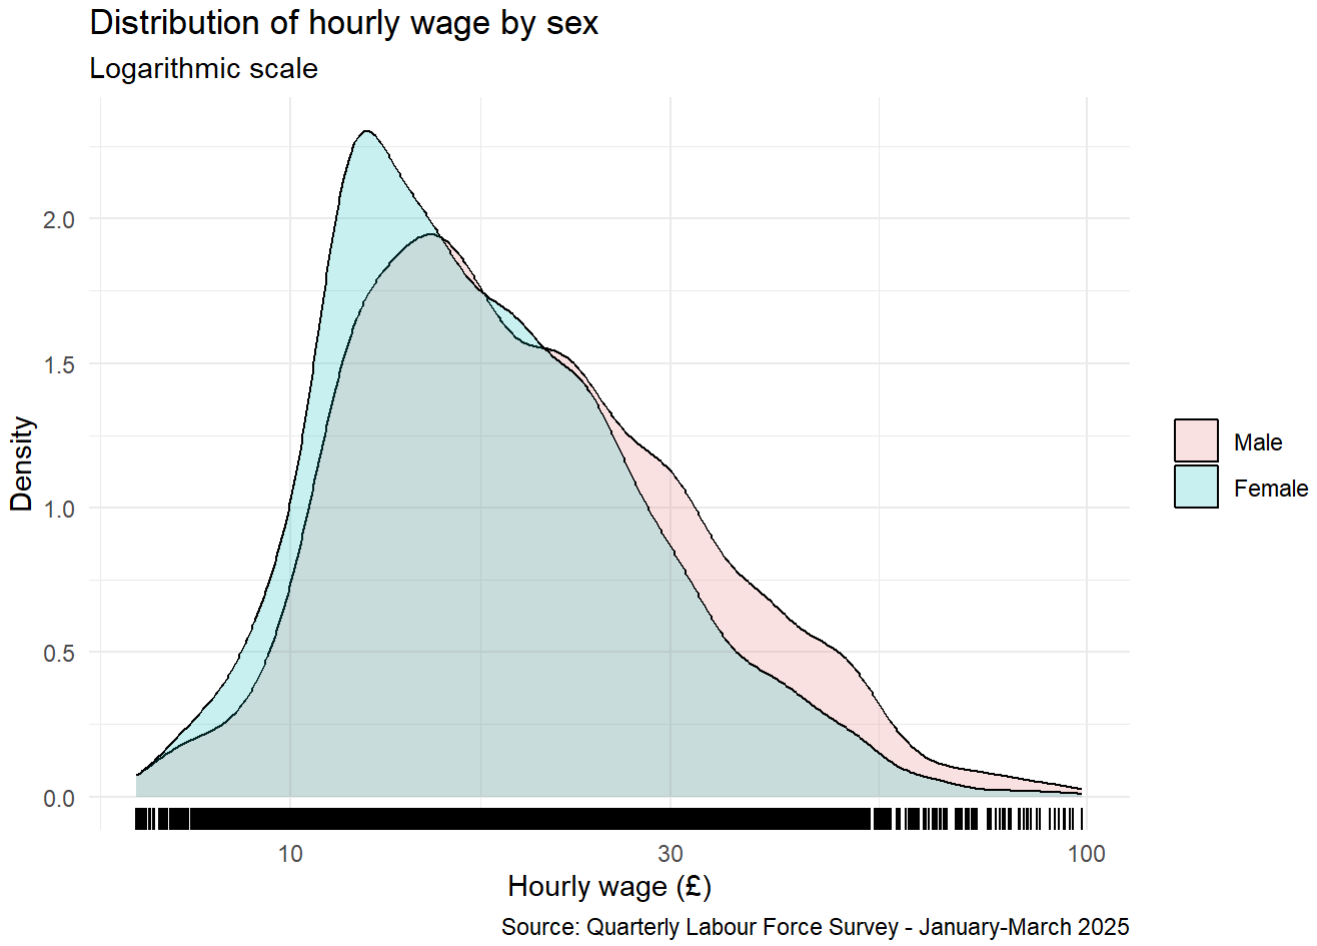
隐藏图例标题（取巧的方法）

```
lfs %>%
  ggplot(aes(HOURPAY)) +
  geom_density(aes(fill = SEX), alpha = 0.2) +
  labs( title = "Distribution of hourly wage by sex",
        subtitle = "Logarithmic scale",
        x = "Hourly wage (£)",
        y = "Density",
        fill = "",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_x_log10() +
  geom_rug()
```

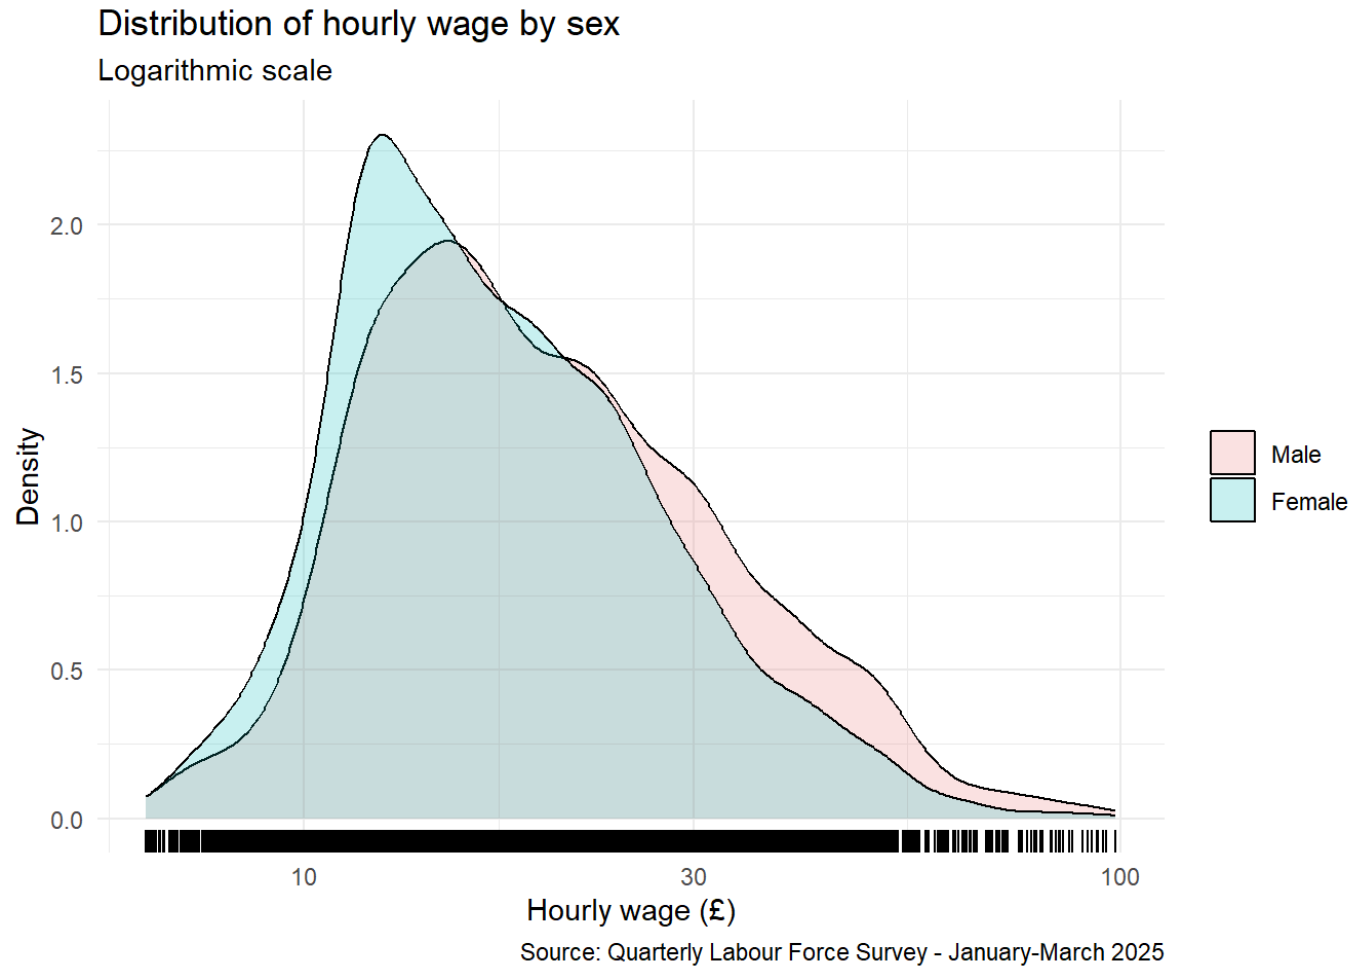


隐藏图例标题（规范的方法）

```
lfs %>%
  ggplot(aes(HOURPAY)) +
  geom_density(aes(fill = SEX), alpha = 0.2) +
  labs( title = "Distribution of hourly wage by sex",
        subtitle = "Logarithmic scale",
        x = "Hourly wage (£)",
        y = "Density",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_x_log10() +
  geom_rug() +
  theme(legend.title = element_blank())
```


Distribution of hourly wage by sex
Logarithmic scale
Density
2.0
1.5
1.0
0.5
0.0
10
30
100
Hourly wage (£)
Male
Female
Source: Quarterly Labour Force Survey - January-March 2025

采用对数刻度的密度图


Distribution of hourly wage by sex
Logarithmic scale
Density
2.0
1.5
1.0
0.5
0.0
10
30
100
Hourly wage (£)
Male
Female
Source: Quarterly Labour Force Survey - January-March 2025

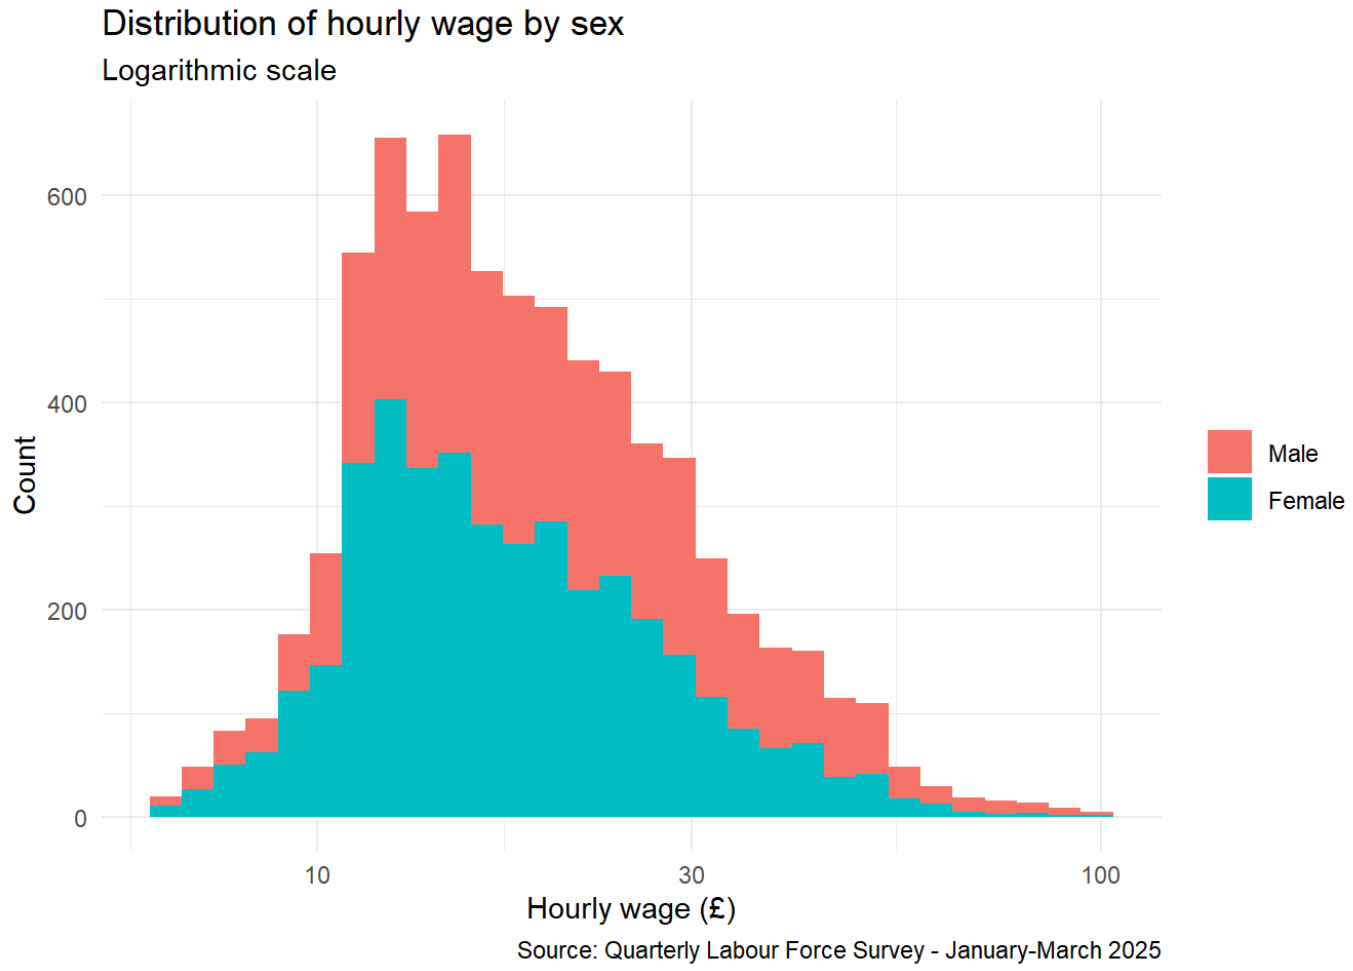
修改直方图的填充颜色

- fill视觉属性可用于许多不同类型的图形。
- 我们在直方图上尝试使用它。

采用对数刻度的直方图

```
lfs %>%
  ggplot(aes(HOURPAY)) +
  geom_histogram(aes(fill=SEX)) +
  labs( title = "Distribution of hourly wage by sex",
        subtitle = "Logarithmic scale",
        x = "Hourly wage (£)",
        y = "Count",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_x_log10() +
  theme(legend.title = element_blank())
```

采用对数刻度的直方图



总结

- 今天我们认识了R语言中最强大的绘图系统之一。
- 还学习了制作有说服力的数据可视化作品所需的关键基础。
- 下节课将继续拓展今天的内容，探索更多绘图功能。