Lecture 4：R语言 ggplot2 数据可视化逐行教程（完全零基础中文版）

> 基于用户提供的 **Lecture 4 Notes / Quantitative Data Analysis** 原始 HTML。按原讲义出现顺序逐段解释全部 **17段R代码**，并解释非R控制台输出。原讲义未给出数据清洗和 `SEX` 重编码的完整流程；本文对此专门标注，不把补充建议冒充老师原代码。

目录

1. 运行前的准备
2. 零基础必会语法
3. 全部17段原文代码逐段讲解
4. 讲义输出怎么读
5. 常见错误与修复
6. 配套练习及答案
7. 函数速查表

一、运行前的准备

1. 本讲研究什么?

本讲使用英国季度劳动力调查（January–March 2025）的 `lfs` 数据，主要观察 `HOURPAY`（小时工资）的分布，还尝试使用 `SEX`（类别编码）进行分组。重点不在回归，而在**用图形正确理解连续数值的分布**：集中于哪里、是否右偏、极端值会怎样影响图形、如何比较不同组。

2. 从零开始运行

```
# 如果尚未安装，再运行一次
install.packages(c("readr", "dplyr", "ggplot2"))

# 每次开启新的 R 会话都需要加载
library(readr)
library(dplyr)
library(ggplot2)

# 文件与脚本在同一个工作目录时，可使用以下文件名
lfs <- read_tsv("lfsp_jm25_eul_pwt24.tab", show_col_types = FALSE)

# 确认读取成功，以及研究变量存在
dim(lfs)
names(lfs)
str(lfs[c("HOURPAY", "SEX")])
summary(lfs$HOURPAY)
table(lfs$SEX, useNA = "ifany")
```

`install.packages()` 负责把工具安装到电脑；`library()` 负责在当前会话中启用；`read_tsv()` 读取TAB分隔文件；`<-` 是赋值（把右侧结果保存为左侧对象）。如果文件不在当前工作目录，需要提供正确路径。`names()` 显示列名；`str()` 显示列类型；`summary()` 看概况。

数据质量警告： `HOURPAY` 可能包含 `NA`、不适用记录或特殊缺失编码。正式作图前需要对照 LFS 数据字典清洗。以下首先原样解释课堂代码，后文提供更稳妥的教学版写法。图中的频数和密度默认也**没有应用调查权重**，不能直接视为英国总体工资分布。

二、零基础必会语法

写法	名称	在这堂课的意思
`lfs`	数据框对象	类似一张表格
`HOURPAY`	列名	小时工资字段
`SEX`	列名	性别分类编码（需查字典）
`lfs$HOURPAY`	`$` 提取	取出数据框中的一整列
`f(x)`	函数调用	用括号把参数交给函数 `f`
`x = 10`	命名参数	指定某项参数的值
`"text"`	字符串	文字需用英文引号括起来
`%>%`	管道	左边结果输入右边函数
`+`	ggplot加图层	把几何对象、标签、主题加到图上
`<`	比较运算符	小于，如 `HOURPAY < 70`
`-HOURPAY`	降序排序简写	在 `arrange()` 中按大到小排序
`c(0,70)`	向量	组合两个值用于设定范围
`aes()`	aesthetic mappings	将数据列映射到横轴、颜色等视觉属性
`fill`	填充	图形内部颜色；不是轮廓线颜色 `colour`
`alpha`	透明度	0全透明，1不透明

`%>%` 与 `+` 的区别（本讲最重要语法）

```
lfs %>% filter(HOURPAY < 70) %>% ggplot(aes(HOURPAY)) + geom_histogram()
```

从左到右：**数据表** `lfs` → **筛选行** `filter()` → **建立绘图对象** `ggplot()` → **添加直方图层** `geom_histogram()`。`%>%` 主要连接数据处理步骤；`+` 主要连接 ggplot 的绘图图层。新手不能把这两类符号随意互换。

变量映射和常量样式的差别

```
geom_density(fill = "blue")      # 无论数据是什么，全部固定为蓝色
geom_density(aes(fill = SEX)) # 由 SEX 每条记录的取值决定填充
```

前者是**常量**，后者是**映射**；这一区别贯穿后半讲。

三、全部17段原文代码逐段讲解

01. 绘制第一张小时工资直方图

课堂原始代码：

```
lfs %>% ggplot(aes(HOURPAY)) + geom_histogram()
```

逐项解释： `lfs` 是数据框；`%>%` 是管道，表示把左边的数据交给右边的绘图函数。`ggplot(aes(HOURPAY))` 建立图形对象，`aes()` 告诉 ggplot 将 `HOURPAY` 映射到横轴。`+ geom_histogram()` 增加直方图这一图层。每根柱表示一段工资范围，柱高表示落入该范围的记录数。没有指定 `binwidth` 时，ggplot2 会默认使用30个箱，并出现提示；这不是运行错误。

看到信息 `stat_bin() using bins = 30. Pick better value binwidth.` 怎么办？ 这只是ggplot2提示它选择了30箱。可以按第3节明确箱宽，不代表程序失败。

02. 添加标题、横轴、纵轴和数据来源

课堂原始代码：

```
lfs %>% ggplot(aes(HOURPAY)) +
  geom_histogram() +
  labs( title = "Distribution of hourly wage",
        x = "Hourly wage (£)",
        y = "Count",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025")
```

逐项解释： `labs()` 专门添加或修改文字标签。`title` 是总标题，`x` 是横轴标题，`y` 是纵轴标题，`caption` 是图下方的来源说明。`=` 把函数参数和参数值对应起来；英文内容放在双引号里属于文本字符串。`geom_histogram()` 的绘图逻辑没有改变，只是图的注释更完整。

03. 手动设置直方图箱宽为10

课堂原始代码：

```
lfs %>% ggplot(aes(HOURPAY)) +
  geom_histogram(binwidth = 10) +
  labs( title = "Distribution of hourly wage",
        x = "Hourly wage (£)",
        y = "Count",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025")
```

逐项解释： `geom_histogram(binwidth = 10)` 将箱宽设为10个工资单位：每个柱覆盖约£10的区间。箱宽越大越平滑、细节越少；箱宽越小越容易暴露细节和随机波动。`binwidth` 是单个区间的宽度，不是柱子数量，也不是工资截断值。实际分箱起点由ggplot2算法决定，并不一定恰好是0、10、20。

04. 将图表主题改为深色

课堂原始代码：

```r
lfs %>% ggplot(aes(HOURPAY)) +
  geom_histogram() +
  labs( title = "Distribution of hourly wage",
        x = "Hourly wage (£)",
        y = "Count",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_dark()
```

逐项解释： `theme_dark()` 控制图的视觉主题，如背景、网格线和文字对比；它不会改变数据、分箱或统计结论。`+` 是向 ggplot 对象添加图层/配置，与管道 `%>%` 不同。主题还可以改为 `theme_minimal()`、`theme_classic()` 等。

05. 找出小时工资最高的10条记录

课堂原始代码：

```r
lfs %>% arrange(-HOURPAY) %>% select(HOURPAY) %>% head(n=10)
```

逐项解释： `arrange(-HOURPAY)` 按 `HOURPAY` 从大到小排序，前面的负号在此表示降序；`select(HOURPAY)` 只保留工资列；`head(n=10)` 只显示前10行。整个过程是数据筛选与查看，不是画图。原讲义的输出显示最大的十个数值从98.8递减到91.4；它们是数据集中的记录，不要直接解释为总体最高工资。`arrange(desc(HOURPAY))` 是更易读的替代写法。

讲义实际控制台输出：

```
# A tibble: 10 × 1
   HOURPAY
     <dbl>
 1    98.8
 2    96.2
 3    96.2
 4    96.1
 5    95.4
 6    94.0
 7    93.8
 8    93.6
 9    92.3
10    91.4
```

`A tibble: 10 × 1` 指10行1列；`<dbl>` 表示双精度数字类型；最左边的1至10是行号，并不是工资值。

06. 筛选小时工资低于70英镑的数据后画图

课堂原始代码：

```r
lfs %>% filter(HOURPAY<70) %>%
   ggplot(aes(HOURPAY)) +
  geom_histogram() +
  labs( title = "Distribution of hourly wage",
        subtitle = "Sample of people earning less than £70 per hour",
        x = "Hourly wage (£)",
        y = "Count",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal()
```

逐项解释： `filter(HOURPAY < 70)` 只保留工资小于70的记录（不包括等于70）；再交给 `ggplot()` 绘图，因此**统计样本本身变化了。** `subtitle` 是副标题；`theme_minimal()` 采用简洁主题。`<` 是"小于"的比较符号，写成 `<=` 则包含70。数据中 `NA` 也不会满足这个筛选条件。

07. 不删数据，仅把视图限制到0–70

课堂原始代码：

```r
lfs %>%
   ggplot(aes(HOURPAY)) +
  geom_histogram() +
  labs( title = "Distribution of hourly wage",
        subtitle = "Sample of people earning less than £70 per hour",
        x = "Hourly wage (£)",
        y = "Count",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  coord_cartesian(xlim = c(0,70))
```

逐项解释： `coord_cartesian(xlim = c(0,70))` 将横轴**可视范围**限制为0到70，但通常不会删除原始观测，和上一段 `filter()` 不同。`xlim` 意为x轴限制，`c(0,70)` 创建含两个端点的向量。这里原讲义副标题仍写"样本工资低于£70"，严格说不准确，因为只是缩放图形视图，并非筛选样本；推荐改成"View focused on £0–£70"。

08. 将横轴改为以10为底的对数刻度

课堂原始代码：

```r
lfs %>%
   ggplot(aes(HOURPAY)) +
  geom_histogram() +
  labs( title = "Distribution of hourly wage",
        subtitle = "Logarithmic scale",
        x = "Hourly wage (£)",
        y = "Count",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_x_log10()
```

逐项解释： `scale_x_log10()` 把横轴变成以10为底的对数刻度，适合非常右偏、跨度很大的正数分布。横轴上等距移动表示**倍数变化**，不再是固定英镑差额。零和负数无法取普通实数的log10，ggplot可能丢弃这些值并报警告；先检查工资非正数及特殊编码是否被处理。它与 `log10(HOURPAY)` 作为新数据列有关联，但不是完全一样的作图设置。

09. 把直方图改成核密度图

课堂原始代码：

```
lfs %>%
   ggplot(aes(HOURPAY)) +
  geom_density() +
  labs( title = "Distribution of hourly wage",
        subtitle = "Logarithmic scale",
        x = "Hourly wage (£)",
        y = "Density",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_x_log10()
```

逐项解释： `geom_density()` 绘制核密度估计（KDE）曲线，将直方图式的区间频数概括成平滑的分布形状。纵轴写 `Density` 而不是 `Count`，因为曲线高度不是人数。这里通过 `scale_x_log10()` 在对数变换后的x轴上计算/展示分布；对照绝对英镑坐标解释曲线时尤其谨慎。密度平滑程度受带宽控制，不能把每个局部波峰都当作真实人群结构。

10. 给密度图增加地毯图

课堂原始代码：

```
lfs %>%
   ggplot(aes(HOURPAY)) +
  geom_density() +
  labs( title = "Distribution of hourly wage",
        subtitle = "Logarithmic scale",
        x = "Hourly wage (£)",
        y = "Density",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_x_log10() +
  geom_rug()
```

逐项解释： `geom_rug()` 在坐标轴附近给每个有效观测添加短线（地毯图），帮助识别数据点的位置和稠密程度；在大样本里短线可能叠成黑带。它和 `geom_density()` 画在同一个ggplot对象中，属于两个图层。

11. 把密度曲线下面填成蓝色

课堂原始代码：

```
lfs %>%
   ggplot(aes(HOURPAY)) +
  geom_density(fill="blue") +
  labs( title = "Distribution of hourly wage",
        subtitle = "Logarithmic scale",
        x = "Hourly wage (£)",
        y = "Density",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_x_log10() +
  geom_rug()
```

逐项解释： `geom_density(fill="blue")` 将密度曲线下方区域固定填充成蓝色。`fill` 写在 `aes()` **外面**代表固定样式，所有观测使用相同颜色；如果写进 `aes(fill = 某变量)`，则按变量映射颜色。这里没有改变核密度计算。

12. 用SEX变量分组填充密度曲线

课堂原始代码：

```
lfs %>%
   ggplot(aes(HOURPAY)) +
  geom_density(aes(fill=SEX)) +
  labs( title = "Distribution of hourly wage by sex",
        subtitle = "Logarithmic scale",
        x = "Hourly wage (£)",
        y = "Density",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_x_log10() +
  geom_rug()
```

逐项解释： `geom_density(aes(fill=SEX))` 将填充映射到数据里的 `SEX` 列，意图按照类别区分多条分布曲线。**关键限制：**如果 `SEX` 是数值型（例如1、2），ggplot可能按连续数值处理，甚至不会自动建立你期待的离散组。稳妥写法是 `aes(fill = factor(SEX), group = factor(SEX))`，并根据官方数据字典将编码映射成人类可读标签。原始代码应先运行检查结果，不要默认它已正确按性别分组。

教学版对照（补充，并非原讲义代码）：

```
# 先把类别编码转换为离散分组
lfs %>%
  filter(!is.na(HOURPAY), HOURPAY > 0, !is.na(SEX)) %>%
  ggplot(aes(x = HOURPAY, fill = factor(SEX), group = factor(SEX))) +
  geom_density(alpha = 0.25) +
  scale_x_log10()
```

`factor(SEX)` 将数值编码当作**类别**，不是连续测量；但1、2分别是什么仍须用官方数据字典核对。这段只处理R的 `NA`，不自动识别调查问卷中的特殊负数编码。

13. 使用alpha透明度降低重叠遮挡

课堂原始代码：

```
lfs %>%
   ggplot(aes(HOURPAY)) +
  geom_density(aes(fill=SEX), alpha=0.2) +
  labs( title = "Distribution of hourly wage by sex",
        subtitle = "Logarithmic scale",
        x = "Hourly wage (£)",
        y = "Density",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_x_log10() +
  geom_rug()
```

逐项解释： `alpha=0.2` 是透明度设置：0为完全透明，1为完全不透明，0.2为比较透明。按不同类别填充的密度区域发生重叠时，更容易同时观察两组。它只改变显示效果，不影响统计数据，也不是显著性水平0.2。

14. 用labs修改图例标题

课堂原始代码：

```
lfs %>%
  ggplot(aes(HOURPAY)) +
  geom_density(aes(fill = SEX), alpha = 0.2) +
  labs( title = "Distribution of hourly wage by sex",
        subtitle = "Logarithmic scale",
        x = "Hourly wage (£)",
        y = "Density",
        fill = "Sex",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_x_log10() +
  geom_rug()
```

逐项解释： `labs(fill = "Sex")` 把填充颜色所对应的**图例标题**设置成 `Sex`。注意 `fill` 在 `labs()` 中控制文字标题，在 `aes(fill=SEX)` 中控制变量到颜色的映射，虽然拼写相同，但作用不同。

15. 将图例标题改为空字符串

课堂原始代码：

```r
lfs %>%
  ggplot(aes(HOURPAY)) +
  geom_density(aes(fill = SEX), alpha = 0.2) +
  labs( title = "Distribution of hourly wage by sex",
        subtitle = "Logarithmic scale",
        x = "Hourly wage (£)",
        y = "Density",
        fill = "",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_x_log10() +
  geom_rug()
```

逐项解释： `labs(fill = "")` 把图例标题设为空文本，所以看起来没有标题，但图例对象仍存在。这不是关闭图例。分类标签和颜色块通常仍可见。

16. 用theme正确移除图例标题

课堂原始代码：

```r
lfs %>%
  ggplot(aes(HOURPAY)) +
  geom_density(aes(fill = SEX), alpha = 0.2) +
  labs( title = "Distribution of hourly wage by sex",
        subtitle = "Logarithmic scale",
        x = "Hourly wage (£)",
        y = "Density",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_x_log10() +
  geom_rug() +
  theme(legend.title = element_blank())
```

逐项解释： `theme(legend.title = element_blank())` 使用主题系统真正移除图例标题元素；与上一段的空字符串不同，语义更明确。`legend.title` 是主题的属性名，`element_blank()` 表示不显示该图形元素；不会隐藏图例中各分类的颜色和标签。

17. 将分组密度图换成分组直方图

课堂原始代码：

```r
lfs %>%
  ggplot(aes(HOURPAY)) +
  geom_histogram(aes(fill=SEX)) +
  labs( title = "Distribution of hourly wage by sex",
        subtitle = "Logarithmic scale",
        x = "Hourly wage (£)",
        y = "Count",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_x_log10() +
  theme(legend.title = element_blank())
```

逐项解释： `geom_histogram(aes(fill=SEX))` 与上面的分组密度图不同：改回直方图，并尝试用 `SEX` 决定柱内颜色。默认位置调整可能将不同组的频数堆叠，所以柱高对应合计记录数，颜色块对应各组组成；不是两个组各自按同一高度标准化的百分比分布。若需对比工资**分布形状**，可能更适合 `position="identity"` 配合透明度，或使用分面/标准化密度。`SEX` 的数值型类别问题仍需先解决。

四、讲义输出怎么读

1. 提示信息不等于报错

讲义绘制直方图时出现的 `stat_bin() using bins = 30. Pick better value binwidth.` 是分箱提示：不指定箱宽时，ggplot2选择30箱作为默认值。

2. 最高工资列表

前述第5段代码返回10×1的tibble及对应工资值。它说明数据中工资列的较高取值，不说明这些人的身份，也不代表已经加权的总体分位数。

3. 比较三种不同的图

- 直方图：横轴是工资区间，纵轴 `Count` 是该区间观测数。
- 密度图：纵轴 `Density` 是经过平滑的密度估计，不是人数。
- 地毯图：坐标轴附近的短线表示各条观测的位置；样本大时会重叠。

4. 为什么绘图前必须看数据?

原讲义通过 `arrange(-HOURPAY)` 先查极值，再用 `filter()`、`coord_cartesian()` 或 `scale_x_log10()` 处理长尾。这个逻辑很重要：**先诊断分布，再选展示方式，不要为了图好看随意删极端值。**

五、常见错误与修复

报错或现象	可能原因	建议处理
`could not find function "ggplot"`	未加载ggplot2	`library(ggplot2)`
`could not find function "%>%"`	未加载dplyr/magrittr	`library(dplyr)`
`object 'lfs' not found`	尚未读取数据或对象名不一致	先运行 `lfs <- read_tsv(...)`
`object 'HOURPAY' not found`	列名不匹配	`names(lfs)` 检查拼写和大小写
`unexpected end of input`	少了括号/引号，或最后多了 `+`	检查代码尾部和括号配对
`log-10 transformation introduced infinite values`	工资含零或无效非正数	核查编码并筛选有效正数

报错或现象	可能原因	建议处理
`Removed ... rows containing non-finite...`	缺失值、非有限值或刻度不可表示	查清具体行的缺失原因，不要直接忽略
分组图只有一条曲线	SEX是数值型、未转分类或分组不明确	检查 `str(lfs$SEX)`，使用 `factor(SEX)`
标签都显示1、2而不是文字	编码还没解码	对照官方变量字典转换标签
图中柱宽和预期不同	未设置 `binwidth` 或箱起点不同	显式设 `binwidth`，必要时检查 `boundary`
缩放后柱高没变	使用 `coord_cartesian()` 只缩放视图	与 `filter()` 区别理解

三种“处理高工资”的方法不一样

```
# 方法A：删去高于或等于70的观测后计算直方图
lfs %>% filter(HOURPAY < 70) %>% ggplot(aes(HOURPAY)) + geom_histogram()

# 方法B：保留样本，仅缩放显示范围
lfs %>% ggplot(aes(HOURPAY)) + geom_histogram() + coord_cartesian(xlim = c(0,
70))

# 方法C：显示对数横轴，便于看清较大数值跨度
lfs %>% filter(HOURPAY > 0) %>% ggplot(aes(HOURPAY)) + geom_histogram() +
scale_x_log10()
```

请注意：A改变统计样本；B主要改变观看范围；C改变坐标尺度并可能排除无法取对数的非正值。不能把三张图当作同一种处理。

六、配套练习及答案

练习1： 不修改其他绘图参数，让直方图每个箱宽5英镑。

```
lfs %>% ggplot(aes(HOURPAY)) + geom_histogram(binwidth = 5)
```

练习2： 添加副标题和来源说明。

```
lfs %>% ggplot(aes(HOURPAY)) +
  geom_histogram() +
  labs(subtitle = "Hourly pay distribution", caption = "Source: LFS 2025 Q1")
```

练习3： 只查看工资大于零且小于50的记录。

```
lfs %>% filter(HOURPAY > 0, HOURPAY < 50) %>% ggplot(aes(HOURPAY)) +
geom_histogram()
```

练习4： 使用对数横轴并画带地毯线的密度图。

```r
lfs %>% filter(HOURPAY > 0) %>%
  ggplot(aes(HOURPAY)) +
  geom_density() + scale_x_log10() + geom_rug()
```

练习5（思考）： 为什么 `aes(fill = SEX)` 比 `fill = "blue"` 更复杂?

答：前者依赖数据列的类型、取值、分组规则、图例；后者只是固定视觉样式。对于数值型类别编码，通常需先转成 `factor`，并确保分类含义正确。

七、函数速查表

函数	英文直译/用途	本讲常见写法
`ggplot()`	创建ggplot图形	`ggplot(aes(HOURPAY))`
`aes()`	视觉映射	`aes(fill = SEX)`
`geom_histogram()`	直方图	`geom_histogram(binwidth = 10)`
`geom_density()`	核密度图	`geom_density(alpha = .2)`
`geom_rug()`	数据点地毯线	`geom_rug()`
`labs()`	图表标签	`labs(title = "...")`
`theme_dark()`	深色主题	`theme_dark()`
`theme_minimal()`	简洁主题	`theme_minimal()`
`theme()`	精细设置外观	`theme(legend.title = element_blank())`
`element_blank()`	隐藏图形元素	`element_blank()`
`arrange()`	排序	`arrange(-HOURPAY)`
`select()`	选择列	`select(HOURPAY)`
`head()`	查看前几行	`head(n = 10)`
`filter()`	筛选行	`filter(HOURPAY < 70)`
`coord_cartesian()`	控制视野	`coord_cartesian(xlim = c(0,70))`
`scale_x_log10()`	x轴对数尺度	`scale_x_log10()`
`factor()`	转类别数据	`factor(SEX)`

学习顺序建议：先单独运行第1段；再做第2、3、4段体会标签、分箱和主题；理解第5–8段关于极端值和对数坐标的不同；然后学第9–11段的密度与rug；最后完成第12–17段的类别映射、透明度、图例与直方图分组。

课程外的严谨性提醒： 原讲义的绘图以LFS样本探索为目标；如果用在正式研究论文中，应先处理特殊缺失编码、明确适用样本、核对 `SEX` 的分类含义，并判断是否必须采用调查权重。