第五讲笔记

定量数据分析

引言

- 上一讲我们开始学习数据可视化。
- 这次我们将继续讨论这一主题。
- 我们将学习如何处理更多数据类型和几何图形。
- 我们还会进一步思考数据可视化在数据分析中的作用。

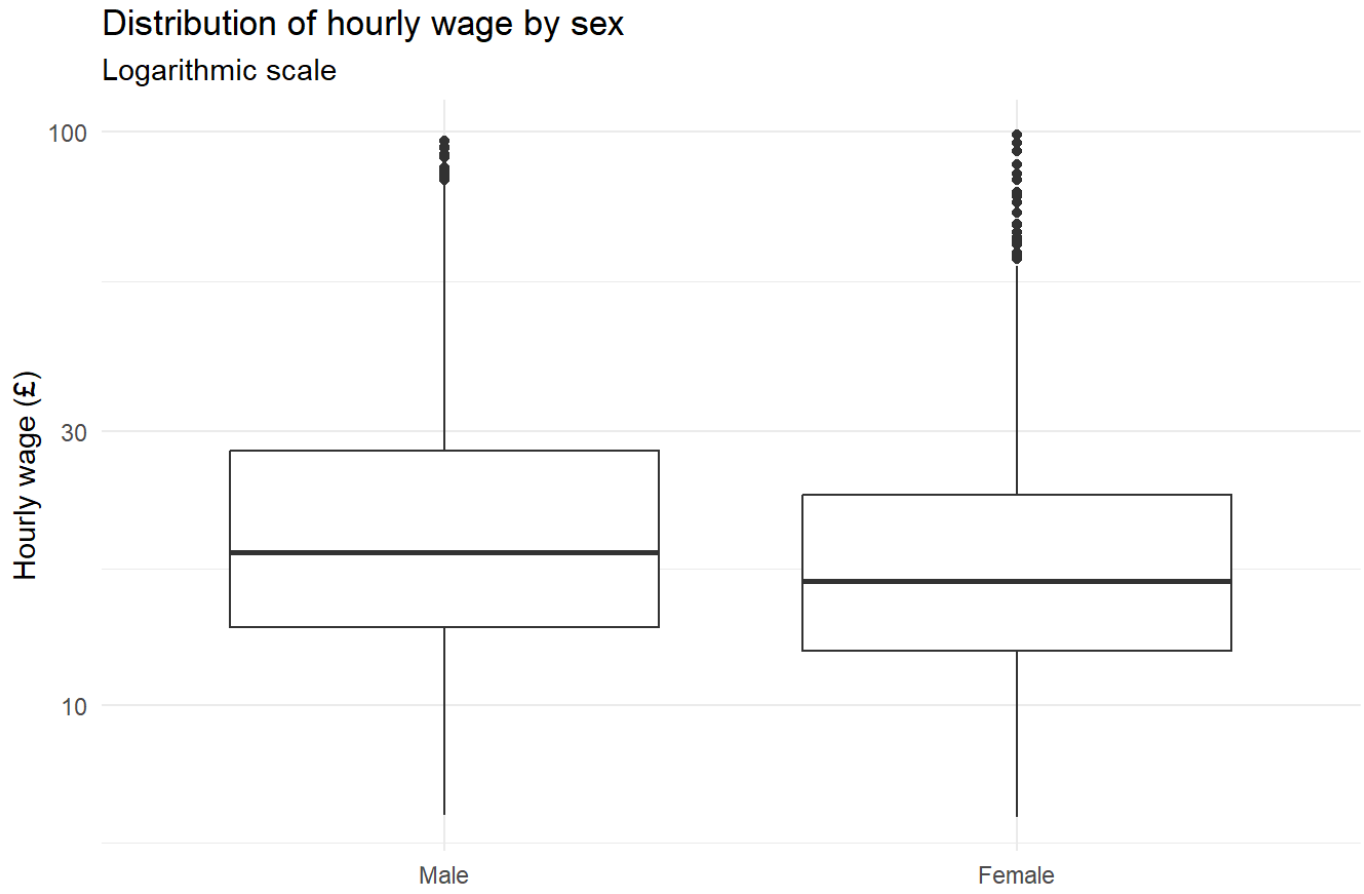
箱线图

- 密度图可以很好地展示连续变量在不同组别中的分布。
- 但如果类别过多，图形可能变得混乱。
- 另一种选择是箱线图。
- 它可以按组展示四分位数。
- 而且更容易比较各组的中位数。
- 需要在图中加入 geom_boxplot，在美学映射中将 SEX 设为 x 变量，并对 y 轴而不是 x 轴采用对数刻度。
- 可以先观察 SEX 变量，不过前面使用的密度图可能更适合展示它。

按性别划分的工资箱线图

```
lfs %>%
  ggplot(aes(SEX, HOURPAY)) +
  geom_boxplot() +
  theme_minimal() +
  scale_y_log10() +
  labs(title = "Distribution of hourly wage by sex",
     subtitle = "Logarithmic scale",
     x = "Sex",
     y = "Hourly wage (£)",
     caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme(legend.title = element_blank())
```

按性别划分的工资箱线图



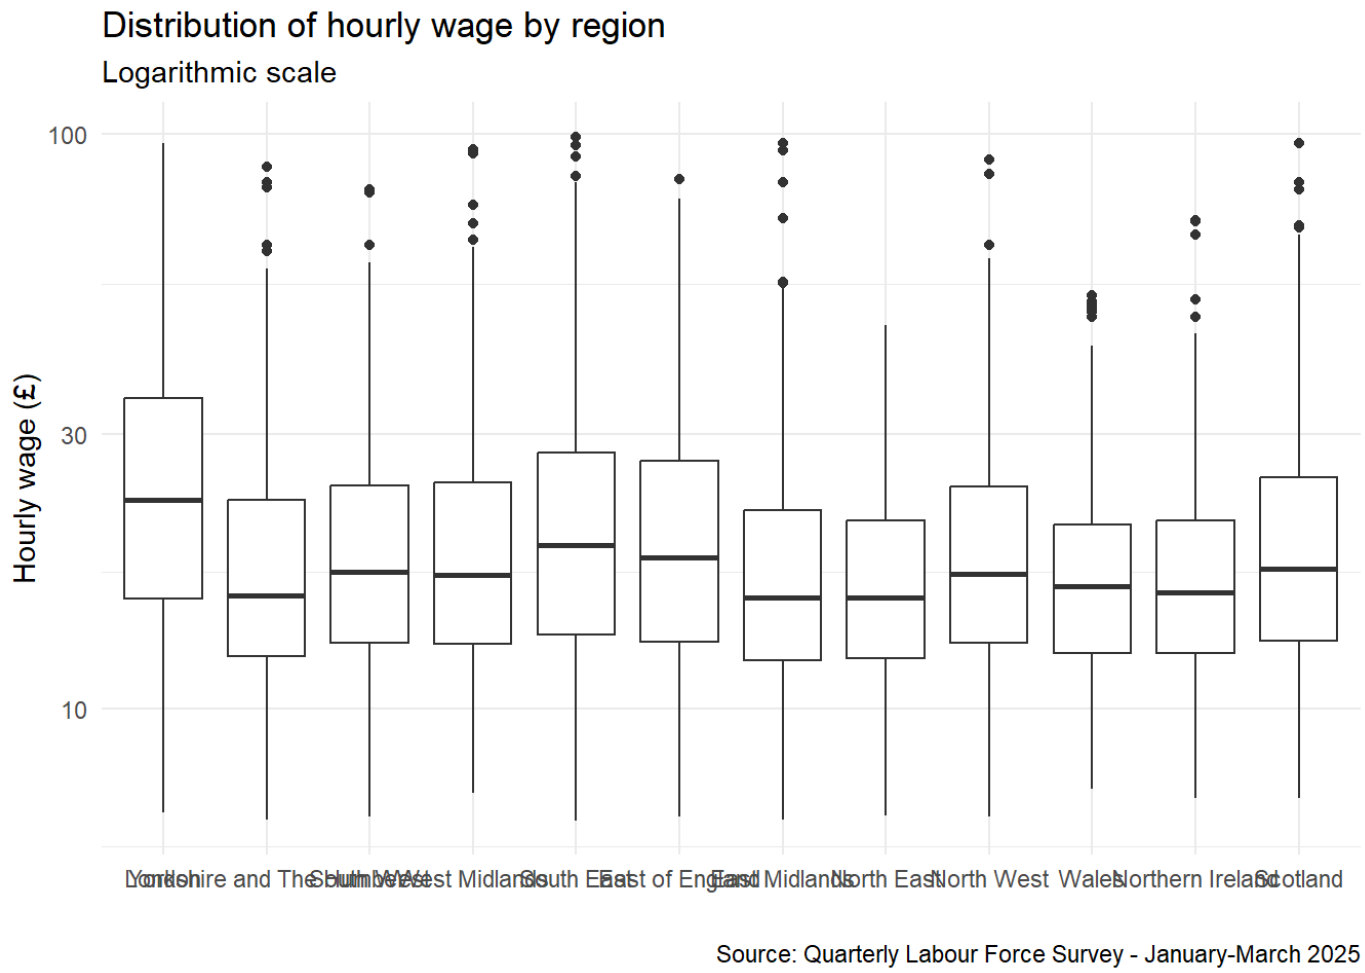
图表解读

- 箱体中间的横线表示中位数。
- 箱体底部表示第一四分位数。
- 箱体顶部表示第三四分位数。
- 这意味着 50% 的观测值位于箱体之内。
- 须线表示除异常值之外的最小值和最大值。
- 异常值用圆点表示。

各地区工资

```
lfs %>%
  ggplot(aes(GOR9D,HOURPAY)) +
  geom_boxplot() +
  labs( title = "Distribution of hourly wage by region",
        subtitle = "Logarithmic scale",
        x = "",
        y = "Hourly wage (£)",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025")
+
  theme_minimal() +
  scale_y_log10() +
  theme(legend.title = element_blank())
```

各地区工资



可以改进之处

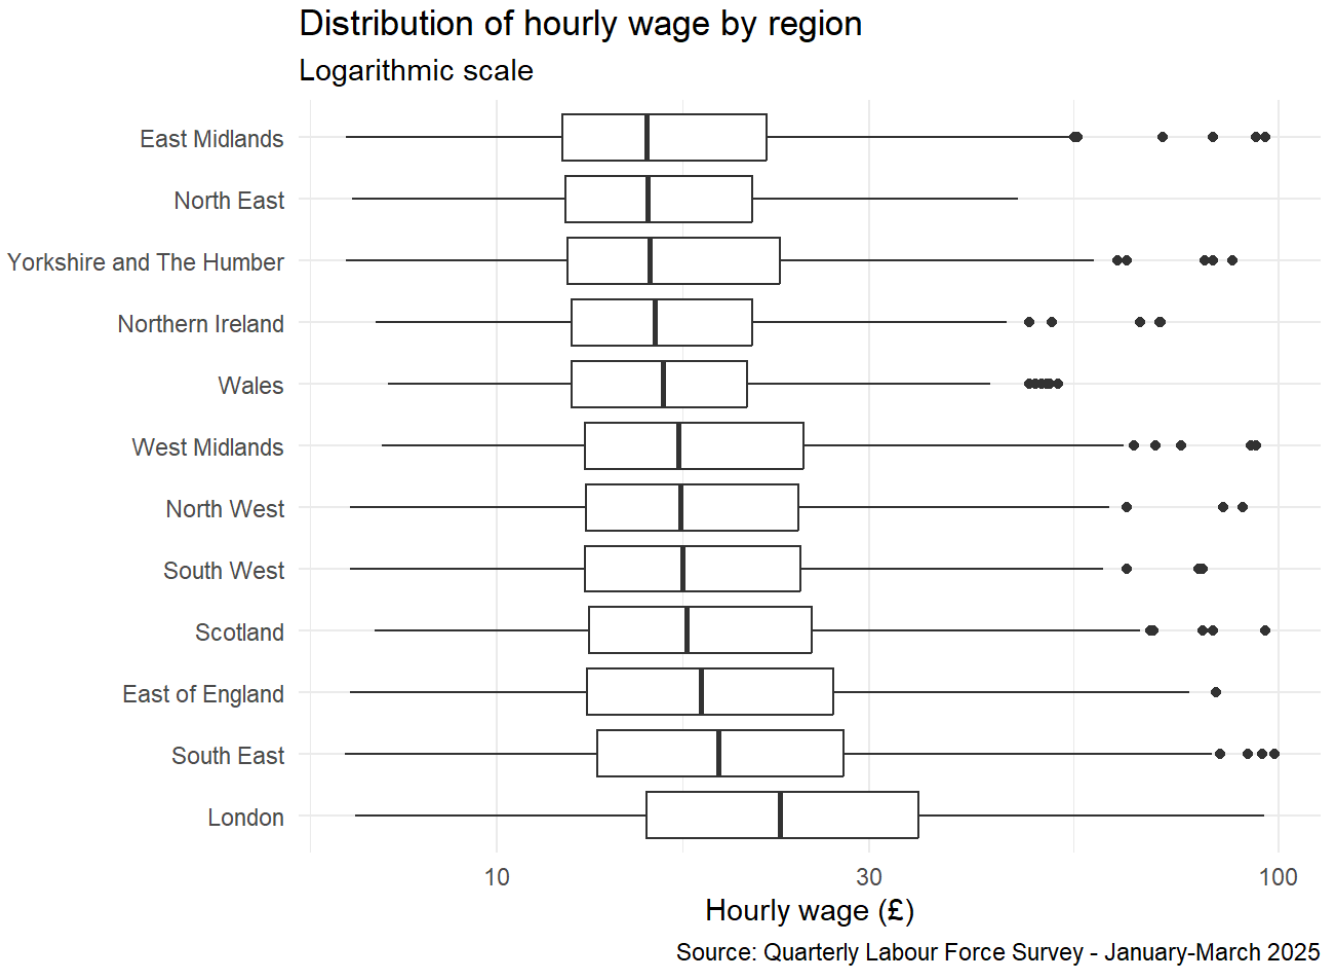
- 横轴标签相互重叠，难以阅读。
- 一些类别之间的高低差异也不容易比较。
- 针对标签问题，我们有几种选择。
- 可以旋转标签，或翻转图形的坐标系统。

- 还可以将地区按降序排列。
- 可以使用 fct_reorder 函数重新排列因子类别。

改进图表

```
lfs %>%
  mutate(GOR9D = fct_reorder(GOR9D,HOURPAY,median,.desc=TRUE)) %>%
  ggplot(aes(GOR9D,HOURPAY)) +
  geom_boxplot() +
  labs( title = "Distribution of hourly wage by region",
        subtitle = "Logarithmic scale",
        x = "",
        y = "Hourly wage (£)",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025")
+
  theme_minimal() +
  scale_y_log10() +
  theme(legend.title = element_blank()) +
  coord_flip()
```

改进图表



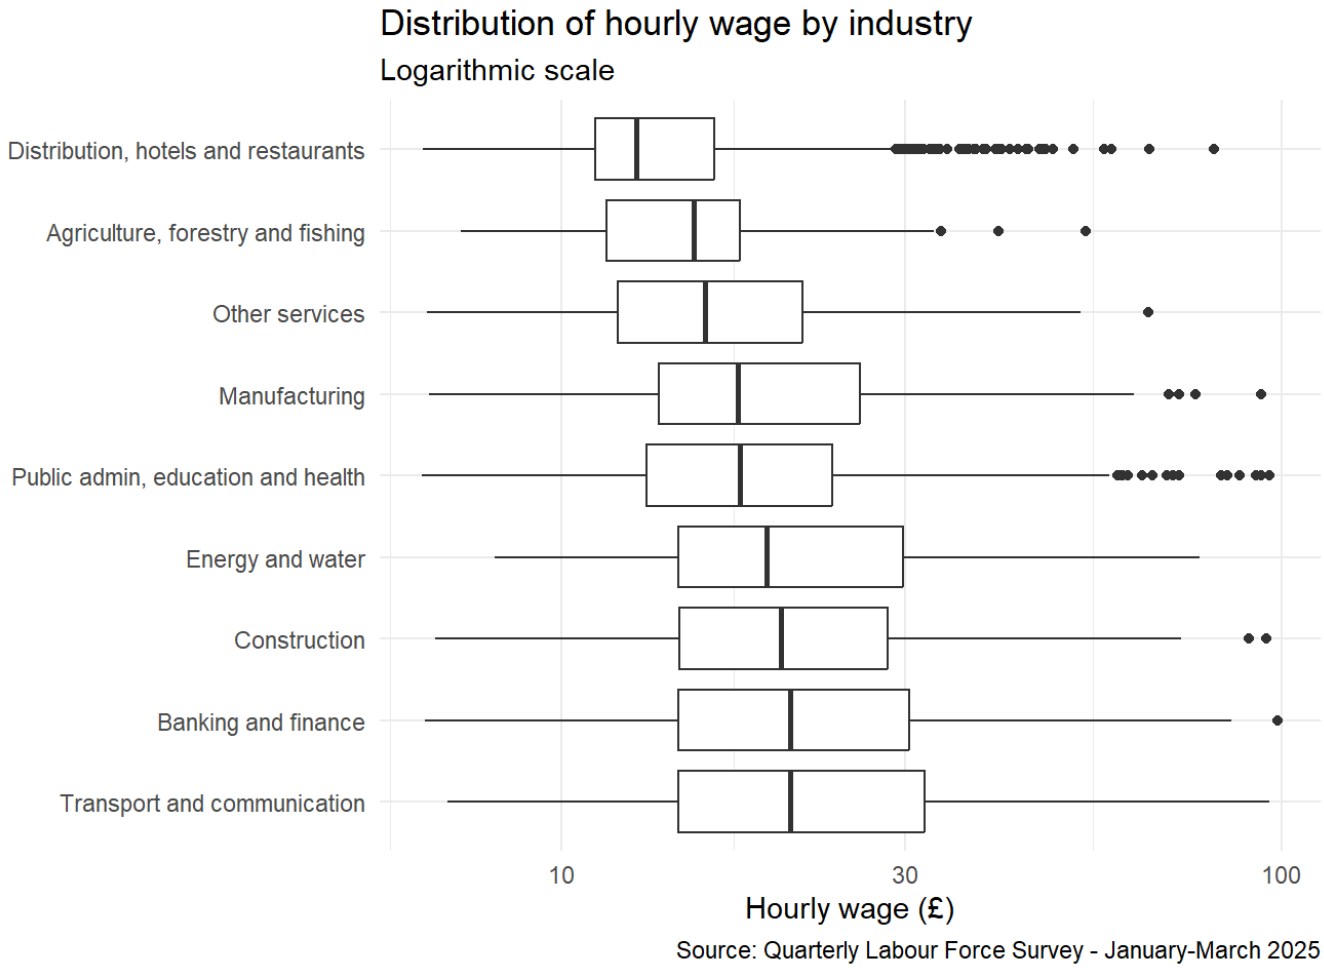
改进后的图表

- 最重要的是，现在标签能够看清了。
- 也更容易观察哪些地区的工资最高、哪些最低。
- 我们再尝试另一个变量。
- 这次考察不同行业的工资。

各行业工资

```
lfs %>%
  mutate(INDE07M = fct_reorder(INDE07M,HOURPAY,median,.desc=TRUE)) %>%
  ggplot(aes(INDE07M,HOURPAY)) +
  geom_boxplot() +
  labs( title = "Distribution of hourly wage by industry",
        subtitle = "Logarithmic scale",
        x = "",
        y = "Hourly wage (£)",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025")
+
  theme_minimal() +
  scale_y_log10() +
  theme(legend.title = element_blank()) +
  coord_flip()
```

各行业工资



添加第三个变量

- 目前我们在这里使用了两个变量：
  - 行业映射到 x 轴。
  - 工资映射到 y 轴。
- 可以将第三个变量映射到可用的视觉属性，从而添加第三个维度。
- 我们将 SEX 变量映射到箱体的填充颜色。

按行业和性别划分的工资

```
lfs %>%
  mutate(INDE07M = fct_reorder(INDE07M,HOURPAY,median,.desc=TRUE)) %>%
  ggplot(aes(INDE07M,HOURPAY)) +
  geom_boxplot(aes(fill=SEX)) +
  labs( title = "Distribution of hourly wage by industry",
        subtitle = "Logarithmic scale",
        x = "",
        y = "Hourly wage (£)",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025")
+
  theme_minimal() +
  scale_y_log10() +
  theme(legend.title = element_blank()) +
  coord_flip()
```

按行业和性别划分的工资



图表解读

- 从图中可以看出，不同行业的工资差异相当明显。
- 还可以看到男性和女性之间的工资差距。
- 看起来几乎所有行业中，男性工资都高于女性。

- 在某些行业，这种差距很小。
- 但在金融业等行业，差距较大。

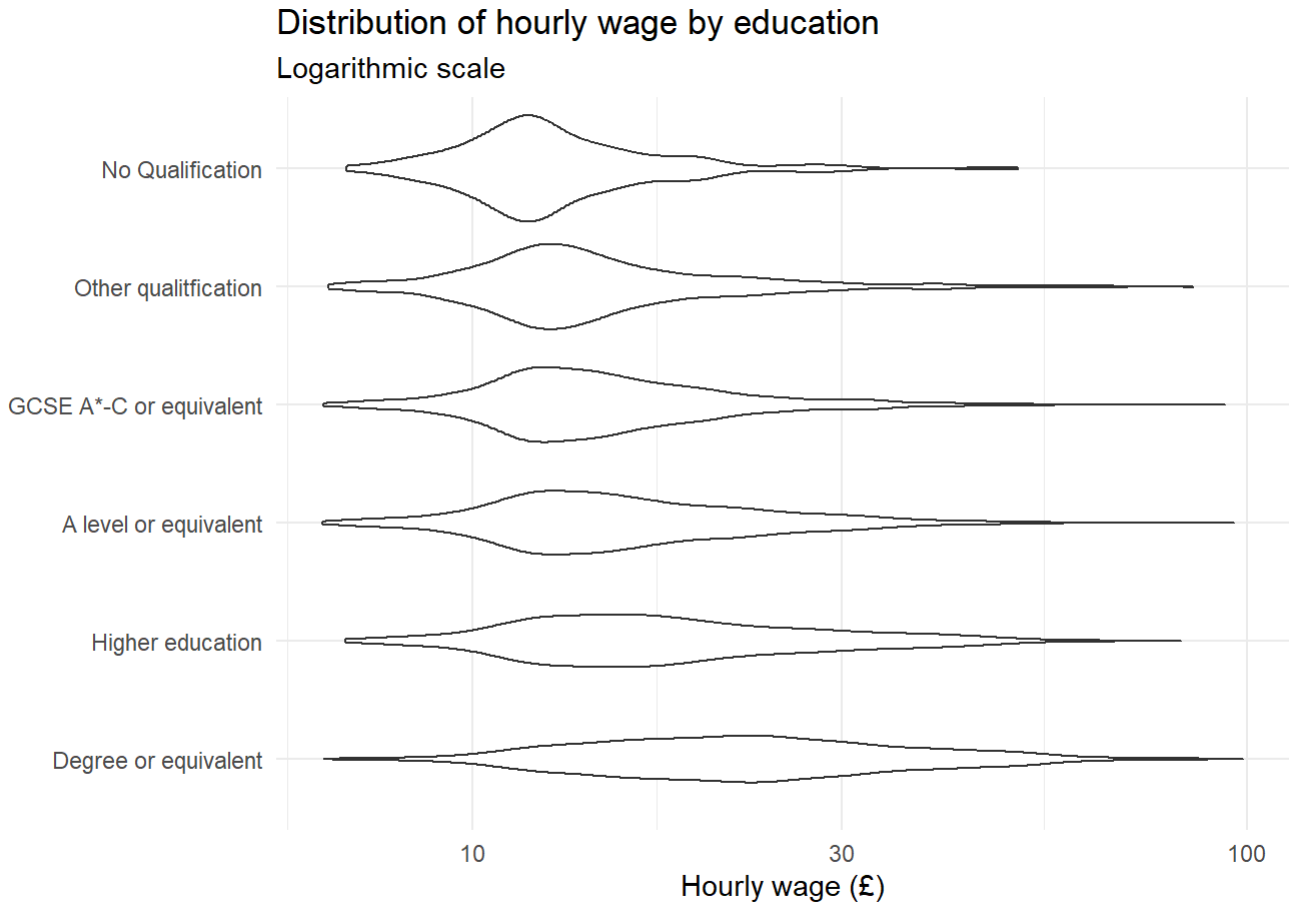
其他可视化方式

- 目前我们一直在使用箱线图这种几何图形。
- 还有其他几种选择可以展示更多细节。
- 我们希望在清楚呈现总体规律与保留细节、复杂性之间取得平衡。
- 过多的细节可能掩盖规律，让图形难以阅读。
- 箱线图的一个直接替代方案是小提琴图。
- 它与前面学到的密度曲线密切相关。
- 我们以教育程度和工资为例。

工资与教育水平

```
lfs %>%
  ggplot(aes(HIQUL22D,HOURPAY)) +
  geom_violin() +
  labs( title = "Distribution of hourly wage by education",
        subtitle = "Logarithmic scale",
        x = "",
        y = "Hourly wage (£)",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025")
+
  theme_minimal() +
  scale_y_log10() +
  theme(legend.title = element_blank()) +
  coord_flip()
```

工资与教育水平



Source: Quarterly Labour Force Survey - January-March 2025

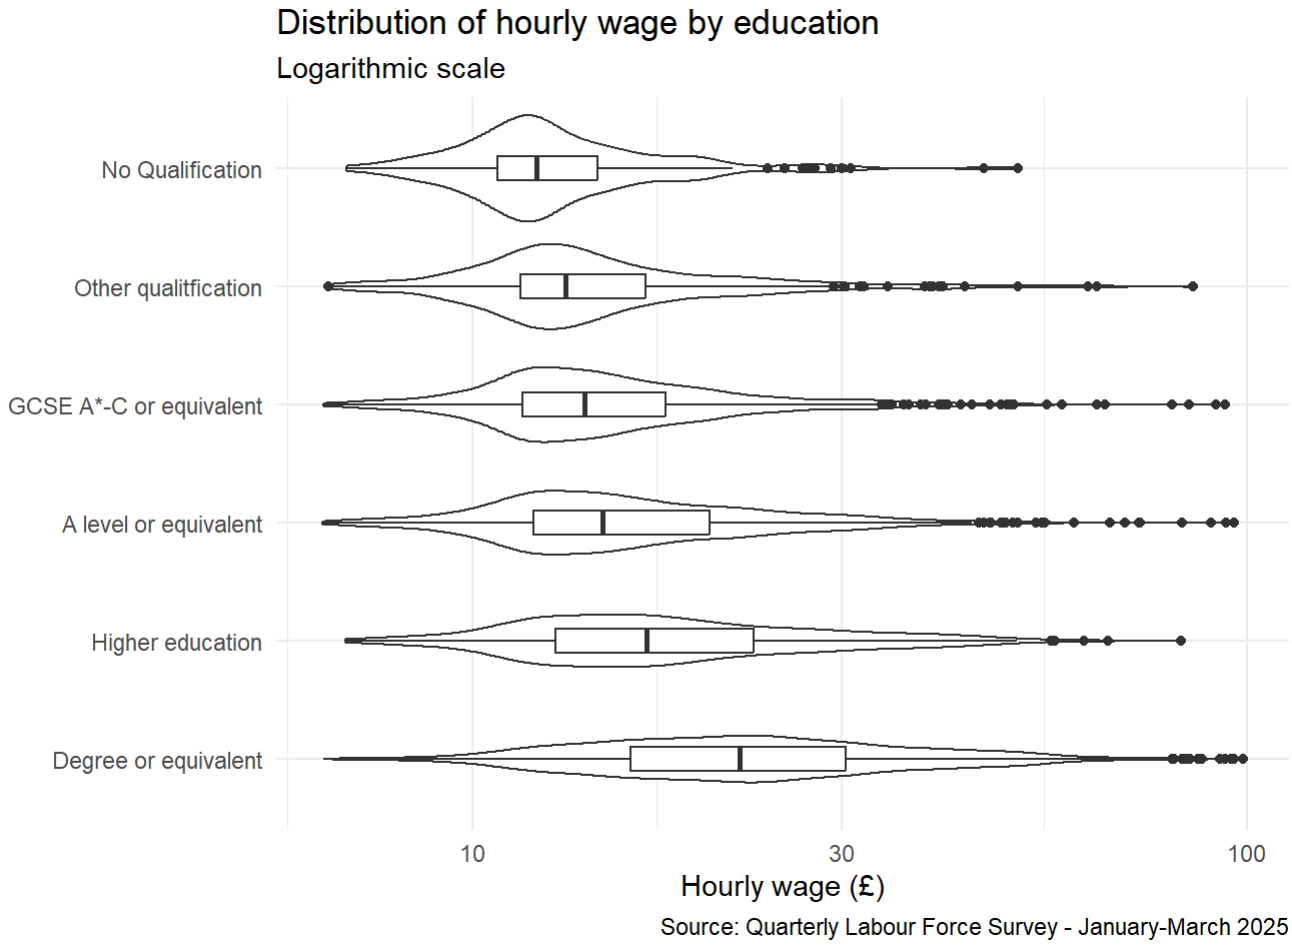
图表解读

- 观测值密度越高的地方，图形就越宽。
- 与箱线图相比，这提供了额外的分布信息。
- 但也使中位数等其他特征更难观察。
- 我们甚至可以将箱线图和小提琴图组合起来！
- 这样可以兼得两种图形的优点。
- 需要使用 width 参数将箱体设置得更窄一些。

工资与教育水平

```
lfs %>%
  ggplot(aes(HIQUL22D,HOURPAY)) +
  geom_violin() +
  geom_boxplot(width=0.2) +
  labs( title = "Distribution of hourly wage by education",
        subtitle = "Logarithmic scale",
        x = "",
        y = "Hourly wage (£)",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025")
+
  theme_minimal() +
  scale_y_log10() +
  theme(legend.title = element_blank()) +
  coord_flip()
```

工资与教育水平



最后一种替代方案

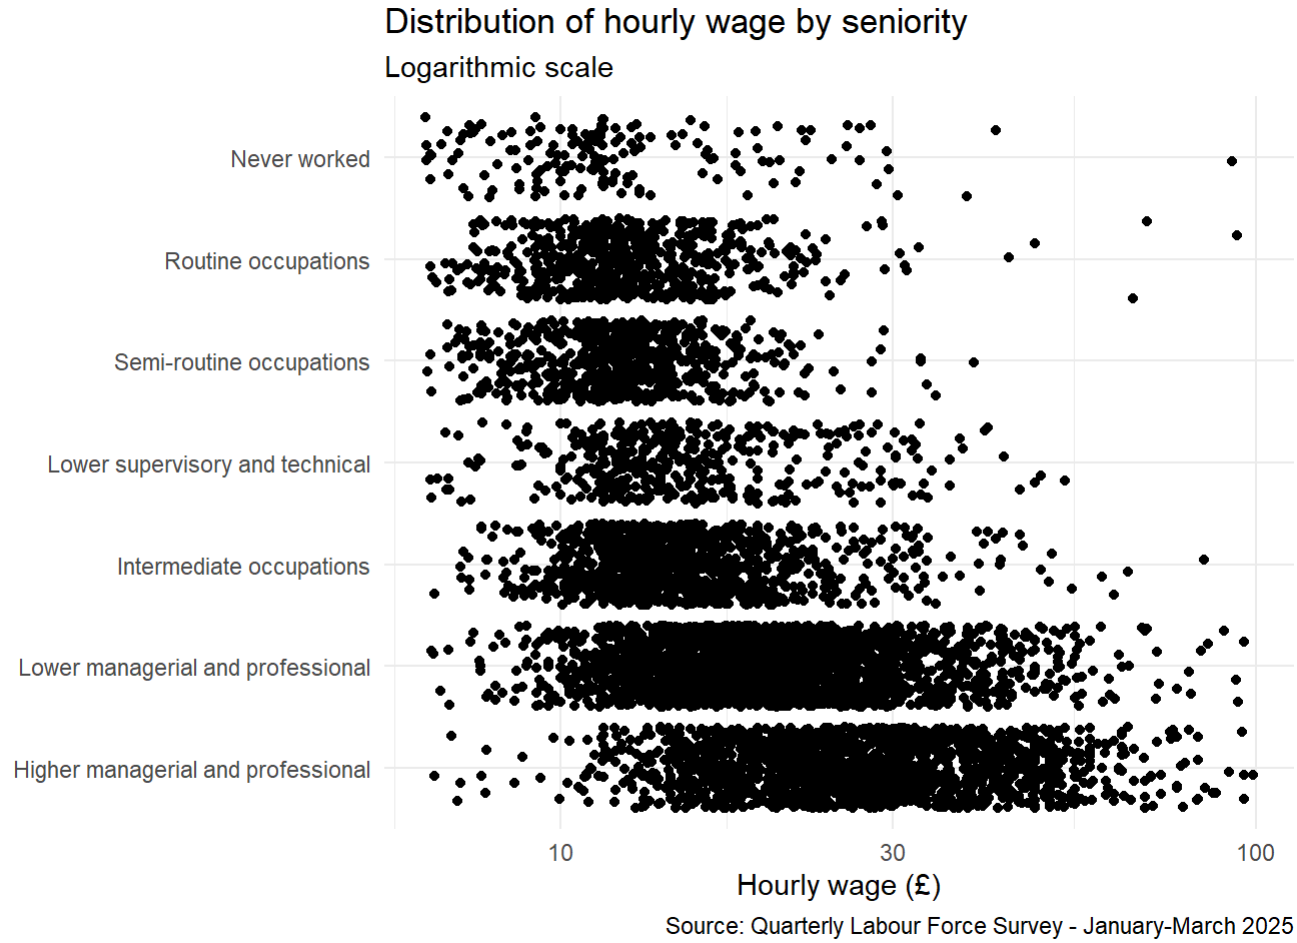
- 现在我们已经看过箱线图和小提琴图的实际应用。
- 也可以用点来展示观测值。
- 不过我们不会直接使用 geom_point，因为 x 轴只有有限个取值，许多点会相互重叠。

- 我们将使用 geom_jitter，使点在 x 轴方向稍微错开。
- 下面以工作职位级别指标为例。

工资与职位级别的抖动散点图

```
lfs %>%
  ggplot(aes(NSECMJ20,HOURPAY)) +
  geom_jitter() +
  labs( title = "Distribution of hourly wage by seniority",
        subtitle = "Logarithmic scale",
        x = "",
        y = "Hourly wage (£)",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025")
+
  theme_minimal() +
  scale_y_log10() +
  theme(legend.title = element_blank()) +
  coord_flip()
```

工资与职位级别的抖动散点图



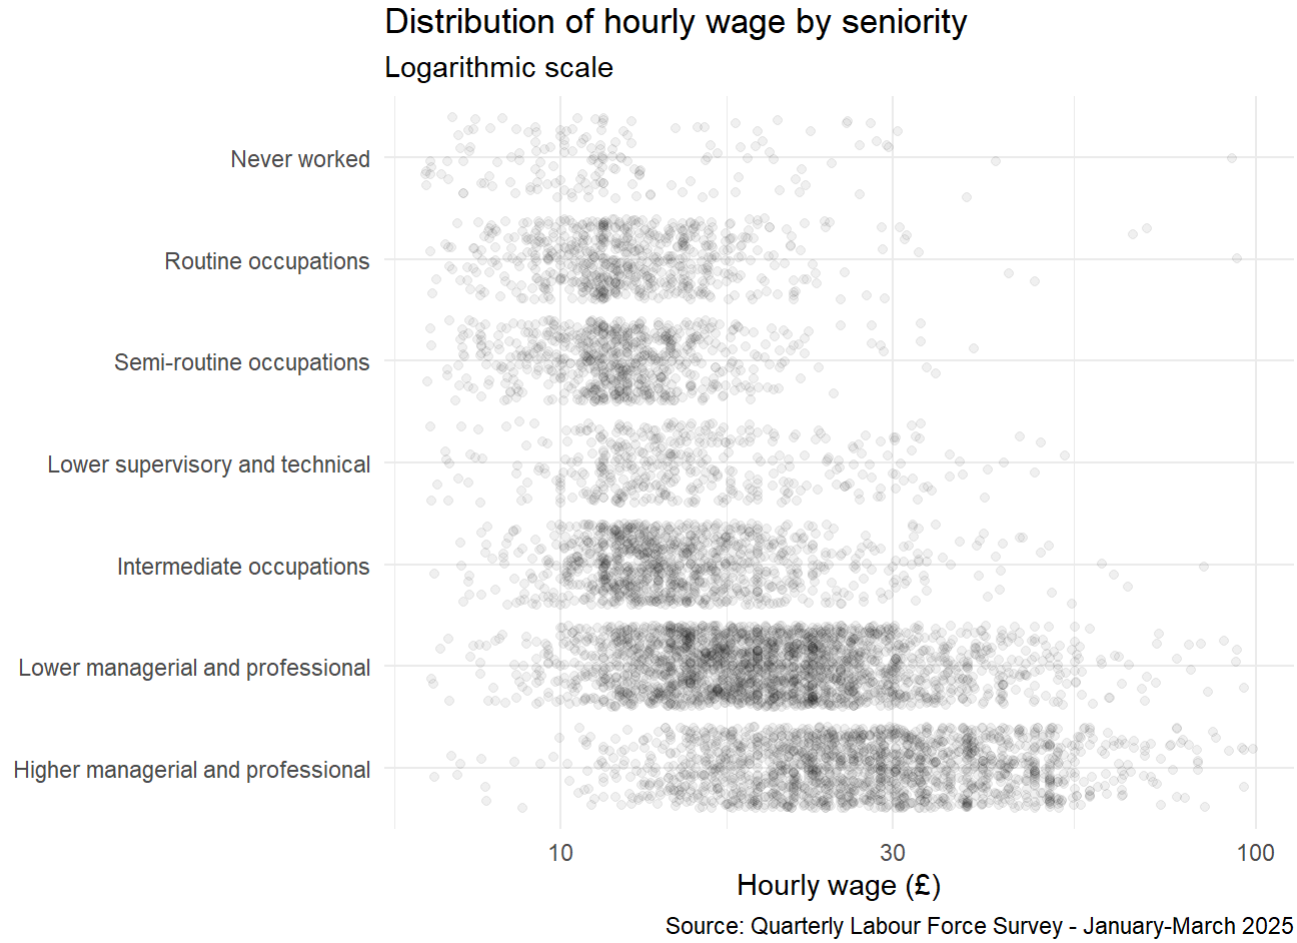
图表解读

- 可以看到，职位级别较高的工作似乎与较高工资有关。
- 图中存在一定程度的过度绘制，即分布中间有许多点相互重叠。
- 可以使用 alpha 参数降低点的不透明度来改善。

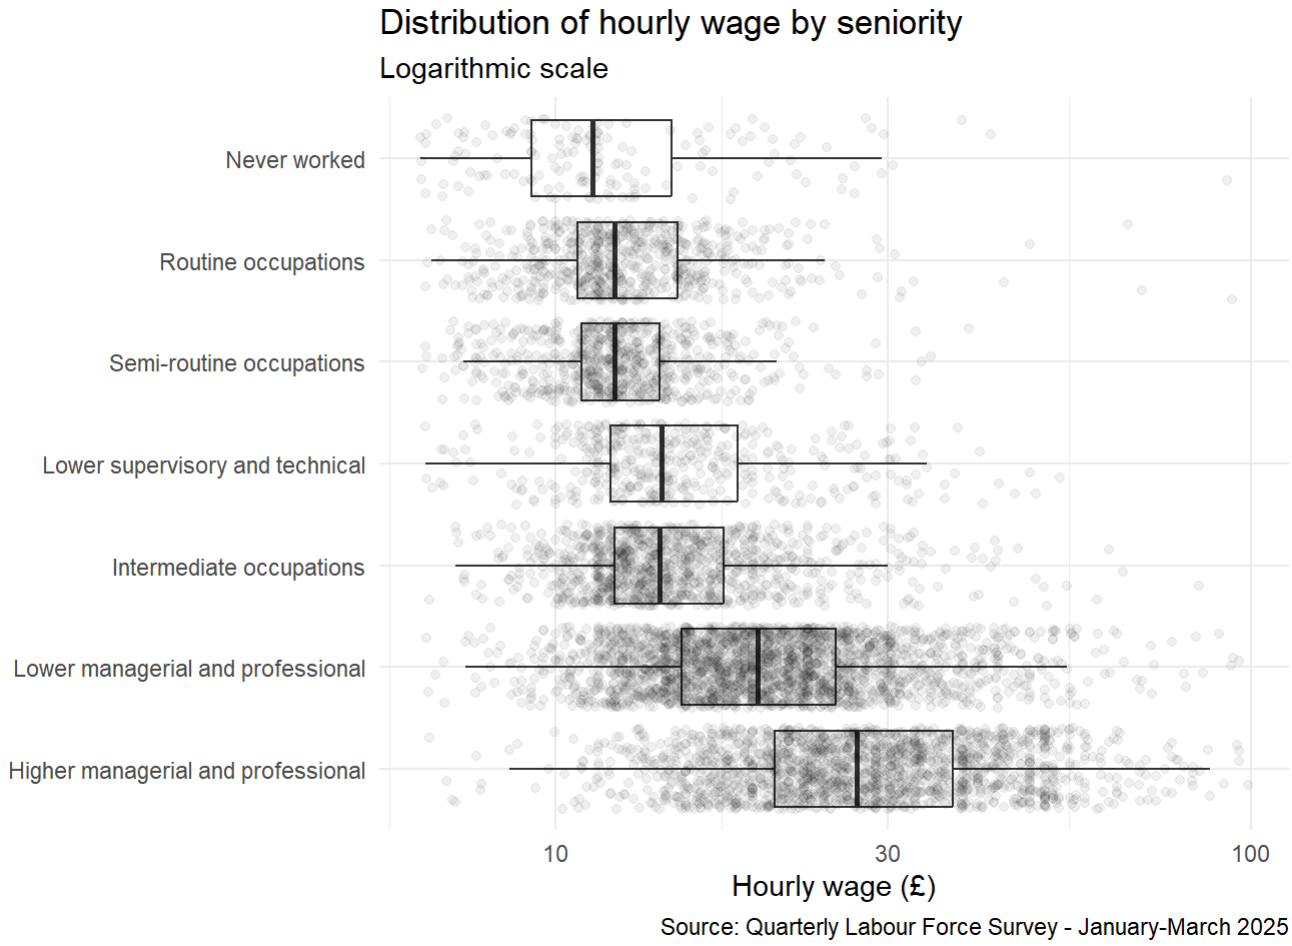
工资与职位级别的抖动散点图

```
lfs %>%
  filter(NSECMJ20!="Small employers and own account workers") %>%
  ggplot(aes(NSECMJ20,HOURPAY)) +
  geom_jitter(alpha=0.05) +
  labs( title = "Distribution of hourly wage by seniority",
        subtitle = "Logarithmic scale",
        x = "",
        y = "Hourly wage (£)",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025")
+
  theme_minimal() +
  scale_y_log10() +
  theme(legend.title = element_blank()) +
  coord_flip()
```

工资与职位级别的抖动散点图



工资与职位级别的抖动散点图



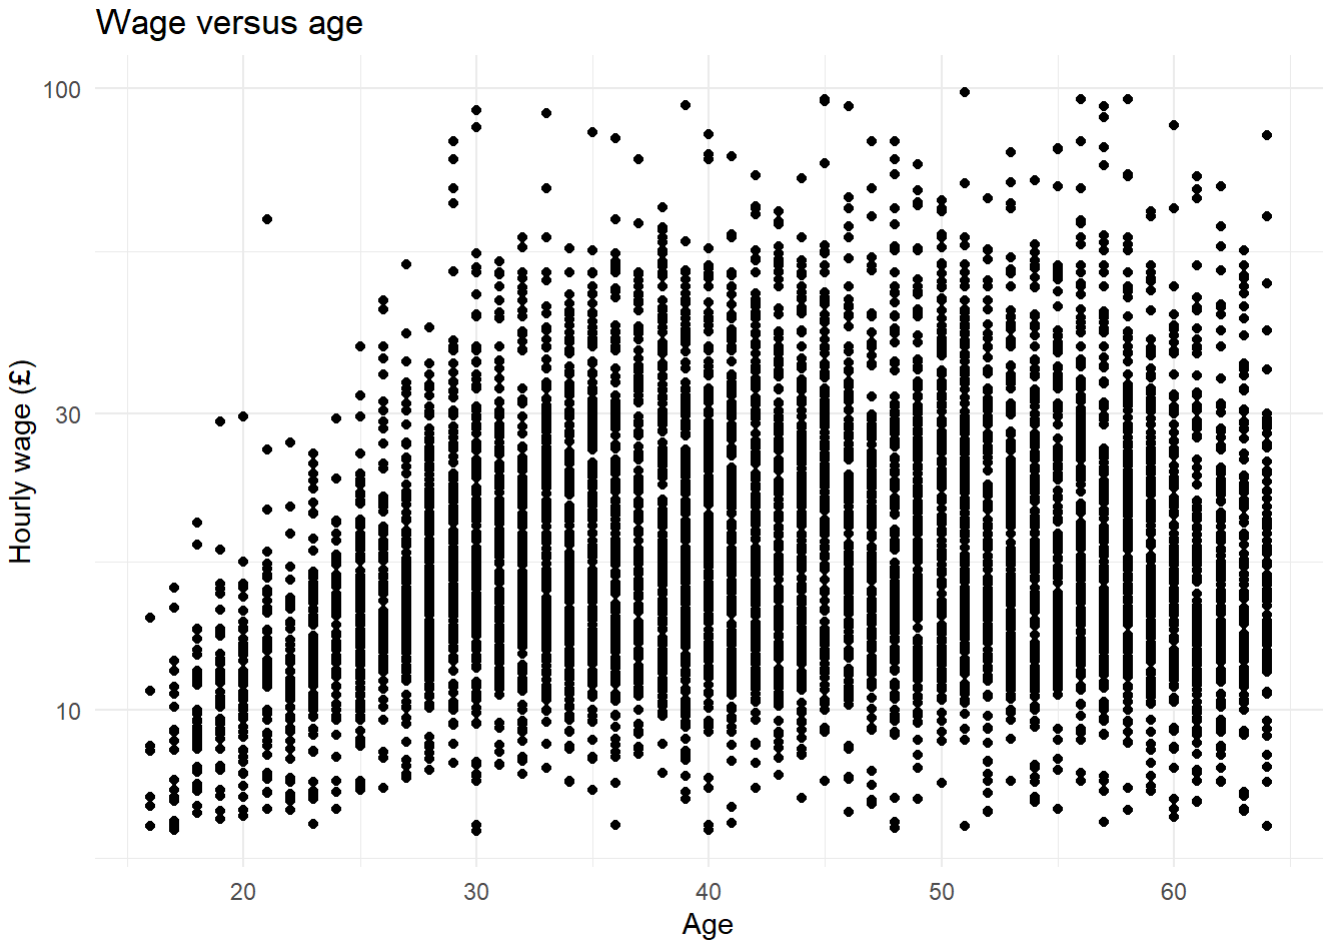
绘制两个比率尺度变量

- 前面的例子主要关注比率尺度变量如何在不同类别之间变化。
- 我们可能还想考察两个比率尺度变量之间的关系。
- 下面考虑工资与年龄。
- 工资仍然使用对数刻度。
- 首先使用点几何图形。

小时工资与年龄

```
lfs %>%
  ggplot(aes(AGE,HOURPAY)) +
  geom_point() +
  theme_minimal() +
  scale_y_log10()
```

小时工资与年龄



存在的问题

- 从图中可以看到一定的关系。
- 图形看起来有些奇怪，因为年龄按整岁记录，也就是说，它呈现离散的取值。
- 这使图上形成明显的竖列。
- 另外还有大量点相互重叠。
- 可以通过对点进行抖动来消除明显的竖列。
- 这会添加少量随机扰动，以缓解部分重叠。
- 这会在一定程度上改变数据点的显示位置，因此使用时应向读者明确说明。

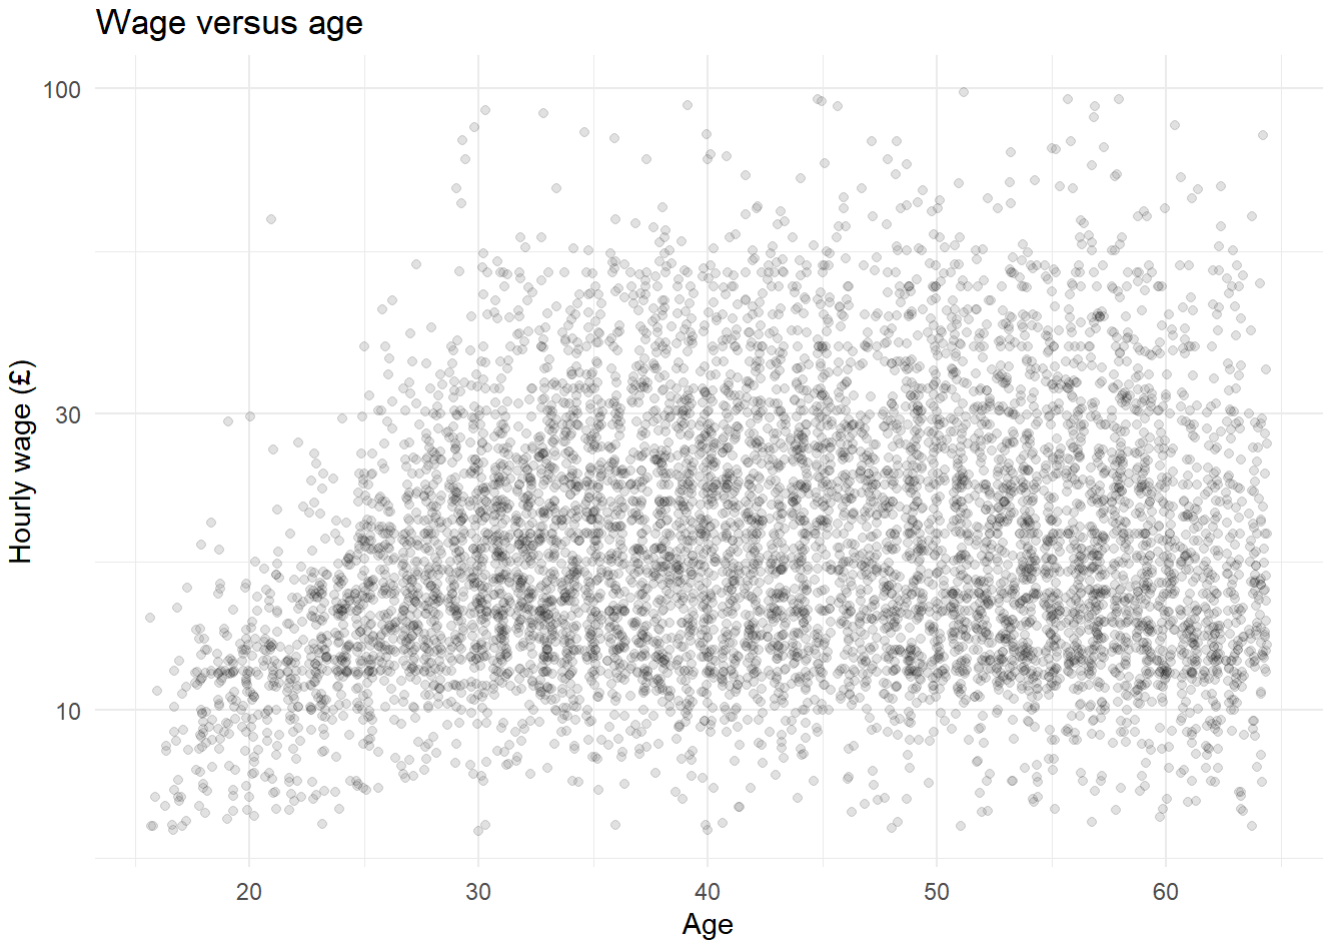
存在的问题

- 可以将 geom_point 的 position 参数设为 jitter，实现点的抖动。
- 也可以直接用 geom_jitter 代替 geom_point。
- 还可以通过 alpha 参数调整点的透明度，让图形更易阅读。
- 也可以考虑通过 size 参数调整点的大小。

小时工资与年龄

```
lfs %>%
  ggplot(aes(AGE,HOURPAY)) +
  geom_jitter(alpha=0.2) +
  theme_minimal() +
  scale_y_log10() +
  labs(title = "Wage versus age",
       x = "Age",
       y = "Hourly wage (£)")
```

小时工资与年龄



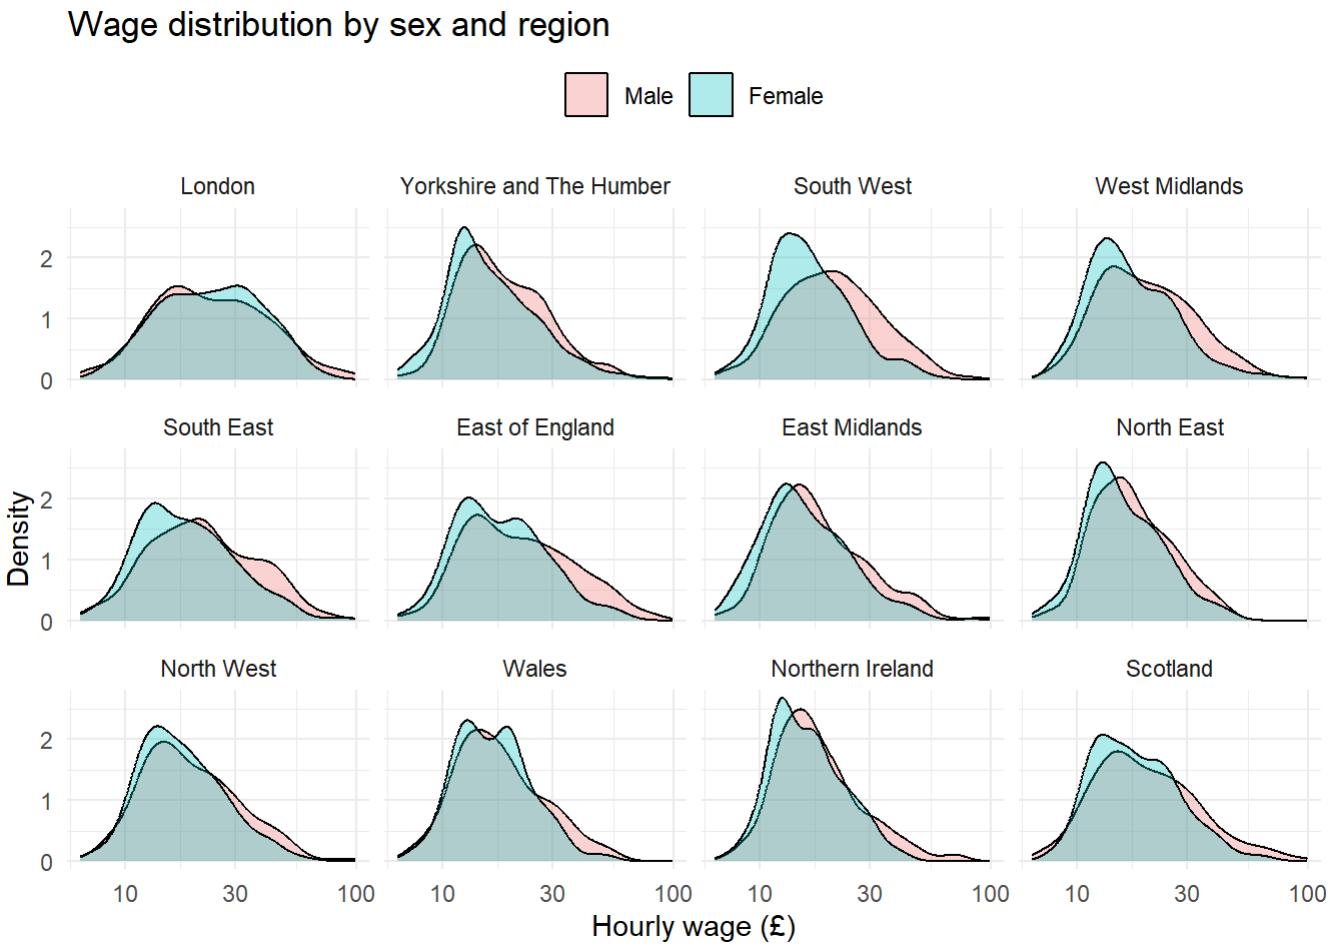
工资差距的地区差异

- 下面比较不同地区的工资差距。
- 同样需要组合三个变量。
- 有许多方式可以做到这一点，但有些方法比其他方法更清晰。
- 这里使用 ggplot 的分面功能。
- 它允许我们按照子组将图形拆分为多个面板。
- 最多可以使用两个因子变量进行这种拆分。

按性别和地区划分的工资分布

```
lfs %>%
  ggplot(aes(HOURPAY, fill=SEX)) +
  geom_density(alpha=0.3) +
  theme_minimal() +
  scale_x_log10() +
  facet_wrap(~GOR9D) +
  theme(legend.position = "top",
        legend.title = element_blank())  +
  labs(title = "Wage distribution by sex and region",
       x = "Hourly wage (£)",
       y = "Density")
```

按性别和地区划分的工资分布



展示四个变量

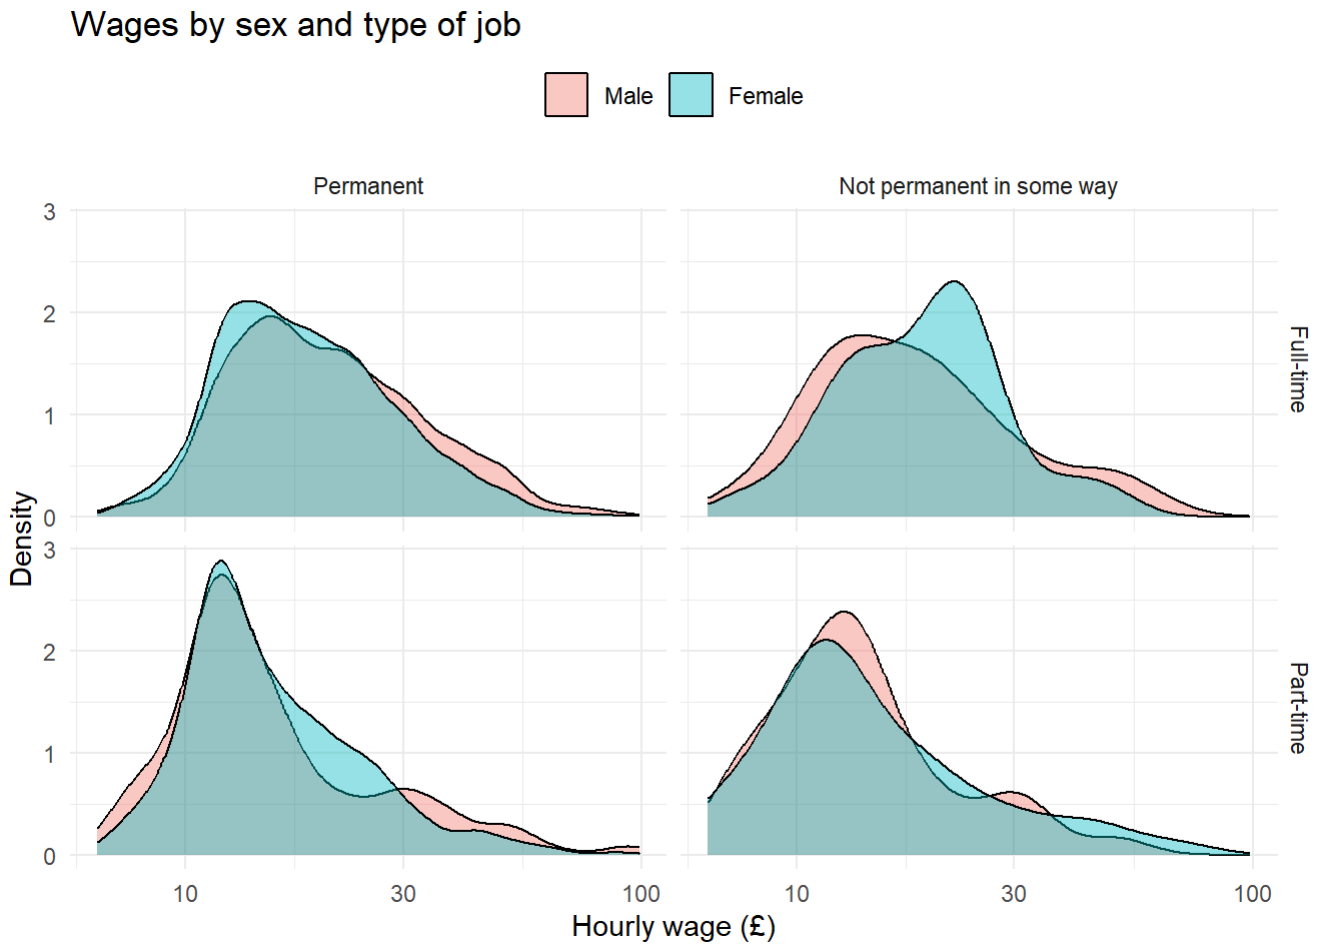
- 我们也可以使用分面来展示四个变量。
- 假设我们想按照工作状态查看工资差距。
- 可以考虑职位是全职还是兼职。

- 还可以考察工作是否为永久性职位。

按性别和工作类型划分的工资

```
lfs %>%
  ggplot(aes(HOURPAY, fill=SEX)) +
  geom_density(alpha=0.4) +
  theme_minimal() +
  scale_x_log10() +
  facet_grid(FTPT~JOBTYP) +
  theme(legend.position = "top",
        legend.title = element_blank()) +
  labs(title = "Wages by sex and type of job",
       x = "Hourly wage (£)",
       y= "Density")
```

按性别和工作类型划分的工资



教育与行业的平均收入

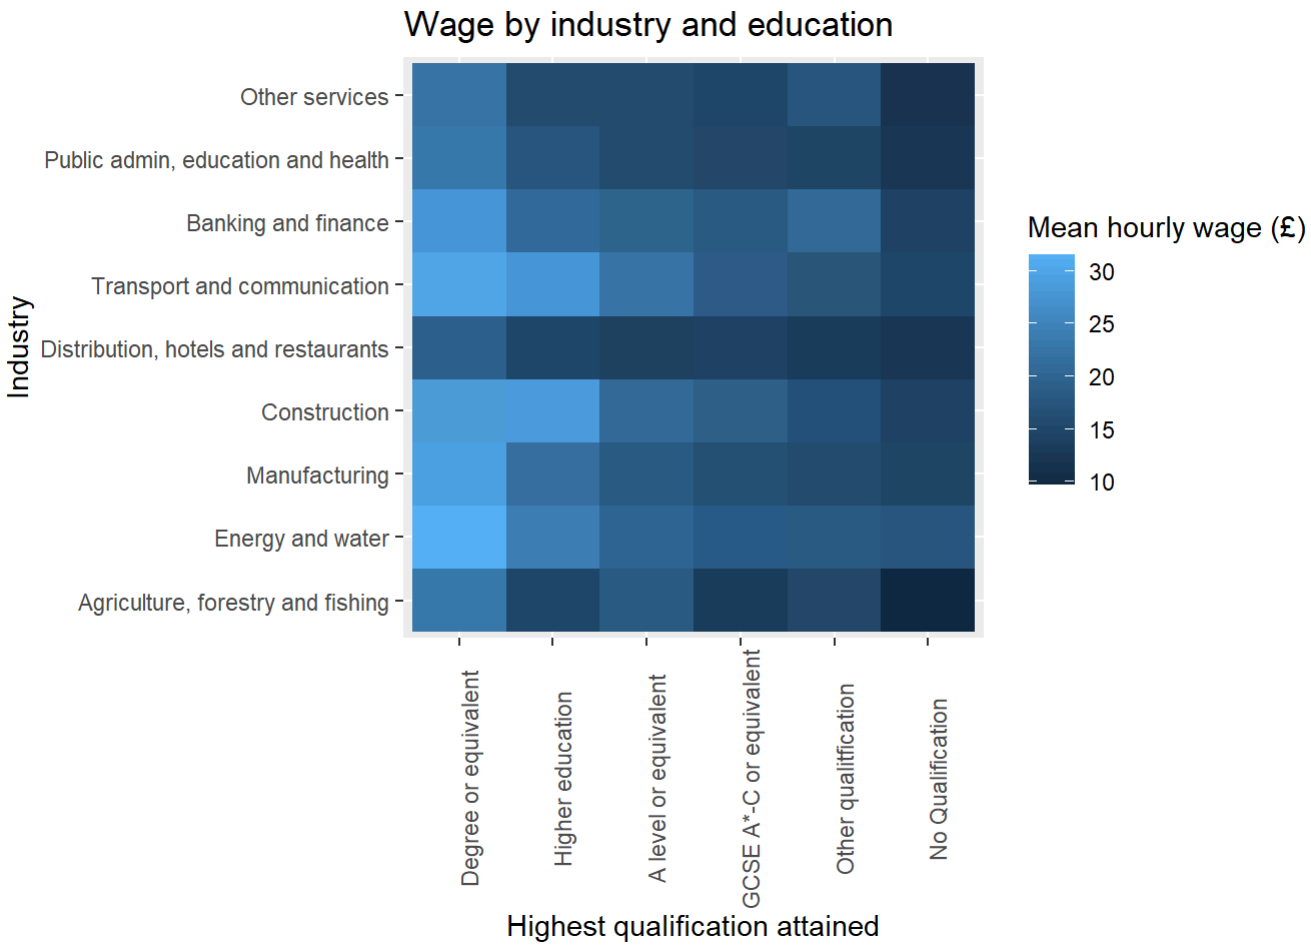
- 另一种很有用的几何图形是方格图（tile）。
- 它能够按组可视化汇总统计量。

- 假设我们想考察不同行业、不同教育水平的平均工资。
- 首先需要处理数据，计算各组的平均收入。
- 可以使用 group_by 完成分组计算，然后使用方格图展示结果。

教育与行业的平均收入

```
lfs %>%
  group_by(HIQUL22D,INDE07M) %>%
  summarise(mean_wage = mean(HOURPAY)) %>%
  ggplot(aes(HIQUL22D,INDE07M,fill=mean_wage)) +
  geom_tile() +
  theme(axis.text.x = element_text(angle = 90)) +
  labs(title = "Wage by industry and education",
       fill = "Mean hourly wage (£)",
       x = "Highest qualification attained",
       y = "Industry")
```

教育与行业的平均收入



方格图（热力图）

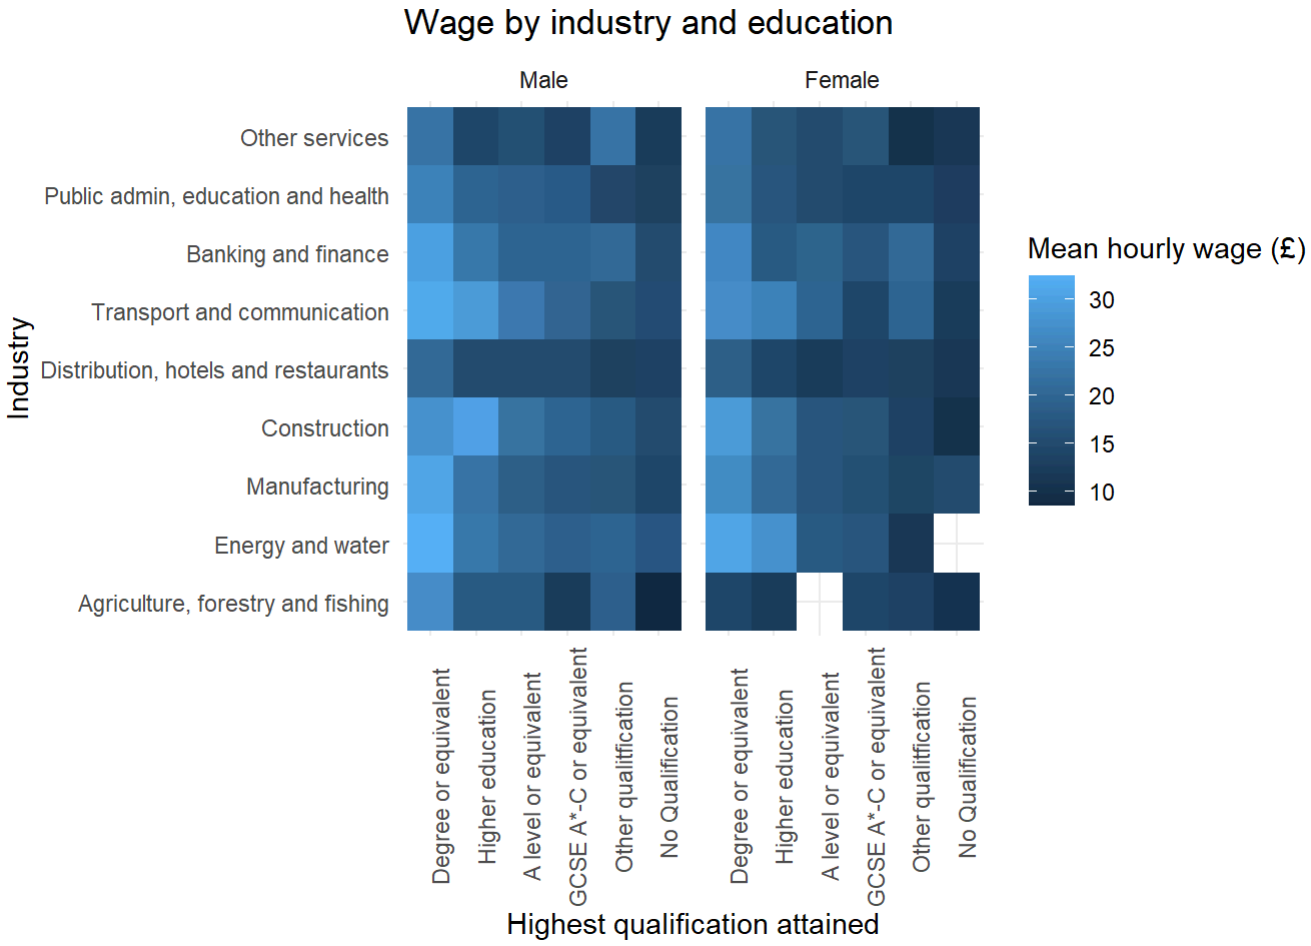
- 这张图让我们迅速看出，教育程度越高，工资往往也越高。

- 它也显示某些行业的平均工资比其他行业高。
- 教育回报在不同行业之间似乎也存在差异。
- 还可以进一步按照性别拆分。

按教育、行业和性别划分的平均收入

```
lfs %>%
  group_by(HIQUL22D,INDE07M,SEX) %>%
  summarise(mean_wage = mean(HOURPAY)) %>%
  ggplot(aes(HIQUL22D,INDE07M,fill=mean_wage)) +
  geom_tile() +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 90)) +
  labs(title = "Wage by industry and education",
       fill = "Mean hourly wage (£)",
       x = "Highest qualification attained",
       y = "Industry") +
  facet_wrap(~SEX)
```

按教育、行业和性别划分的平均收入



教育、行业与性别

- 这张图为分析增加了另一个维度。
- 现在可以发现，女性工资似乎更低。
- 总体上，教育程度越高，工资越高，但这一趋势对女性而言似乎较弱。
- 注意：在农业、林业和渔业中，没有属于“无资格或其他资格”类别的女性观测值。
- 某些方格可能仅由少量观测值计算得出，因此当数据被拆分成许多子组时，应谨慎解读。

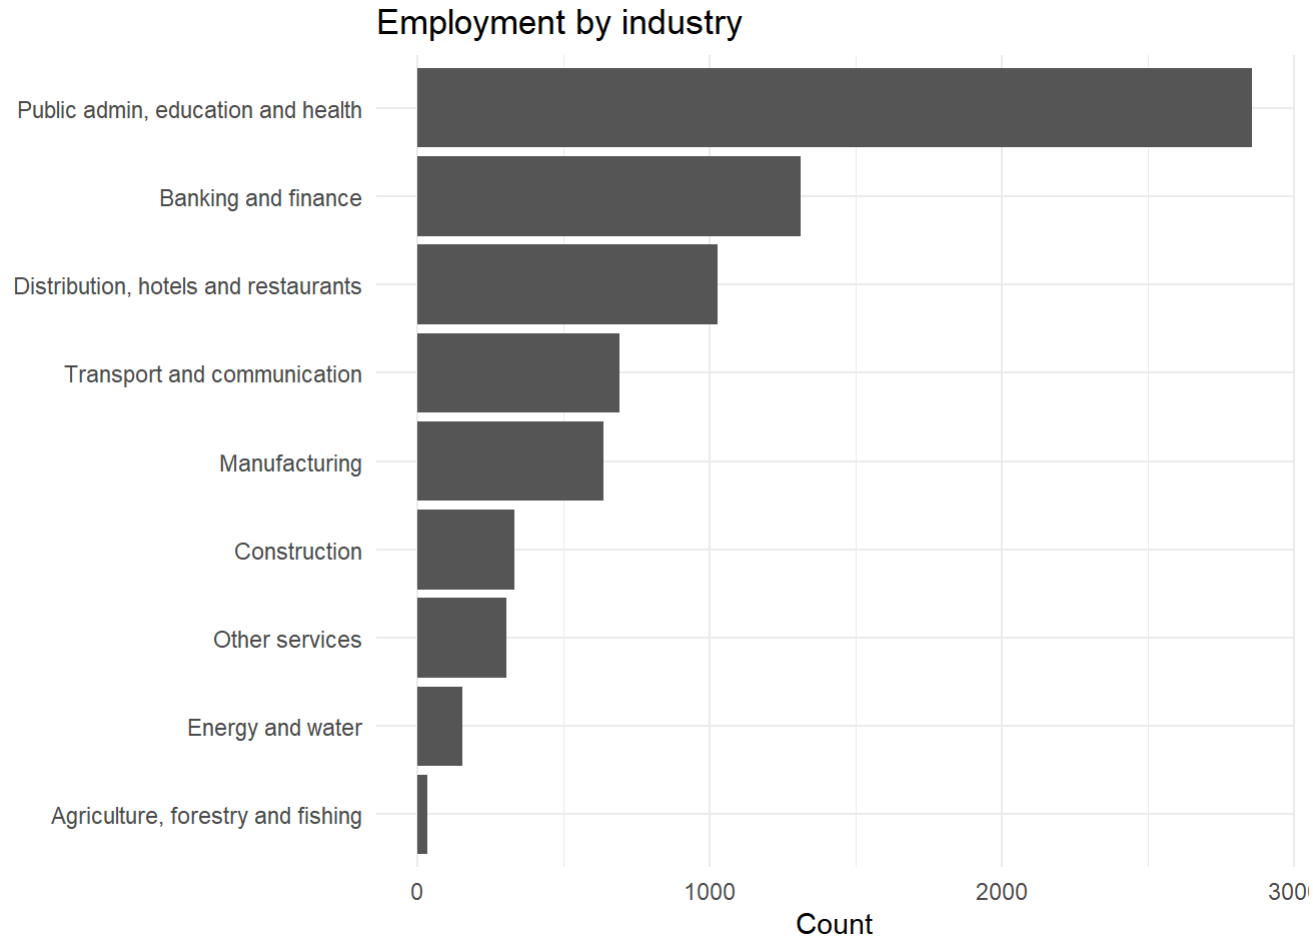
分类变量的分布

- 直方图和密度图可以展示连续变量的分布。
- 我们可能也对教育或行业等分类变量的分布感兴趣。
- 可以使用条形图来展示。
- 它看起来可能与直方图有点相似，但属于不同的图表类型。

各行业就业人数

```
lfs %>%
  mutate(INDE07M = fct_infreq(INDE07M) %>% fct_rev) %>%
  ggplot(aes(INDE07M)) +
  geom_bar() +
  theme_minimal() +
  labs(title = "Employment by industry",
       x = "",
       y = "Count") +
  coord_flip()
```

各行业就业人数



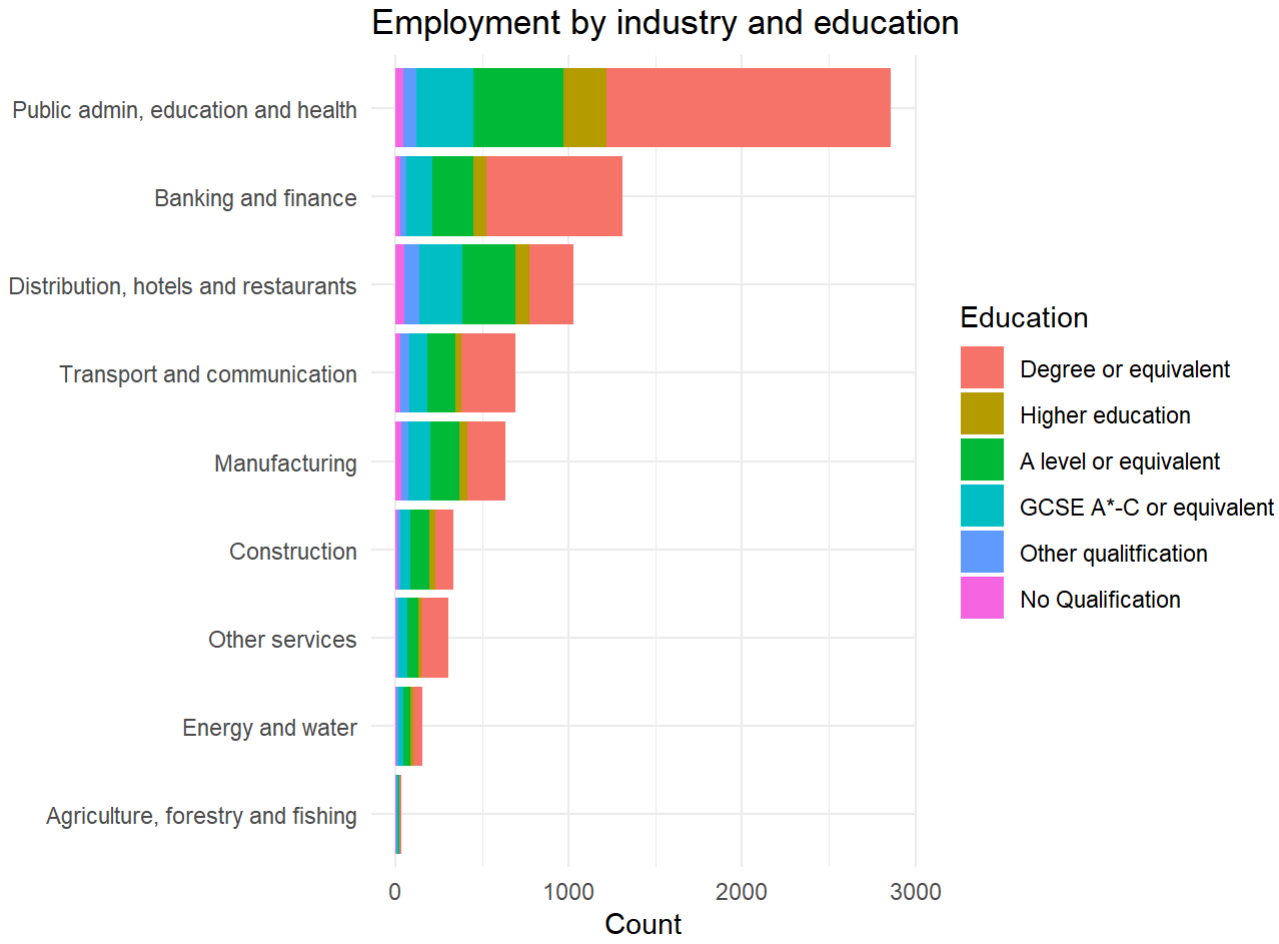
各行业就业人数

- 这样可以清楚地看出哪些行业雇用了最多的人。
- 我们使用了几个技巧：fct_infreq、fct_rev 和 coord_flip。
- 由于农业、林业和渔业（AFF）行业的受雇人数较少，解释该行业的进一步分组结果时应谨慎。
- 假设还想把教育水平纳入分析。

按行业和教育程度划分的就业人数

```
lfs %>%
  mutate(INDE07M = fct_infreq(INDE07M) %>% fct_rev) %>%
  ggplot(aes(INDE07M, fill=HIQUL22D)) +
  geom_bar() +
  theme_minimal() +
  labs(fill = "Education",
       title = "Employment by industry and education",
       x = "",
       y = "Count") +
  coord_flip()
```

按行业和教育程度划分的就业人数



调整图表

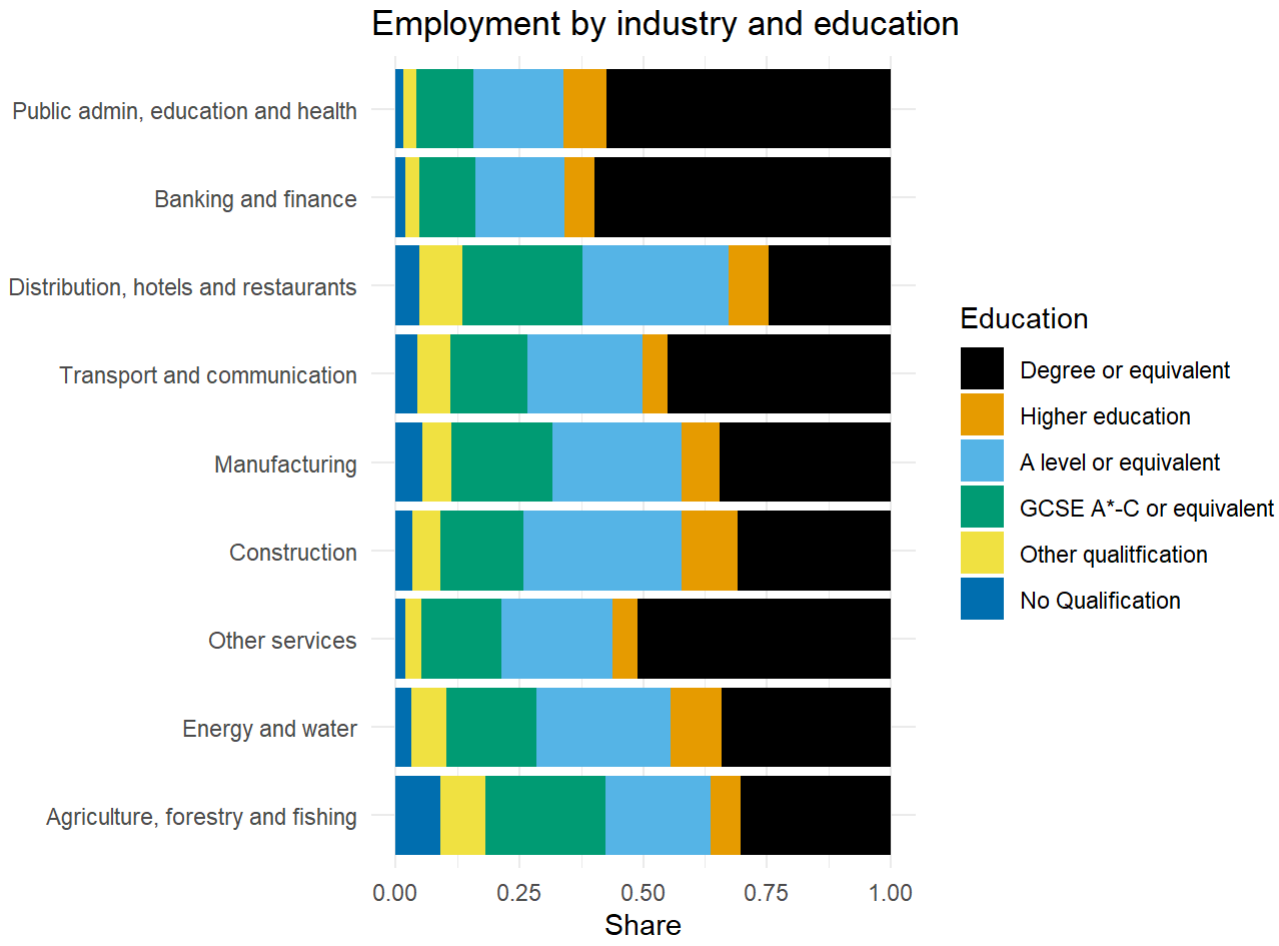
- 由于某些组的人数很少，这张图较难阅读。
- 颜色之间也不容易区分。
- 我将使用 ggthemes 包提供的一些配色，因此需要加载这个包。
- 我们不再观察人数，而是考察每个行业的就业人口中，不同教育水平分别占多少比例。

各行业就业人口的教育水平占比

```
library(ggthemes)

lfs %>%
  mutate(INDE07M = fct_infreq(INDE07M) %>% fct_rev) %>%
  ggplot(aes(INDE07M, fill=HIQUL22D)) +
  geom_bar(position="fill") +
  theme_minimal() +
  labs(fill = "Education",
       title = "Employment by industry and education",
       x = "",
       y = "Share") +
  coord_flip() +
  scale_fill_colorblind()
```

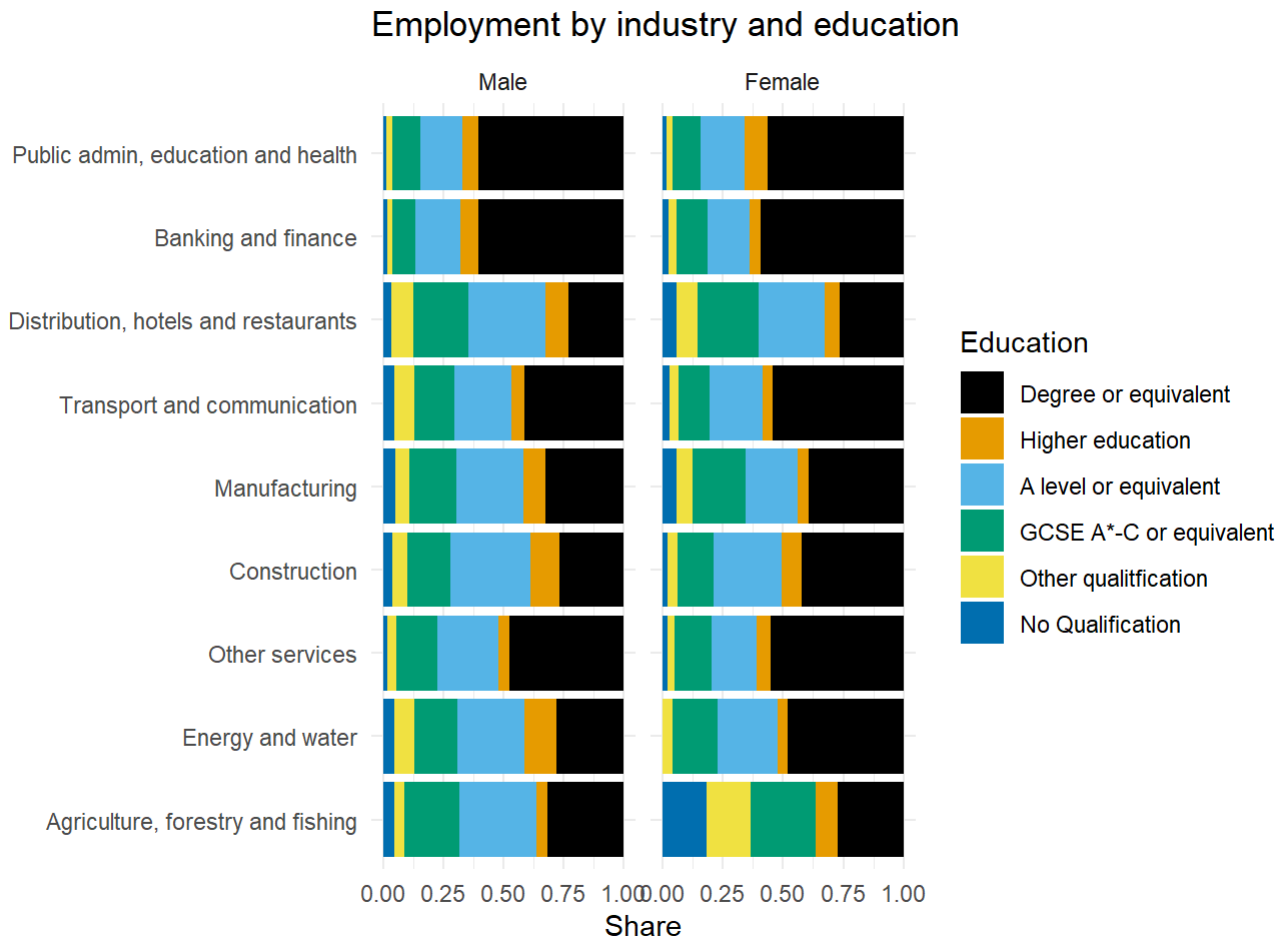
各行业就业人口的教育水平占比



按行业与性别划分的教育水平占比

```
lfs %>%
  mutate(INDE07M = fct_infreq(INDE07M) %>% fct_rev) %>%
  ggplot(aes(INDE07M, fill=HIQUL22D)) +
  geom_bar(position="fill") +
  theme_minimal() +
  labs(fill = "Education",
       title = "Employment by industry and education",
       x = "",
       y = "Share") +
  coord_flip() +
  scale_fill_colorblind() +
  facet_wrap(~SEX)
```

按行业与性别划分的教育水平占比



图表解读

- 现在无法直接看出行业规模，不过行业的排列顺序仍反映其规模。
- 可以看出每个行业中不同教育水平劳动者所占的比例。
- 还可以按性别进一步分组，观察是否存在差异。

class: inverse, center, middle # 关于数据可视化的一些建议

我们学到了什么

- 我们已经概览了多种不同类型的图表。
- 这些图表都是通过以不同方式组合各种元素制作出来的。
- 因此，我们可以制作出非常丰富的图表类型。
- 归根结底，这都与“图形语法”（grammar of graphics）的基本概念有关。
- 应该根据自己的数据和研究主题，考虑如何最佳地组合这些元素。

在报告和出版物中使用图表

- 有些图只需要在自己的屏幕上查看。
- 有些图做得很好，你会想把它们放进最终报告。
- 如果图表要用于正式成果，就应花时间把它们制作得美观、清晰。
- 所有元素都应标注清楚，例如避免直接使用原始变量名。没有人愿意看到名为 G3652xjw 的变量图，因为读者根本不知道它代表什么。
- 还应确保标签不会相互重叠。
- 应该在正文中解释图表展示了什么，以及希望读者从中得到什么结论。
- 话虽如此，图表本身仍应尽可能不依赖额外解释就能看懂。

是否需要图表?

- 不要把太多信息塞进同一张图。
- 也许存在更合适的数据展示方式。
- 不要忽视表格。表格是展示信息的好方法，有时甚至比图表更有信息量。
- 有些数据直接用文字叙述就可以，无需制作表格，例如“样本包含25名男性和24名女性”。

图表分类

- 我倾向于从两个维度对图表进行分类。
- 不同图表在传递信息方面的实用程度不同。
- 它们在美观程度方面也不同。
- 尽可能制作既实用又美观的图表。
- 避免无用的图表，尤其要避免既无用又难看的图表。

其他可视化类型

- 目前我们只讨论了静态可视化。

- 也可以制作动态、交互式可视化。
- R 为此提供了多种工具。
- 某些图表还使用三维空间。
- 但许多图最终需要呈现在纸上（或以图片形式显示在屏幕上）。
- 有人认为应该尽一切可能避免三维图表。

空间数据可视化

- 有些数据具有空间参照信息（我们的数据在一定程度上也有）。
- 将这些数据展示在地图上通常很有帮助。
- R 可以通过多种方式完成这一任务（甚至可以使用 ggplot2）。
- 这超出了本课程的范围，但值得思考。
- 将来也可能对你有帮助。

总结

- 一图胜千言。
- 优秀的数据可视化是清晰、有说服力地表达观点的强大工具。
- 已有研究表明，当政策制定者看到一张好的图表时，它可能在很大程度上影响政策变化。
- 数据可视化也有助于让更广泛的受众理解你的研究。
- 确保你制作的所有可视化都具有恰当的标签和说明。