Lecture 5 Notes | R语言数据可视化零基础逐行教程

> **课程**：URBAN5127 · Quantitative Data Analysis
> **来源**：上传的 `lecture5_notes.html`（Lecture 5 Notes）
> **适合**：从未编过程、刚开始使用 R / RStudio、需要中英文术语对应的学习者
> **原则**：依照讲义原先后顺序呈现全部 **19 段 R 代码**，原代码不擅自改动；"推荐改写"和"常见陷阱"另外标注。

目录与使用建议

本教程依次学习：箱线图 → 行业分组 → 小提琴图 → 抖动散点图 → 年龄与工资散点图 → 按地区/工作类型分面 → 分组汇总及热力图 → 计数条形图 → 堆叠条形图 → 比例条形图 → 按性别分面。

建议将讲义 HTML 与本教程并排打开。每次先在 RStudio 中运行一段课堂代码，再看下面的逐行拆解与图形解读；最后修改一个参数观察变化。由于讲义的工资数据存在缺失、非正值或调查特殊编码的可能，运行时也要注意有效样本和权重问题。

0. 完全零基础先了解的内容

0.1 对象、列和函数

- `lfs` 是存储整个数据集的**数据框**（data frame/tibble），像一个带很多行列的Excel表。
- `AGE`、`SEX`、`HOURPAY` 等是**列名**。大小写要严格一致。
- `ggplot(...)`、`geom_boxplot(...)` 是**函数**，括号中可以指定**参数**。
- `=` 在函数中通常指定参数值；在 `mutate(new_column = ...)` 中则指定新列名和计算内容。
- `"Hourly wage (£)"` 是字符串/文字；`HOURPAY` 不加引号表示数据列。
- `TRUE` 是逻辑真；`0.2` 是数字；`~` 是分面公式语法的一部分。

0.2 需要加载哪些包?

课堂代码使用 `%>%`、`ggplot()`、`fct_reorder()`、`fct_infreq()` 和 `scale_fill_colorblind()`。这些函数来自 tidyverse 各子包以及 ggthemes。首次安装包可运行：

```
install.packages("tidyverse")
install.packages("ggthemes")
```

安装通常只需做一次。每次重新启动R会话后可运行：

```
library(tidyverse)
```

`library(ggthemes)` 在讲义第18段中单独出现；如要提前运行第18、19段，也可以预先加载。确认 `lfs` 已读取，且 `SEX`、`HOURPAY` 等列存在。如何读取文件取决于你的本地文件路径及教师提供的数据处理过程，讲义这19段从**已经存在的** `lfs` **对象**开始，而不是从导入数据开始。

0.3 两种"连接符"极容易混淆

```
lfs %>%
  ggplot(aes(AGE, HOURPAY)) +
  geom_point()
```

`%>%` 将**数据传给函数**：从 lfs 到 ggplot。`+` 是 **ggplot 图层相加**：将点图层叠加到已建立的图上。它们不能简单互换。

0.4 为什么工资图需要留意对数尺度?

`scale_y_log10()` 或 `scale_x_log10()` 让坐标按10倍数量级展示，有助于观察高度偏斜的工资分布；这不代表工资单位变成了对数英镑。严格来说，非正工资不能进行 log10 变换；绘图警告需检查。要判断极端值是否为有效收入、数据特殊编码还是错误，必须参考数据字典。

---

1. 性别与小时工资：第一个箱线图

本段目标：这一段是本讲的起点：用箱线图比较不同性别组的工资。先掌握横轴分组、纵轴数值和对数坐标。

课堂原始代码（保持不变）

```
lfs %>%
  ggplot(aes(SEX, HOURPAY)) +
  geom_boxplot() +
  theme_minimal() +
  scale_y_log10() +
  labs(title = "Distribution of hourly wage by sex",
     subtitle = "Logarithmic scale",
     x = "Sex",
     y = "Hourly wage (£)",
     caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme(legend.title = element_blank())
```

从第一行开始理解

第 1 行： `lfs %>%`
从数据框 `lfs` 开始；`%>%` 把它送往下一步。 末尾 `%>%` 表示继续将数据传到下一步。

第 2 行： `ggplot(aes(SEX, HOURPAY)) +`
开始建立图对象。`aes(...)` 指定横轴、纵轴或填色变量；仅有 ggplot 初始化时可能还没有几何图形。末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 3 行： `geom_boxplot() +`
添加箱线图层，呈现中位数、四分位距等。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 4 行： `theme_minimal() +`
使用简洁的预设图形主题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 5 行： `scale_y_log10() +`
使用底数为10的纵轴对数刻度；非正值不能直接取 log10。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 6 行： `labs(title = "Distribution of hourly wage by sex",`
添加图形标题、轴标题、图例标题和来源说明等。

第 7 行： `subtitle = "Logarithmic scale",`
这一项是图表显示的标题/副标题/来源说明，是一段**文字字符串**，并非统计变量。

第 8 行： `x = "Sex",`
设置横轴或纵轴显示名称；`""` 表示故意留空，不显示轴标题。

第 9 行： `y = "Hourly wage (£)",`
设置横轴或纵轴显示名称；`""` 表示故意留空，不显示轴标题。

第 10 行： `caption = "Source: Quarterly Labour Force Survey - January-March 2025") +`
这行给图添加数据来源说明。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 11 行： `theme(legend.title = element_blank())`
调整图例、轴文字等非数据层的图形外观。 去除特定图形元素，例如图例标题。

本段用到的函数 / 参数解释

名称	零基础含义
`%>%`	管道运算符：把左边的结果交给右边操作；例如 lfs %>% ggplot(...) 相当于以 lfs 为数据作图。
`ggplot`	初始化 ggplot2 图形，指定数据与美学映射。
`aes`	aesthetics，美学映射；把变量映射到 x/y 坐标、颜色或填充等。
`geom_boxplot`	添加箱线图层，呈现中位数、四分位距等。
`scale_y_log10`	使用底数为10的纵轴对数刻度；非正值不能直接取 log10。
`labs`	添加图形标题、轴标题、图例标题和来源说明等。
`theme_minimal`	使用简洁的预设图形主题。
`theme`	调整图例、轴文字等非数据层的图形外观。
`element_blank`	去除特定图形元素，例如图例标题。

数据字段怎么理解?

名称	含义
`lfs`	包含英国劳动力调查记录的数据框名称。
`SEX`	性别类别变量，具体编码以本版本数据字典为准。
`HOURPAY`	小时工资相关变量，本讲作连续数值使用。

图应该怎样读？为什么这样画？

箱体下缘通常是 Q1，上缘通常是 Q3；箱内线是中位数。箱须和离群点的规则由 geom_boxplot() 的统计变换决定，不能认为箱须必然等于最小值和最大值。

动手练习：先原样运行该段，再有意识地只调整一个显示参数（例如标题、透明度、`coord_flip()` 是否添加），观察可视化有何变化；不要同时改动多个地方，否则很难判断是哪一项导致结果改变。

2. 地区与工资：多个箱线图

本段目标：只把横轴的分组变量从 SEX 改成 GOR9D，即可按地区比较工资分布。

课堂原始代码（保持不变）

```
lfs %>%
  ggplot(aes(GOR9D,HOURPAY)) +
  geom_boxplot() +
  labs( title = "Distribution of hourly wage by region",
        subtitle = "Logarithmic scale",
        x = "",
        y = "Hourly wage (£)",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_y_log10() +
  theme(legend.title = element_blank())
```

从第一行开始理解

第 1 行： `lfs %>%`
从数据框 `lfs` 开始； `%>%` 把它送往下一步。 末尾 `%>%` 表示继续将数据传到下一步。

第 2 行： `ggplot(aes(GOR9D,HOURPAY)) +`
开始建立图对象。 `aes(...)` 指定横轴、纵轴或填色变量；仅有 ggplot 初始化时可能还没有几何图形。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 3 行： `geom_boxplot() +`
添加箱线图层，呈现中位数、四分位距等。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 4 行： `labs( title = "Distribution of hourly wage by region",`
添加图形标题、轴标题、图例标题和来源说明等。

第 5 行： `subtitle = "Logarithmic scale",`
这一项是图表显示的标题/副标题/来源说明，是一段**文字字符串**，并非统计变量。

第 6 行： `x = "",`
设置横轴或纵轴显示名称； `""` 表示故意留空，不显示轴标题。

第 7 行： `y = "Hourly wage (£)",`
设置横轴或纵轴显示名称； `""` 表示故意留空，不显示轴标题。

第 8 行： `caption = "Source: Quarterly Labour Force Survey - January-March 2025") +`
这行给图添加数据来源说明。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 9 行： `theme_minimal() +`
使用简洁的预设图形主题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 10 行： `scale_y_log10() +`
使用底数为10的纵轴对数刻度；非正值不能直接取 log10。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 11 行： `theme(legend.title = element_blank())`
调整图例、轴文字等非数据层的图形外观。 去除特定图形元素，例如图例标题。

本段用到的函数 / 参数解释

名称	零基础含义
`%>%`	管道运算符：把左边的结果交给右边操作；例如 lfs %>% ggplot(...) 相当于以 lfs 为数据作图。
`ggplot`	初始化 ggplot2 图形，指定数据与美学映射。
`aes`	aesthetics，美学映射；把变量映射到 x/y 坐标、颜色或填充等。
`geom_boxplot`	添加箱线图层，呈现中位数、四分位距等。
`scale_y_log10`	使用底数为10的纵轴对数刻度；非正值不能直接取 log10。
`labs`	添加图形标题、轴标题、图例标题和来源说明等。
`theme_minimal`	使用简洁的预设图形主题。
`theme`	调整图例、轴文字等非数据层的图形外观。
`element_blank`	去除特定图形元素，例如图例标题。

数据字段怎么理解？

名称	含义
`lfs`	包含英国劳动力调查记录的数据框名称。
`HOURPAY`	小时工资相关变量，本讲作连续数值使用。
`GOR9D`	地区分类变量。

图应该怎样读？为什么这样画？

这是对地区工资分布的比较，不是地区平均工资柱状图。不同组样本量和缺失情况也会影响解释。

与前面代码的区别：这段重点改变的是「只把横轴的分组变量从 SEX 改成 GOR9D，即可按地区比较工资分布。」；对比上一张课堂图，可以逐行定位新增或替换了哪个函数、变量或参数。

动手练习：先原样运行该段，再有意识地只调整一个显示参数（例如标题、透明度、`coord_flip()` 是否添加），观察可视化有何变化；不要同时改动多个地方，否则很难判断是哪一项导致结果改变。

3. 改进地区箱线图：按中位数排序并翻转坐标

本段目标：原图地区名拥挤且排序不利于比较；这里先按工资中位数重排因子，再转成横向箱线图。

课堂原始代码（保持不变）

```
lfs %>%
  mutate(GOR9D = fct_reorder(GOR9D,HOURPAY,median,.desc=TRUE)) %>%
  ggplot(aes(GOR9D,HOURPAY)) +
  geom_boxplot() +
  labs( title = "Distribution of hourly wage by region",
        subtitle = "Logarithmic scale",
        x = "",
        y = "Hourly wage (£)",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_y_log10() +
  theme(legend.title = element_blank()) +
  coord_flip()
```

从第一行开始理解

第 1 行： `lfs %>%`
从数据框 `lfs` 开始；`%>%` 把它送往下一步。 末尾 `%>%` 表示继续将数据传到下一步。

第 2 行： `mutate(GOR9D = fct_reorder(GOR9D,HOURPAY,median,.desc=TRUE)) %>%`
`mutate()` 创建或替换列。这里左边的分类变量名和右边相同，意味着**重新排列类别顺序**，不是新增另一列。 末尾 `%>%` 表示继续将数据传到下一步。

第 3 行： `ggplot(aes(GOR9D,HOURPAY)) +`
开始建立图对象。 `aes(...)` 指定横轴、纵轴或填色变量；仅有 ggplot 初始化时可能还没有几何图形。末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 4 行： `geom_boxplot() +`
添加箱线图层，呈现中位数、四分位距等。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 5 行： `labs( title = "Distribution of hourly wage by region",`
添加图形标题、轴标题、图例标题和来源说明等。

第 6 行： `subtitle = "Logarithmic scale",`
这一项是图表显示的标题/副标题/来源说明，是一段**文字字符串**，并非统计变量。

第 7 行： `x = "",`
设置横轴或纵轴显示名称；`""` 表示故意留空，不显示轴标题。

第 8 行： `y = "Hourly wage (£)",`
设置横轴或纵轴显示名称；`""` 表示故意留空，不显示轴标题。

第 9 行： `caption = "Source: Quarterly Labour Force Survey - January-March 2025") +`
这行给图添加数据来源说明。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 10 行： `theme_minimal() +`
使用简洁的预设图形主题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 11 行： `scale_y_log10() +`
使用底数为10的纵轴对数刻度；非正值不能直接取 log10。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 12 行： `theme(legend.title = element_blank()) +`
调整图例、轴文字等非数据层的图形外观。 去除特定图形元素，例如图例标题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 13 行： `coord_flip()`
交换横纵坐标在图上的显示方向。

本段用到的函数 / 参数解释

名称	零基础含义
`%>%`	管道运算符：把左边的结果交给右边操作；例如 lfs %>% ggplot(...) 相当于以 lfs 为数据作图。
`ggplot`	初始化 ggplot2 图形，指定数据与美学映射。
`aes`	aesthetics，美学映射；把变量映射到 x/y 坐标、颜色或填充等。
`geom_boxplot`	添加箱线图层，呈现中位数、四分位距等。
`mutate`	新建或替换数据列。本讲用于更新因子的排列顺序。
`fct_reorder`	按另一数值变量的汇总统计量对因子类别重新排序（forcats 包）。
`coord_flip`	交换横纵坐标在图上的显示方向。
`scale_y_log10`	使用底数为10的纵轴对数刻度；非正值不能直接取 log10。
`labs`	添加图形标题、轴标题、图例标题和来源说明等。
`theme_minimal`	使用简洁的预设图形主题。
`theme`	调整图例、轴文字等非数据层的图形外观。
`element_blank`	去除特定图形元素，例如图例标题。

数据字段怎么理解?

名称	含义
`lfs`	包含英国劳动力调查记录的数据框名称。
`HOURPAY`	小时工资相关变量，本讲作连续数值使用。
`GOR9D`	地区分类变量。

图应该怎样读？为什么这样画?

fct_reorder(类别, 数值, median, .desc=TRUE) 按各类别数值的中位数重排因子顺序；coord_flip() 仅交换图的显示方向。

与前面代码的区别：这段重点改变的是「原图地区名拥挤且排序不利于比较；这里先按工资中位数重排因子，再转成横向箱线图。」；对比上一张课堂图，可以逐行定位新增或替换了哪个函数、变量或参数。

动手练习：先原样运行该段，再有意识地只调整一个显示参数（例如标题、透明度、`coord_flip()` 是否添加），观察可视化有何变化；不要同时改动多个地方，否则很难判断是哪一项导致结果改变。

4. 行业与工资：行业间差异

本段目标：从地区换成行业类别，采用同一套统计图逻辑。

课堂原始代码（保持不变）

```
lfs %>%
  mutate(INDE07M = fct_reorder(INDE07M,HOURPAY,median,.desc=TRUE)) %>%
  ggplot(aes(INDE07M,HOURPAY)) +
  geom_boxplot() +
  labs( title = "Distribution of hourly wage by industry",
        subtitle = "Logarithmic scale",
        x = "",
        y = "Hourly wage (£)",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_y_log10() +
  theme(legend.title = element_blank()) +
  coord_flip()
```

从第一行开始理解

第 1 行： `lfs %>%`
从数据框 `lfs` 开始；`%>%` 把它送往下一步。 末尾 `%>%` 表示继续将数据传到下一步。

第 2 行： `mutate(INDE07M = fct_reorder(INDE07M,HOURPAY,median,.desc=TRUE)) %>%`
`mutate()` 创建或替换列。这里左边的分类变量名和右边相同，意味着**重新排列类别顺序**，不是新增另一列。 末尾 `%>%` 表示继续将数据传到下一步。

第 3 行： `ggplot(aes(INDE07M,HOURPAY)) +`
开始建立图对象。`aes(...)` 指定横轴、纵轴或填色变量；仅有 ggplot 初始化时可能还没有几何图形。末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 4 行： `geom_boxplot() +`
添加箱线图层，呈现中位数、四分位距等。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 5 行： `labs( title = "Distribution of hourly wage by industry",`
添加图形标题、轴标题、图例标题和来源说明等。

第 6 行： `subtitle = "Logarithmic scale",`
这一项是图表显示的标题/副标题/来源说明，是一段**文字字符串**，并非统计变量。

第 7 行： `x = "",`
设置横轴或纵轴显示名称；`""` 表示故意留空，不显示轴标题。

第 8 行： `y = "Hourly wage (£)",`
设置横轴或纵轴显示名称；`""` 表示故意留空，不显示轴标题。

第 9 行： `caption = "Source: Quarterly Labour Force Survey - January-March 2025") +`
这行给图添加数据来源说明。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 10 行： `theme_minimal() +`
使用简洁的预设图形主题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 11 行： `scale_y_log10() +`
使用底数为10的纵轴对数刻度；非正值不能直接取 log10。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 12 行： `theme(legend.title = element_blank()) +`
调整图例、轴文字等非数据层的图形外观。 去除特定图形元素，例如图例标题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 13 行： `coord_flip()`
交换横纵坐标在图上的显示方向。

本段用到的函数 / 参数解释

名称	零基础含义
`%>%`	管道运算符：把左边的结果交给右边操作；例如 lfs %>% ggplot(...) 相当于以 lfs 为数据作图。
`ggplot`	初始化 ggplot2 图形，指定数据与美学映射。
`aes`	aesthetics，美学映射；把变量映射到 x/y 坐标、颜色或填充等。
`geom_boxplot`	添加箱线图层，呈现中位数、四分位距等。
`mutate`	新建或替换数据列。本讲用于更新因子的排列顺序。
`fct_reorder`	按另一数值变量的汇总统计量对因子类别重新排序（forcats 包）。
`coord_flip`	交换横纵坐标在图上的显示方向。
`scale_y_log10`	使用底数为10的纵轴对数刻度；非正值不能直接取 log10。
`labs`	添加图形标题、轴标题、图例标题和来源说明等。
`theme_minimal`	使用简洁的预设图形主题。
`theme`	调整图例、轴文字等非数据层的图形外观。
`element_blank`	去除特定图形元素，例如图例标题。

数据字段怎么理解?

名称	含义
`lfs`	包含英国劳动力调查记录的数据框名称。
`HOURPAY`	小时工资相关变量，本讲作连续数值使用。
`INDE07M`	行业分类变量。

图应该怎样读？为什么这样画？

行业名称较长时，横向展示通常更清楚。比较工资时必须同时关注不同组的分布和异常值。

与前面代码的区别：这段重点改变的是「从地区换成行业类别，采用同一套统计图逻辑。」；对比上一张课堂图，可以逐行定位新增或替换了哪个函数、变量或参数。

动手练习：先原样运行该段，再有意识地只调整一个显示参数（例如标题、透明度、`coord_flip()` 是否添加），观察可视化有何变化；不要同时改动多个地方，否则很难判断是哪一项导致结果改变。

5. 行业与性别：给箱线图增加第三个变量

本段目标：在行业箱线图中再用 fill 映射性别，增加一个用于组间比较的维度。

课堂原始代码（保持不变）

```
lfs %>%
  mutate(INDE07M = fct_reorder(INDE07M,HOURPAY,median,.desc=TRUE)) %>%
  ggplot(aes(INDE07M,HOURPAY)) +
  geom_boxplot(aes(fill=SEX)) +
  labs( title = "Distribution of hourly wage by industry",
        subtitle = "Logarithmic scale",
        x = "",
        y = "Hourly wage (£)",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_y_log10() +
  theme(legend.title = element_blank()) +
  coord_flip()
```

从第一行开始理解

第 1 行： `lfs %>%`
从数据框 `lfs` 开始；`%>%` 把它送往下一步。 末尾 `%>%` 表示继续将数据传到下一步。

第 2 行： `mutate(INDE07M = fct_reorder(INDE07M,HOURPAY,median,.desc=TRUE)) %>%`
`mutate()` 创建或替换列。这里左边的分类变量名和右边相同，意味着**重新排列类别顺序**，不是新增另一列。 末尾 `%>%` 表示继续将数据传到下一步。

第 3 行： `ggplot(aes(INDE07M,HOURPAY)) +`
开始建立图对象。`aes(...)` 指定横轴、纵轴或填色变量；仅有 ggplot 初始化时可能还没有几何图形。末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 4 行： `geom_boxplot(aes(fill=SEX)) +`
添加箱线图层，呈现中位数、四分位距等。 aesthetics，美学映射；把变量映射到 x/y 坐标、颜色或填充等。 `fill` 指填充色；放在 `aes()` 内是将填充颜色映射到数据列，放在 `labs()` 内则是修改图例标题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 5 行： `labs( title = "Distribution of hourly wage by industry",`
添加图形标题、轴标题、图例标题和来源说明等。

第 6 行： `subtitle = "Logarithmic scale",`
这一项是图表显示的标题/副标题/来源说明，是一段**文字字符串**，并非统计变量。

第 7 行： `x = "",`
设置横轴或纵轴显示名称；`""` 表示故意留空，不显示轴标题。

第 8 行： `y = "Hourly wage (£)",`
设置横轴或纵轴显示名称；`""` 表示故意留空，不显示轴标题。

第 9 行： `caption = "Source: Quarterly Labour Force Survey - January-March 2025") +`
这行给图添加数据来源说明。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 10 行： `theme_minimal() +`
使用简洁的预设图形主题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 11 行： `scale_y_log10() +`
使用底数为10的纵轴对数刻度；非正值不能直接取 log10。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 12 行： `theme(legend.title = element_blank()) +`
调整图例、轴文字等非数据层的图形外观。 去除特定图形元素，例如图例标题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 13 行： `coord_flip()`
交换横纵坐标在图上的显示方向。

本段用到的函数 / 参数解释

名称	零基础含义
`%>%`	管道运算符：把左边的结果交给右边操作；例如 lfs %>% ggplot(...) 相当于以 lfs 为数据作图。
`ggplot`	初始化 ggplot2 图形，指定数据与美学映射。
`aes`	aesthetics，美学映射；把变量映射到 x/y 坐标、颜色或填充等。
`geom_boxplot`	添加箱线图层，呈现中位数、四分位距等。
`mutate`	新建或替换数据列。本讲用于更新因子的排列顺序。
`fct_reorder`	按另一数值变量的汇总统计量对因子类别重新排序（forcats 包）。
`coord_flip`	交换横纵坐标在图上的显示方向。
`scale_y_log10`	使用底数为10的纵轴对数刻度；非正值不能直接取 log10。
`fill`	填充颜色；如果写在 aes() 中，表示由数据类别控制。
`labs`	添加图形标题、轴标题、图例标题和来源说明等。
`theme_minimal`	使用简洁的预设图形主题。
`theme`	调整图例、轴文字等非数据层的图形外观。
`element_blank`	去除特定图形元素，例如图例标题。

数据字段怎么理解?

名称	含义
`lfs`	包含英国劳动力调查记录的数据框名称。
`SEX`	性别类别变量，具体编码以本版本数据字典为准。
`HOURPAY`	小时工资相关变量，本讲作连续数值使用。
`INDE07M`	行业分类变量。

图应该怎样读?为什么这样画?

把 fill 写入 aes() 表示让数据变量决定颜色；这不是为所有箱体指定同一个固定颜色。

与前面代码的区别：这段重点改变的是「在行业箱线图中再用 fill 映射性别，增加一个用于组间比较的维度。」；对比上一张课堂图，可以逐行定位新增或替换了哪个函数、变量或参数。

动手练习：先原样运行该段，再有意识地只调整一个显示参数（例如标题、透明度、`coord_flip()` 是否添加），观察可视化有何变化；不要同时改动多个地方，否则很难判断是哪一项导致结果改变。

6. 教育水平与工资：小提琴图

本段目标：小提琴图把分布形状画出来：同一个教育组中哪里数据密集，形状通常更宽。

课堂原始代码（保持不变）

```
lfs %>%
  ggplot(aes(HIQUL22D,HOURPAY)) +
  geom_violin() +
  labs( title = "Distribution of hourly wage by education",
        subtitle = "Logarithmic scale",
        x = "",
        y = "Hourly wage (£)",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_y_log10() +
  theme(legend.title = element_blank()) +
  coord_flip()
```

从第一行开始理解

第 1 行： `lfs %>%`
从数据框 `lfs` 开始； `%>%` 把它送往下一步。 末尾 `%>%` 表示继续将数据传到下一步。

第 2 行： `ggplot(aes(HIQUL22D,HOURPAY)) +`
开始建立图对象。 `aes(...)` 指定横轴、纵轴或填色变量；仅有 ggplot 初始化时可能还没有几何图形。
末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 3 行： `geom_violin() +`
添加小提琴图层，显示估计分布形状。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 4 行： `labs( title = "Distribution of hourly wage by education",`
添加图形标题、轴标题、图例标题和来源说明等。

第 5 行： `subtitle = "Logarithmic scale",`
这一项是图表显示的标题/副标题/来源说明，是一段**文字字符串**，并非统计变量。

第 6 行： `x = "",`
设置横轴或纵轴显示名称；`""` 表示故意留空，不显示轴标题。

第 7 行： `y = "Hourly wage (£)",`
设置横轴或纵轴显示名称；`""` 表示故意留空，不显示轴标题。

第 8 行： `caption = "Source: Quarterly Labour Force Survey - January-March 2025") +`
这行给图添加数据来源说明。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 9 行： `theme_minimal() +`
使用简洁的预设图形主题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 10 行： `scale_y_log10() +`
使用底数为10的纵轴对数刻度；非正值不能直接取 log10。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 11 行： `theme(legend.title = element_blank()) +`
调整图例、轴文字等非数据层的图形外观。 去除特定图形元素，例如图例标题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 12 行： `coord_flip()`
交换横纵坐标在图上的显示方向。

本段用到的函数 / 参数解释

名称	零基础含义
`%>%`	管道运算符：把左边的结果交给右边操作；例如 lfs %>% ggplot(...) 相当于以 lfs 为数据作图。
`ggplot`	初始化 ggplot2 图形，指定数据与美学映射。
`aes`	aesthetics，美学映射；把变量映射到 x/y 坐标、颜色或填充等。
`geom_violin`	添加小提琴图层，显示估计分布形状。
`coord_flip`	交换横纵坐标在图上的显示方向。
`scale_y_log10`	使用底数为10的纵轴对数刻度；非正值不能直接取 log10。
`labs`	添加图形标题、轴标题、图例标题和来源说明等。
`theme_minimal`	使用简洁的预设图形主题。
`theme`	调整图例、轴文字等非数据层的图形外观。
`element_blank`	去除特定图形元素，例如图例标题。

数据字段怎么理解?

名称	含义
`lfs`	包含英国劳动力调查记录的数据框名称。
`HOURPAY`	小时工资相关变量，本讲作连续数值使用。
`HIQUL22D`	最高教育或资格水平相关分类变量。

图应该怎样读？为什么这样画?

小提琴图使用核密度估计，宽度体现估计密度；它不是每个工资值的真实出现次数。

与前面代码的区别：这段重点改变的是「小提琴图把分布形状画出来：同一个教育组中哪里数据密集，形状通常更宽。」；对比上一张课堂图，可以逐行定位新增或替换了哪个函数、变量或参数。

动手练习：先原样运行该段，再有意识地只调整一个显示参数（例如标题、透明度、`coord_flip()` 是否添加），观察可视化有何变化；不要同时改动多个地方，否则很难判断是哪一项导致结果改变。

7. 小提琴图叠加箱线图

本段目标：把小提琴图和窄箱线图叠加；前者看形状，后者看中位数、四分位数。

课堂原始代码（保持不变）

```
lfs %>%
  ggplot(aes(HIQUL22D,HOURPAY)) +
  geom_violin() +
  geom_boxplot(width=0.2) +
  labs( title = "Distribution of hourly wage by education",
        subtitle = "Logarithmic scale",
        x = "",
        y = "Hourly wage (£)",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_y_log10() +
  theme(legend.title = element_blank()) +
  coord_flip()
```

从第一行开始理解

第 1 行： `lfs %>%`
从数据框 `lfs` 开始； `%>%` 把它送往下一步。 末尾 `%>%` 表示继续将数据传到下一步。

第 2 行： `ggplot(aes(HIQUL22D,HOURPAY)) +`
开始建立图对象。 `aes(...)` 指定横轴、纵轴或填色变量；仅有 ggplot 初始化时可能还没有几何图形。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 3 行： `geom_violin() +`
添加小提琴图层，显示估计分布形状。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 4 行： `geom_boxplot(width=0.2) +`
添加箱线图层，呈现中位数、四分位距等。 `width` 是绘图对象的宽度参数。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 5 行： `labs( title = "Distribution of hourly wage by education",`
添加图形标题、轴标题、图例标题和来源说明等。

第 6 行： `subtitle = "Logarithmic scale",`
这一项是图表显示的标题/副标题/来源说明，是一段**文字字符串**，并非统计变量。

第 7 行： `x = "",`
设置横轴或纵轴显示名称； `""` 表示故意留空，不显示轴标题。

第 8 行： `y = "Hourly wage (£)",`
设置横轴或纵轴显示名称； `""` 表示故意留空，不显示轴标题。

第 9 行： `caption = "Source: Quarterly Labour Force Survey - January-March 2025") +`
这行给图添加数据来源说明。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 10 行： `theme_minimal() +`
使用简洁的预设图形主题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 11 行： `scale_y_log10() +`
使用底数为10的纵轴对数刻度；非正值不能直接取 log10。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 12 行： `theme(legend.title = element_blank()) +`
调整图例、轴文字等非数据层的图形外观。 去除特定图形元素，例如图例标题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 13 行： `coord_flip()`
交换横纵坐标在图上的显示方向。

本段用到的函数 / 参数解释

名称	零基础含义
`%>%`	管道运算符：把左边的结果交给右边操作；例如 lfs %>% ggplot(...) 相当于以 lfs 为数据作图。
`ggplot`	初始化 ggplot2 图形，指定数据与美学映射。
`aes`	aesthetics，美学映射；把变量映射到 x/y 坐标、颜色或填充等。
`geom_boxplot`	添加箱线图层，呈现中位数、四分位距等。
`geom_violin`	添加小提琴图层，显示估计分布形状。
`coord_flip`	交换横纵坐标在图上的显示方向。
`scale_y_log10`	使用底数为10的纵轴对数刻度；非正值不能直接取 log10。
`width`	设置几何图层宽度（本讲用于缩窄叠加的箱线图）。
`labs`	添加图形标题、轴标题、图例标题和来源说明等。
`theme_minimal`	使用简洁的预设图形主题。

名称	零基础含义
`theme`	调整图例、轴文字等非数据层的图形外观。
`element_blank`	去除特定图形元素，例如图例标题。

数据字段怎么理解?

名称	含义
`lfs`	包含英国劳动力调查记录的数据框名称。
`HOURPAY`	小时工资相关变量，本讲作连续数值使用。
`HIQUL22D`	最高教育或资格水平相关分类变量。

图应该怎样读？为什么这样画?

geom_boxplot(width=0.2) 的 0.2 规定箱体相对宽度；它不会改变工资计算结果。

与前面代码的区别：这段重点改变的是「把小提琴图和窄箱线图叠加；前者看形状，后者看中位数、四分位数。」；对比上一张课堂图，可以逐行定位新增或替换了哪个函数、变量或参数。

动手练习：先原样运行该段，再有意识地只调整一个显示参数（例如标题、透明度、`coord_flip()` 是否添加），观察可视化有何变化；不要同时改动多个地方，否则很难判断是哪一项导致结果改变。

8. 社会经济职业分类与工资：抖动散点图

本段目标：抖动图将个人记录画成点；与箱线图不同，它凸显原始观测值，但大量点会重叠。

课堂原始代码（保持不变）

```
lfs %>%
  ggplot(aes(NSECMJ2O,HOURPAY)) +
  geom_jitter() +
  labs( title = "Distribution of hourly wage by seniority",
        subtitle = "Logarithmic scale",
        x = "",
        y = "Hourly wage (£)",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_y_log10() +
  theme(legend.title = element_blank()) +
  coord_flip()
```

从第一行开始理解

第 1 行： `lfs %>%`
从数据框 `lfs` 开始； `%>%` 把它送往下一步。 末尾 `%>%` 表示继续将数据传到下一步。

第 2 行： `ggplot(aes(NSECMJ2O,HOURPAY)) +`
开始建立图对象。 `aes(...)` 指定横轴、纵轴或填色变量；仅有 ggplot 初始化时可能还没有几何图形。
末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 3 行： `geom_jitter() +`
绘制带少量随机抖动的散点，缓解重复位置的遮挡。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 4 行： `labs( title = "Distribution of hourly wage by seniority",`
添加图形标题、轴标题、图例标题和来源说明等。

第 5 行： `subtitle = "Logarithmic scale",`
这一项是图表显示的标题/副标题/来源说明，是一段**文字字符串**，并非统计变量。

第 6 行： `x = "",`
设置横轴或纵轴显示名称；`""` 表示故意留空，不显示轴标题。

第 7 行： `y = "Hourly wage (£)",`
设置横轴或纵轴显示名称；`""` 表示故意留空，不显示轴标题。

第 8 行： `caption = "Source: Quarterly Labour Force Survey - January-March 2025") +`
这行给图添加数据来源说明。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 9 行： `theme_minimal() +`
使用简洁的预设图形主题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 10 行： `scale_y_log10() +`
使用底数为10的纵轴对数刻度；非正值不能直接取 log10。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 11 行： `theme(legend.title = element_blank()) +`
调整图例、轴文字等非数据层的图形外观。 去除特定图形元素，例如图例标题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 12 行： `coord_flip()`
交换横纵坐标在图上的显示方向。

本段用到的函数 / 参数解释

名称	零基础含义
`%>%`	管道运算符：把左边的结果交给右边操作；例如 lfs %>% ggplot(...) 相当于以 lfs 为数据作图。
`ggplot`	初始化 ggplot2 图形，指定数据与美学映射。
`aes`	aesthetics，美学映射；把变量映射到 x/y 坐标、颜色或填充等。
`geom_jitter`	绘制带少量随机抖动的散点，缓解重复位置的遮挡。
`coord_flip`	交换横纵坐标在图上的显示方向。
`scale_y_log10`	使用底数为10的纵轴对数刻度；非正值不能直接取 log10。
`labs`	添加图形标题、轴标题、图例标题和来源说明等。
`theme_minimal`	使用简洁的预设图形主题。
`theme`	调整图例、轴文字等非数据层的图形外观。
`element_blank`	去除特定图形元素，例如图例标题。

数据字段怎么理解?

名称	含义
`lfs`	包含英国劳动力调查记录的数据框名称。
`HOURPAY`	小时工资相关变量，本讲作连续数值使用。
`NSECMJ20`	社会经济分类（课件用于seniority相关展示），不应仅凭名称将它等同于精确工龄。

图应该怎样读?为什么这样画?

抖动会给点的位置添加小幅随机扰动，以减少重叠，不代表观测到的真实工资或类别发生改变。

与前面代码的区别：这段重点改变的是「抖动图将个人记录画成点；与箱线图不同，它凸显原始观测值，但大量点会重叠。」；对比上一张课堂图，可以逐行定位新增或替换了哪个函数、变量或参数。

动手练习：先原样运行该段，再有意识地只调整一个显示参数（例如标题、透明度、`coord_flip()` 是否添加），观察可视化有何变化；不要同时改动多个地方，否则很难判断是哪一项导致结果改变。

9. 筛选类别并降低散点透明度

本段目标：使用 filter 排除讲义指定的类别，并将 alpha 调小到 0.05，缓解海量散点的遮挡。

课堂原始代码（保持不变）

```
lfs %>%
  filter(NSECMJ20!="Small employers and own account workers") %>%
  ggplot(aes(NSECMJ20,HOURPAY)) +
  geom_jitter(alpha=0.05) +
  labs( title = "Distribution of hourly wage by seniority",
        subtitle = "Logarithmic scale",
        x = "",
        y = "Hourly wage (£)",
        caption = "Source: Quarterly Labour Force Survey - January-March 2025") +
  theme_minimal() +
  scale_y_log10() +
  theme(legend.title = element_blank()) +
  coord_flip()
```

从第一行开始理解

第 1 行： `lfs %>%`
从数据框 `lfs` 开始； `%>%` 把它送往下一步。 末尾 `%>%` 表示继续将数据传到下一步。

第 2 行： `filter(NSECMJ20!="Small employers and own account workers") %>%`
`filter()` 依据条件保留数据行；此处 `!=` 表示“不等于”，所以排除指定文字标签的记录。 末尾 `%>%` 表示继续将数据传到下一步。

第 3 行： `ggplot(aes(NSECMJ20,HOURPAY)) +`
开始建立图对象。 `aes(...)` 指定横轴、纵轴或填色变量；仅有 ggplot 初始化时可能还没有几何图形。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 4 行： `geom_jitter(alpha=0.05) +`
绘制带少量随机抖动的散点，缓解重复位置的遮挡。 `alpha` 设置透明度，不改变原始数据。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 5 行： `labs( title = "Distribution of hourly wage by seniority",`
添加图形标题、轴标题、图例标题和来源说明等。

第 6 行： `subtitle = "Logarithmic scale",`
这一项是图表显示的标题/副标题/来源说明，是一段**文字字符串**，并非统计变量。

第 7 行： `x = "",`
设置横轴或纵轴显示名称； `""` 表示故意留空，不显示轴标题。

第 8 行： `y = "Hourly wage (£)",`
设置横轴或纵轴显示名称； `""` 表示故意留空，不显示轴标题。

第 9 行： `caption = "Source: Quarterly Labour Force Survey - January-March 2025") +`
这行给图添加数据来源说明。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 10 行： `theme_minimal() +`
使用简洁的预设图形主题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 11 行： `scale_y_log10() +`
使用底数为10的纵轴对数刻度；非正值不能直接取 log10。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 12 行： `theme(legend.title = element_blank()) +`
调整图例、轴文字等非数据层的图形外观。 去除特定图形元素，例如图例标题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 13 行： `coord_flip()`
交换横纵坐标在图上的显示方向。

本段用到的函数 / 参数解释

名称	零基础含义
`%>%`	管道运算符：把左边的结果交给右边操作；例如 lfs %>% ggplot(...) 相当于以 lfs 为数据作图。
`ggplot`	初始化 ggplot2 图形，指定数据与美学映射。
`aes`	aesthetics，美学映射；把变量映射到 x/y 坐标、颜色或填充等。
`geom_jitter`	绘制带少量随机抖动的散点，缓解重复位置的遮挡。
`filter`	筛选符合条件的行，不是只改变图形的视觉区域。
`coord_flip`	交换横纵坐标在图上的显示方向。
`scale_y_log10`	使用底数为10的纵轴对数刻度；非正值不能直接取 log10。
`alpha`	透明度，通常范围0～1；数值越低越透明。
`labs`	添加图形标题、轴标题、图例标题和来源说明等。
`theme_minimal`	使用简洁的预设图形主题。

名称	零基础含义
`theme`	调整图例、轴文字等非数据层的图形外观。
`element_blank`	去除特定图形元素，例如图例标题。

数据字段怎么理解?

名称	含义
`lfs`	包含英国劳动力调查记录的数据框名称。
`HOURPAY`	小时工资相关变量，本讲作连续数值使用。
`NSECMJ20`	社会经济分类（课件用于seniority相关展示），不应仅凭名称将它等同于精确工龄。

图应该怎样读？为什么这样画?

!= 是“不等于”；引号内必须与实际因子标签匹配。alpha=0.05 表示非常透明（5% 不透明度）。

与前面代码的区别：这段重点改变的是「使用 filter 排除讲义指定的类别，并将 alpha 调小到 0.05，缓解海量散点的遮挡。」；对比上一张课堂图，可以逐行定位新增或替换了哪个函数、变量或参数。

动手练习：先原样运行该段，再有意识地只调整一个显示参数（例如标题、透明度、`coord_flip()` 是否添加），观察可视化有何变化；不要同时改动多个地方，否则很难判断是哪一项导致结果改变。

10. 年龄与小时工资：基本散点图

本段目标：当两个变量都用数值表示时，可以用 geom_point() 作散点图，探索年龄与小时工资关系。

课堂原始代码（保持不变）

```
lfs %>%
  ggplot(aes(AGE,HOURPAY)) +
  geom_point() +
  theme_minimal() +
  scale_y_log10()
```

从第一行开始理解

第 1 行： `lfs %>%`
从数据框 `lfs` 开始； `%>%` 把它送往下一步。 末尾 `%>%` 表示继续将数据传到下一步。

第 2 行： `ggplot(aes(AGE,HOURPAY)) +`
开始建立图对象。 `aes(...)` 指定横轴、纵轴或填色变量；仅有 ggplot 初始化时可能还没有几何图形。
末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 3 行： `geom_point() +`
绘制普通散点图。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 4 行： `theme_minimal() +`
使用简洁的预设图形主题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 5 行： `scale_y_log10()`
使用底数为10的纵轴对数刻度；非正值不能直接取 log10。

本段用到的函数 / 参数解释

名称	零基础含义
`%>%`	管道运算符：把左边的结果交给右边操作；例如 lfs %>% ggplot(...) 相当于以 lfs 为数据作图。
`ggplot`	初始化 ggplot2 图形，指定数据与美学映射。
`aes`	aesthetics，美学映射；把变量映射到 x/y 坐标、颜色或填充等。
`geom_point`	绘制普通散点图。
`scale_y_log10`	使用底数为10的纵轴对数刻度；非正值不能直接取 log10。
`theme_minimal`	使用简洁的预设图形主题。

数据字段怎么理解?

名称	含义
`lfs`	包含英国劳动力调查记录的数据框名称。
`HOURPAY`	小时工资相关变量，本讲作连续数值使用。
`AGE`	年龄。

图应该怎样读？为什么这样画?

散点的每个点对应一条有效观测，不等于发现了因果关系；年龄为整数时容易产生点重合。

与前面代码的区别：这段重点改变的是「当两个变量都用数值表示时，可以用 geom_point() 作散点图，探索年龄与小时工资关系。」；对比上一张课堂图，可以逐行定位新增或替换了哪个函数、变量或参数。

动手练习：先原样运行该段，再有意识地只调整一个显示参数（例如标题、透明度、`coord_flip()` 是否添加），观察可视化有何变化；不要同时改动多个地方，否则很难判断是哪一项导致结果改变。

11. 年龄与工资：使用抖动和透明度

本段目标：年龄往往是整数，很多点落在相同坐标；jitter 和透明度可缓解覆盖问题。

课堂原始代码（保持不变）

```
lfs %>%
  ggplot(aes(AGE,HOURPAY)) +
  geom_jitter(alpha=0.2) +
  theme_minimal() +
  scale_y_log10() +
  labs(title = "Wage versus age",
       x = "Age",
       y = "Hourly wage (£)")
```

从第一行开始理解

第 1 行： `lfs %>%`
从数据框 `lfs` 开始； `%>%` 把它送往下一步。 末尾 `%>%` 表示继续将数据传到下一步。

第 2 行： `ggplot(aes(AGE,HOURPAY)) +`
开始建立图对象。 `aes(...)` 指定横轴、纵轴或填色变量；仅有 ggplot 初始化时可能还没有几何图形。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 3 行： `geom_jitter(alpha=0.2) +`
绘制带少量随机抖动的散点，缓解重复位置的遮挡。 `alpha` 设置透明度，不改变原始数据。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 4 行： `theme_minimal() +`
使用简洁的预设图形主题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 5 行： `scale_y_log10() +`
使用底数为10的纵轴对数刻度；非正值不能直接取 log10。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 6 行： `labs(title = "Wage versus age",`
添加图形标题、轴标题、图例标题和来源说明等。

第 7 行： `x = "Age",`
设置横轴或纵轴显示名称； `""` 表示故意留空，不显示轴标题。

第 8 行： `y = "Hourly wage (£)")`
设置横轴或纵轴显示名称； `""` 表示故意留空，不显示轴标题。

本段用到的函数 / 参数解释

名称	零基础含义
`%>%`	管道运算符：把左边的结果交给右边操作；例如 lfs %>% ggplot(...) 相当于以 lfs 为数据作图。
`ggplot`	初始化 ggplot2 图形，指定数据与美学映射。
`aes`	aesthetics，美学映射；把变量映射到 x/y 坐标、颜色或填充等。
`geom_jitter`	绘制带少量随机抖动的散点，缓解重复位置的遮挡。
`scale_y_log10`	使用底数为10的纵轴对数刻度；非正值不能直接取 log10。

名称	零基础含义
`alpha`	透明度，通常范围0～1；数值越低越透明。
`labs`	添加图形标题、轴标题、图例标题和来源说明等。
`theme_minimal`	使用简洁的预设图形主题。

数据字段怎么理解?

名称	含义
`lfs`	包含英国劳动力调查记录的数据框名称。
`HOURPAY`	小时工资相关变量，本讲作连续数值使用。
`AGE`	年龄。

图应该怎样读？为什么这样画?

geom_jitter(alpha=0.2) 比 geom_point() 更便于看到重叠，但随机抖动不等于测量误差。

与前面代码的区别：这段重点改变的是「年龄往往是整数，很多点落在相同坐标；jitter 和透明度可缓解覆盖问题。」；对比上一张课堂图，可以逐行定位新增或替换了哪个函数、变量或参数。

动手练习：先原样运行该段，再有意识地只调整一个显示参数（例如标题、透明度、`coord_flip()` 是否添加），观察可视化有何变化；不要同时改动多个地方，否则很难判断是哪一项导致结果改变。

12. 性别与地区的工资分布：分面密度图

本段目标：用 facet_wrap() 按地区拆成多个小图，每张小图再用填色区分性别。

课堂原始代码（保持不变）

```
lfs %>%
  ggplot(aes(HOURPAY, fill=SEX)) +
  geom_density(alpha=0.3) +
  theme_minimal() +
  scale_x_log10() +
  facet_wrap(~GOR9D) +
  theme(legend.position = "top",
        legend.title = element_blank())  +
  labs(title = "Wage distribution by sex and region",
       x = "Hourly wage (£)",
       y = "Density")
```

从第一行开始理解

第 1 行： `lfs %>%`
从数据框 `lfs` 开始； `%>%` 把它送往下一步。 末尾 `%>%` 表示继续将数据传到下一步。

第 2 行： `ggplot(aes(HOURPAY, fill=SEX)) +`
开始建立图对象。 `aes(...)` 指定横轴、纵轴或填色变量；仅有 ggplot 初始化时可能还没有几何图形。
末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 3 行： `geom_density(alpha=0.3) +`
绘制核密度曲线，观察连续数据的分布形状。 `alpha` 设置透明度，不改变原始数据。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 4 行： `theme_minimal() +`
使用简洁的预设图形主题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 5 行： `scale_x_log10() +`
使用底数为10的横轴对数刻度。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 6 行： `facet_wrap(~GOR9D) +`
按一个变量拆成多个小面板。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 7 行： `theme(legend.position = "top",`
调整图例、轴文字等非数据层的图形外观。

第 8 行： `legend.title = element_blank()) +`
通过 `element_blank()` 隐藏图例标题，不会删除图例本身。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 9 行： `labs(title = "Wage distribution by sex and region",`
添加图形标题、轴标题、图例标题和来源说明等。

第 10 行： `x = "Hourly wage (£)",`
设置横轴或纵轴显示名称；`""` 表示故意留空，不显示轴标题。

第 11 行： `y = "Density")`
设置横轴或纵轴显示名称；`""` 表示故意留空，不显示轴标题。

本段用到的函数 / 参数解释

名称	零基础含义
`%>%`	管道运算符：把左边的结果交给右边操作；例如 lfs %>% ggplot(...) 相当于以 lfs 为数据作图。
`ggplot`	初始化 ggplot2 图形，指定数据与美学映射。
`aes`	aesthetics，美学映射；把变量映射到 x/y 坐标、颜色或填充等。
`geom_density`	绘制核密度曲线，观察连续数据的分布形状。
`facet_wrap`	按一个变量拆成多个小面板。
`scale_x_log10`	使用底数为10的横轴对数刻度。
`alpha`	透明度，通常范围0～1；数值越低越透明。
`fill`	填充颜色；如果写在 aes() 中，表示由数据类别控制。
`position`	条形的排列方式；"fill" 表示比例堆叠。
`labs`	添加图形标题、轴标题、图例标题和来源说明等。
`theme_minimal`	使用简洁的预设图形主题。
`theme`	调整图例、轴文字等非数据层的图形外观。

名称	零基础含义
`element_blank`	去除特定图形元素，例如图例标题。

数据字段怎么理解?

名称	含义
`lfs`	包含英国劳动力调查记录的数据框名称。
`SEX`	性别类别变量，具体编码以本版本数据字典为准。
`HOURPAY`	小时工资相关变量，本讲作连续数值使用。
`GOR9D`	地区分类变量。

图应该怎样读？为什么这样画?

facet_wrap(~GOR9D) 中 ~ 的右边是分面变量；每个地区单独占一张小图，而不是过滤掉其他地区。

与前面代码的区别：这段重点改变的是「用 facet_wrap() 按地区拆成多个小图，每张小图再用填色区分性别。」；对比上一张课堂图，可以逐行定位新增或替换了哪个函数、变量或参数。

动手练习：先原样运行该段，再有意识地只调整一个显示参数（例如标题、透明度、`coord_flip()` 是否添加），观察可视化有何变化；不要同时改动多个地方，否则很难判断是哪一项导致结果改变。

13. 性别与工作类型：双维分面

本段目标：用 facet_grid(FTPT~JOBTYP) 同时按两个分类变量形成行列网格。

课堂原始代码（保持不变）

```
lfs %>%
  ggplot(aes(HOURPAY, fill=SEX)) +
  geom_density(alpha=0.4) +
  theme_minimal() +
  scale_x_log10() +
  facet_grid(FTPT~JOBTYP) +
  theme(legend.position = "top",
        legend.title = element_blank()) +
  labs(title = "Wages by sex and type of job",
       x = "Hourly wage (£)",
       y= "Density")
```

从第一行开始理解

第 1 行： `lfs %>%`
从数据框 `lfs` 开始； `%>%` 把它送往下一步。 末尾 `%>%` 表示继续将数据传到下一步。

第 2 行： `ggplot(aes(HOURPAY, fill=SEX)) +`
开始建立图对象。 `aes(...)` 指定横轴、纵轴或填色变量；仅有 ggplot 初始化时可能还没有几何图形。
末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 3 行： `geom_density(alpha=0.4) +`
绘制核密度曲线，观察连续数据的分布形状。 `alpha` 设置透明度，不改变原始数据。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 4 行： `theme_minimal() +`
使用简洁的预设图形主题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 5 行： `scale_x_log10() +`
使用底数为10的横轴对数刻度。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 6 行： `facet_grid(FTPT~JOBTYP) +`
按行变量和列变量形成二维分面网格。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 7 行： `theme(legend.position = "top",`
调整图例、轴文字等非数据层的图形外观。

第 8 行： `legend.title = element_blank()) +`
通过 `element_blank()` 隐藏图例标题，不会删除图例本身。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 9 行： `labs(title = "Wages by sex and type of job",`
添加图形标题、轴标题、图例标题和来源说明等。

第 10 行： `x = "Hourly wage (£)",`
设置横轴或纵轴显示名称；`""` 表示故意留空，不显示轴标题。

第 11 行： `y= "Density")`
设置横轴或纵轴显示名称；`""` 表示故意留空，不显示轴标题。

本段用到的函数 / 参数解释

名称	零基础含义
`%>%`	管道运算符：把左边的结果交给右边操作；例如 lfs %>% ggplot(...) 相当于以 lfs 为数据作图。
`ggplot`	初始化 ggplot2 图形，指定数据与美学映射。
`aes`	aesthetics，美学映射；把变量映射到 x/y 坐标、颜色或填充等。
`geom_density`	绘制核密度曲线，观察连续数据的分布形状。
`facet_grid`	按行变量和列变量形成二维分面网格。
`scale_x_log10`	使用底数为10的横轴对数刻度。
`alpha`	透明度，通常范围0～1；数值越低越透明。
`fill`	填充颜色；如果写在 aes() 中，表示由数据类别控制。
`position`	条形的排列方式；"fill" 表示比例堆叠。
`labs`	添加图形标题、轴标题、图例标题和来源说明等。
`theme_minimal`	使用简洁的预设图形主题。
`theme`	调整图例、轴文字等非数据层的图形外观。

名称	零基础含义
`element_blank`	去除特定图形元素，例如图例标题。

数据字段怎么理解？

名称	含义
`lfs`	包含英国劳动力调查记录的数据框名称。
`SEX`	性别类别变量，具体编码以本版本数据字典为准。
`HOURPAY`	小时工资相关变量，本讲作连续数值使用。
`FTPT`	全职/兼职相关分类变量。
`JOBTYP`	工作类型类别变量。

图应该怎样读？为什么这样画？

facet_grid(FTPT~JOBTYP)：波浪号左边控制行，右边控制列；空白格可能表示组合无有效数据。

与前面代码的区别：这段重点改变的是「用 facet_grid(FTPT~JOBTYP) 同时按两个分类变量形成行列网格。」；对比上一张课堂图，可以逐行定位新增或替换了哪个函数、变量或参数。

动手练习：先原样运行该段，再有意识地只调整一个显示参数（例如标题、透明度、`coord_flip()` 是否添加），观察可视化有何变化；不要同时改动多个地方，否则很难判断是哪一项导致结果改变。

14. 教育×行业平均工资：热力图

本段目标：先按教育与行业分组计算平均工资，再将每个组合绘制成一个色块。

课堂原始代码（保持不变）

```
lfs %>%
  group_by(HIQUL22D,INDE07M) %>%
  summarise(mean_wage = mean(HOURPAY)) %>%
  ggplot(aes(HIQUL22D,INDE07M,fill=mean_wage)) +
  geom_tile() +
  theme(axis.text.x = element_text(angle = 90)) +
  labs(title = "Wage by industry and education",
       fill = "Mean hourly wage (£)",
       x = "Highest qualification attained",
       y = "Industry")
```

从第一行开始理解

第 1 行： `lfs %>%`
从数据框 `lfs` 开始； `%>%` 把它送往下一步。 末尾 `%>%` 表示继续将数据传到下一步。

第 2 行： `group_by(HIQUL22D,INDE07M) %>%`
`group_by()` 指定分组键；随后统计会分别对每组计算。当前步骤本身不算均值。 末尾 `%>%` 表示继续将数据传到下一步。

第 3 行： `summarise(mean_wage = mean(HOURPAY)) %>%`
`summarise()` 将各组缩减成汇总结果；`mean_wage = mean(HOURPAY)` 是给计算结果起新列名。 末尾 `%>%` 表示继续将数据传到下一步。

第 4 行： `ggplot(aes(HIQUL22D,INDE07M,fill=mean_wage)) +`
开始建立图对象。`aes(...)` 指定横轴、纵轴或填色变量；仅有 ggplot 初始化时可能还没有几何图形。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 5 行： `geom_tile() +`
按横纵类别组合绘制矩形色块。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 6 行： `theme(axis.text.x = element_text(angle = 90)) +`
调整图例、轴文字等非数据层的图形外观。 设置图中文字样式，例如旋转角度。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 7 行： `labs(title = "Wage by industry and education",`
添加图形标题、轴标题、图例标题和来源说明等。

第 8 行： `fill = "Mean hourly wage (£)",`
设置填充色图例的可见标题文字。

第 9 行： `x = "Highest qualification attained",`
设置横轴或纵轴显示名称；`""` 表示故意留空，不显示轴标题。

第 10 行： `y = "Industry")`
设置横轴或纵轴显示名称；`""` 表示故意留空，不显示轴标题。

本段用到的函数 / 参数解释

名称	零基础含义
`%>%`	管道运算符：把左边的结果交给右边操作；例如 lfs %>% ggplot(...) 相当于以 lfs 为数据作图。
`ggplot`	初始化 ggplot2 图形，指定数据与美学映射。
`aes`	aesthetics，美学映射；把变量映射到 x/y 坐标、颜色或填充等。
`geom_tile`	按横纵类别组合绘制矩形色块。
`group_by`	指定统计汇总所依据的分组变量，不会自动算出统计值。
`summarise`	按每个分组输出汇总值；本讲用来计算组内工资平均值。
`mean`	计算算术平均数，默认碰到 NA 会返回 NA。
`fill`	填充颜色；如果写在 aes() 中，表示由数据类别控制。
`labs`	添加图形标题、轴标题、图例标题和来源说明等。
`theme`	调整图例、轴文字等非数据层的图形外观。
`element_text`	设置图中文字样式，例如旋转角度。

数据字段怎么理解?

名称	含义
`lfs`	包含英国劳动力调查记录的数据框名称。
`HOURPAY`	小时工资相关变量，本讲作连续数值使用。
`INDE07M`	行业分类变量。
`HIQUL22D`	最高教育或资格水平相关分类变量。
`mean_wage`	课件新建的组内平均小时工资列。

图应该怎样读？为什么这样画?

注意原课件使用 mean(HOURPAY)，没有显式 na.rm=TRUE：若某个组包含真正的 NA，平均值就会变成 NA；需按数据处理要求决定是否添加。

与前面代码的区别：这段重点改变的是「先按教育与行业分组计算平均工资，再将每个组合绘制成一个色块。」；对比上一张课堂图，可以逐行定位新增或替换了哪个函数、变量或参数。

动手练习：先原样运行该段，再有意识地只调整一个显示参数（例如标题、透明度、`coord_flip()` 是否添加），观察可视化有何变化；不要同时改动多个地方，否则很难判断是哪一项导致结果改变。

15. 教育×行业×性别：分面热力图

本段目标：在前一段热力图基础上加入 SEX 到分组，再用 facet_wrap() 分性别展示。

课堂原始代码（保持不变）

```
lfs %>%
  group_by(HIQUL22D,INDE07M,SEX) %>%
  summarise(mean_wage = mean(HOURPAY)) %>%
  ggplot(aes(HIQUL22D,INDE07M,fill=mean_wage)) +
  geom_tile() +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 90)) +
  labs(title = "Wage by industry and education",
       fill = "Mean hourly wage (£)",
       x = "Highest qualification attained",
       y = "Industry") +
  facet_wrap(~SEX)
```

从第一行开始理解

第 1 行： `lfs %>%`
从数据框 `lfs` 开始； `%>%` 把它送往下一步。 末尾 `%>%` 表示继续将数据传到下一步。

第 2 行： `group_by(HIQUL22D,INDE07M,SEX) %>%`
`group_by()` 指定分组键；随后统计会分别对每组计算。当前步骤本身不算均值。 末尾 `%>%` 表示继续将数据传到下一步。

第 3 行： `summarise(mean_wage = mean(HOURPAY)) %>%`
`summarise()` 将各组缩减成汇总结果；`mean_wage = mean(HOURPAY)` 是给计算结果起新列名。 末尾 `%>%` 表示继续将数据传到下一步。

第 4 行： `ggplot(aes(HIQUL22D,INDE07M,fill=mean_wage)) +`
开始建立图对象。 `aes(...)` 指定横轴、纵轴或填色变量；仅有 ggplot 初始化时可能还没有几何图形。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 5 行： `geom_tile() +`
按横纵类别组合绘制矩形色块。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 6 行： `theme_minimal() +`
使用简洁的预设图形主题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 7 行： `theme(axis.text.x = element_text(angle = 90)) +`
调整图例、轴文字等非数据层的图形外观。 设置图中文字样式，例如旋转角度。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 8 行： `labs(title = "Wage by industry and education",`
添加图形标题、轴标题、图例标题和来源说明等。

第 9 行： `fill = "Mean hourly wage (£)",`
设置填充色图例的可见标题文字。

第 10 行： `x = "Highest qualification attained",`
设置横轴或纵轴显示名称；`""` 表示故意留空，不显示轴标题。

第 11 行： `y = "Industry") +`
设置横轴或纵轴显示名称；`""` 表示故意留空，不显示轴标题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 12 行： `facet_wrap(~SEX)`
按一个变量拆成多个小面板。

本段用到的函数 / 参数解释

名称	零基础含义
`%>%`	管道运算符：把左边的结果交给右边操作；例如 lfs %>% ggplot(...) 相当于以 lfs 为数据作图。
`ggplot`	初始化 ggplot2 图形，指定数据与美学映射。
`aes`	aesthetics，美学映射；把变量映射到 x/y 坐标、颜色或填充等。
`geom_tile`	按横纵类别组合绘制矩形色块。
`group_by`	指定统计汇总所依据的分组变量，不会自动算出统计值。
`summarise`	按每个分组输出汇总值；本讲用来计算组内工资平均值。
`mean`	计算算术平均数，默认碰到 NA 会返回 NA。
`facet_wrap`	按一个变量拆成多个小面板。
`fill`	填充颜色；如果写在 aes() 中，表示由数据类别控制。

名称	零基础含义
`labs`	添加图形标题、轴标题、图例标题和来源说明等。
`theme_minimal`	使用简洁的预设图形主题。
`theme`	调整图例、轴文字等非数据层的图形外观。
`element_text`	设置图中文字样式，例如旋转角度。

数据字段怎么理解?

名称	含义
`lfs`	包含英国劳动力调查记录的数据框名称。
`SEX`	性别类别变量，具体编码以本版本数据字典为准。
`HOURPAY`	小时工资相关变量，本讲作连续数值使用。
`INDE07M`	行业分类变量。
`HIQUL22D`	最高教育或资格水平相关分类变量。
`mean_wage`	课件新建的组内平均小时工资列。

图应该怎样读？为什么这样画?

按三个变量分组后，每个“学历×行业×性别”组合可生成一个均值。不要将分面区别误认为同一样本的变化。

与前面代码的区别：这段重点改变的是「在前一段热力图基础上加入 SEX 到分组，再用 facet_wrap() 分性别展示。」；对比上一张课堂图，可以逐行定位新增或替换了哪个函数、变量或参数。

动手练习：先原样运行该段，再有意识地只调整一个显示参数（例如标题、透明度、`coord_flip()` 是否添加），观察可视化有何变化；不要同时改动多个地方，否则很难判断是哪一项导致结果改变。

16. 行业就业记录频数：水平条形图

本段目标：这里不再画工资，而是统计不同行业的记录数，用频数对行业排序。

课堂原始代码（保持不变）

```
lfs %>%
  mutate(INDE07M = fct_infreq(INDE07M) %>% fct_rev) %>%
  ggplot(aes(INDE07M)) +
  geom_bar() +
  theme_minimal() +
  labs(title = "Employment by industry",
       x = "",
       y = "Count") +
  coord_flip()
```

从第一行开始理解

第 1 行： `lfs %>%`
从数据框 `lfs` 开始； `%>%` 把它送往下一步。 末尾 `%>%` 表示继续将数据传到下一步。

第 2 行： `mutate(INDE07M = fct_infreq(INDE07M) %>% fct_rev) %>%`
`mutate()` 创建或替换列。这里左边的分类变量名和右边相同，意味着**重新排列类别顺序**，不是新增另一列。 末尾 `%>%` 表示继续将数据传到下一步。

第 3 行： `ggplot(aes(INDE07M)) +`
开始建立图对象。 `aes(...)` 指定横轴、纵轴或填色变量；仅有 ggplot 初始化时可能还没有几何图形。末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 4 行： `geom_bar() +`
默认按类别计数生成柱形图。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 5 行： `theme_minimal() +`
使用简洁的预设图形主题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 6 行： `labs(title = "Employment by industry",`
添加图形标题、轴标题、图例标题和来源说明等。

第 7 行： `x = "",`
设置横轴或纵轴显示名称； `""` 表示故意留空，不显示轴标题。

第 8 行： `y = "Count") +`
设置横轴或纵轴显示名称； `""` 表示故意留空，不显示轴标题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 9 行： `coord_flip()`
交换横纵坐标在图上的显示方向。

本段用到的函数 / 参数解释

名称	零基础含义
`%>%`	管道运算符：把左边的结果交给右边操作；例如 lfs %>% ggplot(...) 相当于以 lfs 为数据作图。
`ggplot`	初始化 ggplot2 图形，指定数据与美学映射。
`aes`	aesthetics，美学映射；把变量映射到 x/y 坐标、颜色或填充等。
`geom_bar`	默认按类别计数生成柱形图。
`mutate`	新建或替换数据列。本讲用于更新因子的排列顺序。
`fct_infreq`	按类别出现频数给因子排序（forcats）。
`coord_flip`	交换横纵坐标在图上的显示方向。
`labs`	添加图形标题、轴标题、图例标题和来源说明等。
`theme_minimal`	使用简洁的预设图形主题。

数据字段怎么理解?

名称	含义
`lfs`	包含英国劳动力调查记录的数据框名称。
`INDE07M`	行业分类变量。

图应该怎样读？为什么这样画?

geom_bar() 默认执行计数统计（stat="count"）；高度是观测数量，不自动等于经过抽样权重推断的就业人口数。

与前面代码的区别：这段重点改变的是「这里不再画工资，而是统计不同行业的记录数，用频数对行业排序。」；对比上一张课堂图，可以逐行定位新增或替换了哪个函数、变量或参数。

动手练习：先原样运行该段，再有意识地只调整一个显示参数（例如标题、透明度、`coord_flip()` 是否添加），观察可视化有何变化；不要同时改动多个地方，否则很难判断是哪一项导致结果改变。

17. 行业×教育：堆叠条形图

本段目标：以学历作为 fill 分类，观察不同行业的学历构成的样本计数。

课堂原始代码（保持不变）

```
lfs %>%
  mutate(INDE07M = fct_infreq(INDE07M) %>% fct_rev) %>%
  ggplot(aes(INDE07M, fill=HIQUL22D)) +
  geom_bar() +
  theme_minimal() +
  labs(fill = "Education",
       title = "Employment by industry and education",
       x = "",
       y = "Count") +
  coord_flip()
```

从第一行开始理解

第 1 行： `lfs %>%`
从数据框 `lfs` 开始； `%>%` 把它送往下一步。 末尾 `%>%` 表示继续将数据传到下一步。

第 2 行： `mutate(INDE07M = fct_infreq(INDE07M) %>% fct_rev) %>%`
`mutate()` 创建或替换列。这里左边的分类变量名和右边相同，意味着**重新排列类别顺序**，不是新增另一列。 末尾 `%>%` 表示继续将数据传到下一步。

第 3 行： `ggplot(aes(INDE07M, fill=HIQUL22D)) +`
开始建立图对象。 `aes(...)` 指定横轴、纵轴或填色变量；仅有 ggplot 初始化时可能还没有几何图形。末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 4 行： `geom_bar() +`
默认按类别计数生成柱形图。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 5 行： `theme_minimal() +`
使用简洁的预设图形主题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 6 行： `labs(fill = "Education",`
添加图形标题、轴标题、图例标题和来源说明等。 `fill` 指填充色；放在 `aes()` 内是将填充颜色映射到数据列，放在 `labs()` 内则是修改图例标题。

第 7 行： `title = "Employment by industry and education",`
这一项是图表显示的标题/副标题/来源说明，是一段**文字字符串**，并非统计变量。

第 8 行： `x = "",`
设置横轴或纵轴显示名称； `""` 表示故意留空，不显示轴标题。

第 9 行： `y = "Count") +`
设置横轴或纵轴显示名称； `""` 表示故意留空，不显示轴标题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 10 行： `coord_flip()`
交换横纵坐标在图上的显示方向。

本段用到的函数 / 参数解释

名称	零基础含义
`%>%`	管道运算符：把左边的结果交给右边操作；例如 lfs %>% ggplot(...) 相当于以 lfs 为数据作图。
`ggplot`	初始化 ggplot2 图形，指定数据与美学映射。
`aes`	aesthetics，美学映射；把变量映射到 x/y 坐标、颜色或填充等。
`geom_bar`	默认按类别计数生成柱形图。
`mutate`	新建或替换数据列。本讲用于更新因子的排列顺序。
`fct_infreq`	按类别出现频数给因子排序（forcats）。
`coord_flip`	交换横纵坐标在图上的显示方向。
`fill`	填充颜色；如果写在 aes() 中，表示由数据类别控制。
`labs`	添加图形标题、轴标题、图例标题和来源说明等。
`theme_minimal`	使用简洁的预设图形主题。

数据字段怎么理解?

名称	含义
`lfs`	包含英国劳动力调查记录的数据框名称。
`INDE07M`	行业分类变量。
`HIQUL22D`	最高教育或资格水平相关分类变量。

图应该怎样读？为什么这样画？

默认堆叠条形图中，不同 fill 类别的计数相加构成每根柱的总高度。

与前面代码的区别：这段重点改变的是「以学历作为 fill 分类，观察不同行业的学历构成的样本计数。」；对比上一张课堂图，可以逐行定位新增或替换了哪个函数、变量或参数。

动手练习：先原样运行该段，再有意识地只调整一个显示参数（例如标题、透明度、`coord_flip()` 是否添加），观察可视化有何变化；不要同时改动多个地方，否则很难判断是哪一项导致结果改变。

18. 行业内部教育比例：100%堆叠图

本段目标：将 geom_bar() 的 position 改成 "fill"，各行业柱子都缩放至总高度 1，对比内部比例。

课堂原始代码（保持不变）

```
library(ggthemes)

lfs %>%
  mutate(INDE07M = fct_infreq(INDE07M) %>% fct_rev) %>%
  ggplot(aes(INDE07M, fill=HIQUL22D)) +
  geom_bar(position="fill") +
  theme_minimal() +
  labs(fill = "Education",
       title = "Employment by industry and education",
       x = "",
       y = "Share") +
  coord_flip() +
  scale_fill_colorblind()
```

从第一行开始理解

第 1 行： `library(ggthemes)`
加载括号内指定的R扩展包；若提示没有该包，请先用 `install.packages()` 安装。

第 3 行： `lfs %>%`
从数据框 `lfs` 开始； `%>%` 把它送往下一步。 末尾 `%>%` 表示继续将数据传到下一步。

第 4 行： `mutate(INDE07M = fct_infreq(INDE07M) %>% fct_rev) %>%`
`mutate()` 创建或替换列。这里左边的分类变量名和右边相同，意味着**重新排列类别顺序**，不是新增另一列。 末尾 `%>%` 表示继续将数据传到下一步。

第 5 行： `ggplot(aes(INDE07M, fill=HIQUL22D)) +`
开始建立图对象。 `aes(...)` 指定横轴、纵轴或填色变量；仅有 ggplot 初始化时可能还没有几何图形。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 6 行： `geom_bar(position="fill") +`
默认按类别计数生成柱形图。 `position="fill"` 让每组柱子占满100%，显示组内比例。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 7 行： `theme_minimal() +`
使用简洁的预设图形主题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 8 行： `labs(fill = "Education",`
添加图形标题、轴标题、图例标题和来源说明等。 `fill` 指填充色；放在 `aes()` 内是将填充颜色映射到数据列，放在 `labs()` 内则是修改图例标题。

第 9 行： `title = "Employment by industry and education",`
这一项是图表显示的标题/副标题/来源说明，是一段**文字字符串**，并非统计变量。

第 10 行： `x = "",`
设置横轴或纵轴显示名称； `""` 表示故意留空，不显示轴标题。

第 11 行： `y = "Share") +`
设置横轴或纵轴显示名称； `""` 表示故意留空，不显示轴标题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 12 行： `coord_flip() +`
交换横纵坐标在图上的显示方向。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 13 行： `scale_fill_colorblind()`
ggthemes 的适合常见色觉差异的定性填色配色方案。

本段用到的函数 / 参数解释

名称	零基础含义
`%>%`	管道运算符：把左边的结果交给右边操作；例如 lfs %>% ggplot(...) 相当于以 lfs 为数据作图。
`ggplot`	初始化 ggplot2 图形，指定数据与美学映射。
`aes`	aesthetics，美学映射；把变量映射到 x/y 坐标、颜色或填充等。
`geom_bar`	默认按类别计数生成柱形图。
`mutate`	新建或替换数据列。本讲用于更新因子的排列顺序。
`fct_infreq`	按类别出现频数给因子排序（forcats）。
`coord_flip`	交换横纵坐标在图上的显示方向。
`fill`	填充颜色；如果写在 aes() 中，表示由数据类别控制。
`position`	条形的排列方式；"fill" 表示比例堆叠。
`labs`	添加图形标题、轴标题、图例标题和来源说明等。
`theme_minimal`	使用简洁的预设图形主题。
`scale_fill_colorblind`	ggthemes 的适合常见色觉差异的定性填色配色方案。
`library`	加载安装好的R包；ggthemes 需要事先安装。

数据字段怎么理解?

名称	含义
`lfs`	包含英国劳动力调查记录的数据框名称。
`INDE07M`	行业分类变量。
`HIQUL22D`	最高教育或资格水平相关分类变量。

图应该怎样读?为什么这样画?

position="fill" 将每根柱归一到高度 1（100%），观察份额而不显示各组总样本量差异。

与前面代码的区别：这段重点改变的是「将 geom_bar() 的 position 改成 "fill"，各行业柱子都缩放至总高度 1，对比内部比例。」；对比上一张课堂图，可以逐行定位新增或替换了哪个函数、变量或参数。

动手练习：先原样运行该段，再有意识地只调整一个显示参数（例如标题、透明度、`coord_flip()` 是否添加），观察可视化有何变化；不要同时改动多个地方，否则很难判断是哪一项导致结果改变。

19. 行业×教育×性别：分面比例图

本段目标：最后在比例堆叠柱形图基础上增加性别分面，比较各性别的行业内部教育组成。

课堂原始代码（保持不变）

```
lfs %>%
  mutate(INDE07M = fct_infreq(INDE07M) %>% fct_rev) %>%
  ggplot(aes(INDE07M, fill=HIQUL22D)) +
  geom_bar(position="fill") +
  theme_minimal() +
  labs(fill = "Education",
       title = "Employment by industry and education",
       x = "",
       y = "Share") +
  coord_flip() +
  scale_fill_colorblind() +
  facet_wrap(~SEX)
```

从第一行开始理解

第 1 行： `lfs %>%`
从数据框 `lfs` 开始；`%>%` 把它送往下一步。 末尾 `%>%` 表示继续将数据传到下一步。

第 2 行： `mutate(INDE07M = fct_infreq(INDE07M) %>% fct_rev) %>%`
`mutate()` 创建或替换列。这里左边的分类变量名和右边相同，意味着**重新排列类别顺序**，不是新增另一列。 末尾 `%>%` 表示继续将数据传到下一步。

第 3 行： `ggplot(aes(INDE07M, fill=HIQUL22D)) +`
开始建立图对象。 `aes(...)` 指定横轴、纵轴或填色变量；仅有 ggplot 初始化时可能还没有几何图形。
末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 4 行： `geom_bar(position="fill") +`
默认按类别计数生成柱形图。 `position="fill"` 让每组柱子占满100%，显示组内比例。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 5 行： `theme_minimal() +`
使用简洁的预设图形主题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 6 行： `labs(fill = "Education",`
添加图形标题、轴标题、图例标题和来源说明等。 `fill` 指填充色；放在 `aes()` 内是将填充颜色映射到数据列，放在 `labs()` 内则是修改图例标题。

第 7 行： `title = "Employment by industry and education",`
这一项是图表显示的标题/副标题/来源说明，是一段**文字字符串**，并非统计变量。

第 8 行： `x = "",`
设置横轴或纵轴显示名称；`""` 表示故意留空，不显示轴标题。

第 9 行： `y = "Share") +`
设置横轴或纵轴显示名称；`""` 表示故意留空，不显示轴标题。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 10 行： `coord_flip() +`
交换横纵坐标在图上的显示方向。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 11 行： `scale_fill_colorblind() +`
ggthemes 的适合常见色觉差异的定性填色配色方案。 末尾 `+` 表示后面还要接一个 ggplot 图层或样式。

第 12 行： `facet_wrap(~SEX)`
按一个变量拆成多个小面板。

本段用到的函数 / 参数解释

名称	零基础含义
`%>%`	管道运算符：把左边的结果交给右边操作；例如 lfs %>% ggplot(...) 相当于以 lfs 为数据作图。
`ggplot`	初始化 ggplot2 图形，指定数据与美学映射。
`aes`	aesthetics，美学映射；把变量映射到 x/y 坐标、颜色或填充等。
`geom_bar`	默认按类别计数生成柱形图。
`mutate`	新建或替换数据列。本讲用于更新因子的排列顺序。
`fct_infreq`	按类别出现频数给因子排序（forcats）。
`coord_flip`	交换横纵坐标在图上的显示方向。
`facet_wrap`	按一个变量拆成多个小面板。
`fill`	填充颜色；如果写在 aes() 中，表示由数据类别控制。
`position`	条形的排列方式；"fill" 表示比例堆叠。
`labs`	添加图形标题、轴标题、图例标题和来源说明等。

名称	零基础含义
`theme_minimal`	使用简洁的预设图形主题。
`scale_fill_colorblind`	ggthemes 的适合常见色觉差异的定性填色配色方案。

数据字段怎么理解？

名称	含义
`lfs`	包含英国劳动力调查记录的数据框名称。
`SEX`	性别类别变量，具体编码以本版本数据字典为准。
`INDE07M`	行业分类变量。
`HIQUL22D`	最高教育或资格水平相关分类变量。

图应该怎样读？为什么这样画？

性别分面后，各面板各行业的柱子在所在面板内部归一化，不要把面积当成全国人口权重。

与前面代码的区别：这段重点改变的是「最后在比例堆叠柱形图基础上增加性别分面，比较各性别的行业内部教育组成。」；对比上一张课堂图，可以逐行定位新增或替换了哪个函数、变量或参数。

动手练习：先原样运行该段，再有意识地只调整一个显示参数（例如标题、透明度、`coord_flip()` 是否添加），观察可视化有何变化；不要同时改动多个地方，否则很难判断是哪一项导致结果改变。

---

20. 第五讲所有代码的总体逻辑

目标	课堂方法	阅读重点
比较连续变量在类别组内的分布	`geom_boxplot()`	中位数、Q1、Q3、箱须、离群点
展示各类别的分布轮廓	`geom_violin()`	核密度形状与宽度
显示大量单条记录	`geom_jitter()`	重叠、透明度、抖动
探索两个连续变量关系	`geom_point()`	散点模式，不代表因果
拆分多个对比面板	`facet_wrap()`、`facet_grid()`	单变量或双变量分面
显示类别组合的数值	`group_by()` → `summarise()` → `geom_tile()`	先汇总再映射填色
统计类别频数	`geom_bar()`	默认样本记录数量
比较数量构成	`geom_bar(aes(fill=...))`	堆叠数量
比较内部份额	`geom_bar(position="fill")`	100%构成而非总量

21. 八组极容易混淆的概念

21.1 `geom_boxplot()` 与 `geom_violin()`

箱线图强调分位数、中位数、离群点；小提琴图强调经平滑估计的分布形状。两种图可以叠加，前提是数据和分组映射一致。

21.2 `geom_point()` 与 `geom_jitter()`

前者按真实数值坐标绘点；后者人为加入少量位置扰动，避免大量观测堆在同一点。抖动是绘图技巧，不应该把微小偏移解读成真实的个体差异。

21.3 `aes(fill = SEX)` 与 `fill = "blue"`

前者由每条记录的性别组决定颜色、通常会出现图例；后者是给图层统一指定蓝色，不涉及一个用来分类的变量。

21.4 `scale_y_log10()` 与 `scale_x_log10()`

注意选的是哪个轴；`coord_flip()` 还会影响图表最后的可视位置。数值为零或负数不能直接做 log10。

21.5 `facet_wrap(~GOR9D)` 与 `facet_grid(FTPT~JOBTYP)`

`facet_wrap` 用单个变量铺设很多面板；`facet_grid` 的 `~` 左侧指定行、右侧指定列。

21.6 `group_by()` 与 `summarise()`

分组只是告诉R"每一组包含什么"；真正计算一组一个平均值的是 `summarise()`。缺任何一个，后续热力图可能无法表达各组的平均工资。

21.7 `geom_bar()` 计数与 `geom_bar(position="fill")` 份额

计数图的柱高是样本行数；`position="fill"` 将每根柱转换成组内的相对构成。**两者回答不同问题**：哪组记录多 vs 某组内部各类别占比多少。

21.8 `fct_reorder()` 与 `fct_infreq()`

`fct_reorder()` 按另一列的统计量（本讲是小时工资的 `median`）给分类排序；`fct_infreq()` 按分类出现次数排序；`fct_rev()` 则把已有顺序倒过来。

22. 零基础常见报错与处理

错误一： `could not find function "ggplot"`
原因：没加载相应包。先安装 tidyverse，再运行 `library(tidyverse)`。

错误二： `object 'lfs' not found`
原因：数据没有成功读取到对象 `lfs`，或重新打开 R 后丢失了上一次会话对象。

错误三： `object 'HOURPAY' not found`
原因：列名不同、数据读入错误、大小写不同，或当前传入的不是包含该列的数据框。先运行 `names(lfs)` 检查。

错误四：找不到 `fct_reorder` 或 `fct_infreq`
它们来自 forcats；一般加载 `tidyverse` 即可，也可用 `forcats::fct_reorder(...)` 明确指定包。

错误五：找不到 `scale_fill_colorblind`
它来自 `ggthemes`；先 `install.packages("ggthemes")`，然后 `library(ggthemes)`。

错误六：`Removed ... rows` / `Transformation introduced infinite values`
可能有缺失值、无效记录或不能取对数的非正数。先检查 `summary(lfs$HOURPAY)` 和工资变量的编码。不能只为了"消除警告"而随意删除数据。

错误七：热力图出现 NA 色块
原课件的 `mean(HOURPAY)` 默认不跳过 NA。在理解数据质量后，若适当，可考虑 `mean(HOURPAY, na.rm = TRUE)`；还应确保一个组并非全部缺失。

错误八：图例和轴标题位置不符合预期
`labs(fill="...")` 改填色图例的标题；`theme(legend.title=element_blank())` 隐藏它；`theme(legend.position="top")` 改变图例位置。作用各不相同。

23. 研究解释中的必要提醒（额外补充，不是课堂原代码）

- `lfs` 是复杂抽样调查微观数据。本讲绘图代码旨在学习 ggplot2 绘图，**并未显式应用劳动力调查权重**；不能将简单样本频数直接解释为英国总人口或总体就业人数。
- `mean(HOURPAY)` 是普通算术平均；若研究目标是具有总体代表性的收入估计，需要讨论调查权重、样本选择及官方推荐的估计方法。
- 性别、行业、教育等分类变量的确切数值编码必须以数据字典为准。讲义中表现为文本标签时，先核对因子水平，再进行解释。
- 相关与差异不等于因果。不同性别/教育/行业的工资差异可能与年龄、经验、工作时间、职业等共同相关。

24. 从零开始的练习题（补充练习，不是课件原文）

1. 从第1段代码出发，把图标题改成英文 `Hourly pay comparison`。指出 `labs()` 中修改了哪个参数。
2. 对比第2、3段，分别指出 `fct_reorder()` 与 `coord_flip()` 解决了什么不同的问题。
3. 对比第6、7段，解释为什么同一张图同时出现小提琴和箱线，以及 `width=0.2` 改变的是什么。
4. 对比第10、11段，解释 `geom_jitter(alpha=0.2)` 为何比基本散点图更容易发现密集区域。
5. 对比第16、17、18段，写出"数量 → 按教育堆叠数量 → 按教育堆叠比例"的函数变化。
6. 对比第14、15段，说明为什么分组时增加 SEX 后，绘图还需要增加 `facet_wrap(~SEX)`。

练习参考提示

第1题：`labs(title=...)`。第2题：前者改变类别顺序，后者改变显示方向。第3题：分布形状和四分位数相结合；宽度仅改变箱体形状。第4题：减少重合并通过透明度看出点聚集。第5题：增加 `fill=HIQUL22D`，再设置 `position="fill"`。第6题：分组生成每个性别独立的组内均值，分面将其分开可视化。

25. 一页速查卡

```
# 在已有 lfs 数据对象基础上：
# 看两类变量的关系
```

```r
ggplot(lfs, aes(AGE, HOURPAY)) + geom_point()

# 分类变量与连续数值
ggplot(lfs, aes(SEX, HOURPAY)) + geom_boxplot()

# 按类别拆成多个图
ggplot(lfs, aes(HOURPAY, fill = SEX)) +
  geom_density(alpha = 0.3) +
  facet_wrap(~GOR9D)

# 先汇总，再画色块（这里仅用于语法演示）
lfs %>%
  group_by(HIQUL22D, INDE07M) %>%
  summarise(mean_wage = mean(HOURPAY), .groups = "drop") %>%
  ggplot(aes(HIQUL22D, INDE07M, fill = mean_wage)) +
  geom_tile()
```

> 最后的速查代码是为了快速记住课堂概念而重组的练习示例；上方第1–19节才是从原 HTML 顺序提取的课堂代码全文。推荐以原讲义图片、老师给定的数据编码与课程要求为最后解释依据。