Lecture 6 | 统计推断、抽样误差、正态分布、t检验与回归——R语言完全零基础逐行代码教程

> **课程**：URBAN5127 Quantitative Data Analysis | **来源**：`lecture6_notes.html`（课堂原始讲义）与对应中文版。
> **读者**：没有编程经验、正在学习R/RStudio的初学者。**方法**：保持讲义全部课堂R代码原样，逐行解释，再用独立标注的教学补充帮助理解。

〇、先认识这一讲：统计推断、抽样误差、正态分布、t检验与回归

这一讲用LFS小时工资的性别差异，说明"样本中观察到差异"与"总体中有差异"并非同一件事；通过正态概率、t检验以及简单线性回归了解统计推断。

读完应当会：

1. 样本和总体的区别。
2. 均值和抽样误差。
3. 正态分布、Z值、尾部概率。
4. 双样本t检验、置信区间、p值。
5. 虚拟变量与一元回归。

原始代码的覆盖范围

- 英文原始HTML中识别到 **4段真正的课堂R代码（`pre.r`）**；下文每一段完整按原顺序出现，**不省略或替换原始代码。**
- HTML中的黑色`## ...`控制台打印是**运行结果**，不能把它当成要重新输入的R命令；网页的JavaScript/CSS也不是本课R代码。
- 如果相同代码在不同位置重复出现，教程仍按原讲义顺序保留并解释其教学目的。

一、先修知识：即使从来没写过代码也能看懂

1.1 R / RStudio到底是什么?

R是一种用于统计分析的编程语言；RStudio是帮助你编辑、运行、检查R程序的工作界面。**R语言**决定代码含义，**RStudio**提供Source（脚本编辑器）、Console（即时运行）、Environment（查看对象）、Plots（看图）等窗口。
建议先创建一个`.R`脚本，将本教程中的每段原始代码逐段粘贴进去；在RStudio中选中一行或几行按Ctrl+Enter（Windows）或Cmd+Enter（macOS）运行。不要一次性运行全部章节：有些讲义代码依赖之前做过的数据处理。

1.2 把R代码当成一句完整的话来阅读

写法	初学者的读法	常见误解
`x <- ...`	把右边结果保存到x	以为`<-`是小于号

写法	初学者的读法	常见误解
`f(x, y)`	调用函数f，把x和y作为参数	以为所有括号都在做数学乘法
`data = lfs`	指定数据对象	以为这里是把变量赋值给lfs
`df$AGE`	从df里抽取AGE这一列	以为`$`有货币意义
`a %>% b()`	先做a，再把结果交给b	与ggplot的图层加号`+`混淆
`y ~ x1 + x2`	用x1、x2共同解释y	把公式中的`+`当成数值求和
`"Female"`	这是**字符串文字**	误以为是变量名
`TRUE`与`FALSE`	布尔值/逻辑值	与文字`"TRUE"`混淆
`# ...`	注释，对运行结果无影响	把注释当成一定会运行的代码
`<`、`==`	分别表示小于、是否相等	把`==`与赋值符混淆

如果一行很长，先找最外层函数，再拆成“传入的数据→做了什么→返回什么”；碰到多层括号，从**最里面的函数**开始理解。

1.3 第一次运行前，需要准备哪些包？

初学者先区分：**安装（install.packages）只需通常做一次，载入（library）在每次新R会话中可能要再执行。**下方是**教学补充**，不是原课件代码：

```
# 第一次使用且尚未安装时，去掉下面一行行首的 # 并运行
# install.packages(c("dplyr", "knitr"))
library(dplyr)
library(knitr)
```

这些包在本讲主要用于：

- `dplyr`：group_by、summarise。
- `knitr`：kable。

`lm()`、`summary()`、`aov()`、`t.test()`、`cor()`、`cor.test()`和`plot()`等来自R基础/推荐自带组件，通常不需要为它们单独安装新包。

1.4 数据对象和运行顺序

- LFS示例中的`lfs`不是R预装对象。课程前几讲已完成**读取、筛选、清洗、因子转换**，这些步骤需要先执行；本教程不臆造文件路径或原始清洗代码。
- 第9讲还使用`mtcars`（R内置数据集）；第8讲第一段代码会创建虚构对象`fake_data`。
- 如果出现`object 'lfs' not found`，不是本行统计公式错了，而是尚未创建或读入`lfs`。
- 课堂输出与现在运行结果只有在使用同一份已清洗数据、相同函数设定、相容包版本时才可能完全一致。

1.5 这几类对象是什么?

- **向量（vector）**：一列同类型值，常由`c(...)`生成。
- **数据框（data.frame / tibble）**：像Excel表格，行对应观测、列对应变量。
- **函数（function）**：执行特定任务，如`mean()`求平均、`lm()`拟合回归。
- **参数（argument）**：括号里告诉函数如何工作的选项，例如`data = lfs`。
- **模型对象**：`lm(...)`运行后返回的结果，里面有系数、残差、拟合值等，不只是一个单独数字。
- **因子（factor）**：R记录分类变量的特殊类型，参照组决定类别回归系数的解释方式。

二、本讲课程代码：原文保留、逐段拆解

代码 01｜计算男性与女性的平均小时工资

原讲义位置：男性与女性的平均工资。

这段想做什么?

先按照SEX划分组别，再对每组HOURPAY求均值，保留两位小数，以便在后面讨论抽样差异。

课堂原始R代码（完整保留）

```
lfs %>% group_by(SEX) %>%
  summarise(mean_wage = mean(HOURPAY) %>% round(2)) %>%
  knitr::kable()
```

逐行讲解

1. **第1行** `lfs %>% group_by(SEX) %>%`：从`lfs`数据框开始进入管道流程。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `group_by(SEX)`按性别分组，影响后续汇总函数。
2. **第2行** `summarise(mean_wage = mean(HOURPAY) %>% round(2)) %>%`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `summarise()`输出每组的统计汇总。 `mean(HOURPAY)`计算小时工资的算术平均数。 `round(2)`代表保留2位小数，而非取第2个值。
3. **第3行** `knitr::kable()`： `knitr::kable()`用于生成展示用表格； `::`指定来自knitr包。

把函数和统计概念拆开看

1. `group_by(SEX)`不会立即计算任何统计量，而是告诉后续`dplyr`函数"接下来按性别分别处理"。
2. `summarise(mean_wage = ...)`每组生成一个名为`mean_wage`的结果；左边是自己起的列名。
3. `mean(HOURPAY) %>% round(2)`先算平均工资，再把得到的数字交给`round(2)`，其中2表示保留两位小数。
4. `knitr::kable()`把汇总数据渲染为适合HTML/Markdown展示的表格。

课件输出怎样读?

该段输出可能作为HTML表格或图形展示，不一定显示为控制台打印。关注对象在下一步代码中是如何被使用的。

初学者容易踩的坑 / 研究上的注意事项

这里的组均值属于**描述统计**：它描述样本，并不能单靠两个均值不同就推出总体具有统计显著的差异。若工资含NA，应根据数据清洗规则处理，而不是直接使用`na.rm=TRUE`而不记录缺失情况。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 02 | 用正态分布计算极端Z值的右尾概率

原讲义位置：使用R获取概率。

这段想做什么?

课程给出标准化统计量11.26，展示R如何计算"标准正态值达到或超过11.26"的概率。

课堂原始R代码（完整保留）

```
1-pnorm(11.26)
```

逐行讲解

1. **第1行** `1-pnorm(11.26)`：`pnorm()` 返回累计正态分布概率；左侧的 `1-` 将左尾转为右尾。

把函数和统计概念拆开看

1. `pnorm(z)` 返回标准正态分布中"随机变量不大于z"的累计概率。
2. `1 - pnorm(11.26)` 用1减去左侧累计概率，得到理论上的右尾概率。
3. 课件输出 `[1] 0` 是数值精度下的显示结果，并不表示数学上的概率严格等于零。
4. 如果进行**双侧**检验，通常还要同时考虑另一侧的极端区域，不能将这一行直接当作双侧p值。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
## [1] 0
```

出现 `[1] 0` 说明R打印了第一个数值元素为0；极小右尾概率在此算法下可能因浮点数舍入显示为0，不代表概率数学上严格等于零。

初学者容易踩的坑 / 研究上的注意事项

对极端尾部概率，教学补充的更稳健写法是 `pnorm(11.26, lower.tail = FALSE)`；这能避免 `1 - pnorm(...)` 因舍入产生0。双侧正态尾部概率示例可写为 `2 * pnorm(abs(11.26), lower.tail = FALSE)`，但这并不替代课件实际使用的Welch t检验。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 03 | 对性别分组进行Welch双样本t检验

原讲义位置：检验不同性别的工资差异。

这段想做什么?

通过原始数据检验两组的总体平均小时工资是否有差异，而不仅观察样本均值。

课堂原始R代码（完整保留）

```
t.test(HOURPAY ~ SEX, data=lfs)
```

逐行讲解

1. **第1行** `t.test(HOURPAY ~ SEX, data=lfs)`：`data=lfs` 明确指定从lfs表取变量。 `~` 连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 `t.test()` 检验性别两组工资的总体均值差，默认是Welch版本。

把函数和统计概念拆开看

1. `t.test()` 在这里因公式右侧是两组分类变量而执行两样本t检验。
2. `HOURPAY ~ SEX` 可读为"用性别分组比较小时工资"；波浪线左边是被比较的数值变量，右边是分组变量。
3. `data=lfs` 说明变量都到lfs数据框中寻找。
4. R默认使用Welch两样本t检验，允许两组方差不同；这和经典等方差t检验的自由度与标准误可能不同。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
##
##  Welch Two Sample t-test
##
## data:  HOURPAY by SEX
## t = 11.257, df = 6531.3, p-value < 2.2e-16
## alternative hypothesis: true difference in means between group Male and group
Female is not equal to 0
## 95 percent confidence interval:
##  2.526349 3.591807
## sample estimates:
##   mean in group Male mean in group Female
##             22.48338             19.42430
```

读法顺序：先看`Welch Two Sample t-test`确认检验版本，再看`t`和`df`，然后`p-value`，最后核对两组样本均值及95%置信区间。**不要**把p值理解成"性别导致工资差异的概率"。

初学者容易踩的坑 / 研究上的注意事项

课件输出`t = 11.257`、`df = 6531.3`且`p-value < 2.2e-16`，说明在零均值差的假设下，观察到如此极端或更极端差异的概率极低。仍需检查样本设计、代表性及实际差值大小；p值不是"原假设为真的概率"。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 04｜用虚拟变量回归表示性别工资差异

原讲义位置：线性模型中的t检验。

这段想做什么?

把刚才的组均值问题表达成回归：以男性为参考组，女性的系数代表相对于男性的平均工资差。

课堂原始R代码（完整保留）

```
lm(HOURPAY ~ SEX, data=lfs) %>% summary()
```

逐行讲解

1. **第1行** `lm(HOURPAY ~ SEX, data=lfs) %>% summary()`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。`data=lfs`明确指定从lfs表取变量。`~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。`lm()`拟合线性回归，括号内包括公式与数据来源。`summary()`输出摘要；模型对象包括估计系数、标准误、t值、p值等。

把函数和统计概念拆开看

1. `lm()`表示拟合普通最小二乘线性模型（OLS）。
2. `HOURPAY ~ SEX`中的SEX如为factor变量，R会按参照组生成相应虚拟变量。
3. `%>% summary()`查看详细回归表，包括系数、标准误、t值、p值和R^2。
4. `(Intercept)`是参考组预测均值，`SEXFemale`表示女性相对参考组男性的差值，参照组需按实际factor levels确认。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
## Call:
## Residuals:
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  22.4834     0.1959  114.76   <2e-16 ***
## SEXFemale    -3.0591     0.2676  -11.43   <2e-16 ***
## Multiple R-squared:  0.01748,    Adjusted R-squared:  0.01734
## F-statistic: 130.6 on 1 and 7345 DF,  p-value: < 2.2e-16
```

回归摘要读法：`Call`说明实际模型公式；`Coefficients`中`Estimate`是系数、`Std. Error`是标准误、`t value`是估计/标准误、`Pr(>|t|)`为显著性检验；`Multiple R-squared`是模型在当前因变量尺度下的解释比例。

初学者容易踩的坑 / 研究上的注意事项

课件示例截距为22.4834，`SEXFemale=-3.0591`，即男性参考组的预测均值约22.48，女性比其低约3.06（单位取决于原数据）。回归中的t检验使用该回归的方差设定，因此t值不一定与上一段Welch t检验完全一样。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

三、按课堂顺序串起来：这一讲完整分析流程

一步一步理解"抽样—估计—检验"

1. **总体**是想描述的所有对象；**样本**是实际拿到的数据。数据只覆盖样本，因此相同研究重复抽样可能得到不同均值。
2. **描述性差异**：比如样本里男性均值22.48，女性均值19.42，差3.06。这个数字只是本次样本的结果。
3. **零假设H_0**：在总体中两组均值相同，差为0；**备择假设H_1**：两组总体均值不同（双侧）。
4. **检验统计量**衡量观察到的差异相对于抽样不确定性有多大；t值/Z值越极端，通常越不支持H_0。
5. **p值**是假定H_0成立时，出现至少同样极端数据的概率；它不是"结论错误的概率"，更不是效应大小。
6. **95%置信区间**通过重复抽样方法构建，其覆盖总体参数的长期比例约95%；不是"参数有95%的随机概率落入本次固定区间"。
7. **重要前提**：LFS可能有复杂抽样、权重及缺失编码；课堂`mean/t.test/lm`演示标准方法，但正式研究需决定是否使用调查设计。

需要记住的完整逻辑

1. 先**分组描述样本均值**，观察实际差异。
2. 再**假设总体无差异**，理解抽样波动可能造成什么样的样本差距。
3. 用概率和**Welch t检验**评估这种差异的统计证据。
4. 把两组均值改写为**线性回归+虚拟变量**，学会比较系数、标准误与p值。

四、函数与参数速查表

函数/运算符	用来做什么	使用时先检查什么
`group_by()`	设置分组；不会马上求均值，而是影响随后`summarise()`如何处理数据	输入是什么类型？缺失值和参考组怎么处理？
`summarise()`	按组或对全表汇总，通常每个组产生一行结果	输入是什么类型？缺失值和参考组怎么处理？
`mean()`	计算算术平均数；缺失值处理需额外留意	输入是什么类型？缺失值和参考组怎么处理？

函数/运算符	用来做什么	使用时先检查什么
`round()`	按指定小数位对数值进行四舍五入显示	输入是什么类型？缺失值和参考组怎么处理？
`kable()`	把数据框渲染成课程文档中的表格	输入是什么类型？缺失值和参考组怎么处理？
`pnorm()`	计算正态分布的累计分布函数（默认均值0、标准差1）	输入是什么类型？缺失值和参考组怎么处理？
`t.test()`	执行t检验；公式接口在本例比较两组均值	输入是什么类型？缺失值和参考组怎么处理？
`lm()`	拟合普通最小二乘线性回归模型	输入是什么类型？缺失值和参考组怎么处理？
`summary()`	根据对象类型给出统计摘要；lm对象显示系数、标准误、p值和拟合统计量	输入是什么类型？缺失值和参考组怎么处理？
`%>%`	管道符：把左边结果交给右边函数，便于从左到右阅读操作顺序	这里是回归公式、比较表达式还是普通计算？
`~`	模型/检验公式分隔符：在回归中通常左边是结果变量，右边是解释变量	这里是回归公式、比较表达式还是普通计算？

五、本讲用到的变量：名字不是它们的中文意思

原变量名	根据本系列讲义能够确认/需要核对的含义
`HOURPAY`	小时工资（此系列课程LFS示例中的因变量）
`SEX`	性别分组

> **避免误译**：LFS数据的编码与变量类别需以课程使用的变量说明、元数据和预处理后的 `levels()` 为准。上表中对含义不明确的字段明确提示了“需要数据字典核实”，没有强行猜测。

六、初学者常见错误与排查顺序

1. **object not found（对象不存在）**：确认是否先创建了 `lfs` 或 `fake_data`，或前一步的 `select()` 是否把变量删掉。
2. **could not find function（找不到函数）**：确认是否安装并 `library()` 了相应包。
3. **unexpected symbol / unexpected end of input（语法错误）**：检查括号、引号、逗号和前一行末尾的 `%>%` 是否完整。
4. **missing values / NA / -Inf**：统计函数遇到 `NA` 或 `log(0)` 会出问题，正式分析需遵循数据字典及清洗记录。
5. **contrasts can be applied only to factors with 2 or more levels**：筛选样本后某个分类变量可能只剩一类，需要检查 `table()` 或 `levels()`。
6. **课程输出与自己不同**：先比较数据版本、样本行数、变量类型、参考组、缺失处理和包版本，不要立即修改统计模型去“凑数”。
7. **统计显著误当成因果关系**：观察数据中的关联仍可能受未观测因素影响，报告必须诚实描述限制。

七、课后练习：自己独立运行，别只看解释

练习 1 | 算均值

把示例分组汇总的`round(2)`改成`round(1)`。观察显示的小数位变化，并思考总体推断是否变化。

建议提交的自查结果：贴上所运行的代码、关键输出，并用自己的中文解释观察到的变化。

练习 2 | 读t检验

找出t.test输出的两组均值、均值差的置信区间及p值，分别用一句中文解释。

建议提交的自查结果：贴上所运行的代码、关键输出，并用自己的中文解释观察到的变化。

练习 3 | 回归换参照

用`levels(lfs$SEX)`确认默认参考组，再尝试研究修改参考组后系数符号为什么改变。

建议提交的自查结果：贴上所运行的代码、关键输出，并用自己的中文解释观察到的变化。

八、读完本讲，能否回答下面5个问题？

1. 上面的课堂代码中，哪些是**原始数据框**，哪些是处理后产生的新对象？
2. `%>%`、`~`、`data=.`分别在代码中起什么作用？
3. 这讲最重要的**模型或统计检验的原假设**是什么？输出中哪个部分告诉你结果？
4. 如果你只把一个参数改掉，图形/估计会如何变化？为什么？
5. 这个方法能不能直接证明因果关系？若不能，还需要什么研究设计或额外前提？

编写说明：教程中的"课堂原始R代码"均直接提取自`lecture6_notes.html`；数值输出摘录也来自该文件，未声称重新计算。对语法、注意事项和练习的解释属于**额外教学补充**。这不是翻译版课件的替代品；建议并排打开本教程和`lecture6_notes_中文版.html`核对原始图表、文字与结果。