第7讲笔记

定量数据分析

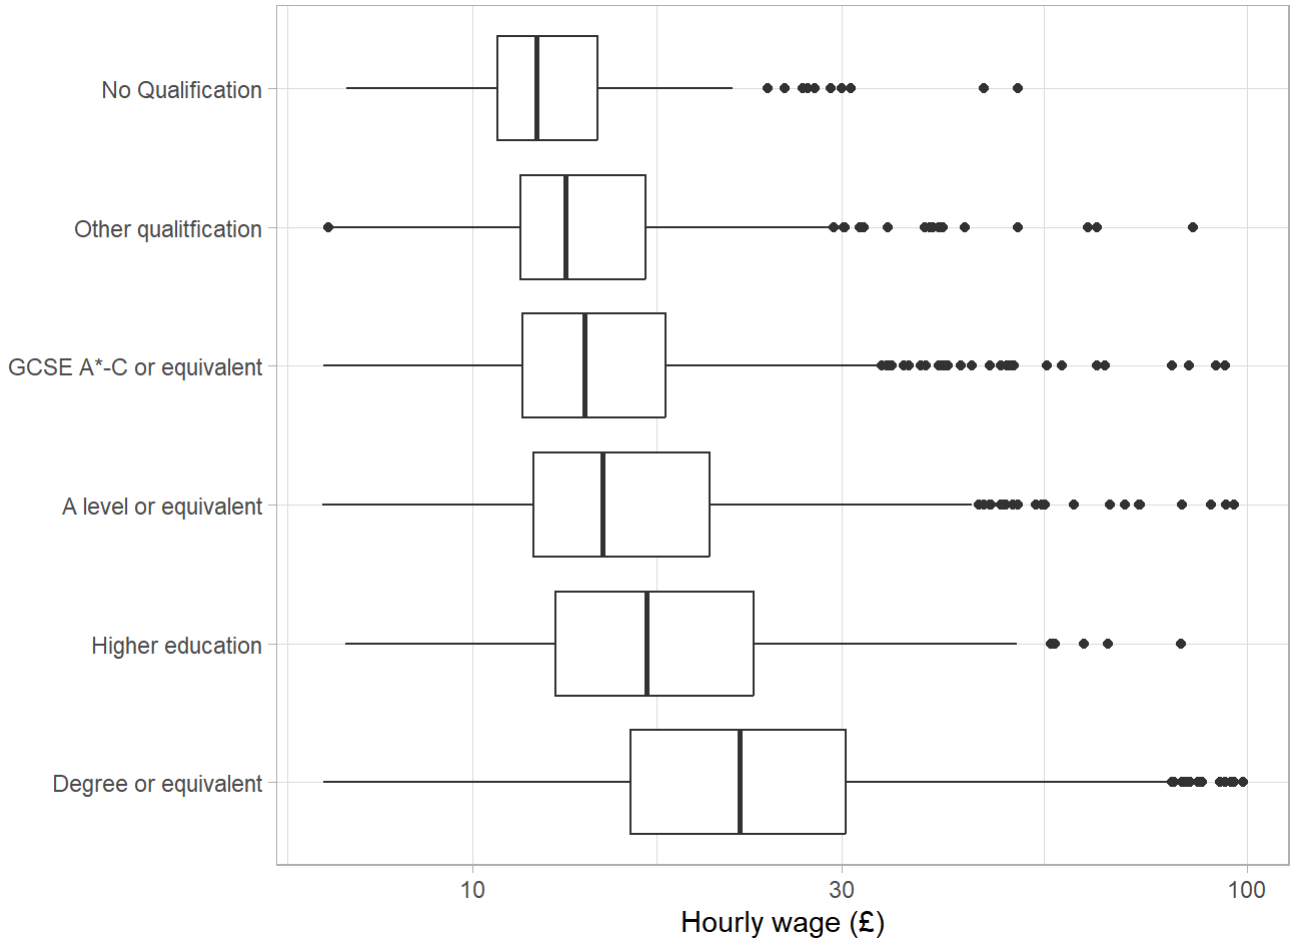
引言

- 上次我们学习了如何检验观察到的差异是否由抽样误差造成。
- 我们检验了男女平均工资之间的差异。
- 今天我们将学习如何检验两个以上类别之间的差异。
- 看看平均工资是否随教育水平而变化（教育水平由个人获得的最高学历或资格来衡量）。
- 为了我们大家的利益，希望答案是肯定的！

最高学历／资格水平

最高学历 / 资格	观测数	平均工资（英镑）	标准差
学位或同等资格	3535	25.02	12.65
高等教育	565	19.63	9.88
A Level或同等资格	1604	17.33	8.86
GCSE A*–C或同等资格	1102	16.16	8.29
其他资格	331	15.63	8.55
无资格证书	210	13.53	5.39

最高学历／资格水平



教育

- 从图中可以看出，工资中位数随教育水平而变化。
- 然而，不同组别之间仍有大量重叠。
- 如果重新抽取一个样本，这些差异还能重复出现吗？

我们的假设是什么？

- 我们认为教育与工资有关。

$$H_0 : \mu_{degree} = \mu_{HE} = \mu_{Alevel} = \mu_{GCSE} = \mu_{Other} = \mu_{None}$$

$$H_A : \mu_{degree} \neq \mu_{HE} \neq \mu_{Alevel} \neq \mu_{GCSE} \neq \mu_{Other} \neq \mu_{None}$$

线性模型

- 我们可以利用线性模型框架写出一个方程。
- 定义一组虚拟变量，在以下情形中取值：
  - 如果所讨论的资格是该人拥有的最高资格，则取1。
  - 否则取0。

回归方程

$$\text{Wage}_i = \beta_0 + \beta_1 \cdot \text{HE}_i + \beta_2 \cdot \text{A level}_i + \beta_3 \cdot \text{GCSE}_i + \beta_4 \cdot \text{Other}_i + \beta_5 \cdot \text{None}_i$$

模型参数

- β_0 will be the average wage of a person with a degree
- β_1 is the difference between the average wage of a person with a degree and a person with only some higher education
- β_2 is the difference between the average wage of a person with a degree and a person with A levels
- β_3 is the difference between the average wage of a person with a degree and a person with GCSEs
- β_4 is the difference between the average wage of a person with a degree and a person with some other qualification
- β_5 is the difference between the average wage of a person with a degree and a person with no qualifications

线性回归模型

```
lm(HOURPAY ~ HIQUL22D, data = lfs) %>% summary()
```

线性回归模型

```
##
## Call:
## lm(formula = HOURPAY ~ HIQUL22D, data = lfs)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -18.595  -6.305  -2.448   3.576  78.822
##
## Coefficients:
##                                Estimate Std. Error t value Pr(>|t|)
## (Intercept)                     25.0155     0.1812  138.06   <2e-16 ***
## HIQUL22DHigher education        -5.3873     0.4881  -11.04   <2e-16 ***
## HIQUL22DA level or equivalent   -7.6878     0.3243  -23.70   <2e-16 ***
## HIQUL22DGCSE A*-C or equivalent -8.8511     0.3717  -23.81   <2e-16 ***
## HIQUL22DOther qualitfication    -9.3824     0.6192  -15.15   <2e-16 ***
## HIQUL22DNo Qualification       -11.4876     0.7652  -15.01   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 10.77 on 7341 degrees of freedom
## Multiple R-squared:  0.1293, Adjusted R-squared:  0.1287
## F-statistic: 218.1 on 5 and 7341 DF,  p-value: < 2.2e-16
```

结果解释

- 这里我们得到了较强的结果。
- 所有低于学位水平的教育类别，其平均工资都更低。
- 所有差异都具有统计显著性。
- 在本例中，有足够证据拒绝之前设定的原假设。
- 但并非总会如此。
- 有时各参数单独来看都不显著，但联合起来却具有显著性。

变异

- 数据的变异可以从两个维度理解：
    1. 组内变异（同一教育类别内）。
    2. 组间变异（不同教育类别之间）。
- 我们需要回答的是：组间差异是否显著大于人与人之间的差异？

将这些概念形式化

- 需要将刚才讨论的变异概念写成正式的统计量：

1. 总变异：总平方和（SST）。
2. 组间变异：组间平方和（SSA）。
3. 组内变异：组内平方和（SSW）。

总变异

总平方和可以定义为：

$$SST = \sum_{j=1}^{c} \sum_{i=1}^{n_j} (X_{ij} - \bar{\bar{X}})^2$$

where

- $\bar{\bar{X}} = \frac{\sum_{j=1}^{c} \sum_{i=1}^{n_j} X_{ij}}{n}$ = Grand Mean
- X_{ij} is the ith value in group j
- n_j is the number of values in group j
- n is the total number of values across all groups
- c is the number of groups

组间变异

组间变异定义为：

$$SSA = \sum_{j=1}^{c} n_j (\bar{X}_j - \bar{\bar{X}})^2$$

其中：

- c is the number of groups
- n_j is the number of values in group j
- $\bar{X}_j$ is the sample mean of group j
- $\bar{\bar{X}}$ is the grand mean

组内变异

组内变异定义为：

$$SSW = \sum_{j=1}^{c} \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_j)^2$$

where

- X_{ij} is the ith value in group j
- $\bar{X}_j$ is the sample mean of group j

均方

- 我们可以将这三个平方和（SS）分别除以其自由度（d.o.f.），得到方差或均方。

    1. 组间平方和比较c个组，贡献$c-1$个自由度。
    2. 由于每个c组都贡献n_j-1个自由度，因此组内平方和对应$n-c$个自由度。
    3. 总变异对应$n-1$个自由度，因为共有n个观测值和1个总体样本均值。

均方误差

组间均方：

$$MSA = \frac{SSA}{c-1}$$

The Mean Square Within:

$$MSW = \frac{SSW}{n-c}$$

The Mean Square Total:

$$MST = \frac{SST}{n-1}$$

检验

- 开展检验需要：

    1. 陈述原假设与备择假设。
    2. 定义检验统计量。
    3. 选择显著性水平。

假设

$$H_0 : \mu_1 = \mu_2 = \ldots = \mu_c$$

$$H_A : \mu_1 \neq \mu_2 \neq \ldots \neq \mu_c$$

- 原假设认为各组均值之间没有统计学上的差异。
- 备择假设认为并非所有组的均值都相等。
- 可能只有一个组的均值与其他组存在显著差异。
- 这个方法本身并不告诉我们哪些组的均值不同。

检验统计量

- 我们使用F检验来检验原假设。
- 它利用F分布。

$$F = \frac{MSA}{MSW}$$

- F is our test statistic with $c - 1$ degrees of freedom on the numerator and $n - c$ degrees of freedom on the denominator
- MSA表示组间均方。
- MSW表示组内均方。

F检验

- 幸运的是，我们不必手工完成全部计算。
- 可以使用R中的方差分析（ANOVA）函数。

```
aov(HOURPAY ~ HIQUL22D, data = lfs) %>% summary()
```

```
##               Df Sum Sq Mean Sq F value Pr(>F)
## HIQUL22D       5 126542   25308   218.1 <2e-16 ***
## Residuals   7341 851935     116
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

结果解释

- 可以看到，R提供了部分计算过程的信息。
- 它告诉我们最终的F值。
- 更关键的是，我们还得到了p值。
- 它非常小，因此可以有把握地拒绝原假设。
- 看来平均工资确实随教育水平变化。

补充信息

- 请注意，Sum Sq列显示平方和。
- 它是衡量数据变异的指标。
- 这里将其拆分为两部分：
    1. 可由分类变量（HIQUL22D）解释的变异。
    2. 尚未解释的变异（残差Residuals）。
- 由此可以计算教育变量解释了多少变异。
- 用HIQUL22D对应的平方和除以总平方和。

$$\frac{126542}{126542 + 851935} = 0.129325$$

结果解释

- 计算结果为**0.129325**。
- 这说明教育水平可以解释工资差异中约**12.93%**的变异。
- 了解这些之后，让我们回到本讲开始时的线性模型。

原来它一直都在那里

```
Call:
lm(formula = HOURPAY ~ HIQUL22D, data = lfs)

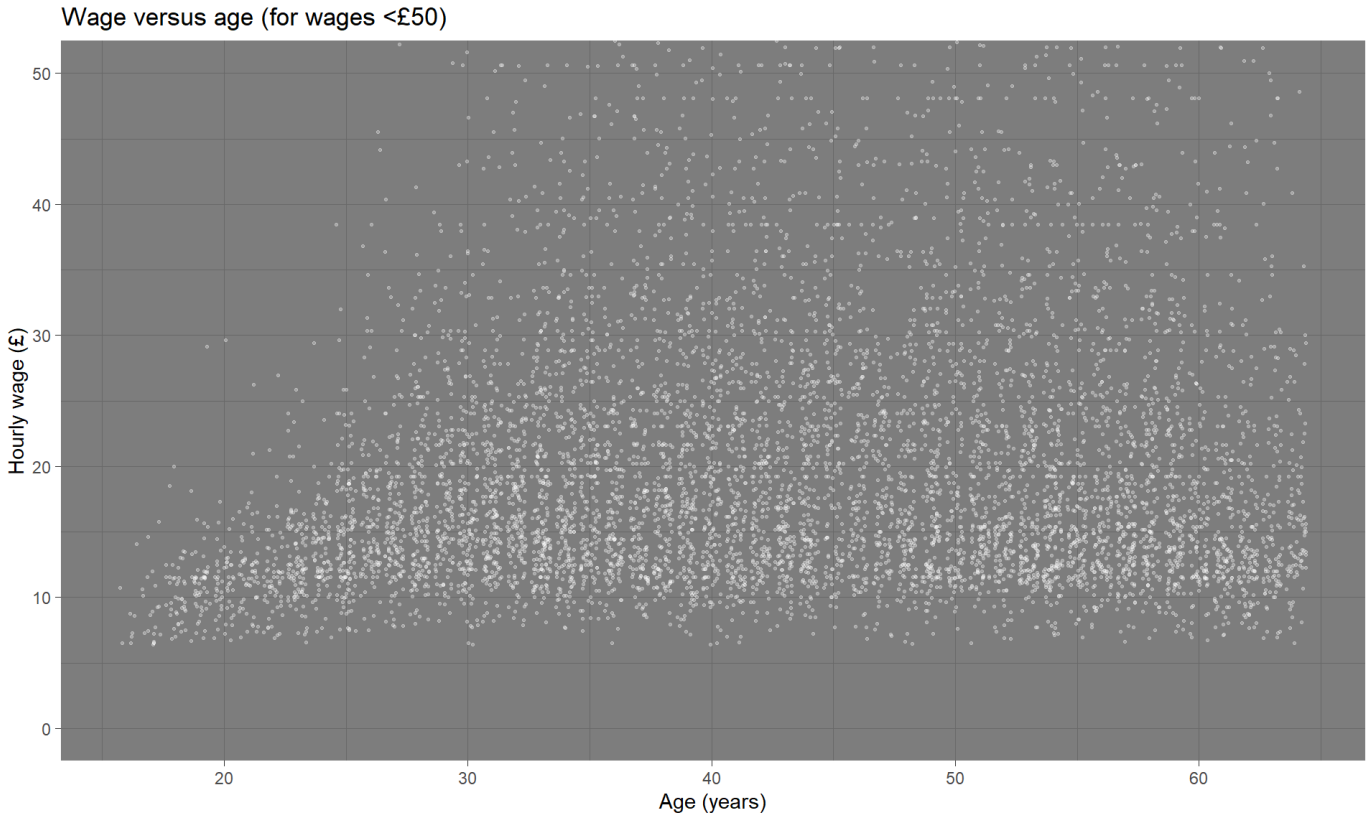
Residuals:
    Min      1Q  Median      3Q     Max 
-18.595  -6.305  -2.448   3.576  78.822 

Coefficients:
                               Estimate Std. Error t value Pr(>|t|)    
(Intercept)                     25.0155     0.1812  138.06   <2e-16 ***
HIQUL22DHigher education        -5.3873     0.4881  -11.04   <2e-16 ***
HIQUL22DA level or equivalent   -7.6878     0.3243  -23.70   <2e-16 ***
HIQUL22DGCSE A*-C or equivalent -8.8511     0.3717  -23.81   <2e-16 ***
HIQUL22DOther qualitfication    -9.3824     0.6192  -15.15   <2e-16 ***
HIQUL22DNo Qualification       -11.4876     0.7652  -15.01   <2e-16 ***
---
Signif. codes:  0 ’***’ 0.001 ’**’ 0.01 ’*’ 0.05 ’.’ 0.1 ’ ’ 1

Residual standard error: 10.77 on 7341 degrees of freedom
Multiple R-squared:  0.1293,    Adjusted R-squared:  0.1287 
F-statistic: 218.1 on 5 and 7341 DF,  p-value: < 2.2e-16
```

线性模型

- 现在我们又看到了线性模型的一些强大之处。
- 模型的一个假设是因变量属于区间尺度或比率尺度。
- 我们已经看到，分类变量可以作为自变量进入模型。
- 有序变量也采用相同的方式，但模型不会自动利用其顺序信息。
- 自变量也可以是区间尺度或比率尺度的连续变量。
- 假设我们想研究年龄与收入。



衡量变量关系

- 将数据可视化是理解两个变量之间关系的重要步骤。
- 将变量间的关系量化也很有用。
- 如果要检验统计显著性，也必须进行量化。
- 有几种可行的方法。

方差

- 我们已经接触过衡量单个变量变异的方差。
- 也可以考察两个变量如何共同变化。
- 回忆一下，样本方差写作：

$$S_x^2 = \frac{\sum_i^n (x_i - \bar{x})^2}{n-1}$$

- The sample covariance is given by:

$$\operatorname{cov}(X,Y) = \sum_{i=1}^{N} \frac{(x_i - \bar{x})(y_i - \bar{y})}{n-1}$$

协方差

- 如果x高于其均值时y也高于其均值，那么协方差为正。

- 如果x低于其均值时y高于其均值，那么协方差为负。
- 如果x的变化无法告诉我们y的变化情况，那么协方差为零。
- 协方差的单位较难解释，因为它依赖x和y各自的单位。
- 标准做法是通过两个变量各自的离散程度对其进行标准化。
- 这得到所谓的皮尔逊积差相关系数（Pearson product-moment correlation coefficient），取值范围在−1至1之间。

$$r = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sqrt{\sum (x - \bar{x})^2 \sum (y - \bar{y})^2}}$$

如何解释r的绝对值

范围	相关强度
0	无相关关系
0-0.2	极弱、可忽略的相关关系
0.2-0.4	弱相关、低相关性
0.4-0.7	中等相关
0.7-0.9	强相关、高度相关
0.9-1	非常强的相关关系
1	完全相关

在R中计算相关系数

- 如果只需要相关系数，可以使用cor()函数。

```
cor(lfs$HOURPAY, lfs$AGE)
```

```
## [1] 0.1375462
```

检验统计显著性

- 可以使用cor.test()函数检验相关系数的统计显著性。

```
cor.test(lfs$HOURPAY, lfs$AGE)
```

```
##
##  Pearson's product-moment correlation
##
## data:  lfs$HOURPAY and lfs$AGE
## t = 11.901, df = 7345, p-value < 2.2e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.1150412 0.1599101
## sample estimates:
##       cor
## 0.1375462
```

检验统计显著性

- 也可以使用公式写法得到相同的结果。

```
cor.test(~ HOURPAY + AGE, data=lfs)
```

```
##
##  Pearson's product-moment correlation
##
## data:  HOURPAY and AGE
## t = 11.901, df = 7345, p-value < 2.2e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.1150412 0.1599101
## sample estimates:
##       cor
## 0.1375462
```

线性模型

```
lm(HOURPAY ~ AGE, data=lfs) %>% summary()
```

```
##
## Call:
## lm(formula = HOURPAY ~ AGE, data = lfs)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -17.155  -7.615  -3.334   4.221  76.885
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) 15.18591    0.49378   30.75   <2e-16 ***
## AGE          0.13233    0.01112   11.90   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 11.43 on 7345 degrees of freedom
## Multiple R-squared:  0.01892,    Adjusted R-squared:  0.01879
## F-statistic: 141.6 on 1 and 7345 DF,  p-value: < 2.2e-16
```

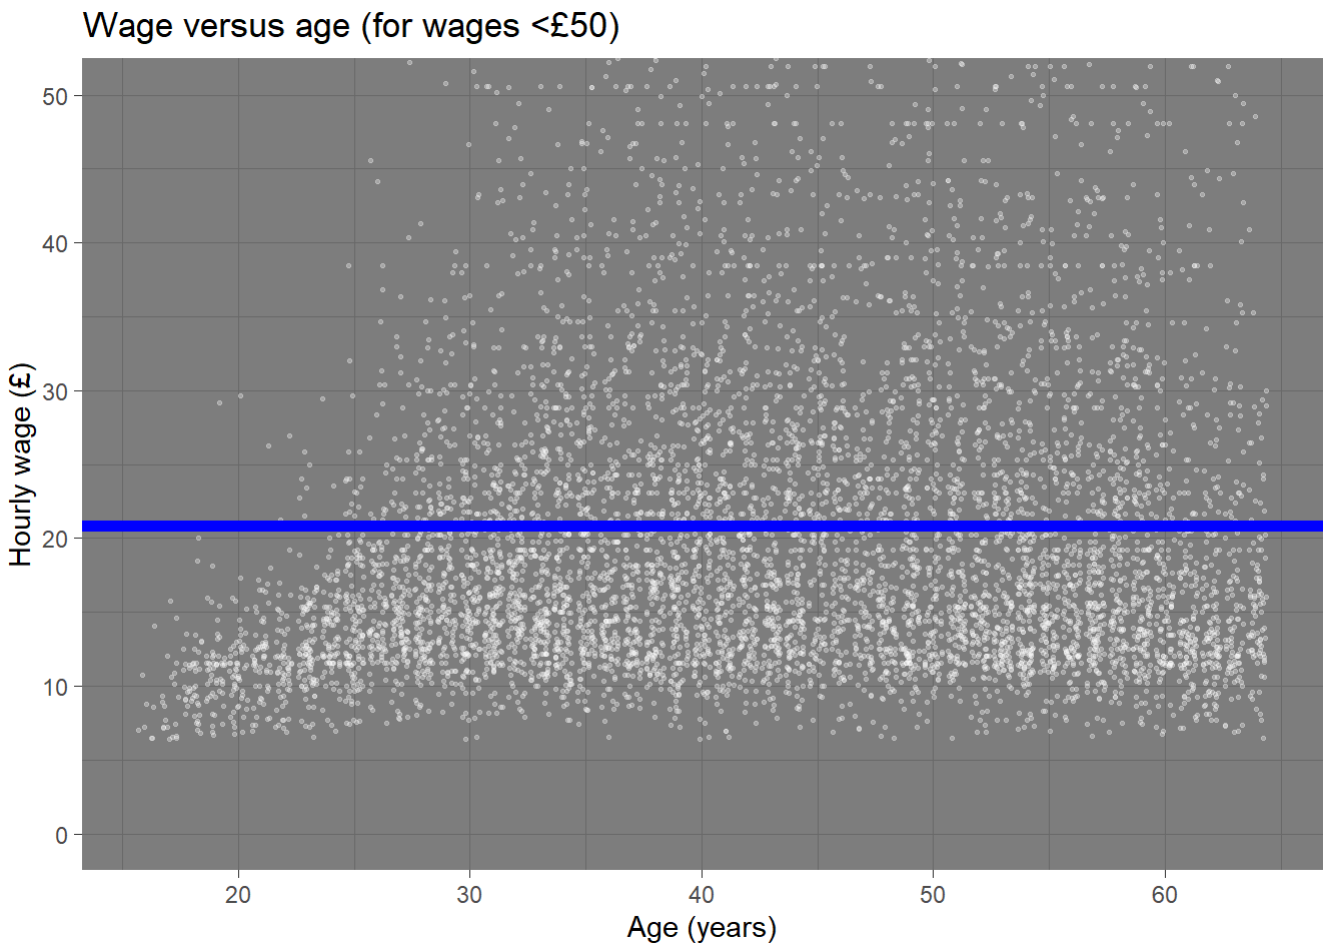
线性模型

- 这里不能直接看到相关系数，但相关信息就在输出中。
- 将R^2开平方，就能得到相关系数的绝对值（其符号还需根据关系方向判断）。
- 在本例中，Estimate（估计系数）恰好也接近相关系数。
- 这只是巧合，尽管两项指标确实有关。
- 首先来看它从何而来。

猜测某个人的工资

- 如果我从总体中随机抽取一个人，让你猜测其工资，那么最好的猜测就是平均工资。

```
## Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.0.
## ℹ Please use `linewidth` instead.
## This warning is displayed once every 8 hours.
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was
## generated.
```



更好的预测

- 可以看到，年轻人的工资较低。
- 如果知道一个人的年龄，就可以更好地预测工资。
- 目前我们的预测方程为$\text{HOURPAY}_i = \beta_0$。
- 在方程中加入年龄：$\text{HOURPAY}_i = \beta_0 + \beta_1 \cdot \text{AGE}$。
- 但这还不完全正确，因为找不到一组β_0和β_1能完美预测所有人的工资。
- 因此再加上一项表示预测误差：$\text{HOURPAY}_i = \beta_0 + \beta_1 \cdot \text{AGE} + \varepsilon_i$。

选择参数

- 任务是选择能够优化预测的β_0和β_1取值。
- ε这一项代表预测误差，即残差。
- 我们希望让误差尽可能小。
- 一种衡量误差的方法是将残差平方后求和，即$\text{SSR} = \sum \varepsilon_i^2$。
- 然后选择使其最小的参数值。
- 可以通过数值方法解决问题。
- 也可以使用微积分。

求解所需方程

$$\frac{\partial}{\partial \hat{\beta}_0} \sum_{i=1}^{n} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 = -2 \sum (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)$$

$$\frac{\partial}{\partial \hat{\beta}_1} \sum_{i=1}^{n} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 = -2 \sum x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)$$

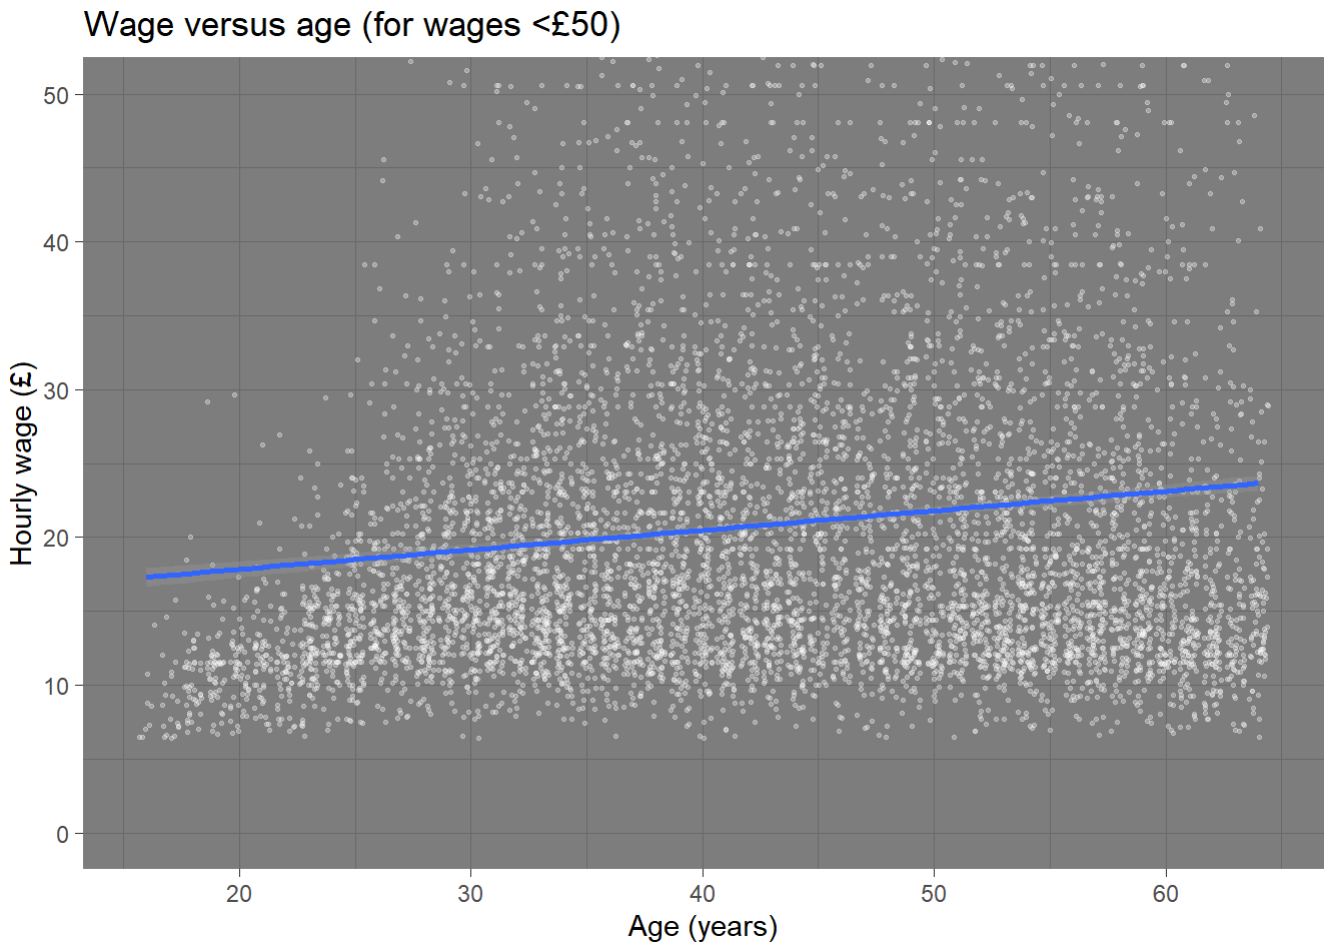
解答

$$\hat{\beta}_1 = \frac{\frac{1}{n}\sum_{i=1}^{n} x_i y_i - \bar{x}\bar{y}}{\frac{1}{n}\sum_{i=1}^{n} x_i^2 - \bar{x}^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

线性模型

- 我们已经见过这些参数的求解结果。
- β_0 is the intercept from the linear model
- β_1 is the coefficient attached to age
- 可以用图形呈现其效果。



线性模型

```
lm(HOURPAY ~ AGE, data=lfs) %>% summary()
```

```
##
## Call:
## lm(formula = HOURPAY ~ AGE, data = lfs)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -17.155  -7.615  -3.334   4.221  76.885
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) 15.18591    0.49378   30.75   <2e-16 ***
## AGE          0.13233    0.01112   11.90   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 11.43 on 7345 degrees of freedom
## Multiple R-squared:  0.01892,    Adjusted R-squared:  0.01879
## F-statistic: 141.6 on 1 and 7345 DF,  p-value: < 2.2e-16
```

结果解释

- 截距代表年龄为零的人所对应的工资。
- 这并不是有用的解释。
- 在线性模型中，我们通常不会过分解读截距。
- 年龄的回归系数告诉我们年龄与工资之间的关联。
- 年龄每增加一岁，工资平均会高出**0.13**英镑。
- 这种关联具有统计显著性。
- 年龄变异能够解释工资变异中的**1.9%**。

相关与因果

相关不等于因果。

因与果的错误归因（Cum hoc ergo propter hoc）

- 这是一种著名的逻辑谬误。
- 使用这些方法，我们所展示的只是相关关系。
- 写作此类分析时必须谨慎。
- 不要写成“证明了”某个结论。
- 不要轻易说某事“导致”另一件事。
- 应该说某个变量与另一个变量“存在关联”。

总结

- 我们又看到了线性模型的一些强大之处。
- 它可以借助类别型、有序型以及连续（区间 / 比率尺度）自变量来衡量变量关联。
- 它还可以检验统计显著性。
- 后面还有更多精彩内容。