Lecture 7 | 方差分析、相关分析与简单线性回归——R语言完全零基础逐行代码教程

> **课程**：URBAN5127 Quantitative Data Analysis | **来源**：`lecture7_notes.html`（课堂原始讲义）与对应中文版。
> **读者**：没有编程经验、正在学习R/RStudio的初学者。**方法**：保持讲义全部课堂R代码原样，逐行解释，再用独立标注的教学补充帮助理解。

〇、先认识这一讲：方差分析、相关分析与简单线性回归

这一讲比较不同最高资格水平的小时工资，用ANOVA检验组均值，再用工资和年龄解释Pearson相关系数及一元线性回归。

读完应当会：

1. 分类解释变量与参照组。
2. ANOVA：组间变异/组内变异。
3. F统计量与p值。
4. Pearson相关系数。
5. 相关性不等于因果关系。
6. 连续解释变量的回归解释。

原始代码的覆盖范围

- 英文原始HTML中识别到 **7段真正的课堂R代码（`pre.r`）**；下文每一段完整按原顺序出现，**不省略或替换原始代码。**
- HTML中的黑色`## ...`控制台打印是**运行结果**，不能把它当成要重新输入的R命令；网页的JavaScript/CSS也不是本课R代码。
- 如果相同代码在不同位置重复出现，教程仍按原讲义顺序保留并解释其教学目的。

一、先修知识：即使从来没写过代码也能看懂

1.1 R / RStudio到底是什么?

R是一种用于统计分析的编程语言；RStudio是帮助你编辑、运行、检查R程序的工作界面。**R语言**决定代码含义，**RStudio**提供Source（脚本编辑器）、Console（即时运行）、Environment（查看对象）、Plots（看图）等窗口。
建议先创建一个`.R`脚本，将本教程中的每段原始代码逐段粘贴进去；在RStudio中选中一行或几行按Ctrl+Enter（Windows）或Cmd+Enter（macOS）运行。不要一次性运行全部章节：有些讲义代码依赖之前做过的数据处理。

1.2 把R代码当成一句完整的话来阅读

写法	初学者的读法	常见误解
`x <- ...`	把右边结果保存到x	以为`<-`是小于号
`f(x, y)`	调用函数f，把x和y作为参数	以为所有括号都在做数学乘法

写法	初学者的读法	常见误解
`data = lfs`	指定数据对象	以为这里是把变量赋值给lfs
`df$AGE`	从df里抽取AGE这一列	以为 `$` 有货币意义
`a %>% b()`	先做a，再把结果交给b	与ggplot的图层加号 `+` 混淆
`y ~ x1 + x2`	用x1、x2共同解释y	把公式中的 `+` 当成数值求和
`"Female"`	这是**字符串文字**	误以为是变量名
`TRUE` 与 `FALSE`	布尔值/逻辑值	与文字 `"TRUE"` 混淆
`# ...`	注释，对运行结果无影响	把注释当成一定会运行的代码
`<`、`==`	分别表示小于、是否相等	把 `==` 与赋值符混淆

如果一行很长，先找最外层函数，再拆成"传入的数据→做了什么→返回什么"；碰到多层括号，从**最里面的函数**开始理解。

1.3 第一次运行前，需要准备哪些包?

初学者先区分：**安装（install.packages）只需通常做一次，载入（library）在每次新R会话中可能要再执行。**下方是**教学补充**，不是原课件代码：

```
# 第一次使用且尚未安装时，去掉下面一行行首的 # 并运行
# install.packages(c("dplyr"))
library(dplyr)
```

这些包在本讲主要用于：

- `dplyr`：%>% 管道（也可由magrittr提供）。

`lm()`、`summary()`、`aov()`、`t.test()`、`cor()`、`cor.test()`和`plot()`等来自R基础/推荐自带组件，通常不需要为它们单独安装新包。

1.4 数据对象和运行顺序

- LFS示例中的`lfs`不是R预装对象。课程前几讲已完成**读取、筛选、清洗、因子转换**，这些步骤需要先执行；本教程不臆造文件路径或原始清洗代码。
- 第9讲还使用`mtcars`（R内置数据集）；第8讲第一段代码会创建虚构对象`fake_data`。
- 如果出现`object 'lfs' not found`，不是本行统计公式错了，而是尚未创建或读入`lfs`。
- 课堂输出与现在运行结果只有在使用同一份已清洗数据、相同函数设定、相容包版本时才可能完全一致。

1.5 这几类对象是什么?

- **向量（vector）**：一列同类型值，常由`c(...)`生成。
- **数据框（data.frame / tibble）**：像Excel表格，行对应观测、列对应变量。
- **函数（function）**：执行特定任务，如`mean()`求平均、`lm()`拟合回归。
- **参数（argument）**：括号里告诉函数如何工作的选项，例如`data = lfs`。

- **模型对象**：`lm(...)`运行后返回的结果，里面有系数、残差、拟合值等，不只是一个单独数字。
- **因子（factor）**：R记录分类变量的特殊类型，参照组决定类别回归系数的解释方式。

二、本讲课程代码：原文保留、逐段拆解

代码 01 | 以最高资格类别预测小时工资：分类解释变量回归

原讲义位置：线性回归模型。

这段想做什么?

查看不同教育资格组的平均小时工资差异，理解"参考组"决定了系数相对谁比较。

课堂原始R代码（完整保留）

```
lm(HOURPAY ~ HIQUL22D, data = lfs) %>% summary()
```

逐行讲解

1. **第1行** `lm(HOURPAY ~ HIQUL22D, data = lfs) %>% summary()`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。`data=lfs`明确指定从lfs表取变量。`~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。`lm()`拟合线性回归，括号内包括公式与数据来源。`summary()`输出摘要；模型对象包括估计系数、标准误、t值、p值等。

把函数和统计概念拆开看

1. `HIQUL22D`是分类变量时，`lm()`会为除基准类别之外的各类别建立比较系数。
2. `(Intercept)`代表基准类别的平均工资预测值。
3. 每一个学历系数代表相对基准类别的差额，而不是该组工资本身。
4. 必须使用`levels(lfs$HIQUL22D)`确认实际参照组；课程正文以拥有学位的人作为示例参照类别。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
## Call:
## Residuals:
## Coefficients:
##                                 Estimate Std. Error t value Pr(>|t|)
## (Intercept)                      25.0155     0.1812  138.06   <2e-16 ***
## HIQUL22DHigher education         -5.3873     0.4881  -11.04   <2e-16 ***
## HIQUL22DA level or equivalent    -7.6878     0.3243  -23.70   <2e-16 ***
## HIQUL22DGCSE A*-C or equivalent  -8.8511     0.3717  -23.81   <2e-16 ***
## HIQUL22DOther qualitfication     -9.3824     0.6192  -15.15   <2e-16 ***
## HIQUL22DNo Qualification        -11.4876     0.7652  -15.01   <2e-16 ***
## Multiple R-squared:  0.1293, Adjusted R-squared:  0.1287
## F-statistic: 218.1 on 5 and 7341 DF,  p-value: < 2.2e-16
```

回归摘要读法：`Call`说明实际模型公式；`Coefficients`中`Estimate`是系数、`Std. Error`是标准误、`t value`是估计/标准误、`Pr(>|t|)`为显著性检验；`Multiple R-squared`是模型在当前因变量尺度下的解释比例。

初学者容易踩的坑 / 研究上的注意事项

该回归中每个分类系数的t检验只针对"该类别与基准类别的差异"。如果要一次检验所有类别的整体差异，可使用后面的ANOVA/F检验。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 02 | 用单因素方差分析检验资格类别的整体工资差异

原讲义位置：F检验。

这段想做什么?

把工资总变异划分为组间变异和组内变异，以F统计量检验各组总体均值是否相同。

课堂原始R代码（完整保留）

```
aov(HOURPAY ~ HIQUL22D, data = lfs) %>% summary()
```

逐行讲解

1. **第1行** `aov(HOURPAY ~ HIQUL22D, data = lfs) %>% summary()`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。`data=lfs`明确指定从lfs表取变量。`~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。`aov()`执行ANOVA，重点关注整体F统计量和p值。`summary()`输出摘要；模型对象包括估计系数、标准误、t值、p值等。

把函数和统计概念拆开看

1. `aov()`是R中执行方差分析（ANOVA）的函数。
2. `HOURPAY ~ HIQUL22D`表示按学历类别考察小时工资。
3. `summary()`给出Df（自由度）、Sum Sq（平方和）、Mean Sq（均方）、F value和Pr(>F)。
4. 检验的原假设是各学历类别的总体平均工资都相同；显著性不能告诉你究竟哪些具体两组不同。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
##               Df Sum Sq Mean Sq F value Pr(>F)
## HIQUL22D       5 126542   25308   218.1 <2e-16 ***
## Residuals   7341 851935     116
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

重点找`HIQUL22D`所在行的`F value`与`Pr(>F)`。原假设是全部教育组均值相等；整体检验显著不自动指出哪两组不同。

初学者容易踩的坑 / 研究上的注意事项

ANOVA解释为"是否存在至少一组均值不同"的整体检验。观察条件还包括观测独立、残差结构与各组方差情况；如要比较成对差异，应另设合理的多重比较程序。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 03 | 计算工资与年龄的Pearson相关系数

原讲义位置：在R中计算相关系数。

这段想做什么？

用一个介于-1与1之间的系数总结两个数值变量的线性相关方向和强度。

课堂原始R代码（完整保留）

```
cor(lfs$HOURPAY, lfs$AGE)
```

逐行讲解

1. **第1行** `cor(lfs$HOURPAY, lfs$AGE)`：`cor()`计算Pearson相关系数，默认不自动进行显著性检验。

把函数和统计概念拆开看

1. `lfs$HOURPAY`通过`$`从数据框取出工资列。
2. `lfs$AGE`同理取出年龄列。
3. `cor(x,y)`默认计算Pearson相关系数，度量**线性关联**而非因果影响。
4. 若有缺失值，`cor()`的默认处理可能返回NA；应明确选择合理的缺失值处理方式。

课件输出怎样读？

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
## [1] 0.1375462
```

`[1]`是R展示向量第一个元素的标签；后面的数字才是样本相关系数，正数表示正向线性关系。

初学者容易踩的坑 / 研究上的注意事项

原讲义输出`0.1375462`：表示较弱的正向线性关联。这并不表示"年龄使工资提高13.75%"，也不说明原因一定是年龄。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 04 | 用cor.test检验相关系数是否显著：向量写法

原讲义位置：检验统计显著性。

这段想做什么?

在上一段相关系数之外，同时报告检验统计量、置信区间与p值。

课堂原始R代码（完整保留）

```
cor.test(lfs$HOURPAY, lfs$AGE)
```

逐行讲解

1. **第1行** `cor.test(lfs$HOURPAY, lfs$AGE)`：`cor.test()`不只计算r，还提供t统计量、置信区间和p值。

把函数和统计概念拆开看

1. `cor.test(x,y)`检验总体相关系数是否为0。
2. 默认`method = "pearson"`，可在其他情境根据研究问题考虑Spearman等方法。
3. 输出中的`t`和`df`来自相关检验的统计量与自由度。
4. `95 percent confidence interval`是总体相关系数的区间估计，不应误认为95%的样本位于该区间。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
##
##  Pearson's product-moment correlation
##
## data:  lfs$HOURPAY and lfs$AGE
## t = 11.901, df = 7345, p-value < 2.2e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.1150412 0.1599101
## sample estimates:
##       cor
## 0.1375462
```

`cor`表示样本Pearson相关系数，`p-value`检验总体相关是否为零，`confidence interval`反映估计不确定性。这三个量回答不同问题。

初学者容易踩的坑 / 研究上的注意事项

讲义报告`p-value < 2.2e-16`，意味着"零相关"的原假设很难解释观测数据；但0.1375仍是小的相关系数：**统计显著不等于关系强。**

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"

- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 05 | 同一个相关性检验：公式写法

原讲义位置：检验统计显著性。

这段想做什么?

用公式接口`~ HOURPAY + AGE`代替两个`$`向量，输出与上一段应相同。

课堂原始R代码（完整保留）

```
cor.test(~ HOURPAY + AGE, data=lfs)
```

逐行讲解

1. **第1行** `cor.test(~ HOURPAY + AGE, data=lfs)`：`data=lfs`明确指定从lfs表取变量。`cor.test()`不只计算r，还提供t统计量、置信区间和p值。

把函数和统计概念拆开看

1. `~ HOURPAY + AGE`是`cor.test()`支持的双变量公式形式。
2. 这里`+`是公式中连接两个待比较变量，而不是对整列工资和年龄做数值加法。
3. `data=lfs`让R在lfs里解析变量名。
4. 这一写法与前面的`cor.test(lfs$HOURPAY, lfs$AGE)`应给出同一检验。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
##
##  Pearson's product-moment correlation
##
## data:  HOURPAY and AGE
## t = 11.901, df = 7345, p-value < 2.2e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.1150412 0.1599101
## sample estimates:
##       cor
## 0.1375462
```

`cor`表示样本Pearson相关系数，`p-value`检验总体相关是否为零，`confidence interval`反映估计不确定性。这三个量回答不同问题。

初学者容易踩的坑 / 研究上的注意事项

注意：`cor.test()`的公式写法和`lm()`公式写法并不完全相同。`lm(y ~ x)`明确左边是被解释变量，`cor.test(~x+y)`表示对称的两变量关联。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。

- 用一句话回答：“我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？”
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 06 | 用年龄预测小时工资的一元线性回归

原讲义位置：线性模型。

这段想做什么?

学习连续自变量的回归系数如何解释：年龄每增加1单位，平均预测工资变化多少。

课堂原始R代码（完整保留）

```
lm(HOURPAY ~ AGE, data=lfs) %>% summary()
```

逐行讲解

1. **第1行** `lm(HOURPAY ~ AGE, data=lfs) %>% summary()`：出现 `%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=lfs` 明确指定从lfs表取变量。 `~` 连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 `lm()` 拟合线性回归，括号内包括公式与数据来源。 `summary()` 输出摘要；模型对象包括估计系数、标准误、t值、p值等。

把函数和统计概念拆开看

1. `AGE` 是数值变量时， `lm(HOURPAY ~ AGE)` 拟合一条直线。
2. 截距表示AGE为0时的数学预测值，可能不属于样本年龄范围，不应作现实解释。
3. `AGE` 的系数是工资对年龄的线性斜率，其单位为工资单位/岁。
4. `Multiple R-squared` 描述线性模型在样本中解释的工资变异比例。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
## Call:
## Residuals:
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) 15.18591    0.49378   30.75   <2e-16 ***
## AGE          0.13233    0.01112   11.90   <2e-16 ***
## Multiple R-squared:  0.01892,    Adjusted R-squared:  0.01879
## F-statistic: 141.6 on 1 and 7345 DF,  p-value: < 2.2e-16
```

回归摘要读法： `Call` 说明实际模型公式； `Coefficients` 中 `Estimate` 是系数、 `Std. Error` 是标准误、 `t value` 是估计/标准误、 `Pr(>|t|)` 为显著性检验； `Multiple R-squared` 是模型在当前因变量尺度下的解释比例。

初学者容易踩的坑 / 研究上的注意事项

课件中工资与年龄的相关约0.1375；对于只有一个连续解释变量、带截距的线性回归，R^2约是相关系数的平方（约0.0189），所以可能显著但解释度有限。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 07 | 再次查看一元回归结果：强调截距与斜率

原讲义位置：线性模型。

这段想做什么?

老师再次运行相同的回归，不是新模型，而是借同一输出说明回归方程的两个参数。

课堂原始R代码（完整保留）

```
lm(HOURPAY ~ AGE, data=lfs) %>% summary()
```

逐行讲解

1. **第1行** `lm(HOURPAY ~ AGE, data=lfs) %>% summary()`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。`data=lfs`明确指定从lfs表取变量。`~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。`lm()`拟合线性回归，括号内包括公式与数据来源。`summary()`输出摘要；模型对象包括估计系数、标准误、t值、p值等。

把函数和统计概念拆开看

1. 本段代码与上一段完全相同，结果应该一致。
2. `(Intercept)`是回归方程中β_0的估计。
3. `AGE`行的估计系数是β_1，决定直线的倾斜方向和幅度。
4. 用`预测工资 = 截距 + AGE系数 × 年龄`可以代入一个年龄作预测；预测不是因果结论。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
## Call:
## Residuals:
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) 15.18591    0.49378   30.75   <2e-16 ***
## AGE          0.13233    0.01112   11.90   <2e-16 ***
## Multiple R-squared:  0.01892,    Adjusted R-squared:  0.01879
## F-statistic: 141.6 on 1 and 7345 DF,  p-value: < 2.2e-16
```

回归摘要读法：`Call`说明实际模型公式；`Coefficients`中`Estimate`是系数、`Std. Error`是标准误、`t value`是估计/标准误、`Pr(>|t|)`为显著性检验；`Multiple R-squared`是模型在当前因变量尺度下的解释比例。

初学者容易踩的坑 / 研究上的注意事项

将重复代码保留是为了对应原课件顺序。面对自己的研究，务必区分"变量之间存在统计关联"和"控制其他条件后仍能作因果解释"。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

三、按课堂顺序串起来：这一讲完整分析流程

三种问题，三种分析

- **ANOVA**：分类变量将人分成多组（例如学历），总体均值是否至少有一组不同？重点看F检验。
- **相关**：两个数值变量（例如年龄、工资）一起变化的线性方向和强度如何？重点看r及其区间。
- **回归**：当x变化一单位，y的线性预测均值变化多少？重点看回归系数、标准误、显著性和模型假设。
- **参照组**：类别变量回归系数通常相对于某个基准类。换参照组会改变系数显示方式，不会凭空创造新信息。
- **样本显著 vs 实质重要**：大量数据能检出很小的关系；研究问题仍要解释实际效应有多大。

需要记住的完整逻辑

1. 用分类回归查看各学历组相对基准组的工资差。
2. 用ANOVA的**整体F检验**判断各组总体均值是否完全相同。
3. 用`cor()`定量描述年龄和工资的线性关联。
4. 用`cor.test()`检验相关系数。
5. 用`lm(HOURPAY ~ AGE)`转化为可解释的年龄斜率。

四、函数与参数速查表

函数/运算符	用来做什么	使用时先检查什么
`lm()`	拟合普通最小二乘线性回归模型	输入是什么类型？缺失值和参考组怎么处理？
`summary()`	根据对象类型给出统计摘要；lm对象显示系数、标准误、p值和拟合统计量	输入是什么类型？缺失值和参考组怎么处理？
`aov()`	拟合方差分析模型，检验组间均值差异	输入是什么类型？缺失值和参考组怎么处理？
`cor()`	计算相关系数（默认Pearson）	输入是什么类型？缺失值和参考组怎么处理？
`cor.test()`	计算相关系数并进行显著性检验，给出置信区间	输入是什么类型？缺失值和参考组怎么处理？
`%>%`	管道符：把左边结果交给右边函数，便于从左到右阅读操作顺序	这里是回归公式、比较表达式还是普通计算？

函数/运算符	用来做什么	使用时先检查什么
`~`	模型/检验公式分隔符：在回归中通常左边是结果变量，右边是解释变量	这里是回归公式、比较表达式还是普通计算？
`$`	从数据框中按名称取出一列，如 `lfs$AGE`	这里是回归公式、比较表达式还是普通计算？
`+`	回归公式里的加号表示**纳入多个解释变量**，不是把它们逐行数值相加	这里是回归公式、比较表达式还是普通计算？

五、本讲用到的变量：名字不是它们的中文意思

原变量名	根据本系列讲义能够确认/需要核对的含义
`HOURPAY`	小时工资（此系列课程LFS示例中的因变量）
`AGE`	年龄（数值变量）
`HIQUL22D`	最高资格 / 学历水平（分类变量）

> **避免误译**：LFS数据的编码与变量类别需以课程使用的变量说明、元数据和预处理后的 `levels()` 为准。上表中对含义不明确的字段明确提示了“需要数据字典核实”，没有强行猜测。

六、初学者常见错误与排查顺序

1. **object not found（对象不存在）**：确认是否先创建了 `lfs` 或 `fake_data`，或前一步的 `select()` 是否把变量删掉。
2. **could not find function（找不到函数）**：确认是否安装并 `library()` 了相应包。
3. **unexpected symbol / unexpected end of input（语法错误）**：检查括号、引号、逗号和前一行末尾的 `%>%` 是否完整。
4. **missing values / NA / -Inf**：统计函数遇到 `NA` 或 `log(0)` 会出问题，正式分析需遵循数据字典及清洗记录。
5. **contrasts can be applied only to factors with 2 or more levels**：筛选样本后某个分类变量可能只剩一类，需要检查 `table()` 或 `levels()`。
6. **课程输出与自己不同**：先比较数据版本、样本行数、变量类型、参考组、缺失处理和包版本，不要立即修改统计模型去“凑数”。
7. **统计显著误当成因果关系**：观察数据中的关联仍可能受未观测因素影响，报告必须诚实描述限制。

七、课后练习：自己独立运行，别只看解释

练习 1 | ANOVA

在 `aov()` 输出中指出 `Df`、`F value` 和 `Pr(>F)` 各代表什么。

建议提交的自查结果：贴上所运行的代码、关键输出，并用自己的中文解释观察到的变化。

练习 2 | 相关系数

比较`cor(lfs$HOURPAY,lfs$AGE)`与`cor.test(~HOURPAY+AGE,data=lfs)`中的相关系数是否一致。

建议提交的自查结果：贴上所运行的代码、关键输出，并用自己的中文解释观察到的变化。

练习 3 | 回归解释

解释`lm(HOURPAY~AGE,data=lfs)`中年龄系数的单位，说明为什么不能直接说"年龄导致工资变化"。

建议提交的自查结果：贴上所运行的代码、关键输出，并用自己的中文解释观察到的变化。

八、读完本讲，能否回答下面5个问题?

1. 上面的课堂代码中，哪些是**原始数据框**，哪些是处理后产生的新对象?
2. `%>%`、`~`、`data=.`分别在代码中起什么作用?
3. 这讲最重要的**模型或统计检验的原假设**是什么？输出中哪个部分告诉你结果?
4. 如果你只把一个参数改掉，图形/估计会如何变化？为什么?
5. 这个方法能不能直接证明因果关系？若不能，还需要什么研究设计或额外前提?

编写说明：教程中的"课堂原始R代码"均直接提取自`lecture7_notes.html`；数值输出摘录也来自该文件，未声称重新计算。对语法、注意事项和练习的解释属于**额外教学补充**。这不是翻译版课件的替代品；建议并排打开本教程和`lecture7_notes_中文版.html`核对原始图表、文字与结果。