Lecture 8 | 多元回归建模、异常值与影响点诊断——R语言完全零基础逐行代码教程

> **课程**：URBAN5127 Quantitative Data Analysis | **来源**：`lecture8_notes.html`（课堂原始讲义）与对应中文版。
> **读者**：没有编程经验、正在学习R/RStudio的初学者。**方法**：保持讲义全部课堂R代码原样，逐行解释，再用独立标注的教学补充帮助理解。

〇、先认识这一讲：多元回归建模、异常值与影响点诊断

这一讲主要讨论多元回归的建模思路与估计假设，配合人为构造的示例和LFS模型，演示异常点如何改变回归，以及残差-杠杆值诊断图。

读完应当会：

1. 变量选择和遗漏变量。
2. R^2与调整R^2的区别。
3. 极端值、异常值、杠杆值和影响点。
4. 残差-杠杆图、Cook距离。
5. 去除观测前的研究判断。

原始代码的覆盖范围

- 英文原始HTML中识别到 **4段真正的课堂R代码（`pre.r`）**；下文每一段完整按原顺序出现，**不省略或替换原始代码。**
- HTML中的黑色`## ...`控制台打印是**运行结果**，不能把它当成要重新输入的R命令；网页的JavaScript/CSS也不是本课R代码。
- 如果相同代码在不同位置重复出现，教程仍按原讲义顺序保留并解释其教学目的。

一、先修知识：即使从来没写过代码也能看懂

1.1 R / RStudio到底是什么?

R是一种用于统计分析的编程语言；RStudio是帮助你编辑、运行、检查R程序的工作界面。**R语言**决定代码含义，**RStudio**提供Source（脚本编辑器）、Console（即时运行）、Environment（查看对象）、Plots（看图）等窗口。
建议先创建一个`.R`脚本，将本教程中的每段原始代码逐段粘贴进去；在RStudio中选中一行或几行按Ctrl+Enter（Windows）或Cmd+Enter（macOS）运行。不要一次性运行全部章节：有些讲义代码依赖之前做过的数据处理。

1.2 把R代码当成一句完整的话来阅读

写法	初学者的读法	常见误解
`x <- ...`	把右边结果保存到x	以为`<-`是小于号
`f(x, y)`	调用函数f，把x和y作为参数	以为所有括号都在做数学乘法
`data = lfs`	指定数据对象	以为这里是把变量赋值给lfs

写法	初学者的读法	常见误解
`df$AGE`	从df里抽取AGE这一列	以为 `$` 有货币意义
`a %>% b()`	先做a，再把结果交给b	与ggplot的图层加号 `+` 混淆
`y ~ x1 + x2`	用x1、x2共同解释y	把公式中的 `+` 当成数值求和
`"Female"`	这是**字符串文字**	误以为是变量名
`TRUE` 与 `FALSE`	布尔值/逻辑值	与文字 `"TRUE"` 混淆
`# ...`	注释，对运行结果无影响	把注释当成一定会运行的代码
`<`、`==`	分别表示小于、是否相等	把 `==` 与赋值符混淆

如果一行很长，先找最外层函数，再拆成“传入的数据→做了什么→返回什么”；碰到多层括号，从**最里面的函数**开始理解。

1.3 第一次运行前，需要准备哪些包?

初学者先区分：**安装（install.packages）只需通常做一次，载入（library）在每次新R会话中可能要再执行。**下方是**教学补充**，不是原课件代码：

```
# 第一次使用且尚未安装时，去掉下面一行行首的 # 并运行
# install.packages(c("dplyr"))
library(dplyr)
```

这些包在本讲主要用于：

- `dplyr`：filter以及%>%管道。

`lm()`、`summary()`、`aov()`、`t.test()`、`cor()`、`cor.test()`和`plot()`等来自R基础/推荐自带组件，通常不需要为它们单独安装新包。

1.4 数据对象和运行顺序

- LFS示例中的`lfs`不是R预装对象。课程前几讲已完成**读取、筛选、清洗、因子转换**，这些步骤需要先执行；本教程不臆造文件路径或原始清洗代码。
- 第9讲还使用`mtcars`（R内置数据集）；第8讲第一段代码会创建虚构对象`fake_data`。
- 如果出现`object 'lfs' not found`，不是本行统计公式错了，而是尚未创建或读入`lfs`。
- 课堂输出与现在运行结果只有在使用同一份已清洗数据、相同函数设定、相容包版本时才可能完全一致。

1.5 这几类对象是什么?

- **向量（vector）**：一列同类型值，常由`c(...)`生成。
- **数据框（data.frame / tibble）**：像Excel表格，行对应观测、列对应变量。
- **函数（function）**：执行特定任务，如`mean()`求平均、`lm()`拟合回归。
- **参数（argument）**：括号里告诉函数如何工作的选项，例如`data = lfs`。
- **模型对象**：`lm(...)`运行后返回的结果，里面有系数、残差、拟合值等，不只是一个单独数字。

- **因子（factor）**：R记录分类变量的特殊类型，参照组决定类别回归系数的解释方式。

二、本讲课程代码：原文保留、逐段拆解

代码 01｜手动创建包含极端值的示例数据框

原讲义位置：制作一组模拟数据。

这段想做什么？

建立一个虚构的9行数据集，其中最后一个人的年龄65、工资200，与其他8人差异很大。

课堂原始R代码（完整保留）

```
fake_data <- data.frame(age= c(20, 23, 25, 26, 28, 30, 32, 33, 65 ),
                        wage = c(10, 11, 15, 9, 8, 20, 22, 25, 200))
```

逐行讲解

1. **第1行** `fake_data <- data.frame(age= c(20, 23, 25, 26, 28, 30, 32, 33, 65 ),`：赋值：用`<-`将右侧结果保存到`fake_data`。 `data.frame()`把同样长度的列装成一张表格。`c(...)`将逗号分开的数值组合成一个向量；同一行中的数字对应不同观测。
2. **第2行** `wage = c(10, 11, 15, 9, 8, 20, 22, 25, 200))`：`c(...)`将逗号分开的数值组合成一个向量；同一行中的数字对应不同观测。

把函数和统计概念拆开看

1. `fake_data <- ...`把右边的结果赋给左边的新对象，方便后续代码继续使用。
2. `data.frame()`把各列放在一起创建二维表。
3. `age = c(...)`中的`c()`把9个年龄数字拼成向量。
4. `wage = c(...)`构造对应的9个工资数字；两列必须有相同元素数量。

课件输出怎样读？

此代码主要**创建/修改对象**，默认可能不打印结果。可运行`names(lfs)`、`head(lfs)`或`str(fake_data)`（根据本段对象）检查执行效果。

初学者容易踩的坑 / 研究上的注意事项

此数据是课件刻意构造的**虚构示例**，不能把工资200理解为LFS真实离群记录。可以先运行`fake_data`和`str(fake_data)`确认行列。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 02 | 绘制虚构数据回归的残差-杠杆值图

原讲义位置：残差与杠杆值。

这段想做什么?

先以年龄预测工资，再用第五种内置诊断图检查哪些点可能对拟合直线具有较强影响。

课堂原始R代码（完整保留）

```
fake_data %>% lm(wage ~ age, data=.) %>% plot(which=5)
```

逐行讲解

1. **第1行** `fake_data %>% lm(wage ~ age, data=.) %>% plot(which=5)`：从前面人为构建的`fake_data`示例表开始管道流程。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.`中的`.`是管道传来的数据，**不是小数点或缺失值。** `~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 `lm()`拟合线性回归，括号内包括公式与数据来源。 `plot(which=5)`为线性模型绘制第5种诊断图：残差与杠杆值图。

把函数和统计概念拆开看

1. `fake_data %>% lm(wage ~ age, data=.)`把fake_data交给lm。
2. `data=.`中的点号表示管道左边传来的数据框。
3. `plot(which=5)`对前面的lm对象画第5幅标准诊断图（Residuals vs Leverage）。
4. 横轴是杠杆值（与解释变量位置有关），纵轴是标准化残差；图中Cook距离等值线帮助判断影响程度。

课件输出怎样读?

这段课堂代码主要生成**图形**，并非打印一张数字表。应打开RStudio的Plots窗口，结合本节"逐项讲解"和"统计含义"观察坐标轴、点、曲线或Cook距离等信息。

初学者容易踩的坑 / 研究上的注意事项

杠杆高不等于肯定有误；影响点也不应仅因对结果不利就自动删除。应先检查数据是否录入正确、解释变量范围及研究范围。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 03 | 排除40岁及以上观察后，重新拟合与诊断

原讲义位置：排除极端值后的残差与杠杆值图。

这段想做什么?

在虚构样本中添加年龄条件，理解"改变样本范围"会改变回归结果，也会改变能推广到的人群。

课堂原始R代码（完整保留）

```
fake_data %>%  filter(age<40) %>% lm(wage ~ age, data=.) %>% plot(which=5)
```

逐行讲解

1. **第1行** `fake_data %>%  filter(age<40) %>% lm(wage ~ age, data=.) %>% plot(which=5)`：从前面人为构建的`fake_data`示例表开始管道流程。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.`中的`.`是管道传来的数据，**不是小数点或缺失值。** `~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 `lm()`拟合线性回归，括号内包括公式与数据来源。 `filter(age<40)`保留年龄低于40的真实数据行，**会改变样本。** `plot(which=5)`为线性模型绘制第5种诊断图：残差与杠杆值图。

把函数和统计概念拆开看

1. `filter(age<40)`只保留年龄严格小于40岁的行；数学符号`<`表示小于。
2. 筛选后的8行数据才被传递给`lm()`，不是只缩放绘图横轴。
3. 新的`plot(which=5)`诊断的是**新拟合**的模型，而不是原模型。
4. 这次筛选是为了演示对影响点的敏感性，不构成通用的异常值处理规则。

课件输出怎样读?

这段课堂代码主要生成**图形**，并非打印一张数字表。应打开RStudio的Plots窗口，结合本节"逐项讲解"和"统计含义"观察坐标轴、点、曲线或Cook距离等信息。

初学者容易踩的坑 / 研究上的注意事项

一旦删除65岁记录，结论仅针对被筛选后的样本范围；报告中必须解释筛选理由，并比较有/无筛选的模型结果。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 04 | 在LFS多元工资模型中检查影响点

原讲义位置：我们回归模型的残差与杠杆值图。

这段想做什么?

把残差-杠杆诊断方法应用到多元回归，并用多个控制变量比较工资。

课堂原始R代码（完整保留）

```
lm(HOURPAY ~ SEX + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02 + MARSTA
+ INDE07M + NSECMJ20 + AGE + GOR9D, data=lfs) %>% plot(which=5)
```

逐行讲解

1. **第1行** `lm(HOURPAY ~ SEX + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02 + MARSTA + INDE07M + NSECMJ20 + AGE + GOR9D, data=lfs) %>% plot(which=5)`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。`data=lfs`明确指定从lfs表取变量。`~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 公式中的`+`表示**同时纳入**这些解释变量，并非对列做逐行算术加法。 `lm()`拟合线性回归，括号内包括公式与数据来源。 `plot(which=5)`为线性模型绘制第5种诊断图：残差与杠杆值图。

把函数和统计概念拆开看

1. `lm(HOURPAY ~ ... , data=lfs)`拟合多解释变量线性回归。
2. 公式中的`+`表示把多个变量一起纳入模型，并不表示把这些列相加。
3. `SEX`、`HIQUL22D`等如果是分类因子，R会自动构造虚拟变量。
4. `plot(which=5)`检查该多元模型的高杠杆 / 高影响观察。

课件输出怎样读?

这段课堂代码主要生成**图形**，并非打印一张数字表。应打开RStudio的Plots窗口，结合本节“逐项讲解”和“统计含义”观察坐标轴、点、曲线或Cook距离等信息。

初学者容易踩的坑 / 研究上的注意事项

观察含大量控制变量的诊断图时，优先判断异常记录是否真实以及是否系统性影响系数，而不是按一个阈值机械删除。统计异常与调查数据编码错误是不同问题。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答：“我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？”
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

三、按课堂顺序串起来：这一讲完整分析流程

看懂回归诊断：三个容易混淆的量

- **残差（Residual）**：真实的工资减去模型预测工资，表示这一个点偏离预测有多大。
- **杠杆值（Leverage）**：一个观测在**解释变量空间**中的位置有多独特；高杠杆意味着可能大幅拉动回归线。
- **Cook距离（Cook's distance）**：估计删除某个点后整个模型拟合会变化多少；结合残差和杠杆判断影响程度。
- **极端值不等于录入错误。**同一个离群点可能是研究最关键的真实现象，需要先核查来源、量纲、样本范围和敏感性。
- **诊断不是自动删除算法**：明确筛选理由、记录删前删后样本量与系数变化，是可复现研究的重要部分。

需要记住的完整逻辑

1. 创建一份带明显极端值的虚构数据。
2. 先拟合全部样本并看第5张诊断图。
3. 有依据地调整样本范围，再重画同样的诊断图。
4. 最后将同一方法用于LFS多元工资回归。

四、函数与参数速查表

函数/运算符	用来做什么	使用时先检查什么
`lm()`	拟合普通最小二乘线性回归模型	输入是什么类型？缺失值和参考组怎么处理？
`data.frame()`	创建表格型数据框，要求各列长度相容	输入是什么类型？缺失值和参考组怎么处理？
`c()`	把多个值连接成一个向量	输入是什么类型？缺失值和参考组怎么处理？
`plot()`	根据输入对象类型绘制图形；用于lm时有内置回归诊断图	输入是什么类型？缺失值和参考组怎么处理？
`filter()`	根据逻辑条件保留符合条件的观测行	输入是什么类型？缺失值和参考组怎么处理？
`%>%`	管道符：把左边结果交给右边函数，便于从左到右阅读操作顺序	这里是回归公式、比较表达式还是普通计算？
`<-`	赋值符：把右边得到的值保存到左边对象或变量名	这里是回归公式、比较表达式还是普通计算？
`~`	模型/检验公式分隔符：在回归中通常左边是结果变量，右边是解释变量	这里是回归公式、比较表达式还是普通计算？
`<`	比较运算符：小于；`age < 40` 就是只保留40以下	这里是回归公式、比较表达式还是普通计算？
`+`	回归公式里的加号表示**纳入多个解释变量**，不是把它们逐行数值相加	这里是回归公式、比较表达式还是普通计算？
`data=.`	点号`.`指管道前一步传过来的对象；明确告诉回归函数用哪个数据框	这里是回归公式、比较表达式还是普通计算？

五、本讲用到的变量：名字不是它们的中文意思

原变量名	根据本系列讲义能够确认/需要核对的含义
`HOURPAY`	小时工资（此系列课程LFS示例中的因变量）
`SEX`	性别分组
`AGE`	年龄（数值变量）

原变量名	根据本系列讲义能够确认/需要核对的含义
`HIQUL22D`	最高资格 / 学历水平（分类变量）
`FLEX22W6`	灵活工作安排相关变量（准确类别见数据字典）
`FTPT`	全职 / 兼职
`EMPLEN`	就业年限或工作持续时间相关变量（按数据字典核实）
`JOBTYP`	工作类型
`MPNR02`	LFS其他解释变量（请以原始数据字典确认编码含义）
`MARSTA`	婚姻状况
`INDE07M`	行业分类
`NSECMJ20`	社会经济分类
`GOR9D`	地理区域分组
`fake_data`	第8讲人为创建的虚构示例数据

> **避免误译**：LFS数据的编码与变量类别需以课程使用的变量说明、元数据和预处理后的`levels()`为准。上表中对含义不明确的字段明确提示了“需要数据字典核实”，没有强行猜测。

六、初学者常见错误与排查顺序

1. **object not found（对象不存在）**：确认是否先创建了`lfs`或`fake_data`，或前一步的`select()`是否把变量删掉。
2. **could not find function（找不到函数）**：确认是否安装并`library()`了相应包。
3. **unexpected symbol / unexpected end of input（语法错误）**：检查括号、引号、逗号和前一行末尾的`%>%`是否完整。
4. **missing values / NA / -Inf**：统计函数遇到`NA`或`log(0)`会出问题，正式分析需遵循数据字典及清洗记录。
5. **contrasts can be applied only to factors with 2 or more levels**：筛选样本后某个分类变量可能只剩一类，需要检查`table()`或`levels()`。
6. **课程输出与自己不同**：先比较数据版本、样本行数、变量类型、参考组、缺失处理和包版本，不要立即修改统计模型去“凑数”。
7. **统计显著误当成因果关系**：观察数据中的关联仍可能受未观测因素影响，报告必须诚实描述限制。

七、课后练习：自己独立运行，别只看解释

练习 1 | 创建数据

将示例工资200改为30，再重新拟合回归并查看诊断图。

建议提交的自查结果：贴上所运行的代码、关键输出，并用自己的中文解释观察到的变化。

练习 2 | 对比样本

比较筛选 `age<40` 前后OLS系数的变化，记录样本行数。

建议提交的自查结果：贴上所运行的代码、关键输出，并用自己的中文解释观察到的变化。

练习 3 | 判断影响点

选出一个高杠杆观测，解释为什么不能仅因为它"离群"就删除。

建议提交的自查结果：贴上所运行的代码、关键输出，并用自己的中文解释观察到的变化。

八、读完本讲，能否回答下面5个问题?

1. 上面的课堂代码中，哪些是**原始数据框**，哪些是处理后产生的新对象?
2. `%>%`、`~`、`data=.`分别在代码中起什么作用?
3. 这讲最重要的**模型或统计检验的原假设**是什么？输出中哪个部分告诉你结果?
4. 如果你只把一个参数改掉，图形/估计会如何变化？为什么?
5. 这个方法能不能直接证明因果关系？若不能，还需要什么研究设计或额外前提?

编写说明：教程中的"课堂原始R代码"均直接提取自 `lecture8_notes.html`；数值输出摘录也来自该文件，未声称重新计算。对语法、注意事项和练习的解释属于**额外教学补充**。这不是翻译版课件的替代品；建议并排打开本教程和 `lecture8_notes_中文版.html` 核对原始图表、文字与结果。