Lecture 8 补充课件：多元线性回归——R语言完全零基础逐行代码教程

> **对应原始讲义**：`7.lecture8_regressions.html`（**Multiple linear regression**，Dr. David McArthur）。
> **使用方式**：将本文件放入 Obsidian、VS Code、Typora 等支持 Markdown 的工具，依照第 1 → 11 个模型逐一阅读。
> **编写原则**：完整保留课件中的 **11 段 R 原始代码及其 11 段对应的控制台输出。**讲义中的原有解释和数值与扩展教学说明分开标识。
> **重要区别**：这是第 8 讲的单独"多元线性回归补充课件"，并不是前面 `lecture8_notes.html` 那份文件的重复教程。

阅读前先知道：这一讲到底在研究什么？

原课件用英国劳动力调查（LFS）数据探索**小时工资与性别之间的统计关联**，并且逐步在回归模型中加入受教育程度、零工时合同、全职或兼职、在现雇主处工作年限、工作合同类型、企业规模、婚姻状况、行业、职业等级、年龄及地区。

研究的问题可以用非常简单的中文表述：

> **男性与女性的平均小时工资是否不同？这种差异在把其他相关因素放入模型之后，还剩下多少？**

这并非 11 个彼此无关的练习：**每新增一个解释变量，就会得到一个新模型。**老师借此展示：由于遗漏了其他与工资有关的因素，最初仅包含性别的回归系数，可能与多变量控制后的系数不同。

请先记住三个词：

- **因变量（dependent variable）**：要解释的结果。这里为 `HOURPAY`（每小时工资，以英镑/小时为单位）。
- **主要自变量（key independent variable）**：最关注的解释因素。这里为 `SEX`（性别）；输出里最常读的是 `SEXFemale` 这一行。
- **控制变量（control variables）**：其他可能与工资有关、值得在模型中考虑的因素，例如 `AGE`、`HIQUL22D`。

课件分析的是**关联（association）**，而非通过这几段代码就证明性别、教育或婚姻状况对工资的因果影响。后文出现的"控制其他变量"指**统计条件比较**，不意味着我们随机分配了人们的性别、学历或工作。

第一章：第一次接触 R，也能看懂所有代码

1. R 和 RStudio 分别是什么？

- **R**：一种用于数据处理、统计计算与绘图的编程语言。
- **RStudio**：帮助你编辑、执行和管理 R 代码的软件界面。
- **脚本（script）**：以 `.R` 为扩展名的纯文本代码文件。
- **R Markdown（`.Rmd`）**：可将正文、代码、运行结果放在同一报告中的文件。
- **Console（控制台）**：RStudio 显示代码执行、输出与报错的区域。

在 RStudio 中，把代码输入脚本，再按 **Ctrl+Enter（Windows）/Cmd+Enter（Mac）** 可执行当前行或选中的代码。多行代码可一起选中运行。

2. 什么是数据框？`lfs` 是什么？

想象 Excel：每**行**是一个受访者，每**列**是一个变量（如工资、性别、年龄）。R 中储存这种数据的一种常见形式叫**数据框（data frame）**。

原课件所有模型都有 `data = lfs`，含义是：从已经加载到 R 的数据对象 `lfs` 中寻找变量。`lfs` 不是 R 的内置数据集，也不是一个函数。**原 HTML 课件没有提供创建 `lfs` 的完整数据清洗代码**，所以只复制回归语句到空白 RStudio 会遇到 `object 'lfs' not found`。

学习回归前，应先在自己的 R 工作环境中准备课程对应的 LFS 数据。为了检查数据是否读入成功，你可以使用以下**教学补充代码（非老师原始代码）**：

```
# 查看对象是否存在
exists("lfs")

# 看前六行
head(lfs)

# 看数据结构、每列的数据类型
str(lfs)

# 看列名是否包含工资、性别等
names(lfs)

# 看数据的行数和列数
dim(lfs)
```

`#` 后是注释，不执行；`head()` 看前几行；`str()` 看结构；`names()` 看列名；`dim()` 返回“行数、列数”。

3. 为什么出现 `library()` 和 `%>%`？

`%>%` 是管道操作符，常由 `magrittr` 或 `dplyr` 提供：它把左侧结果传给右侧函数。比如 `x %>% summary()` 类似 `summary(x)`。

在原课件的 `lm(...) %>% summary` 中，意思是：

1. `lm(...)` 先拟合一个线性模型；
2. `%>%` 把这个模型传给 `summary`；
3. `summary` 打印模型结果。

原课件直接使用 `%>%`，**没有在这份 HTML 内展示载入程序包的命令。**若你的环境尚未启用该操作符，可使用以下**教学补充代码**：

```
# 以下命令只在尚未安装时执行一次
install.packages("dplyr")

# 每次开启新的R会话后，需要使用时载入
library(dplyr)
```

也可以不使用管道，改写为 R 基础语法 `summary(lm(HOURPAY ~ SEX, data = lfs))`。这只是等价写法，**原课件代码仍在下文逐字保留。**

4. 符号逐个认识

R 中写法	中文意思	在本课件里的作用
`lm()`	linear model（线性模型）函数	拟合普通最小二乘线性回归（OLS）
`(` 和 `)`	圆括号	放置传给函数的参数
`,`	逗号	分隔不同的函数参数
`=`	设置参数或赋值（视位置而定）	`data = lfs` 指定使用的数据
`~`	回归公式分隔符，读作"由……解释"	左边是因变量，右边是解释变量
`+`	在公式右侧加入另一解释变量	**不是把工资与性别数值相加**
`%>%`	管道：把结果送入下一步	把模型送给 `summary`
`summary`	摘要函数	在这里输出回归结果
`SEXFemale`	R 回归输出中的一个系数名	女性相对于未展示参照类别（这里是男性）的差异
`**` / `***`	显著性标记	**是输出表格的标记**，不是要键入的 R 代码

初学者最常见的误会：`HOURPAY ~ SEX + AGE` 的 `+` 并不是数学上 `SEX + AGE` 后去预测工资，而是告诉 `lm()` 同时放入两个解释变量。

5. 回归公式写成数学语言

第一段模型可以表示为：

[HOURPAY_i = \beta_0 + \beta_1 Female_i + \varepsilon_i]

`i` 代表第 `i` 个受访者；`Female_i` 是指示变量（女性为 1，男性为 0，采用本课件展示的分类编码）；β_0 是截距；β_1 是"女性相对男性的条件平均工资差异"；ϵ_i 是模型未能解释的部分。

增加学历后的模型则写成：

[HOURPAY_i = \beta_0 + \beta_1 Female_i + \sum_k\gamma_k Education_{ik} + \varepsilon_i]

由于教育程度是分类变量，R 会为它的多个类别建立虚拟变量，**通常不需要手动为每种学历写一列 0/1。**每个系数的比较对象是"被省略的参照类别"。

第二章：怎样读懂任何一份 `lm()` 输出？

在接下来的 11 段结果里，控制台包含下列固定栏目。本章只需先理解基本含义，之后看实际数值会更容易。

A. `Call:`——运行了什么模型

它将执行时的回归公式打印出来。例如 `lm(formula = HOURPAY ~ SEX, data = lfs)`，意味着工资是结果变量，性别是解释变量。

B. `Residuals:`——残差的概况

残差（residual）= 真实工资 − 模型预测工资。

- `Min`：最小残差；`Max`：最大残差；
- `1Q`：下四分位数；`Median`：中位数；`3Q`：上四分位数。

比如某人真实小时工资 20 英镑、模型预测 18 英镑，残差就是 `20 − 18 = +2`；若预测 25 英镑，残差是 `20 − 25 = −5`。残差越大（按绝对值计），对该受访者预测得越不准。这里的五数概括**不能替代完整的残差诊断。**

C. `Coefficients:`——最重要的系数表

原始表头	中文	该怎样理解
`Estimate`	估计系数	与参照组相比，工资水平相差多少（此处为英镑/小时）；连续变量则是每增加一单位对应多少差异
`Std. Error`	标准误	系数估计的不确定性，越小通常意味着越精确（还需结合估计值）
`t value`	t 统计量	通常是 `Estimate / Std. Error`
`Pr(>|t|)`	双侧 t 检验的 p 值	在相应检验假设成立时，观察到如此或更极端 t 值的概率

`(Intercept)` 是截距：当所有连续解释变量等于 0、所有分类变量处于各自参照组时，模型预测的工资。**截距不一定对应现实中具有代表性的人**，尤其含有 `AGE` 时，年龄为 0 的情况不符合此处就业人群的实际含义。不要把所有模型的截距都直接解释为“普通男性的工资”。

D. 显著性星号怎么读?

```
***  p < 0.001
 **  p < 0.01
  *  p < 0.05
  .  p < 0.10（通常只称边缘证据，不等同于5%显著）
空白 p >= 0.10
```

常见课堂规则是 `p < 0.05` 时认为“在 5% 水平上统计显著”。但**统计显著不等于效应很大、不等于社会上一定重要，也不等于证明因果**；“不显著”也不能证明系数真实等于 0。

输出中的 `<2e-16`、`2.39e-13` 是科学计数法：`2e-16` 等于 2×10^{-16}，不是“2乘以 e 减16”；这里的 `e` 表示十的幂次。

E. `Multiple R-squared`、`Adjusted R-squared`

- **R^2（决定系数）**：在样本内，模型解释的工资变异比例。`R² = 0.01748` 大约是 **1.748%**，并不是“性别决定了 1.748% 的工资”这种因果结论。
- **Adjusted R-squared（调整后的 R^2）**：对解释变量的数量作惩罚修正，适合辅助比较复杂度不同的回归模型，但不是唯一优劣标准。
- 这里 11 个模型逐步加变量，普通 R^2 在相同样本上通常不会下降，因为模型有更多自由度；因此**R^2 增加本身不能证明新增变量具有因果意义或提高了样本外预测能力。**

F. `Residual standard error` 与 `F-statistic`

- **Residual standard error（残差标准误）**：残差波动的典型规模。因工资以英镑/小时为单位，这里也以英镑/小时计。常被称为残差的标准差估计。
- **F-statistic（F 统计量）**：通常用来检验模型中（不含截距的）全部斜率系数是否同时为 0。它的 p 值很小时，说明至少有某些解释变量提供了统计信息；**这不意味着所有变量单独显著。**
- **degrees of freedom（自由度，DF）**：与样本量及估计的参数个数有关。比如第一个模型剩余自由度为 7345，含截距与性别两个参数，可推知该模型使用了 7347 条完整观测。

G. 分类变量、参照组、虚拟变量

以第一个模型为例，输出只写 `SEXFemale`，没有单独一行 `SEXMale`，因为**男性是参照组。**若女性系数为 `-3.0591`，含义是：

> 女性平均小时工资比男性低 3.0591 英镑（在只控制性别的模型中）。

若加入学历而系数变为 `-3.6690`，则含义变为：

> 在控制学历后，女性相对男性的估计小时工资差异为 −3.6690 英镑。

这里的比较概念与“把女性工资降低 3.6690 英镑”完全不同：回归是描述样本关联，不是在修改数据。

第三章：正式学习 11 段课堂代码

阅读约定：每小节先完整展示教师 HTML 中的 **原始 R 代码**，再完整保留紧跟的 **控制台原始输出**，之后分解为：执行目标、语法、关键数字、回归意义、常见误区。输出中英文分类名称不翻译成 R 变量名，以保证你能与老师页面逐项对照。

原始代码 1 / 11

教师原课件代码（完整、可复制）：

```
lm(HOURPAY ~ SEX, data = lfs) %>% summary
```

教师原课件对应输出（原样保留，供逐行对照）：

```
Call:
lm(formula = HOURPAY ~ SEX, data = lfs)

Residuals:
    Min      1Q  Median      3Q     Max
```

```
-16.033  -7.639  -3.384   4.256  79.396

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  22.4834     0.1959  114.76   <2e-16 ***
SEXFemale    -3.0591     0.2676  -11.43   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 11.44 on 7345 degrees of freedom
Multiple R-squared:  0.01748,   Adjusted R-squared:  0.01734
F-statistic: 130.6 on 1 and 7345 DF,  p-value: < 2.2e-16
```

模型 1 | 只有性别：最简单的线性回归

研究目标：不加入其他控制因素，只比较男性与女性的平均小时工资。

逐行（逐个组成部分）拆解：

1. `lm(`：开始调用 R 内置的线性模型函数 `lm`；不是加载数据，也不是直接画图。
2. `HOURPAY ~ SEX`：公式左侧的 `HOURPAY` 是因变量；右侧的 `SEX` 是唯一自变量。
3. `data = lfs`：从 `lfs` 数据框里寻找这两个列名，而不是读取硬盘上名叫 lfs 的文件。
4. `)`：结束 `lm()` 参数列表并返回拟合好的模型对象。
5. `%>%`：把刚获得的模型继续传到下一步。
6. `summary`：打印模型摘要。它虽然没有显式写 `()`，在这段管道表达式中仍然作为函数调用。

回归结果怎么一步一步读：

- `(Intercept) = 22.4834`：男性（参照组）的**模型预测平均小时工资**为 £22.4834。
- `SEXFemale = −3.0591`：女性比男性平均少 £3.0591/小时。
- **由两者计算女性预测均值**：`22.4834 − 3.0591 = 19.4243` 英镑/小时。这是按这份样本与模型计算的预测均值，不是全英国女性工资的固定数字。
- `Std. Error`：性别系数标准误 `0.2676`，代表估计存在抽样不确定性。
- `t value = −11.43`、`p < 2e−16`、`***`：在通常假设下，性别系数显著不为 0。
- `R² = 0.01748`：仅凭性别，模型解释了工资样本变异约 **1.75%**。因此"统计上显著"和"解释程度很高"不是一回事。
- `Residual standard error = 11.44`：预测误差仍有较大波动（英镑/小时）。

一个能帮助理解的日常类比：这像是把所有受访者仅分成"男性""女性"两组，用这两个组各自的平均工资预测组内每个人。组内的人仍然差异很大，因此 R^2 可以很低。

常见错误：`lm(SEX ~ HOURPAY, data = lfs)` 把因变量和自变量颠倒了，研究问题会完全不同；`lm(HOURPAY + SEX, data = lfs)` 缺少公式的 `~`；缺少 `lfs` 数据时不能运行。

原始代码 2 / 11

教师原课件代码（完整、可复制）：

```r
lm(HOURPAY ~ SEX + HIQUL22D, data = lfs) %>% summary
```

教师原课件对应输出（原样保留，供逐行对照）：

```
Call:
lm(formula = HOURPAY ~ SEX + HIQUL22D, data = lfs)

Residuals:
    Min      1Q  Median      3Q     Max
-20.566  -6.337  -2.241   3.373  77.020

Coefficients:
                               Estimate Std. Error t value Pr(>|t|)
(Intercept)                     27.1162     0.2285  118.65   <2e-16 ***
SEXFemale                       -3.6690     0.2491  -14.73   <2e-16 ***
HIQUL22DHigher education        -5.5659     0.4812  -11.57   <2e-16 ***
HIQUL22DA level or equivalent   -7.9860     0.3203  -24.93   <2e-16 ***
HIQUL22DGCSE A*-C or equivalent -9.0507     0.3666  -24.69   <2e-16 ***
HIQUL22DOther qualitfication    -9.7761     0.6109  -16.00   <2e-16 ***
HIQUL22DNo Qualification       -11.7713     0.7544  -15.60   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 10.62 on 7340 degrees of freedom
Multiple R-squared:  0.1543,    Adjusted R-squared:  0.1536
F-statistic: 223.2 on 6 and 7340 DF,  p-value: < 2.2e-16
```

模型 2 | 加入教育水平 `HIQUL22D`

与模型 1 相比多出了什么？ 在 `SEX` 后面加入 `+ HIQUL22D`，让不同学历成为控制变量。

代码每部分的具体含义：`HOURPAY ~ SEX + HIQUL22D` 表示同时使用性别和学历来解释工资；`HIQUL22D` 是一整列教育类别，**不要求新手手动制作五个新变量。**R 对分类因子建立对应的虚拟变量；`data = lfs` 仍指同一个数据框；`%>% summary` 仍打印结果。

这个模型必须掌握"参照组"：老师在 HTML 中明确指出：`SEX` 的参照类别是 **Male（男性）**，`HIQUL22D` 的参照类别是 **Degree（学位）**。因此：

- `(Intercept) = 27.1162`：男性且学历是 Degree 的预测平均小时工资为 £27.1162（没有其他解释变量）。
- `SEXFemale = −3.6690`：**在学历水平相同时**，女性比男性估计少 £3.6690/小时。
- `HIQUL22DNo Qualification = −11.7713`：不具备资格证书者相对于 Degree 学历，工资估计低 £11.7713/小时（比较时保持性别相同）。
- `HIQUL22DHigher education = −5.5659`：此教育类别相对 Degree 较低 £5.5659/小时；不是相对于"不具备资格证书"低这么多。
- `HIQUL22DA level or equivalent = −7.9860`、`HIQUL22DGCSE A*-C or equivalent = −9.0507`：也都**相对于 Degree**；不能把这些系数直接相加比较不同学历。

把公式变成具体数字：

- Degree 男性：`27.1162`。
- Degree 女性：`27.1162 − 3.6690 = 23.4472`。
- 无资格男性：`27.1162 − 11.7713 = 15.3449`。
- 无资格女性：`27.1162 − 3.6690 − 11.7713 = 11.6759`。

这四个数字是 **该加性模型给出的预测值**，不是个体工资保证值。由于公式没有 `SEX:HIQUL22D` 交互项，模型还**假定女性与男性的工资差异在所有学历类别中相同**；这是建模形式的假设，并没有在这里单独检验。

与第一段比较：女性相对男性的估计差异由 `-3.0591` 变成 `-3.6690`，绝对值反而增加。老师指出一种可能解释：男女学历构成不同，而控制学历后未调整的工资差异被重新分解。**这不能单凭回归系数就严格证明"女性比男性学历高"**；要验证样本学历构成仍需做描述性统计。`R² = 0.1543`，模型解释工资变异约 **15.43%**，明显高于第一段。

易错理解：不能说"女性降薪 3.669 英镑"；不能说"学历解释了性别工资差异的 15.43%"。R^2 指**全模型解释的总体工资变异比例。**

原始代码 3 / 11

教师原课件代码（完整、可复制）：

```
lm(HOURPAY ~ SEX + HIQUL22D + FLEX22W6 + FTPT, data = lfs) %>% summary
```

教师原课件对应输出（原样保留，供逐行对照）：

```
Call:
lm(formula = HOURPAY ~ SEX + HIQUL22D + FLEX22W6 + FTPT, data = lfs)

Residuals:
    Min      1Q  Median      3Q     Max
-20.379  -6.206  -2.200   3.361  77.630

Coefficients:
                                Estimate Std. Error t value Pr(>|t|)
(Intercept)                      22.0827     0.8968  24.624  < 2e-16 ***
SEXFemale                        -3.0794     0.2577 -11.949  < 2e-16 ***
HIQUL22DHigher education         -5.4010     0.4780 -11.300  < 2e-16 ***
HIQUL22DA level or equivalent    -7.7981     0.3185 -24.485  < 2e-16 ***
HIQUL22DGCSE A*-C or equivalent  -8.7889     0.3652 -24.064  < 2e-16 ***
HIQUL22DOther qualitfication     -9.5050     0.6071 -15.658  < 2e-16 ***
HIQUL22DNo Qualification        -11.3429     0.7506 -15.112  < 2e-16 ***
FLEX22W6No                        5.2259     0.8751   5.972 2.46e-09 ***
FTPTPart-time                    -2.3996     0.3164  -7.584 3.77e-14 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 10.54 on 7338 degrees of freedom
Multiple R-squared:  0.1668,    Adjusted R-squared:  0.1659
F-statistic: 183.6 on 8 and 7338 DF,  p-value: < 2.2e-16
```

模型 3 | 加入零工时合同与全职/兼职状态

新增变量：

- `FLEX22W6`：讲义用来表示是否为 **zero-hours contract（零工时合同）**。
- `FTPT`：全职或兼职（full-time / part-time）。

代码拆开看：`HOURPAY ~ SEX + HIQUL22D + FLEX22W6 + FTPT` 右侧现在有 **四个变量名**；但它们是分类变量，输出的非截距系数**超过四行**（因为一个变量可拆为几个分类水平）。这也是为什么 `F-statistic` 的分子自由度是 8，而不是 4。

新增系数的读法：

- `FLEX22W6No = +5.2259`：不属于零工时合同的人，相对于属于该类合同的人，在控制性别、教育及 FTPT 后，估计每小时工资高 **£5.2259**。
- `FTPTPart-time = −2.3996`：兼职相对于全职，在控制其他已列变量后，估计每小时工资低 **£2.3996**。
- `SEXFemale = −3.0794`：同学历、同零工时合同状态、同全职兼职状态时，女性工资比男性低 **£3.08/小时**（四舍五入）。
- `R² = 0.1668`：解释约 **16.68%** 的样本工资变异，比模型 2 的 15.43% 更高。

为什么女性系数从 −3.669 变回 −3.079？ 因为新加入的工时与合同类型改变了模型对工资差异的分解。老师认为女性更可能从事兼职、而兼职时薪通常更低，因此加入这些因素后性别系数变化。**方向合理不等于已验证统计机制**：在未展示分组比例、因果设计或中介分析之前，只能把它作为讲义中的解释性讨论。

动手计算预测值（仅作为演示加减法）：对 Degree、非零工时合同、兼职的女性，模型预测为：

`22.0827 − 3.0794 + 5.2259 − 2.3996 = 21.8296`（英镑/小时）。

注意这里不用另外加上一个“女性组的工资”项：截距加各个相关组别系数就足够。

原始代码 4 / 11

教师原课件代码（完整、可复制）：

```
lm(HOURPAY ~ SEX + HIQUL22D + FLEX22W6 + FTPT + EMPLEN, data = lfs) %>% summary
```

教师原课件对应输出（原样保留，供逐行对照）：

```
Call:
lm(formula = HOURPAY ~ SEX + HIQUL22D + FLEX22W6 + FTPT + EMPLEN,
    data = lfs)

Residuals:
    Min      1Q  Median      3Q     Max
-22.293  -6.130  -2.107   3.118  76.537

Coefficients:
                                Estimate Std. Error t value Pr(>|t|)
(Intercept)                      21.0349     1.1507  18.281  < 2e-16 ***
SEXFemale                        -3.0489     0.2545 -11.978  < 2e-16 ***
HIQUL22DHigher education         -5.7451     0.4728 -12.151  < 2e-16 ***
HIQUL22DA level or equivalent    -7.8133     0.3146 -24.833  < 2e-16 ***
HIQUL22DGCSE A*-C or equivalent  -9.0634     0.3613 -25.086  < 2e-16 ***
HIQUL22DOther qualitfication     -9.4442     0.5993 -15.758  < 2e-16 ***
HIQUL22DNo Qualification        -11.7892     0.7424 -15.880  < 2e-16 ***
FLEX22W6No                       3.8811     0.8717   4.452 8.63e-06 ***
FTPTPart-time                   -2.3085     0.3125  -7.387 1.67e-13 ***
EMPLENThree months, less than 6 -0.2034     0.9795  -0.208 0.835498
```

```
EMPLEN6 months, less than 12      0.4157     0.8990   0.462 0.643783
EMPLEN1 year, less than 2         0.1716     0.8205   0.209 0.834335
EMPLEN2 years, less than 5        1.4995     0.7837   1.913 0.055745 .
EMPLEN5 years, less than 10       2.8545     0.7971   3.581 0.000344 ***
EMPLEN10 years, less than 20      3.9389     0.7935   4.964 7.06e-07 ***
EMPLEN20 years or more            5.1767     0.8105   6.387 1.80e-10 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 10.4 on 7331 degrees of freedom
Multiple R-squared:  0.189, Adjusted R-squared:  0.1874
F-statistic: 113.9 on 15 and 7331 DF,  p-value: < 2.2e-16
```

模型 4 | 加入在现雇主处工作时间 `EMPLEN`

`EMPLEN` 是 **employment length at current employer**（在当前雇主处的工作时间），在课件中作为**分类变量**进入模型。

新增部分如何工作：`+ EMPLEN` 并不是把一个"工作年限数字"加到工资上，而是让 R 根据 `EMPLEN` 的类别，在输出中列出多个与未显示参照类别比较的系数。例如：

- `EMPLENThree months, less than 6`：3个月至不足6个月；
- `EMPLEN6 months, less than 12`：6个月至不足12个月；
- `EMPLEN1 year, less than 2`：1年至不足2年；
- `EMPLEN2 years, less than 5`：2年至不足5年；
- `EMPLEN5 years, less than 10`：5年至不足10年；
- `EMPLEN10 years, less than 20`：10年至不足20年；
- `EMPLEN20 years or more`：20年或以上。

其参照组未在输出中单列，直观看来是较短在职期限。原课件没有在正文写出参照组的精确标签，**请用 `levels(lfs$EMPLEN)` 核实，而不是凭空确定标签。**

实际输出说明什么?

- `EMPLENThree months, less than 6 = −0.2034` 且 `p = 0.835498`：相对参照组估计较低，但差异不显著。
- `EMPLEN2 years, less than 5 = +1.4995`、`p = 0.055745`：在 5% 水平上**不显著**（只有句点 `.`）。
- `EMPLEN5 years, less than 10 = +2.8545`，`p = 0.000344`：差异显著。
- `EMPLEN10 years, less than 20 = +3.9389`：估计差异更大。
- `EMPLEN20 years or more = +5.1767`：估计差异进一步上升。
- `SEXFemale = −3.0489`：控制在当前雇主工作时间后，性别差异仍接近 **−£3.05**。
- `R² = 0.1890`：解释 **18.90%** 的工资变异。

不要误解：`+5.1767` **不是**"每工作一年工资增加 £5.18"；它代表的是"20年及以上"这个类别与参照类别之间的预测时薪差异。把它解释成每年增长属于分类变量与连续变量混淆。

补充检查方法（非原始课堂代码）：`table(lfs$EMPLEN, useNA = "ifany")` 能查看在职时间各类的人数（前提是 lfs 已载入）。

原始代码 5 / 11

教师原课件代码（完整、可复制）：

```
lm(HOURPAY ~ SEX + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP, data = lfs) %>%
summary
```

教师原课件对应输出（原样保留，供逐行对照）：

```
Call:
lm(formula = HOURPAY ~ SEX + HIQUL22D + FLEX22W6 + FTPT + EMPLEN +
    JOBTYP, data = lfs)

Residuals:
    Min      1Q  Median      3Q     Max
-22.291  -6.126  -2.103   3.113  76.546

Coefficients:
                                Estimate Std. Error t value Pr(>|t|)
(Intercept)                      20.9736     1.1793  17.784  < 2e-16 ***
SEXFemale                        -3.0488     0.2546 -11.977  < 2e-16 ***
HIQUL22DHigher education         -5.7434     0.4729 -12.146  < 2e-16 ***
HIQUL22DA level or equivalent    -7.8108     0.3148 -24.810  < 2e-16 ***
HIQUL22DGCSE A*-C or equivalent  -9.0590     0.3618 -25.039  < 2e-16 ***
HIQUL22DOther qualitfication     -9.4414     0.5995 -15.749  < 2e-16 ***
HIQUL22DNo Qualification        -11.7870     0.7425 -15.874  < 2e-16 ***
FLEX22W6No                       3.9228     0.8893   4.411 1.04e-05 ***
FTPTPart-time                   -2.3147     0.3136  -7.381 1.75e-13 ***
EMPLENThree months, less than 6 -0.2085     0.9798  -0.213 0.831462
EMPLEN6 months, less than 12     0.4261     0.9002   0.473 0.635947
EMPLEN1 year, less than 2        0.1803     0.8214   0.220 0.826233
EMPLEN2 years, less than 5       1.5153     0.7866   1.926 0.054088 .
EMPLEN5 years, less than 10      2.8723     0.8007   3.587 0.000336 ***
EMPLEN10 years, less than 20     3.9573     0.7973   4.963 7.09e-07 ***
EMPLEN20 years or more           5.1949     0.8142   6.380 1.87e-10 ***
JOBTYPNot permanent in some way  0.1705     0.7174   0.238 0.812127
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 10.4 on 7330 degrees of freedom
Multiple R-squared:  0.189, Adjusted R-squared:  0.1873
F-statistic: 106.8 on 16 and 7330 DF,  p-value: < 2.2e-16
```

模型 5 | 加入永久或临时职位 `JOBTYP`

新变量：`JOBTYP` 区分工作是否 permanent（永久性质）或 not permanent（非永久性质）。输出中的 `JOBTYPNot permanent in some way` 是"以某种方式非永久"的类别，它与**被省略的永久工作参照类别**比较。

代码层面：这次唯一改变是把 `+ JOBTYP` 加到上个模型末尾。因变量与其他自变量不变，`data = lfs` 不变，结尾仍是管道传给 `summary`。在 R 的加性线性模型中，它**并没有**指定"仅对女性控制工作类型"；`JOBTYP` 对所有参与拟合的观测适用。

关键结果：

- `JOBTYPNot permanent in some way = +0.1705`：样本估计非永久职位每小时工资比永久职位高约 17 便士（在控制其他因素后）。
- `Std. Error = 0.7174`、`t = 0.238`、`p = 0.812127`：这一项没有足够证据认定系数不同于 0。
- `SEXFemale = −3.0488`：几乎与模型 4 的 `−3.0489` 一样。
- `R² = 0.1890`：四舍五入后与前一个模型相同；添加此变量没有明显改善总体拟合。

讲义正文仅说该项"看起来不具有统计显著性"；它**没有**进行关于所有合同变量的复杂因果判断。

新手要学会的判断：不能因为 `Estimate` 是正数就断言"临时工作工资更高"；这可能只是样本波动。对无显著证据的结果，适宜写成"该模型中没有发现其与小时工资的统计显著关联"。也不能把"没有发现显著关联"写成"已经证明完全无影响"。

原始代码 6 / 11

教师原课件代码（完整、可复制）：

```
lm(HOURPAY ~ SEX + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02, data = lfs) %>% summary
```

教师原课件对应输出（原样保留，供逐行对照）：

```
Call:
lm(formula = HOURPAY ~ SEX + HIQUL22D + FLEX22W6 + FTPT + EMPLEN +
    JOBTYP + MPNR02, data = lfs)

Residuals:
    Min      1Q  Median      3Q     Max
-24.110  -6.028  -2.068   3.031  77.222

Coefficients:
                                      Estimate Std. Error t value Pr(>|t|)
(Intercept)                           20.84866    1.20417  17.314  < 2e-16 ***
SEXFemale                             -3.02767    0.25204 -12.012  < 2e-16 ***
HIQUL22DHigher education              -5.41810    0.46892 -11.554  < 2e-16 ***
HIQUL22DA level or equivalent         -7.37501    0.31388 -23.496  < 2e-16 ***
HIQUL22DGCSE A*-C or equivalent       -8.49001    0.36100 -23.518  < 2e-16 ***
HIQUL22DOther qualitfication          -8.83659    0.59560 -14.836  < 2e-16 ***
HIQUL22DNo Qualification             -11.24586    0.73622 -15.275  < 2e-16 ***
FLEX22W6No                            3.32410    0.88173   3.770 0.000165 ***
FTPTPart-time                        -1.86697    0.31327  -5.960 2.65e-09 ***
EMPLENThree months, less than 6      -0.34450    0.97040  -0.355 0.722596
EMPLEN6 months, less than 12          0.33142    0.89180   0.372 0.710179
EMPLEN1 year, less than 2            -0.02982    0.81356  -0.037 0.970762
EMPLEN2 years, less than 5            1.25437    0.77936   1.609 0.107551
EMPLEN5 years, less than 10           2.45569    0.79377   3.094 0.001984 **
EMPLEN10 years, less than 20          3.43153    0.79075   4.340 1.45e-05 ***
EMPLEN20 years or more                4.54149    0.80804   5.620 1.98e-08 ***
JOBTYPNot permanent in some way      -0.06978    0.71049  -0.098 0.921763
MPNR0211-19                          -1.11462    0.52949  -2.105 0.035319 *
MPNR0220-24                          -0.71904    0.68668  -1.047 0.295076
MPNR02Don't know but under 25        -2.23238    0.89162  -2.504 0.012310 *
```

```
MPNR0225-49                                -0.72845    0.46038  -1.582 0.113631
MPNR0250-249                                0.09719    0.39421   0.247 0.805267
MPNR02250-499                               1.86456    0.56304   3.312 0.000932 ***
MPNR02Don't know but between 50 and 499     0.78142    0.65889   1.186 0.235672
MPNR02500 or more                           3.19590    0.39315   8.129 5.05e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 10.29 on 7322 degrees of freedom
Multiple R-squared:  0.2071,    Adjusted R-squared:  0.2045
F-statistic:  79.7 on 24 and 7322 DF,  p-value: < 2.2e-16
```

模型 6 | 加入企业规模 `MPNR02`

变量含义：课件将 `MPNR02` 用作 **size of the firm（企业规模）** 的指标。输出中有许多按照员工数量分组的类别。

为什么增加一个变量却多了 8 行系数? 因为 `MPNR02` 是多类别变量：`11-19`、`20-24`、`25-49`、`50-249`、`250-499`、`500 or more`，还包含某些"不确定人数但知道范围"的回答类别。R 自动以一个未显示类别作参照，从而为其他类别分别估计差值。

典型结果：

- `MPNR0211-19 = -1.11462`，`p = 0.035319`：该组与参照类别相比，小时工资估计低约 £1.11，在 5% 水平显著。
- `MPNR02250-499 = +1.86456`，`p = 0.000932`：工资估计高约 £1.86。
- `MPNR02500 or more = +3.19590`，`p = 5.05e-16`：工资估计高约 £3.20。
- `MPNR02Don't know but under 25 = -2.23238`：这一行也作为**类别**进入回归；说明"无法给出精确规模但知道少于25人"并非普通数字缺失值。
- `SEXFemale = -3.02767`：性别差异仍在 **−£3.03/小时** 附近。
- `R² = 0.2071`：模型解释变异约 **20.71%**。

有关参照组的严谨性：仅从结果表可以确定"该变量有一个未显示的参照类别"；但这份 HTML 正文没有明写 `MPNR02` 的参照组文字标签。你可能会猜是最小规模组，但正式写作前应通过 `levels(lfs$MPNR02)` 或 `contrasts(lfs$MPNR02)` 查证。

不要把各规模系数简单排列为确定的因果增长规律：企业规模还可能与行业、城市、职业分布等共变。此处的结果是控制模型已有变量后的条件关联。

原始代码 7 / 11

教师原课件代码（完整、可复制）：

```
lm(HOURPAY ~ SEX + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02 +
MARSTA, data = lfs) %>% summary
```

教师原课件对应输出（原样保留，供逐行对照）：

```
Call:
lm(formula = HOURPAY ~ SEX + HIQUL22D + FLEX22W6 + FTPT + EMPLEN +
    JOBTYP + MPNR02 + MARSTA, data = lfs)
```

```
Residuals:
    Min      1Q  Median      3Q     Max
-24.798  -6.026  -1.954   3.214  76.056

Coefficients:
                                                  Estimate Std. Error
(Intercept)                                      19.919009   1.195219
SEXFemale                                        -3.006896   0.250727
HIQUL22DHigher education                         -5.492173   0.464690
HIQUL22DA level or equivalent                    -7.133012   0.311736
HIQUL22DGCSE A*-C or equivalent                  -8.287454   0.358561
HIQUL22DOther qualitfication                     -9.007106   0.590139
HIQUL22DNo Qualification                        -11.161196   0.729359
FLEX22W6No                                       2.822237   0.873588
FTPTPart-time                                    -2.147829   0.311183
EMPLENThree months, less than 6                  -0.385802   0.960456
EMPLEN6 months, less than 12                      0.100754   0.882826
EMPLEN1 year, less than 2                        -0.287125   0.805630
EMPLEN2 years, less than 5                        0.870865   0.771994
EMPLEN5 years, less than 10                       1.835654   0.787130
EMPLEN10 years, less than 20                      2.598980   0.785419
EMPLEN20 years or more                            3.467156   0.804347
JOBTYPNot permanent in some way                  -0.085073   0.703213
MPNR0211-19                                      -1.031462   0.524134
MPNR0220-24                                      -0.625892   0.679732
MPNR02Don't know but under 25                    -2.135717   0.882739
MPNR0225-49                                      -0.670691   0.455719
MPNR0250-249                                      0.004716   0.390188
MPNR02250-499                                     1.800051   0.557272
MPNR02Don't know but between 50 and 499           0.753469   0.652287
MPNR02500 or more                                 3.216213   0.389263
MARSTAMarried, living with spouse                 3.173124   0.263834
MARSTAMarried separated from spouse               1.766559   0.816595
MARSTADivorced                                    3.415284   0.484361
MARSTAWidowed                                     3.524637   1.207088
MARSTACurrently or previously in civil partnership  0.154012   1.179948
                                                 t value Pr(>|t|)
(Intercept)                                       16.666  < 2e-16 ***
SEXFemale                                        -11.993  < 2e-16 ***
HIQUL22DHigher education                         -11.819  < 2e-16 ***
HIQUL22DA level or equivalent                    -22.882  < 2e-16 ***
HIQUL22DGCSE A*-C or equivalent                  -23.113  < 2e-16 ***
HIQUL22DOther qualitfication                     -15.263  < 2e-16 ***
HIQUL22DNo Qualification                         -15.303  < 2e-16 ***
FLEX22W6No                                         3.231 0.001241 **
FTPTPart-time                                     -6.902 5.55e-12 ***
EMPLENThree months, less than 6                   -0.402 0.687927
EMPLEN6 months, less than 12                       0.114 0.909141
EMPLEN1 year, less than 2                         -0.356 0.721553
EMPLEN2 years, less than 5                         1.128 0.259326
EMPLEN5 years, less than 10                        2.332 0.019723 *
EMPLEN10 years, less than 20                       3.309 0.000941 ***
EMPLEN20 years or more                             4.311 1.65e-05 ***
JOBTYPNot permanent in some way                   -0.121 0.903712
MPNR0211-19                                       -1.968 0.049113 *
```

```
MPNR0220-24                                          -0.921 0.357189
MPNR02Don't know but under 25                        -2.419 0.015569 *
MPNR0225-49                                          -1.472 0.141139
MPNR0250-249                                          0.012 0.990357
MPNR02250-499                                         3.230 0.001243 **
MPNR02Don't know but between 50 and 499               1.155 0.248080
MPNR02500 or more                                     8.262  < 2e-16 ***
MARSTAMarried, living with spouse                    12.027  < 2e-16 ***
MARSTAMarried separated from spouse                   2.163 0.030549 *
MARSTADivorced                                        7.051 1.94e-12 ***
MARSTAWidowed                                         2.920 0.003512 **
MARSTACurrently or previously in civil partnership    0.131 0.896155
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 10.19 on 7317 degrees of freedom
Multiple R-squared:  0.2241,    Adjusted R-squared:  0.221
F-statistic: 72.85 on 29 and 7317 DF,  p-value: < 2.2e-16
```

模型 7 | 加入婚姻状况 `MARSTA`

新增变量：`MARSTA` 是婚姻或伴侣关系类别。讲义中列出了 `Married, living with spouse`、`Married separated from spouse`、`Divorced`、`Widowed`、`Currently or previously in civil partnership` 等水平。

这一段输出有什么特别？ 因为分类系数太多，R 输出可能由于控制台宽度而把"估计系数/标准误"与"t 值/p 值"**分成上下两组显示。**这不是两次回归，而是**同一个模型的系数表被换行打印**：上半部分的第 N 行与下半部分的第 N 行对应。

应重点看这些结果：

- `SEXFemale = −3.006896`：性别工资差异约 **−£3.01/小时。**
- `MARSTAMarried, living with spouse = +3.173124`：相比婚姻状况的参照类别，已婚且与配偶同住者在该模型中估计时薪高约 £3.17。
- `MARSTADivorced = +3.415284`：同理，相对婚姻参照类别估计高约 £3.42。
- `MARSTACurrently or previously in civil partnership = +0.154012`：该项在输出的 p 值约 `0.896155`，未达到显著标准。
- `R² = 0.2241`：解释比例约 **22.41%。**

讲义没有在正文明确指出婚姻变量的参照类别文字；请查看 `levels(lfs$MARSTA)` 及 `contrasts(lfs$MARSTA)`。不要不经检查就断言比较对象一定是某个婚姻群体。

统计理解的关键：已婚人群更高的估计工资，并不能证明"结婚会让工资增长"；可能涉及年龄、教育、工作经历、选择效应等共同影响。本段仅表明加入婚姻状况后，拟合系数和拟合优度发生变化。

原始代码 8 / 11

教师原课件代码（完整、可复制）：

```
lm(HOURPAY ~ SEX + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02 + MARSTA
+ INDE07M, data = lfs) %>% summary
```

教师原课件对应输出（原样保留，供逐行对照）：

```
Call:
lm(formula = HOURPAY ~ SEX + HIQUL22D + FLEX22W6 + FTPT + EMPLEN +
    JOBTYP + MPNR02 + MARSTA + INDE07M, data = lfs)

Residuals:
    Min      1Q  Median      3Q     Max
-27.805  -5.904  -1.654   3.339  77.322

Coefficients:
                                                Estimate Std. Error t value
Pr(>|t|)
(Intercept)                                     18.07111    2.07800   8.696
< 2e-16 ***
SEXFemale                                       -2.12838    0.25647  -8.299
< 2e-16 ***
HIQUL22DHigher education                        -5.26106    0.45578 -11.543
< 2e-16 ***
HIQUL22DA level or equivalent                   -7.11075    0.30890 -23.020
< 2e-16 ***
HIQUL22DGCSE A*-C or equivalent                 -8.19836    0.35614 -23.020
< 2e-16 ***
HIQUL22DOther qualitfication                    -8.99971    0.58280 -15.442
< 2e-16 ***
HIQUL22DNo Qualification                       -11.44694    0.71833 -15.935
< 2e-16 ***
FLEX22W6No                                      2.13716    0.85560   2.498
0.012517 *
FTPTPart-time                                   -1.30824    0.30956  -4.226
2.41e-05 ***
EMPLENThree months, less than 6                 -0.56519    0.93856  -0.602
0.547066
EMPLEN6 months, less than 12                    0.15466    0.86267   0.179
0.857720
EMPLEN1 year, less than 2                       -0.34300    0.78733  -0.436
0.663105
EMPLEN2 years, less than 5                      0.83877    0.75470   1.111
0.266434
EMPLEN5 years, less than 10                     1.79826    0.76963   2.337
0.019490 *
EMPLEN10 years, less than 20                    2.60800    0.76807   3.396
0.000689 ***
EMPLEN20 years or more                          3.69426    0.78725   4.693
2.75e-06 ***
JOBTYPNot permanent in some way                 0.51033    0.68856   0.741
0.458621
MPNR0211-19                                     -0.50335    0.51319  -0.981
0.326710
MPNR0220-24                                     -0.01248    0.66650  -0.019
0.985057
MPNR02Don't know but under 25                   -1.40105    0.86441  -1.621
0.105102
MPNR0225-49                                     0.03596    0.44944   0.080
0.936228
```

```
MPNR0250-249                                        0.49980    0.38521   1.297
0.194509
MPNR02250-499                                       1.94956    0.54714   3.563
0.000369 ***
MPNR02Don't know but between 50 and 499             1.00554    0.64016   1.571
0.116279
MPNR02500 or more                                   3.73024    0.38657   9.650
< 2e-16 ***
MARSTAMarried, living with spouse                   3.04695    0.25907  11.761
< 2e-16 ***
MARSTAMarried separated from spouse                 1.84784    0.79818   2.315
0.020637 *
MARSTADivorced                                      3.52986    0.47429   7.442
1.10e-13 ***
MARSTAWidowed                                       3.68233    1.18007   3.120
0.001813 **
MARSTACurrently or previously in civil partnership  0.16740    1.15310   0.145
0.884575
INDE07MEnergy and water                             4.42746    1.91293   2.314
0.020668 *
INDE07MManufacturing                                2.28935    1.78234   1.284
0.199019
INDE07MConstruction                                 4.48751    1.82011   2.466
0.013705 *
INDE07MDistribution, hotels and restaurants        -0.81363    1.76477  -0.461
0.644784
INDE07MTransport and communication                  4.96552    1.77793   2.793
0.005238 **
INDE07MBanking and finance                          4.19420    1.75992   2.383
0.017189 *
INDE07MPublic admin, education and health          -0.39858    1.75291  -0.227
0.820134
INDE07MOther services                              -0.11917    1.82864  -0.065
0.948042
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9.952 on 7309 degrees of freedom
Multiple R-squared:  0.2602,    Adjusted R-squared:  0.2565
F-statistic: 69.48 on 37 and 7309 DF,  p-value: < 2.2e-16
```

模型 8｜加入行业 `INDE07M`

新增内容：`INDE07M` 是工作所属行业（industry）。这是课堂展示性别系数显著变化的关键一步。

代码操作：在原公式末尾再添加 `+ INDE07M`，R 会产生行业类别相对于行业参照组的多行系数；无需写循环，也无需自己对每个行业调用一次 `lm()`。请留意**一行公式可以很长，不代表它是 12 个不同的模型。**

新增行业系数的例子：

- `INDE07MEnergy and water = +4.42746`，`p = 0.020668`。
- `INDE07MConstruction = +4.48751`，`p = 0.013705`。
- `INDE07MTransport and communication = +4.96552`，`p = 0.005238`。

- `INDE07MBanking and finance = +4.19420`，`p = 0.017189`。
- `INDE07MPublic admin, education and health = −0.39858`，`p = 0.820134`，不显著。

这些都是**相对被省略的行业参照组**的差异。原课件没有在正文明确给出该基准组的名称，因此需要用因子水平检查，不能擅自为参照组命名。

最重要的变化是性别项：

- 模型 7 的女性系数约 `−3.0069`；
- 模型 8 的女性系数变为 `−2.12838`；
- 即当进一步把行业类别纳入模型后，男女条件工资差异的**绝对值**下降约 `0.88` 英镑/小时。

老师据此讨论：行业之间存在工资差异，一些男性占比较高的行业可能薪酬较高，行业构成可能解释一部分原始工资差异。严格而言，**本课件没有通过性别×行业交叉表或因果分析证明这一机制**；它展示的是加入行业后的系数变化。

`R² = 0.2602`：样本工资变异解释比例提高至 **26.02%**。这仍不等于“行业独自解释了26.02%”。

常见疑问：“行业有的系数显著、有的却不显著，是否说明整个变量没用？”不一定；单个类别与基准组的 t 检验，不等同于对**整个行业变量**的联合 F 检验。若希望检验整组因素，需要额外模型比较；这**不属于本讲原始代码。**

原始代码 9 / 11

教师原课件代码（完整、可复制）：

```
lm(HOURPAY ~ SEX + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02 + MARSTA
+ INDE07M + NSECMJ20, data = lfs) %>% summary
```

教师原课件对应输出（原样保留，供逐行对照）：

```
Call:
lm(formula = HOURPAY ~ SEX + HIQUL22D + FLEX22W6 + FTPT + EMPLEN +
    JOBTYP + MPNR02 + MARSTA + INDE07M + NSECMJ20, data = lfs)

Residuals:
    Min      1Q  Median      3Q     Max
-29.785  -5.085  -1.209   2.884  79.650

Coefficients:
                                                Estimate Std. Error t value
Pr(>|t|)
(Intercept)                                     26.19639    1.93934  13.508
< 2e-16 ***
SEXFemale                                       -1.81276    0.24012  -7.550
4.90e-14 ***
HIQUL22DHigher education                        -3.17471    0.42574  -7.457
9.88e-14 ***
HIQUL22DA level or equivalent                   -4.11659    0.29875 -13.779
< 2e-16 ***
HIQUL22DGCSE A*-C or equivalent                 -4.40433    0.34803 -12.655
< 2e-16 ***
```

```
HIQUL22DOther qualitfication                          -4.10139    0.56512  -7.258
4.35e-13 ***
HIQUL22DNo Qualification                              -5.92687    0.69490  -8.529
< 2e-16 ***
FLEX22W6No                                             0.39773    0.79824   0.498
0.618316
FTPTPart-time                                          0.03967    0.29256   0.136
0.892142
EMPLENThree months, less than 6                       -0.44517    0.86747  -0.513
0.607840
EMPLEN6 months, less than 12                          -0.30842    0.79761  -0.387
0.699004
EMPLEN1 year, less than 2                             -0.48591    0.72751  -0.668
0.504219
EMPLEN2 years, less than 5                             0.35393    0.69807   0.507
0.612162
EMPLEN5 years, less than 10                            0.71789    0.71281   1.007
0.313906
EMPLEN10 years, less than 20                           1.51428    0.71140   2.129
0.033322 *
EMPLEN20 years or more                                 2.41304    0.72966   3.307
0.000947 ***
JOBTYPNot permanent in some way                        0.21536    0.63742   0.338
0.735473
MPNR0211-19                                           -0.14893    0.47435  -0.314
0.753551
MPNR0220-24                                            0.11269    0.61576   0.183
0.854796
MPNR02Don't know but under 25                         -1.16732    0.79908  -1.461
0.144106
MPNR0225-49                                           -0.08240    0.41601  -0.198
0.843000
MPNR0250-249                                           0.35521    0.35649   0.996
0.319086
MPNR02250-499                                          1.37499    0.50709   2.712
0.006713 **
MPNR02Don't know but between 50 and 499                0.67591    0.59225   1.141
0.253801
MPNR02500 or more                                      2.30709    0.36185   6.376
1.93e-10 ***
MARSTAMarried, living with spouse                      2.34713    0.24139   9.724
< 2e-16 ***
MARSTAMarried separated from spouse                    1.98767    0.73805   2.693
0.007094 **
MARSTADivorced                                         3.18823    0.43928   7.258
4.34e-13 ***
MARSTAWidowed                                          3.32084    1.09141   3.043
0.002353 **
MARSTACurrently or previously in civil partnership     0.07321    1.06572   0.069
0.945237
INDE07MEnergy and water                                3.76222    1.76919   2.127
0.033494 *
INDE07MManufacturing                                   2.05983    1.64759   1.250
0.211262
INDE07MConstruction                                    3.77356    1.68292   2.242
0.024974 *
```

```
INDE07MDistribution, hotels and restaurants         -0.47190    1.63117  -0.289
0.772358
INDE07MTransport and communication                   3.96325    1.64482   2.410
0.015998 *
INDE07MBanking and finance                           2.85373    1.62740   1.754
0.079550 .
INDE07MPublic admin, education and health           -0.32214    1.61998  -0.199
0.842384
INDE07MOther services                               -0.36766    1.69012  -0.218
0.827796
NSECMJ20Lower managerial and professional           -6.10448    0.29727 -20.535
< 2e-16 ***
NSECMJ20Intermediate occupations                   -10.73648    0.37507 -28.625
< 2e-16 ***
NSECMJ20Lower supervisory and technical            -10.11014    0.52727 -19.175
< 2e-16 ***
NSECMJ20Semi-routine occupations                   -11.83911    0.45612 -25.956
< 2e-16 ***
NSECMJ20Routine occupations                        -12.62290    0.47731 -26.446
< 2e-16 ***
NSECMJ20Never worked                               -10.00244    0.81956 -12.205
< 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9.194 on 7303 degrees of freedom
Multiple R-squared:  0.3691,    Adjusted R-squared:  0.3654
F-statistic: 99.38 on 43 and 7303 DF,  p-value: < 2.2e-16
```

模型 9 | 加入职业等级 `NSECMJ20`

新增变量：`NSECMJ20` 是社会经济职业类别或职业等级，讲义正文称为 **seniority（职位层级/职业等级）**。结果里能看到高层管理与专业岗位（参照类别）、低层管理与专业岗位、中间层职业、常规职业等多种类别。

特别重要：相对谁比较？ 原课件指出常规职业（Routine occupations）的工资比**较高管理层职位**低约 £12.62。由系数名与说明可知，`NSECMJ20` 的参照组是较高管理及专业类别（Higher managerial and professional）。

具体数值：

- `NSECMJ20Lower managerial and professional = −6.10448`：相对较高管理及专业类别，估计少 £6.10/小时。
- `NSECMJ20Intermediate occupations = −10.73648`：估计少 £10.74/小时。
- `NSECMJ20Routine occupations = −12.62290`：估计少 **£12.62/小时**。
- `NSECMJ20Semi-routine occupations = −11.83911`：估计少约 £11.84/小时。
- `NSECMJ20Never worked = −10.00244`：这是原始因子中的一个类别；请不要自行把它解释为对所有未就业者的独立分析。
- `SEXFemale = −1.81276`：控制职业等级后，女性相对男性的差异约 **−£1.81/小时**。
- `R² = 0.3691`：解释比例上升为 **36.91%**，与先前模型相比增幅明显。

如何理解这一步：研究不同职业层级的工资差异，在理论上很有必要，因为职位或职业结构通常与工资直接相关。加入它后，原先与性别一起变化的部分工资差异可能由职业结构所吸收。但仍不可把这种统计现象直接称为"职业等级的因果中介效应"。

代码学习目标：看到 `+ NSECMJ20` 时，要知道它属于**多类别控制变量**；多个类别系数不会彼此相加成为 `NSECMJ20` 的总效应。只能为被预测者实际所属的那个类别选择相应的系数。

原始代码 10 / 11

教师原课件代码（完整、可复制）：

```
lm(HOURPAY ~ SEX + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02 + MARSTA
+ INDE07M + NSECMJ20 + AGE, data = lfs) %>% summary
```

教师原课件对应输出（原样保留，供逐行对照）：

```
Call:
lm(formula = HOURPAY ~ SEX + HIQUL22D + FLEX22W6 + FTPT + EMPLEN +
    JOBTYP + MPNR02 + MARSTA + INDE07M + NSECMJ20 + AGE, data = lfs)

Residuals:
    Min      1Q  Median      3Q     Max
-30.360  -5.126  -1.250   2.981  80.029

Coefficients:
                                                 Estimate Std. Error t value
Pr(>|t|)
(Intercept)                                     2.274e+01  1.963e+00  11.584
< 2e-16 ***
SEXFemale                                      -1.753e+00  2.388e-01  -7.339
2.39e-13 ***
HIQUL22DHigher education                       -3.374e+00  4.238e-01  -7.961
1.96e-15 ***
HIQUL22DA level or equivalent                  -4.115e+00  2.970e-01 -13.856
< 2e-16 ***
HIQUL22DGCSE A*-C or equivalent                -4.799e+00  3.486e-01 -13.766
< 2e-16 ***
HIQUL22DOther qualitfication                   -4.428e+00  5.629e-01  -7.866
4.20e-15 ***
HIQUL22DNo Qualification                       -6.519e+00  6.938e-01  -9.396
< 2e-16 ***
FLEX22W6No                                      2.230e-01  7.938e-01   0.281
0.778816
FTPTPart-time                                  -9.227e-02  2.912e-01  -0.317
0.751351
EMPLENThree months, less than 6                -4.469e-01  8.624e-01  -0.518
0.604330
EMPLEN6 months, less than 12                   -3.018e-01  7.930e-01  -0.381
0.703485
EMPLEN1 year, less than 2                      -4.897e-01  7.233e-01  -0.677
0.498380
EMPLEN2 years, less than 5                      1.750e-01  6.943e-01   0.252
0.800970
```

```
EMPLEN5 years, less than 10                          3.528e-01  7.098e-01   0.497
0.619169
EMPLEN10 years, less than 20                         8.021e-01  7.114e-01   1.127
0.259590
EMPLEN20 years or more                               1.112e+00  7.388e-01   1.505
0.132267
JOBTYPNot permanent in some way                      2.220e-01  6.337e-01   0.350
0.726105
MPNR0211-19                                         -3.772e-05  4.719e-01   0.000
0.999936
MPNR0220-24                                          1.658e-01  6.122e-01   0.271
0.786569
MPNR02Don't know but under 25                       -9.276e-01  7.949e-01  -1.167
0.243226
MPNR0225-49                                          2.462e-02  4.137e-01   0.059
0.952558
MPNR0250-249                                         5.388e-01  3.550e-01   1.518
0.129071
MPNR02250-499                                        1.496e+00  5.043e-01   2.967
0.003016 **
MPNR02Don't know but between 50 and 499              7.647e-01  5.889e-01   1.299
0.194123
MPNR02500 or more                                    2.556e+00  3.607e-01   7.086
1.51e-12 ***
MARSTAMarried, living with spouse                    1.446e+00  2.588e-01   5.589
2.36e-08 ***
MARSTAMarried separated from spouse                  8.427e-01  7.440e-01   1.133
0.257420
MARSTADivorced                                       1.729e+00  4.640e-01   3.727
0.000195 ***
MARSTAWidowed                                        1.635e+00  1.100e+00   1.487
0.137187
MARSTACurrently or previously in civil partnership -6.873e-01  1.063e+00  -0.647
0.517819
INDE07MEnergy and water                              3.754e+00  1.759e+00   2.134
0.032857 *
INDE07MManufacturing                                 2.071e+00  1.638e+00   1.264
0.206146
INDE07MConstruction                                  3.781e+00  1.673e+00   2.260
0.023865 *
INDE07MDistribution, hotels and restaurants         -3.048e-01  1.622e+00  -0.188
0.850906
INDE07MTransport and communication                   4.013e+00  1.635e+00   2.454
0.014148 *
INDE07MBanking and finance                           2.905e+00  1.618e+00   1.795
0.072643 .
INDE07MPublic admin, education and health           -4.107e-01  1.611e+00  -0.255
0.798724
INDE07MOther services                               -3.300e-01  1.680e+00  -0.196
0.844317
NSECMJ20Lower managerial and professional           -6.054e+00  2.956e-01 -20.479
< 2e-16 ***
NSECMJ20Intermediate occupations                    -1.069e+01  3.729e-01 -28.676
< 2e-16 ***
NSECMJ20Lower supervisory and technical             -1.001e+01  5.243e-01 -19.101
< 2e-16 ***
```

```
NSECMJ20Semi-routine occupations                    -1.180e+01  4.535e-01 -26.015
< 2e-16 ***
NSECMJ20Routine occupations                         -1.275e+01  4.747e-01 -26.851
< 2e-16 ***
NSECMJ20Never worked                                -8.792e+00  8.251e-01 -10.655
< 2e-16 ***
AGE                                                  1.071e-01  1.151e-02   9.306
< 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9.14 on 7302 degrees of freedom
Multiple R-squared:  0.3765,    Adjusted R-squared:  0.3728
F-statistic: 100.2 on 44 and 7302 DF,  p-value: < 2.2e-16
```

模型 10 | 加入年龄 AGE

新增变量：`AGE`（年龄）。注意与前面的分类变量不同，讲义中它直接作为**连续数值变量**参与回归。

这是语法上很重要的区别：`AGE` 是一个量化数值，输出通常就叫 `AGE`，只有**一行系数**，而不是 `AGE18-25`、`AGE26-35` 等多个类别行（除非数据预先分组或 R 中把年龄转成因子）。

读懂关键输出：

- `AGE = 1.071e-01` 等于 **0.1071**，可四舍五入为 **£0.11/小时/岁**。
- 更完整的表达是：在控制其余已经纳入的因素后，年龄每增加 1 岁，模型估计小时工资平均增加约 **£0.1071**。
- 如果只按线性模型关系推算，年龄差 10 岁时，工资差约 `10 × 0.1071 = 1.071` 英镑/小时（其他变量都固定），但**这不意味着任何人连续工作十年工资必然增长这个数**。
- `SEXFemale = -1.753e+00` 等于 **−1.753**，即约 **−£1.75/小时**。
- `R² = 0.3765`：总体解释约 **37.65%**。

为什么有 `e+00`？ 这是科学计数法：

- `2.274e+01 = 22.74`；
- `-1.753e+00 = -1.753`；
- `1.071e-01 = 0.1071`；
- `-3.772e-05 = -0.00003772`。

R 在系数表较长时统一用科学记数法缩短打印长度。并不是回归算法换了，也不是单位换了。

潜在模型限制：当前模型将年龄与工资的关系假定为**线性**。现实中不同年龄段可能有复杂工资轨迹。若要考虑二次项、分段回归等，需要另外建模；原 HTML 这里没有做这些检查。年龄还可能与职业工龄相关，但二者含义不同。

原始代码 11 / 11

教师原课件代码（完整、可复制）：

```r
lm(HOURPAY ~ SEX + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02 + MARSTA
+ INDE07M + NSECMJ20 + AGE + GOR9D, data = lfs) %>% summary
```

教师原课件对应输出（原样保留，供逐行对照）：

```
Call:
lm(formula = HOURPAY ~ SEX + HIQUL22D + FLEX22W6 + FTPT + EMPLEN +
    JOBTYP + MPNR02 + MARSTA + INDE07M + NSECMJ20 + AGE + GOR9D,
    data = lfs)

Residuals:
    Min      1Q  Median      3Q     Max
-31.140  -5.101  -1.189   3.046  79.547

Coefficients:
                                              Estimate Std. Error t value
Pr(>|t|)
(Intercept)                                   25.78853    1.98215  13.010
< 2e-16 ***
SEXFemale                                     -1.78189    0.23677  -7.526
5.87e-14 ***
HIQUL22DHigher education                      -3.23076    0.42198  -7.656
2.16e-14 ***
HIQUL22DA level or equivalent                 -3.85940    0.29611 -13.034
< 2e-16 ***
HIQUL22DGCSE A*-C or equivalent               -4.53640    0.34719 -13.066
< 2e-16 ***
HIQUL22DOther qualitfication                  -4.44594    0.55803  -7.967
1.87e-15 ***
HIQUL22DNo Qualification                      -6.14744    0.68828  -8.932
< 2e-16 ***
FLEX22W6No                                     0.40302    0.78712   0.512
0.608648
FTPTPart-time                                 -0.07943    0.28902  -0.275
0.783459
EMPLENThree months, less than 6               -0.39861    0.85519  -0.466
0.641152
EMPLEN6 months, less than 12                  -0.18981    0.78648  -0.241
0.809302
EMPLEN1 year, less than 2                     -0.30792    0.71735  -0.429
0.667754
EMPLEN2 years, less than 5                     0.34445    0.68859   0.500
0.616933
EMPLEN5 years, less than 10                    0.52264    0.70371   0.743
0.457692
EMPLEN10 years, less than 20                   1.06104    0.70594   1.503
0.132879
EMPLEN20 years or more                         1.57930    0.73389   2.152
0.031434 *
JOBTYPNot permanent in some way                0.15802    0.62841   0.251
0.801461
MPNR0211-19                                    0.01830    0.46778   0.039
0.968800
MPNR0220-24                                    0.17017    0.60750   0.280
0.779394
MPNR02Don't know but under 25                 -1.01501    0.78914  -1.286
0.198407
```

```
MPNR0225-49                                          0.05431    0.41028   0.132
0.894685
MPNR0250-249                                         0.51390    0.35217   1.459
0.144539
MPNR02250-499                                        1.50815    0.50016   3.015
0.002576 **
MPNR02Don't know but between 50 and 499              0.65691    0.58493   1.123
0.261452
MPNR02500 or more                                    2.40393    0.35823   6.711
2.08e-11 ***
MARSTAMarried, living with spouse                    1.44619    0.25735   5.620
1.98e-08 ***
MARSTAMarried separated from spouse                  0.79898    0.73767   1.083
0.278795
MARSTADivorced                                       1.68799    0.46047   3.666
0.000248 ***
MARSTAWidowed                                        1.62508    1.09137   1.489
0.136521
MARSTACurrently or previously in civil partnership  -0.38073    1.05538  -0.361
0.718297
INDE07MEnergy and water                              3.70456    1.74382   2.124
0.033671 *
INDE07MManufacturing                                 2.19235    1.62412   1.350
0.177099
INDE07MConstruction                                  3.84059    1.65911   2.315
0.020649 *
INDE07MDistribution, hotels and restaurants         -0.39967    1.60802  -0.249
0.803718
INDE07MTransport and communication                   3.64347    1.62184   2.246
0.024702 *
INDE07MBanking and finance                           2.61233    1.60432   1.628
0.103503
INDE07MPublic admin, education and health           -0.37672    1.59701  -0.236
0.813522
INDE07MOther services                               -0.61520    1.66640  -0.369
0.712006
NSECMJ20Lower managerial and professional           -5.89892    0.29352 -20.097
< 2e-16 ***
NSECMJ20Intermediate occupations                   -10.52187    0.37006 -28.433
< 2e-16 ***
NSECMJ20Lower supervisory and technical             -9.81153    0.51984 -18.874
< 2e-16 ***
NSECMJ20Semi-routine occupations                   -11.54158    0.45036 -25.627
< 2e-16 ***
NSECMJ20Routine occupations                        -12.49647    0.47149 -26.504
< 2e-16 ***
NSECMJ20Never worked                                -8.66825    0.81832 -10.593
< 2e-16 ***
AGE                                                  0.10231    0.01142   8.956
< 2e-16 ***
GOR9DYorkshire and The Humber                       -4.31942    0.50909  -8.485
< 2e-16 ***
GOR9DSouth West                                     -3.69832    0.50952  -7.258
4.32e-13 ***
GOR9DWest Midlands                                  -3.25102    0.54650  -5.949
2.83e-09 ***
```

```
GOR9DSouth East                                    -2.42283    0.47010  -5.154
2.62e-07 ***
GOR9DEast of England                               -2.23360    0.53480  -4.176
2.99e-05 ***
GOR9DEast Midlands                                 -4.01808    0.52771  -7.614
2.99e-14 ***
GOR9DNorth East                                    -5.24307    0.65972  -7.947
2.19e-15 ***
GOR9DNorth West                                    -4.00454    0.52126  -7.682
1.77e-14 ***
GOR9DWales                                         -4.97962    0.66622  -7.474
8.65e-14 ***
GOR9DNorthern Ireland                              -5.08488    0.57151  -8.897
< 2e-16 ***
GOR9DScotland                                      -3.28323    0.53089  -6.184
6.57e-10 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9.055 on 7291 degrees of freedom
Multiple R-squared:  0.389, Adjusted R-squared:  0.3844
F-statistic: 84.41 on 55 and 7291 DF,  p-value: < 2.2e-16
```

模型 11 | 加入地区 `GOR9D`：本讲最终的多元线性回归

新增变量：`GOR9D` 表示地区类别（region），用于控制英国不同地区工资水平的差异。

代码里所有变量按顺序回顾：

`HOURPAY` 是小时工资（因变量）；右侧依次是 `SEX`（性别）、`HIQUL22D`（教育）、`FLEX22W6`（零工时合同）、`FTPT`（全兼职）、`EMPLEN`（现雇主工作时间）、`JOBTYP`（工作合同类型）、`MPNR02`（企业规模）、`MARSTA`（婚姻状况）、`INDE07M`（行业）、`NSECMJ20`（职业等级）、`AGE`（年龄）、`GOR9D`（地区）。**公式右边写了12个变量名，但因为多个是分类变量，实际估计出的回归参数远多于12个。**

课件最终结果应当怎么读?

- `SEXFemale = −1.78189`：控制表中其他因素后，女性相对于男性的估计小时工资差异约 **−£1.78。**
- `Std. Error = 0.23677`、`t = −7.526`、`p = 5.87e−14`：在该模型假设下，这一条件差异统计显著。
- `AGE = +0.10231`：控制其他变量后，年龄每增加一岁，对应时薪估计高约 **10.2便士。**
- `GOR9DScotland = −3.28323`：与地区参照组伦敦相比，苏格兰的条件时薪估计低约 **£3.28。**
- `GOR9DWales = −4.97962`：相对伦敦的条件时薪估计低约 **£4.98。**
- `GOR9DNorth East = −5.24307`：相对伦敦的条件时薪估计低约 **£5.24。**
- `GOR9DSouth East = −2.42283`：相对伦敦的条件时薪估计低约 **£2.42。**
- `R² = 0.3890`：整个模型解释样本中约 **38.90%** 的小时工资变异。
- `Adjusted R² = 0.3844`：对参数数量作调整后，解释程度约 38.44%。
- `Residual standard error = 9.055`：残差典型尺度比第一段的 11.44 更小。

为什么地区比较的是伦敦？ 原讲义末尾文字明确指出“其他地区工资似乎都低于伦敦”。结果表中没有 London 行，但有其他地区行，说明伦敦是本次地区编码下的基准组。

讲义特别提醒：这里谈论的是 **nominal wages（名义工资）**，未根据各地区物价水平调整成 **real wages（实际购买力意义上的工资）**。伦敦名义时薪更高，不能据此就说伦敦居民必然生活得更富裕。

不要把 $R^2 = 38.9\%$ 理解为“模型已经解释所有原因”：仍然有大约 61.1% 的样本工资变异在这个简单模型里没有被解释。也不能由 R^2 推出模型具备 38.9% 的“预测准确率”。

写学术报告时可以这样表达：

> 在纳入教育、合同与工时特征、在职时长、企业规模、婚姻状况、行业、职业等级、年龄及地区变量后，女性相对男性的估计小时工资差异为约 −£1.78（该模型中 p 值极小）；模型 R^2 为约 0.389。这是控制所列变量后的统计关联，而非因果效应估计。

一个必须说明的推断限制：此处原始 `summary(lm(...))` 使用普通线性模型标准误；这份课件没有额外展示异方差检验、稳健标准误、样本权重或复杂调查设计修正。因此不要自行宣称这里已经完成全部模型假设检验或复杂抽样推断。

第四章：11 个模型的变化放在一张表里

这张表的系数来自各段**原始 `lm()` 输出**，统一将女性系数解释为“女性相对男性、在该模型已包含的解释变量条件下的工资差异”。注意第 1 段几乎未控制其他因素；第 11 段加入了很多控制因素，两者表示的**条件比较不同。**

模型	本次增加的控制因素	`SEXFemale` 系数 (£/小时)	R^2	调整 R^2	残差标准误 (£/小时)
1	仅 SEX	-3.0591	0.01748	0.01734	11.440
2	学历 HIQUL22D	-3.6690	0.15430	0.15360	10.620
3	零工时合同 FLEX22W6、全兼职 FTPT	-3.0794	0.16680	0.16590	10.540
4	现雇主工作年限 EMPLEN	-3.0489	0.18900	0.18740	10.400
5	永久/临时工作 JOBTYP	-3.0488	0.18900	0.18730	10.400
6	企业规模 MPNR02	-3.0277	0.20710	0.20450	10.290
7	婚姻状况 MARSTA	-3.0069	0.22410	0.22100	10.190
8	行业 INDE07M	-2.1284	0.26020	0.25650	9.952
9	职业等级 NSECMJ20	-1.8128	0.36910	0.36540	9.194
10	年龄 AGE	-1.7530	0.37650	0.37280	9.140
11	地区 GOR9D	-1.7819	0.38900	0.38440	9.055

如何看这张表，而不是机械背数字？

第一个问题：为什么 `SEXFemale` 一开始是 −3.06，第二次反而到 −3.67？

因为控制学历后的比较对象从“不同性别的总体均值差异”变成了“相同学历条件下的性别差异”。当学历与性别、工资都有一定关联时，增加它可以使性别系数变大或变小。**没有规定回归加入控制变量后系数一定接近零。**

第二个问题：为什么加入行业和职业等级后差异缩小比较多？

本课件的数据表现为：从模型 7 的 −3.0069，到模型 8 的 −2.1284，再到模型 9 的 −1.8128。说明行业、职业等级与工资及模型其他解释变量共同关联，改变了性别系数的条件比较。但单纯比较系数并不能确定因果机制。

第三个问题：为什么 R^2 几乎一直增加？

因为普通最小二乘法在同一样本中引入更多自变量，不会使残差平方和上升，所以普通 R^2 不会下降。加变量多了也会“更能贴合当前样本”，但未必更有意义、也未必对新数据预测得更好。要进一步评估，可以看调整 R^2、交叉验证、理论合理性和模型诊断。

第四个问题：每一个新变量都值得一直保留吗？

不能只看它自己的某一个类别是否有星号就简单删除；对多类别变量尤其要综合理论、联合检验、共线性、控制目的与模型稳健性。该课件是教学演示，并不是一个已经完成全部检验的最终发表模型。

这份数据各模型是否使用了相同样本？

从原输出看，模型 1 的残差自由度为 7345，加上截距与 1 个性别系数，推得样本量 **7347**；第 11 段的残差自由度为 7291，加上模型估计的 56 个参数，同样为 **7347**。中间其他模型与此一致。即**这份课件展示的 11 个模型使用相同有效样本量**（根据控制台自由度推断），因此此处 R^2 比较不会因观测数变化而混淆。但是在**自己的数据**上添加控制变量时，缺失值常导致样本变化，不能默认也总是如此。

第五章：使用真正的零基础思维，理解回归过程中的 10 个问题

问题 1：为什么“加一个变量”却多出好多行系数？

因为这个新变量可能是**分类变量**，R 会自动转换为多个虚拟变量。比如 `HIQUL22D` 有多个学历类别，输出会为所有**非参照类别**列出系数，而不是只有 1 个学历总系数。

问题 2：为什么参照类别不出现在系数表里？

这是避免包含截距时所有类别虚拟变量完全共线的一种常用编码方式。参照类别的效应被吸收到截距里。选择不同参照类别会改变各类别系数的显示方式，但不改变模型对同一观测的拟合值。

问题 3：`SEXFemale` 是什么意思？

它不是要在代码里使用的新变量名，而是 R 在**结果表里拼接因子变量名与类别标签**形成的系数名称。`SEXFemale` 表示女性相对于性别的参照组男性的条件差异。

问题 4：`+` 与 `%>%` 有什么本质区别？

公式里的 `+` 是**声明多个预测变量。** `%>%` 是**把已经计算出的对象传给下一步函数。**例如 `lm(HOURPAY ~ SEX + AGE, data = lfs) %>% summary` 中，这两个符号分别负责模型结构和代码执行流程。

问题 5：负的系数代表“坏”吗？

不是。负号表示在该模型的比较方式下，被比较组的预测数值较低；它本身不表示道德评价，也不自动证明因果或统计显著。

问题 6：为什么 `p < 0.05` 不是“该理论有95%的概率是真的”？

p 值是在给定统计检验的零假设和其他假设下，衡量观察到如此或更极端数据的概率。它不是零假设为真或为假的后验概率，也不是结果可重复的保证。

问题 7：多个系数都为负，是不是应该加起来？

仅当你希望预测**同一个人**且这些系数分别对应此人的真实属性时，可以把截距与相关的类别差值及连续变量项按公式相加。**不能把同一个分类变量下所有互斥类别（所有学历或所有地区）同时加上去**，因为一个人通常只能属于其中一个类别。

问题 8：为什么年龄系数 0.107 而教育是 −11.77？

年龄系数的单位是“每增加 1 岁”；教育系数的单位是“所属教育类别相对参照学历”。数值大小不在同一比较尺度上，不能直接说“教育影响是年龄的 110 倍”。

问题 9：R^2 只有 0.389，是不是模型失败？

不是。社会科学中的个人工资由许多未测量或难以建模的因素共同决定，R^2 不必等于 1。是否足够好取决于研究目标、理论、识别策略、预测要求和诊断。课件也明确指出，还有大部分工资变异没有被模型解释。

问题 10：这 11 段代码能不能直接用于自己的 NHTS 行程研究？

不能原封不动复制 `HOURPAY`、`SEX`、`HIQUL22D` 等变量名，因为它们属于 LFS 工资示例。**可以迁移思路，不可迁移变量**：先建立一元基准模型，再逐步增加相关人口学与家庭特征作为控制，比较主要解释变量的系数、R^2、标准误和模型诊断，同时审查数据结构、抽样设计以及观测间的独立性。

第六章：可以自己运行的教学补充代码（不属于教师 HTML 原代码）

以下例子只在你已经准备好课程的 `lfs` 数据框后运行。**与第三章的教师原始 11 段代码分开**，防止对照时搞混。

练习 A：不用管道拟合第一个模型

```r
# 创建模型对象（把模型“存起来”）
model1 <- lm(HOURPAY ~ SEX, data = lfs)

# 显示模型结果
summary(model1)
```

- `<-` 是赋值符号：把函数结果保存到变量 `model1` 里。
- `model1` 只是自拟对象名称，并不是课程数据中的列。
- `summary(model1)` 与直接 `lm(...) %>% summary` 在模型输入相同时有同样的摘要结果。

练习 B：看分类变量有哪些水平

```
# 先看变量本身的储存类型
str(lfs$HIQUL22D)

# 如果该变量是因子，显示因子水平
levels(lfs$HIQUL22D)

# 查看某个类别的人数（包含缺失项计数）
table(lfs$HIQUL22D, useNA = "ifany")

# 如属于factor，可查看对比编码
contrasts(lfs$HIQUL22D)
```

`$` 的用法：`lfs$HIQUL22D` 意味着从 `lfs` 里取出 `HIQUL22D` 这列。`levels()` 适用于因子；若返回 `NULL`，请先用 `str()` 判断类型，不要随意把数值编码强行转换后直接回归。

练习 C：分别保存最简单和更完整的模型

```
model1 <- lm(HOURPAY ~ SEX, data = lfs)
model2 <- lm(HOURPAY ~ SEX + HIQUL22D, data = lfs)

summary(model1)
summary(model2)

# 只取出估计系数
coef(model1)
coef(model2)
```

`coef()` 返回系数向量，适合看模型参数；`summary()` 返回详细的拟合诊断统计和回归系数的推断结果。

练习 D：从模型对象里提取 R^2

```
summary(model1)$r.squared
summary(model2)$r.squared
```

`summary(model1)` 的返回值包含多个命名元素；`$r.squared` 访问其中的 R^2。

练习 E：查看最终模型的预测值与残差

```
final_model <- lm(
  HOURPAY ~ SEX + HIQUL22D + FLEX22W6 + FTPT +
    EMPLEN + JOBTYP + MPNR02 + MARSTA + INDE07M +
    NSECMJ20 + AGE + GOR9D,
  data = lfs
)
```

```r
# 提取各观测的模型拟合值
head(fitted(final_model))

# 提取各观测的残差
head(residuals(final_model))

# 画基础残差-拟合值图，供初步检查
plot(final_model, which = 1)
```

注意：完整诊断不能只看一张图；还应根据课程后续章节理解函数形式、异方差、高杠杆值、影响点、共线性和抽样设计等问题。`which = 1` 是指定显示第 1 种诊断图，不是说只绘制 1 个数据点。

第七章：初学者最常见的报错及处理方法

你可能看到的错误或困惑	主要原因	应怎样检查
`object 'lfs' not found`	没有创建/读取 `lfs` 对象	先运行数据读取步骤，再试 `exists("lfs")`
`could not find function "%>%"`	未载入提供管道的包	执行 `library(dplyr)`，或使用 `summary(lm(...))`
`object 'HOURPAY' not found`	数据列名拼错，或传入数据框不对	用 `names(lfs)` 与 `str(lfs)` 检查
`0 (non-NA) cases`	有效样本不足或相关变量全是缺失	检查缺失值、数据筛选与变量编码
`contrasts can be applied only to factors with 2 or more levels`	某分类变量在当前拟合样本只剩一种类别	检查筛选条件、因子水平和缺失
`NA/NaN/Inf in 'y'` 等	目标变量含非法或无限值	检查 `HOURPAY` 的类型和异常编码
模型系数出现 `NA`	设计矩阵秩不足、完全共线或冗余类别	检查变量间的关系、编码和因子水平
输出里出现 `e+01`	科学计数法	按 `×10^指数` 还原，不表示代码执行错误
控制台中长系数表被分成两块	控制台宽度较窄，打印自动换行	按同一行名的顺序对应阅读，必要时加宽 Console
`SEXFemale` 不存在于 `names(lfs)`	系数名并非原始列名	原始数据列是 `SEX`；结果表组合形成系数名称

对调查数据的额外提示：LFS 原始数据可能包含“拒绝回答”“不适用”“不知道”等特殊编码。课件 HTML 只展示已准备好的 `lfs` 数据上的回归，不提供从原始调查文件到该对象的完整清洗步骤。不要仅凭本教程就假定原始数据可以直接 `lm()`；先核对数据字典和教师的预处理要求。

第八章：自我练习（附答案）

练习 1：解释单变量回归

第一个模型输出 `SEXFemale = −3.0591`，`R² = 0.01748`。请用自己的话说明两个数字含义，指出能否据此证明因果。

参考答案：样本中女性相对于男性估计低约 £3.06/小时；仅包含性别的模型解释约 1.75% 的样本工资变异。这是统计关联，不能直接证明性别因素导致工资变化。

练习 2：认识参照组

第二个模型输出 `HIQUL22DNo Qualification = −11.7713`。它与哪个学历比较？

参考答案：Degree（学位），因为课件明确说明该变量的参照组为 Degree。不是与 Higher education 比较。

练习 3：手算预测值

第二个模型中，学历为 Degree 的女性预测工资是多少？

参考答案：`27.1162 − 3.6690 = 23.4472` 英镑/小时。

练习 4：理解分类与连续

`EMPLEN20 years or more = 5.1767` 与 `AGE = 0.1071` 为什么解释方式不同？

参考答案：前者为工作年限类别相对参照类别的时薪差异；后者是年龄每增加 1 岁所对应的时薪差异。

练习 5：理解没有统计显著性

`JOBTYPNot permanent in some way` 在模型 5 的 `p = 0.812127`，能否断言临时职位一定没有任何工资差异？

参考答案：不能。只能说本模型没有获得足够统计证据来拒绝该系数为 0 的零假设；不能证明"差异绝对不存在"。

练习 6：比较模型

模型 1 的女性系数是 `−3.0591`，模型 11 是 `−1.78189`。可以写"加入控制变量使女性的工资上涨 £1.28/小时"吗？

参考答案：不可以。变的是**模型估计的条件差异**，不是任何个人的实际工资。两项相差约 1.277 英镑/小时，只能说在纳入这些控制变量后性别相关系数绝对值变小了。

练习 7：关于地区工资

最终模型显示苏格兰相对伦敦系数约 −3.28323，是否等于苏格兰比伦敦生活水平低？

参考答案：不能。这是名义小时工资的条件差异；尚未比较地区物价、生活成本或其他福利。

练习 8：提出改进

若希望知道“学历与工资之间的关联是否因性别不同而不同”，当前的 `HOURPAY ~ SEX + HIQUL22D` 公式足够吗？

参考答案：不够。当前加性模型假设性别差异不随学历变化，可进一步考虑交互项、可视化及检验。这属于课件外的拓展，而非老师在本 HTML 中已经完成的模型。

第九章：函数与术语速查

写法 / 名称	中文名称	本讲主要作用
`lm()`	线性回归函数	根据工资与解释变量估计 OLS 回归
`summary()`	摘要函数	打印系数表、残差、拟合指标
`%>%`	管道操作符	将模型结果送给 `summary`
`data = lfs`	指定数据来源	让公式中的变量从 `lfs` 查找
`~`	回归公式分隔符	左为因变量、右为解释变量
`+`	添加自变量	在公式中纳入更多解释变量
`coef()`	提取估计系数	查看截距与各变量系数
`fitted()`	拟合值	查看模型对各样本的预测
`residuals()`	残差	真实值减拟合值
`str()`	结构检查	看列的类型与数据形式
`names()`	列名查看	核对工资、学历等列是否存在
`levels()`	因子水平	识别分类变量的类别
`contrasts()`	因子对比编码	查看类别如何相对参照组编码
`table()`	频数表	查看各类别人数
`Estimate`	系数估计值	方向及差异大小
`Std. Error`	标准误	系数估计的不确定性
`Pr(>|t|)`	双侧 t 检验 p 值	单个参数的统计显著性
`Multiple R-squared`	决定系数 R^2	样本内工资变异解释比例
`Adjusted R-squared`	调整后的 R^2	对参数数量作修正的拟合指标
`Residual standard error`	残差标准误	估计残差波动尺度
`F-statistic`	F 统计量	通常检验非截距系数联合为 0

第十章：课件原文与补充教学内容的边界

这份教程严格围绕 `7.lecture8_regressions.html` 里的 11 段 `lm()` 回归及其输出组织。**实际表格数字和教师代码来自原 HTML**，额外的 `exists()`、`str()`、`levels()`、模型对象保存和残差图等示例是为了帮助零基础入门而新增的教学练习。

原课件**没有提供**：从原始 LFS 文件读入并清洗 `lfs` 的全流程、回归的因果识别设计、全部模型诊断、复杂抽样权重/聚类标准误的计算或样本外预测评估。因此，这份教程不把这些额外操作包装成老师已经完成的内容。

建议复习顺序：先吃透 `~` 与 `+` → 再读懂参照类别和截距 → 学会读 `Estimate`、p值与 R^2 → 最后理解为什么逐步控制变量会改变 `SEXFemale` 的系数。这样回到自己的 R 回归课程作业时，才能把操作和统计意义连接起来。