第9讲笔记

定量数据分析

引言

- 今天继续讨论线性模型的基本假设。
- 上次我们从变量选择开始。
- 这是一个关键步骤，而且应在项目一开始就考虑。
- 其他一些假设则更偏向技术层面。
- 先回顾五项假设。

模型假设

我们将讨论以下假设（引自Peter Kennedy的《计量经济学指南》）：

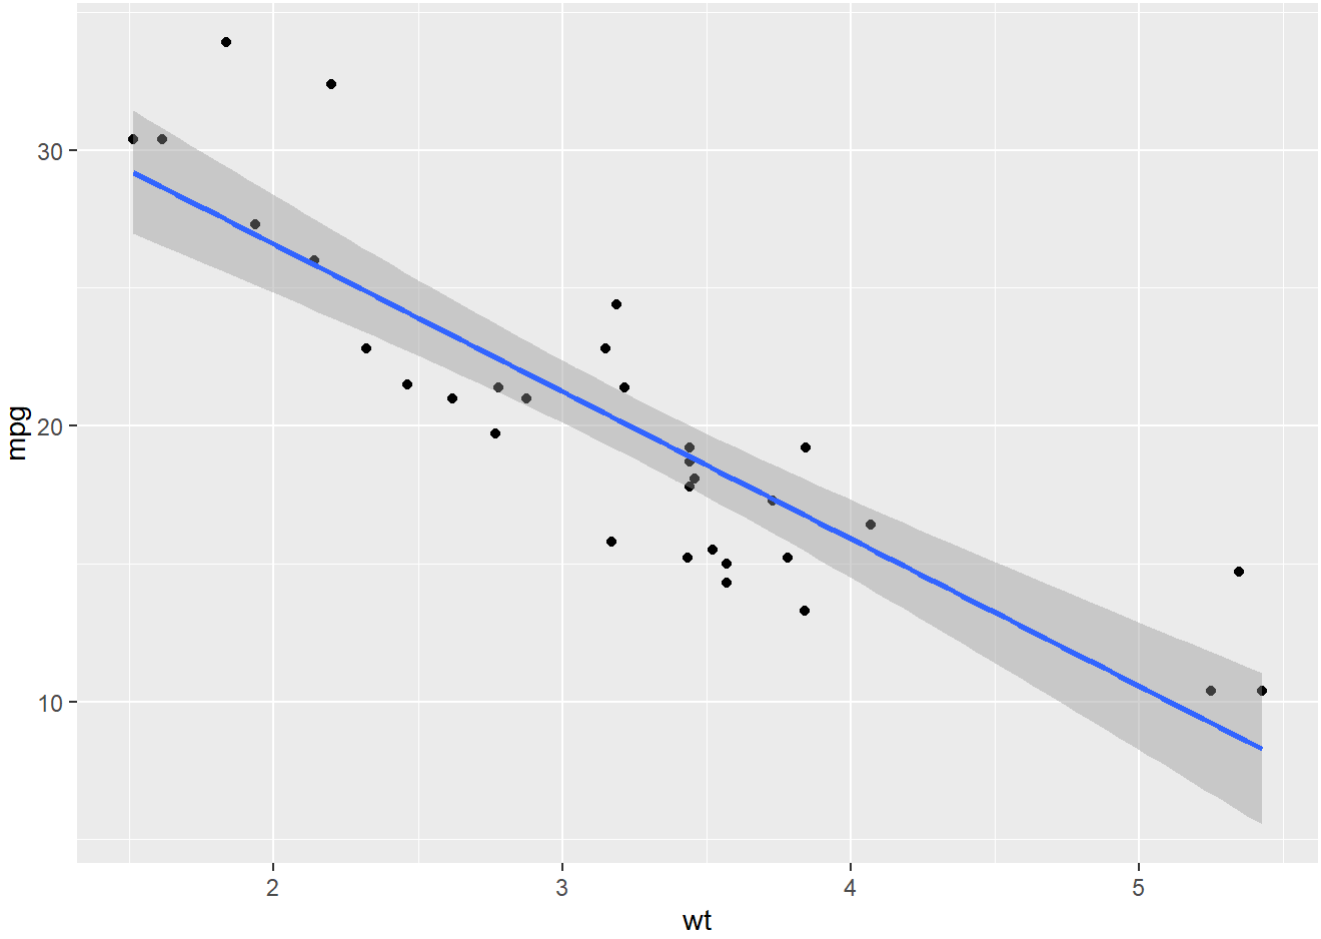
1. 模型设定正确。
2. 残差方差相同，并且彼此独立。
3. 自变量之间不存在完全线性关系。
4. 自变量是固定的，且测量没有误差。
5. 残差的期望为零。

模型设定正确

- 迄今为止，我们一直假设所建模关系具有某种特定的函数形式。
- 例如，对年龄变量，我们假设年龄每增加一岁，预测工资就发生固定幅度的变化。
- 这一金额不取决于个人目前的工资或年龄；只要年龄变化，就增加一个固定金额。
- 在我们的例子中，这样的假设似乎不太合理。
- 其实我们不必受到这种形式的限制。

可视化非线性关系

- 为了说明这一点，我暂时改用另一份数据集。
- R内置了一个名为mtcars的数据集，包含不同汽车的信息。
- 我们将研究燃油效率（mpg）与汽车重量（wt）之间的关系。
- 在R控制台输入data(mtcars)即可加载数据。



一些思考

- 变量之间的关系看起来相对接近线性。
- 但回归模型低估了最轻和最重汽车的燃油效率。
- 在重量中间范围内，模型表现还不错。
- 一种处理办法是对mpg变量进行对数变换。

对数

- $2^3 = 2 \times 2 \times 2 = 8$
- $\log_2 8 = 3$
- 如果$a^x = y$，那么$\log_a y = x$。
- 这里a是对数的底数。
- $\log_2 8$ asks to what power must we raise 2 to get 8
- 常见的底数是10和e（2.718282.....）。

一些运算法则

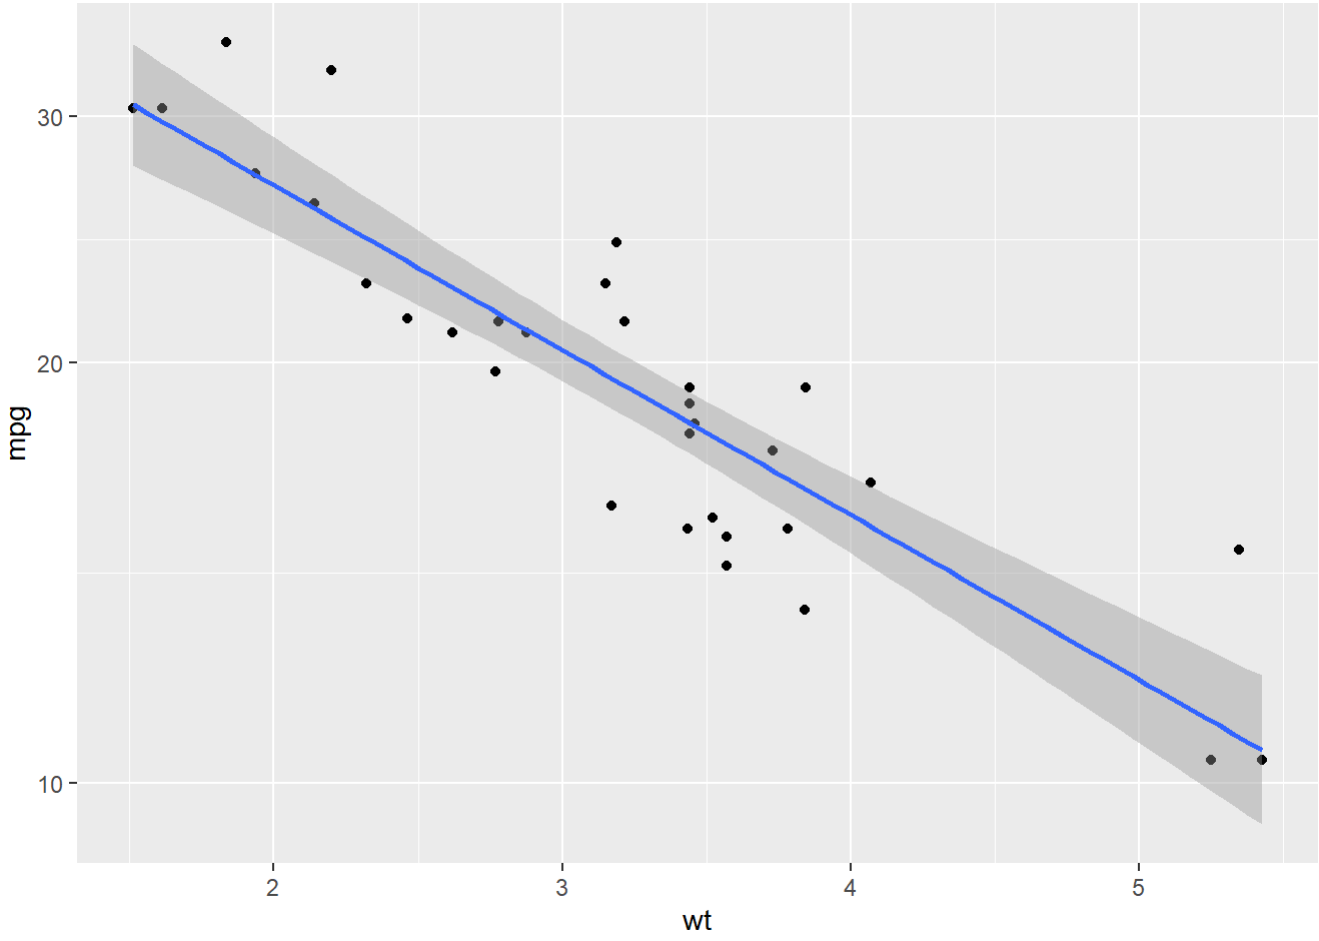
- 对数只在$x > 0$时有定义。

- $\log(xy) = \log x + \log y$
- $\log \frac{x}{y} = \log x - \log y$
- $\log x^n = n \log x$

这有什么帮助?

- 此前我们估计的关系形式是$y = \beta_0 + \beta_1 x$。
- 假设我们认为x与y的关系应为$y = \beta_0 \cdot x^{\beta_1}$。
- 由于该式对参数而言是非线性的，因此不能直接使用OLS估计。
- 两边取对数可得：$\log y = \log \beta_0 + \beta_1 \cdot \log x$。
- 由于它对参数是线性的，因此可以用OLS估计。
- 重新查看刚才的图，但这次让mpg变量使用对数尺度。

对数变换

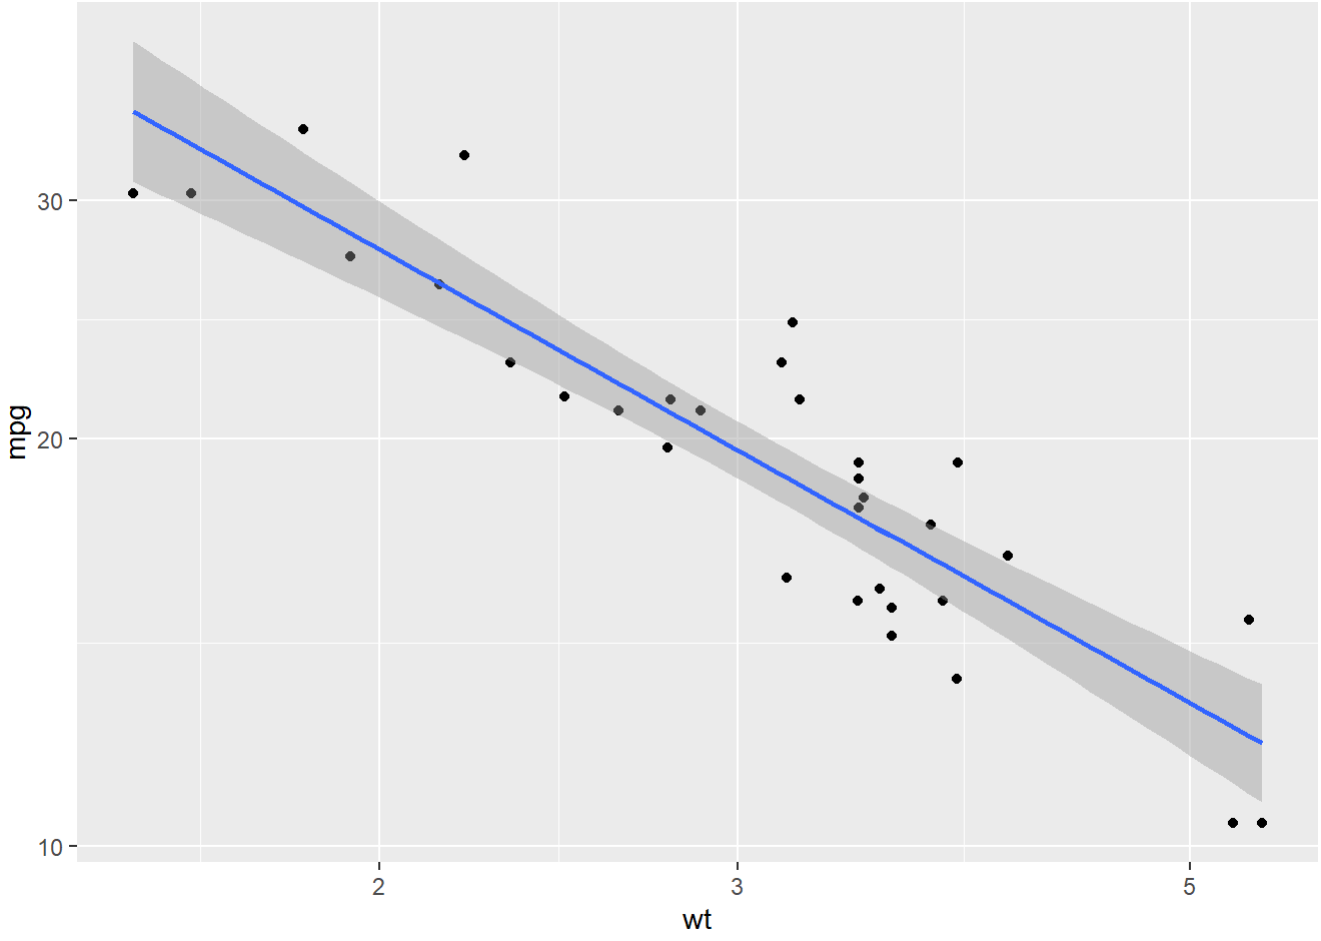


对数变换

- 看起来稍微好了一些。
- 模型低估分布两端观测值的倾向减弱了。

- 还可以考虑对wt变量也进行对数变换。

对数变换



对数变换

- 这样看起来更好。
- 在对数尺度下，两个变量之间的关系看起来更接近线性。
- 可以把这一思路用于回归模型。
- 来看三个相应的模型。

线性模型

```
mtcars %>% lm(mpg ~ wt, data=.) %>% summary
```

```
##
## Call:
## lm(formula = mpg ~ wt, data = .)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -4.5432 -2.3647 -0.1252  1.4096  6.8727
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  37.2851     1.8776  19.858  < 2e-16 ***
## wt           -5.3445     0.5591  -9.559 1.29e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.046 on 30 degrees of freedom
## Multiple R-squared:  0.7528, Adjusted R-squared:  0.7446
## F-statistic: 91.38 on 1 and 30 DF,  p-value: 1.294e-10
```

半对数模型

```
mtcars %>% mutate(log_mpg = log(mpg)) %>% lm(log_mpg ~ wt, data=.) %>% summary
```

```
##
## Call:
## lm(formula = log_mpg ~ wt, data = .)
##
## Residuals:
##       Min        1Q    Median        3Q       Max
## -0.210346 -0.085932 -0.006136  0.061335  0.308623
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  3.83191    0.08396   45.64  < 2e-16 ***
## wt          -0.27178    0.02500  -10.87 6.31e-12 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1362 on 30 degrees of freedom
## Multiple R-squared:  0.7976, Adjusted R-squared:  0.7908
## F-statistic: 118.2 on 1 and 30 DF,  p-value: 6.31e-12
```

双对数模型

```
mtcars %>% mutate(log_mpg = log(mpg), log_wt = log(wt)) %>% lm(log_mpg ~ log_wt, da
ta=.) %>% summary
```

```
##
## Call:
## lm(formula = log_mpg ~ log_wt, data = .)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.18141 -0.10681 -0.02125  0.08109  0.26930
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  3.90181    0.08790   44.39  < 2e-16 ***
## log_wt      -0.84182    0.07549  -11.15 3.41e-12 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1334 on 30 degrees of freedom
## Multiple R-squared:  0.8056, Adjusted R-squared:  0.7992
## F-statistic: 124.4 on 1 and 30 DF,  p-value: 3.406e-12
```

结果解释

- 在线性模型中，系数表示自变量增加一个单位时，因变量变化多少单位。
- 在半对数模型中，系数将自变量的单位变化与因变量的百分比变化联系起来。
- 在双对数模型中，系数描述自变量百分比变化与因变量百分比变化之间的关系。

如何解释半对数模型

- 系数乘以100（$\beta \cdot 100$），近似表示自变量增加一个单位时因变量变化的百分比。
- 当β接近零时，这一近似较准确。
- 精确的百分比变化可计算为$100 \cdot (e^{\beta} - 1)$。

如何解释双对数模型

- 双对数模型中的系数近似表示自变量增加1%时，因变量变化的百分比。
- 精确值可用$(1.01^{\beta} - 1) \cdot 100$计算。
- 如果自变量增加10%，则可计算$(1.1^{\beta} - 1) \cdot 100$。

我们的模型系数

- 原始模型的系数为−5.34。
- 汽车重量增加1吨，与每加仑行驶里程减少5.34英里有关。
- 半对数模型的系数为−0.27。
- 重量增加1吨，与每加仑行驶里程下降28.03%有关。
- 双对数模型的系数为−0.84。
- 重量增加1%，与每加仑行驶里程下降0.83%有关。

选择模型

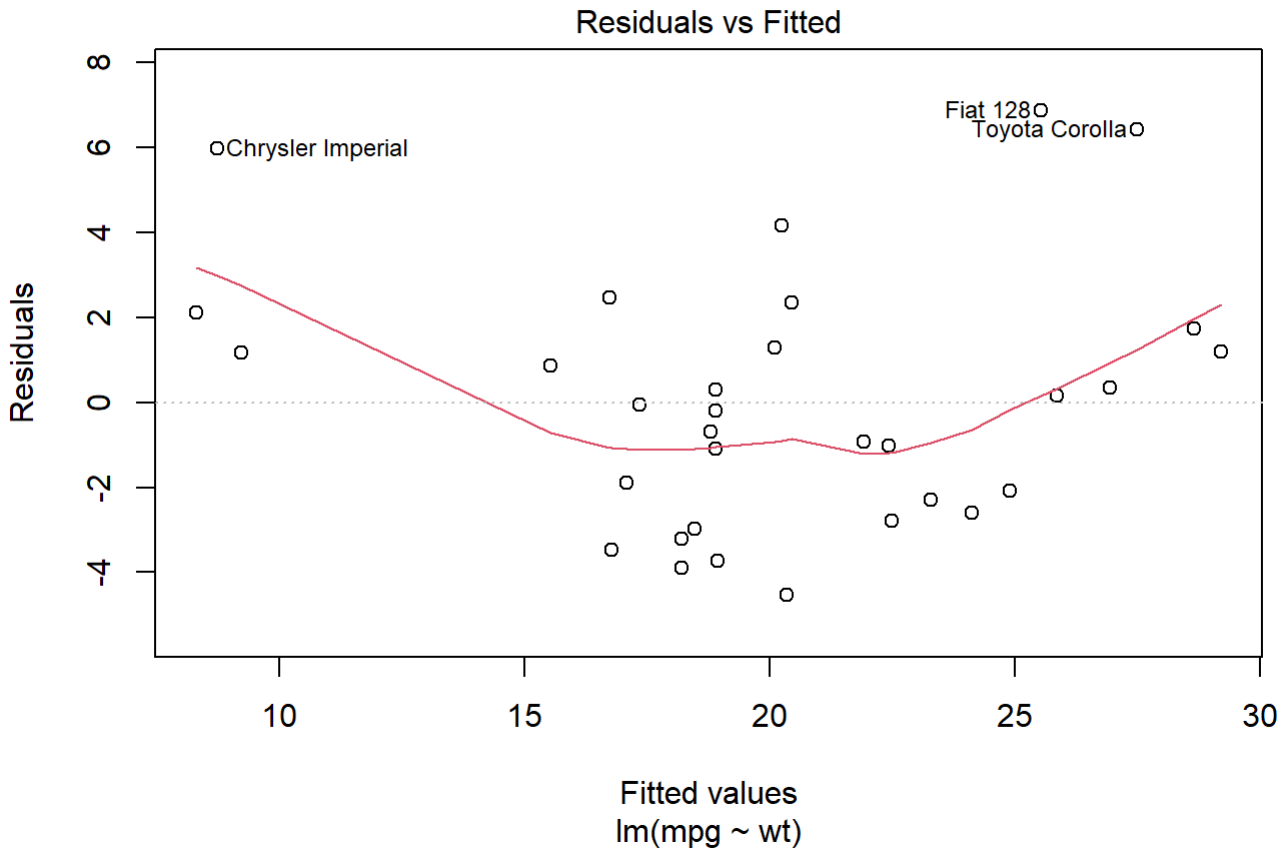
- 我们可能事先就有理论理由偏好某种模型设定。
- 如果没有，也可以根据二元关系可视化选择。
- 还可以比较拟合优度指标。
- 本例中，双对数模型的R^2最高，但只比半对数模型略高一点。
- 此外，也可以使用一些诊断图和诊断工具。

残差与拟合值图

- 回到使用mtcars数据集进行的第一次回归。
- 当时我们绘制了每加仑英里数与车重的散点图。
- 我们估计的回归方程为$\widehat{\text{mpg}}_i = \beta_0 + \beta_1 \cdot \text{wt}$。
- 通过将拟合值（$\widehat{\text{mpg}}$）与残差作图，可以了解模型的表现。
- 它可以帮助发现非线性模式，以及其他一些问题（后面再讨论）。

第一次回归的残差与拟合值图

```
mtcars %>% lm(mpg ~ wt, data=.) %>% plot(which=1)
```

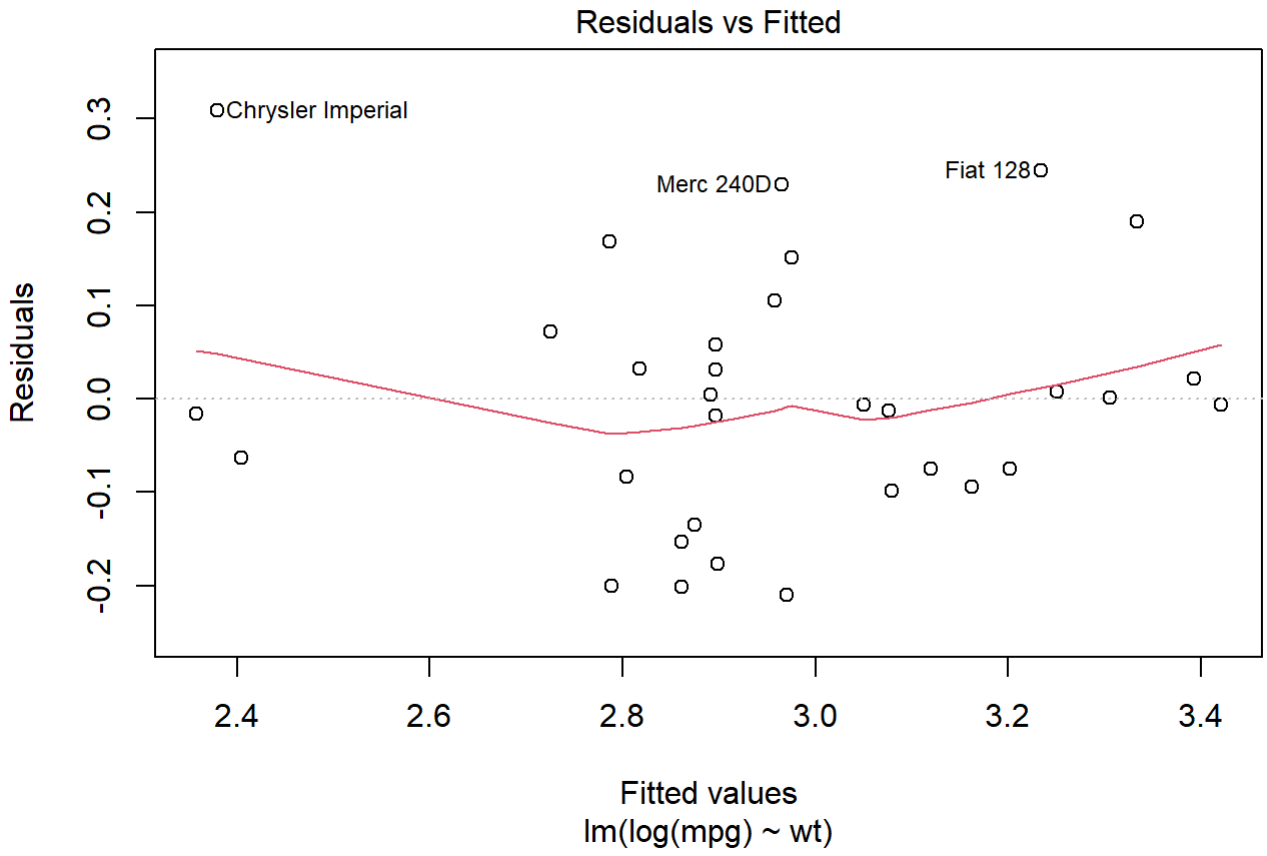


结果解释

- 这只是从另一个角度呈现刚才看到的现象。
- 模型低估了最轻与最重汽车的燃油效率，却高估了中等重量汽车的效率。
- 这不是好事，因为残差中仍然存在有规律的结构。
- 我们应该尝试解释这些结构，使残差只剩下白噪声，即随机波动。

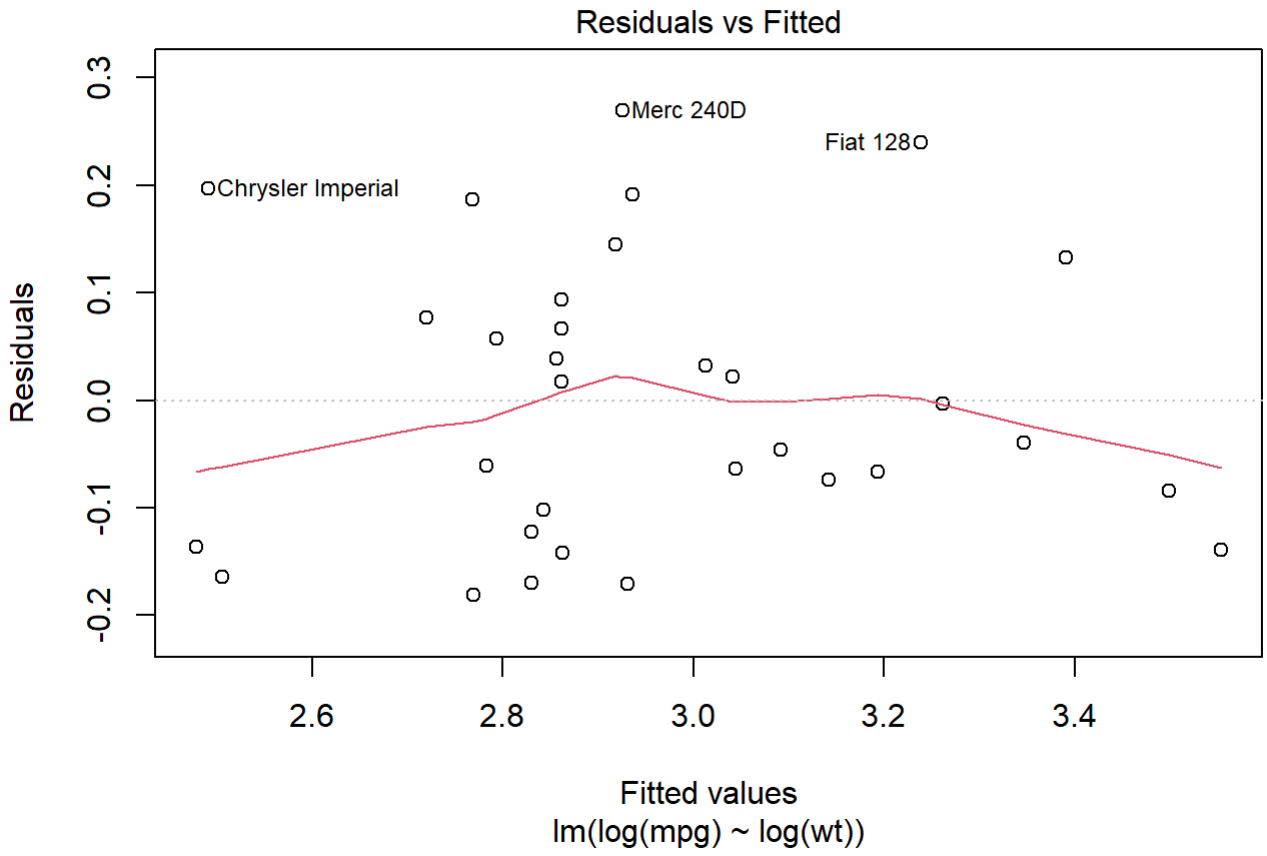
第二次回归的残差与拟合值图

```
mtcars %>% lm(log(mpg) ~ wt, data=.) %>% plot(which=1)
```



第三次回归的残差与拟合值图

```
mtcars %>% lm(log(mpg) ~ log(wt), data=.) %>% plot(which=1)
```



RESET检验

- 可以使用Ramsey回归方程设定误差检验（RESET）帮助作出判断。
- 这是一个一般性的模型设定检验，可以识别包括非线性在内的多种设定错误。
- 如果原始回归为$y_i = \beta_0 + \beta_1 \cdot x_i$，则进一步估计类似这样的模型：
  $y_i = \beta_0 + \beta_1 \cdot x_i + \gamma_1 \cdot \hat{y}^2 + \gamma_2 \cdot \hat{y}^3$。
- 然后对γ系数进行F检验，判断它们是否显著。
- 拒绝原假设，说明模型可能设定错误。
- 可以使用lmtest包中的resettest()函数（不要忘记先安装并加载该包）。

线性模型的RESET检验

```
mtcars %>% lm(mpg ~ wt, data=.) %>% resettest()
```

```
##
##  RESET test
##
## data:  .
## RESET = 5.1315, df1 = 2, df2 = 28, p-value = 0.01263
```

半对数模型的RESET检验

```
mtcars %>% mutate(log_mpg = log(mpg)) %>% lm(log_mpg ~ wt, data=.) %>% resettest()
```

```
##
##  RESET test
##
## data:  .
## RESET = 1.2329, df1 = 2, df2 = 28, p-value = 0.3068
```

双对数模型的RESET检验

```
mtcars %>% mutate(log_mpg = log(mpg), log_wt = log(wt)) %>% lm(log_mpg ~ log_wt, da
ta=.) %>% resettest()
```

```
##
##  RESET test
##
## data:  .
## RESET = 0.75605, df1 = 2, df2 = 28, p-value = 0.4789
```

一些思考

- 本例中，线性模型表现不佳这一点比较明显。
- 我们可以从以下方面看出来：
    - 二元关系图。
    - 拟合优度指标。
    - 残差与拟合值图。
    - RESET检验。
- 如果我们更懂物理，或许能从理论上解释车重与燃油效率之间为何存在非线性关系。

回到我们的模型

- 我之所以建议使用mtcars数据集，是因为其中的非线性模式更容易观察。
- 现在可以着手分析我们自己的模型。
- 正如你所料，在较大的模型中情况会更复杂。
- 先对模型执行RESET检验。

RESET检验

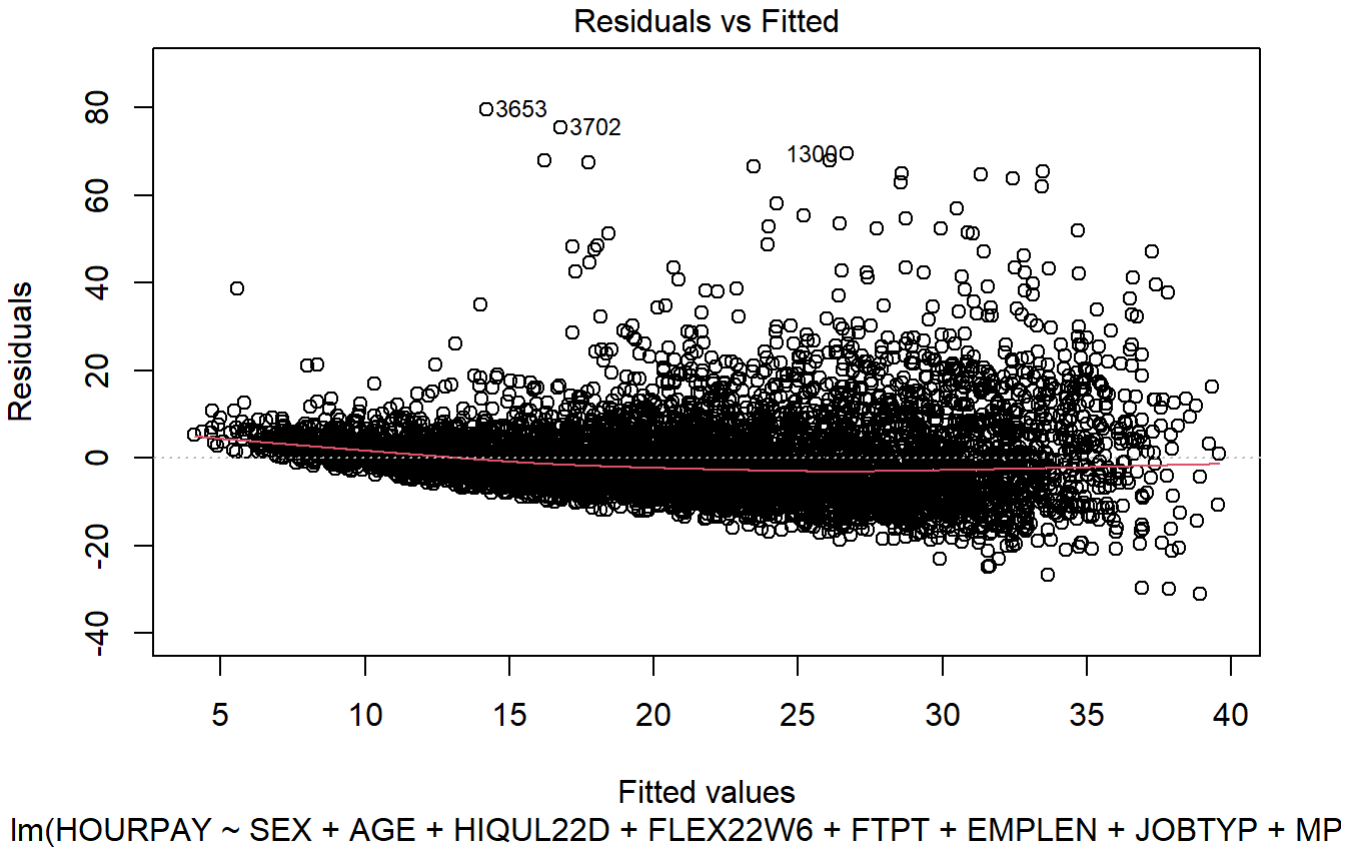
```
lfs %>%
  lm(HOURPAY ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02 +
MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.) %>%
  resettest()
```

```
##
##  RESET test
##
## data:  .
## RESET = 123.33, df1 = 2, df2 = 7289, p-value < 2.2e-16
```

RESET检验

- 看来对模型来说不是什么好消息。
- 有强烈迹象表明模型存在某种设定错误。
- 看一看残差与拟合值图。

残差与拟合值图



结果解释

- 这张图与之前看到的很不一样。
- 红色曲线出现了一定弯曲。
- 此外还有一些其他模式。
- 对于部分高收入者，模型低估了他们的工资。
- 拟合值越高，点的离散程度似乎越大。
- 这种扩散程度随拟合值增大的情况会带来问题，引出了假设2。

假设2

- 我们假设残差具有相同的方差，并且相互独立。
- 方差恒定称为同方差性（homoscedasticity），相反则为异方差性（heteroscedasticity）。
- 如果满足这一假设，残差与拟合值图中的点应当均匀分布在零线两侧。
- 异方差通常呈现出漏斗形。
- 在我们的图中可以清楚看到这种迹象。

异方差的类型

- 异方差可能由不同原因产生。
- 第一种原因可能是模型设定错误，因此应当先检查这个问题。
- 修正模型设定可能消除异方差。
- 即使模型设定正确，也仍可能存在异方差，有时称为纯粹异方差。
- 纯粹异方差意味着标准误可能有误，因此p值与假设检验也不可靠。
- 不过，这个问题相对容易解决。

我们的模型有异方差吗？

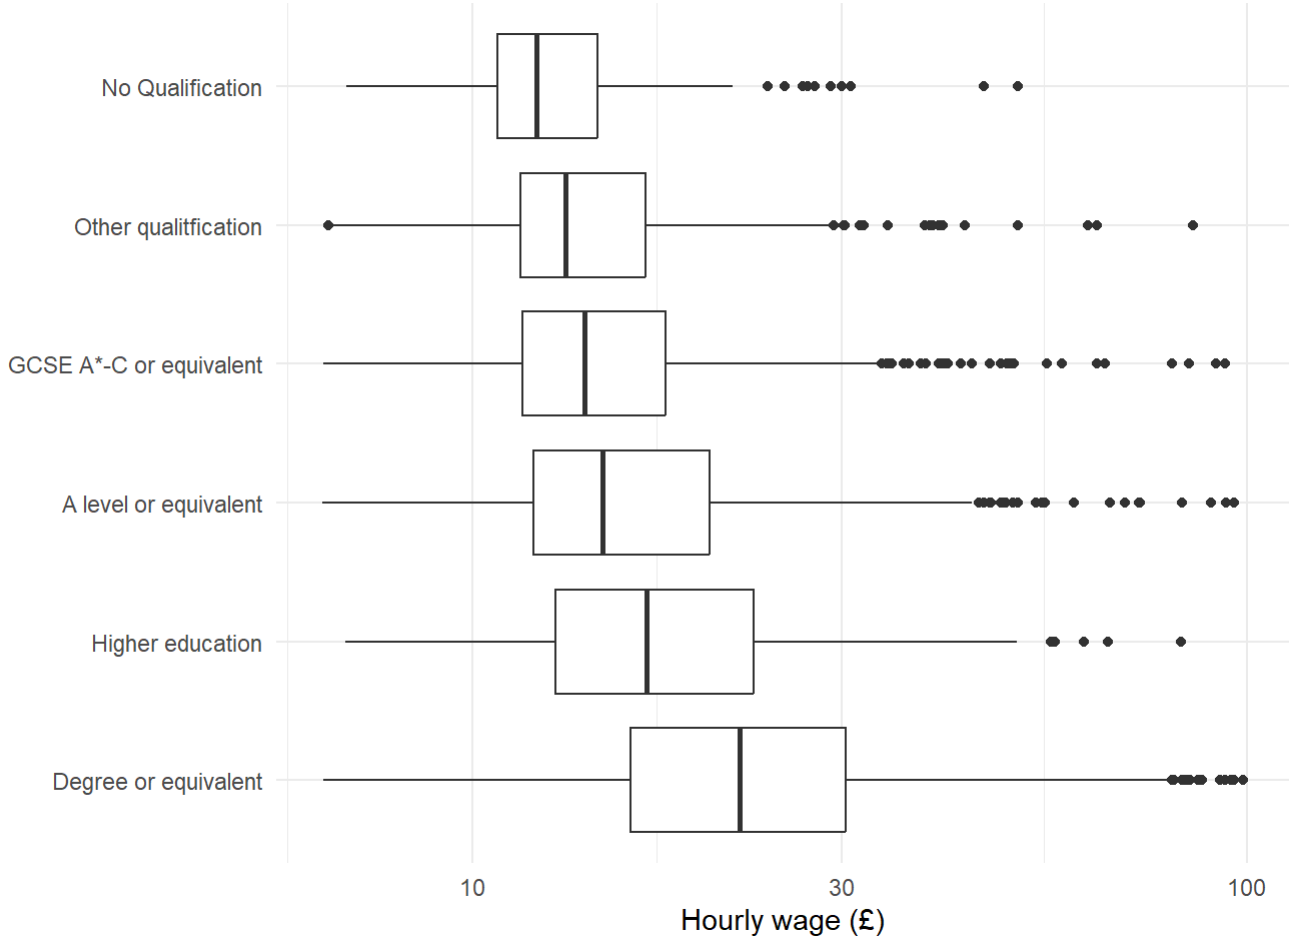
- 首先检查模型设定是否正确。
- 再问自己：有没有事先可以预见的异方差原因？
- 哪些变量可能导致异方差？
- 这个思考过程在模型设计、描述性统计和数据可视化阶段就应当开始。
- 模型中存在几个候选因素，例如教育。

教育

HIQUL22D	观测数	均值	方差	标准差
学位或同等资格	3535	25.02	159.93	12.65

HIQUL22D	观测数	均值	方差	标准差
高等教育	565	19.63	97.70	9.88
A Level或同等资格	1604	17.33	78.49	8.86
GCSE A*–C或同等资格	1102	16.16	68.67	8.29
其他资格	331	15.63	73.18	8.55
无资格证书	210	13.53	29.07	5.39

教育



教育

- 从这些基础描述性统计来看，教育可能导致异方差的迹象已经出现。
- 即使还没查看数据，我们也应当对此有所预期。
- 这意味着即使模型设定正确，仍可能存在异方差。

检验异方差

- 虽然观察图形并独立思考很重要，但正式的统计检验也有帮助。
- 已经开发了多种检验方法，各有优缺点。

- 我们将学习Breusch–Pagan检验。

Breusch–Pagan检验

- 这一检验也有不同版本。
- 基本思想是将残差方差的估计值（残差的平方）对自变量进行回归。
- 如果方差中的过多变异可由自变量解释，就拒绝同方差性的原假设。
- 可以使用lmtest包中的bptest()函数进行检验。
- 现在也可以对模型运行这个检验，但意义不大，因为已经发现模型设定有问题。

检查模型是否存在异方差

```
lfs %>%
  lm(HOURPAY ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNRO2 +
MARSTA + INDE07M + NSECMJ20 + GOR9D,
     data=.) %>%
 bptest()
```

```
##
##  studentized Breusch-Pagan test
##
## data:  .
## BP = 390.68, df = 55, p-value < 2.2e-16
```

残差分布

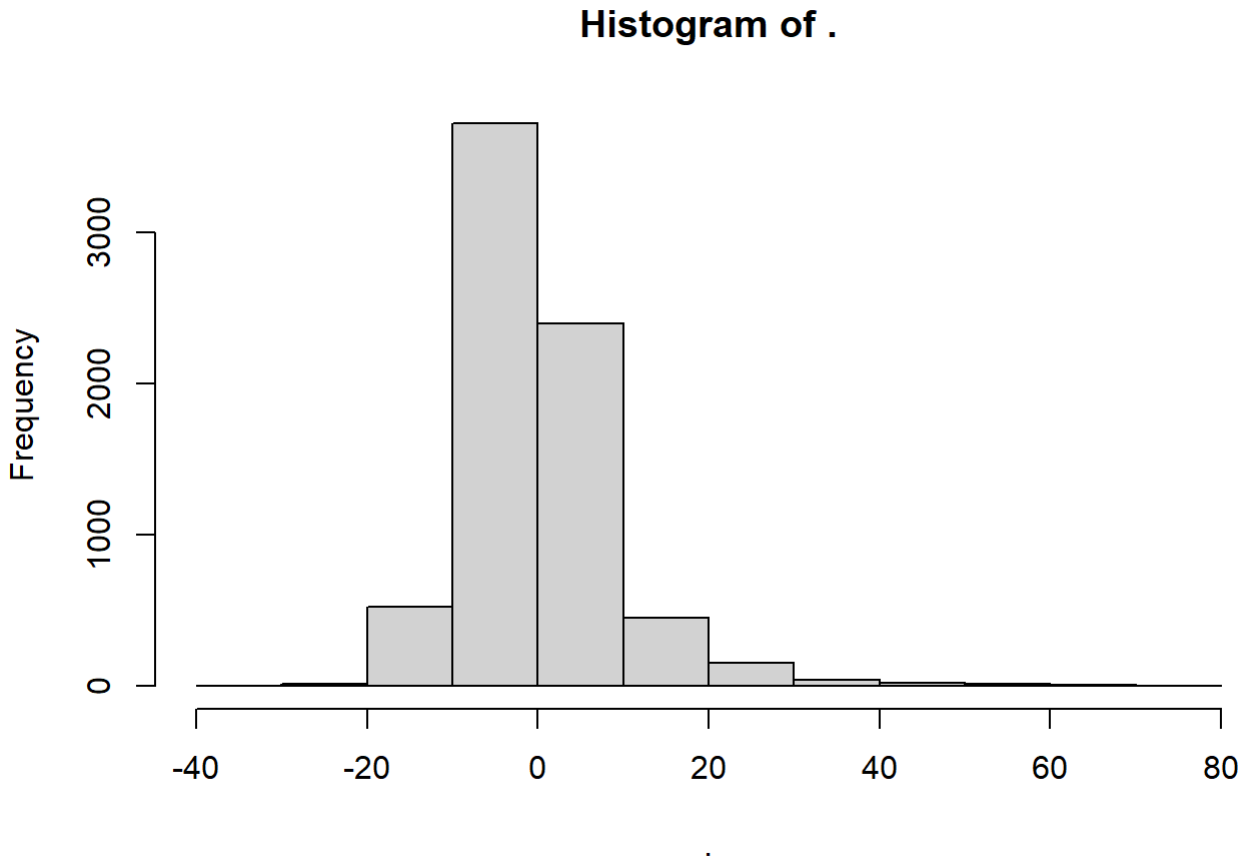
- 我们假设残差的方差恒定。
- 另一个假设是残差服从正态分布。
- 如果不符合，就可能无法可靠地执行假设检验。
- 有几种检查方法。
- 虽然存在正态性统计检验，但我不推荐，因为它们过于敏感。
- 几乎总会拒绝“服从正态分布”的原假设。

残差分布

- 更好的办法是把正态性看作程度问题。
- 残差越接近正态分布越好。
- 可以查看残差直方图。

- 也可以使用所谓的QQ图。

残差直方图

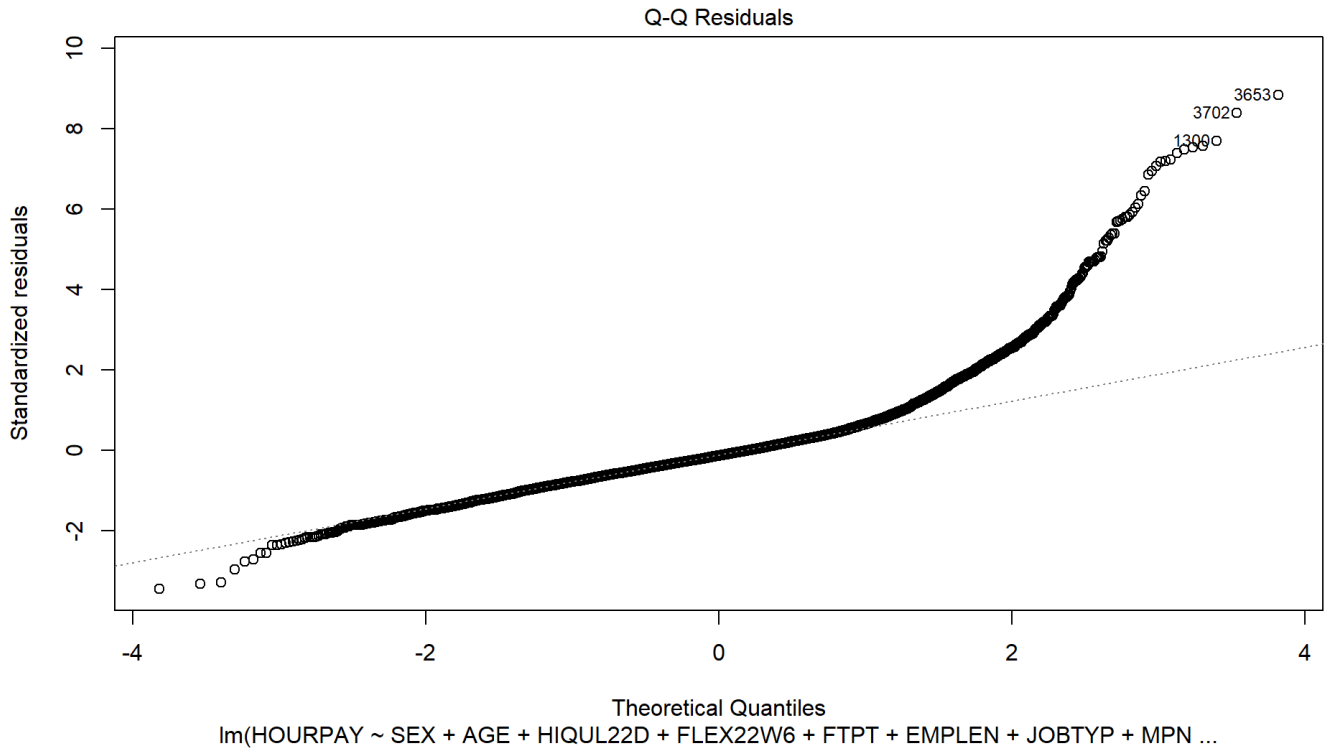


残差分布

- 直方图看起来不太符合正态分布。
- 它高度偏斜，因此模型的p值可能不可靠。
- 另一种有用的图形是分位数—分位数图（Q–Q图）。
- 我们希望图中点尽量落在虚线附近。
- 如果分布完全符合正态，那么所有点都应落在该线上。

残差QQ图

```
lm(HOURPAY ~ SEX + AGE +  HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNRO2 + MARSTA + INDE07M + NSECMJ20 + GOR9D, data=lfs) %>% plot(which=2)
```



残差分布

- QQ图只是观察分布的另一种方式。
- 不出所料，它显示同样的问题：残差不服从正态分布。

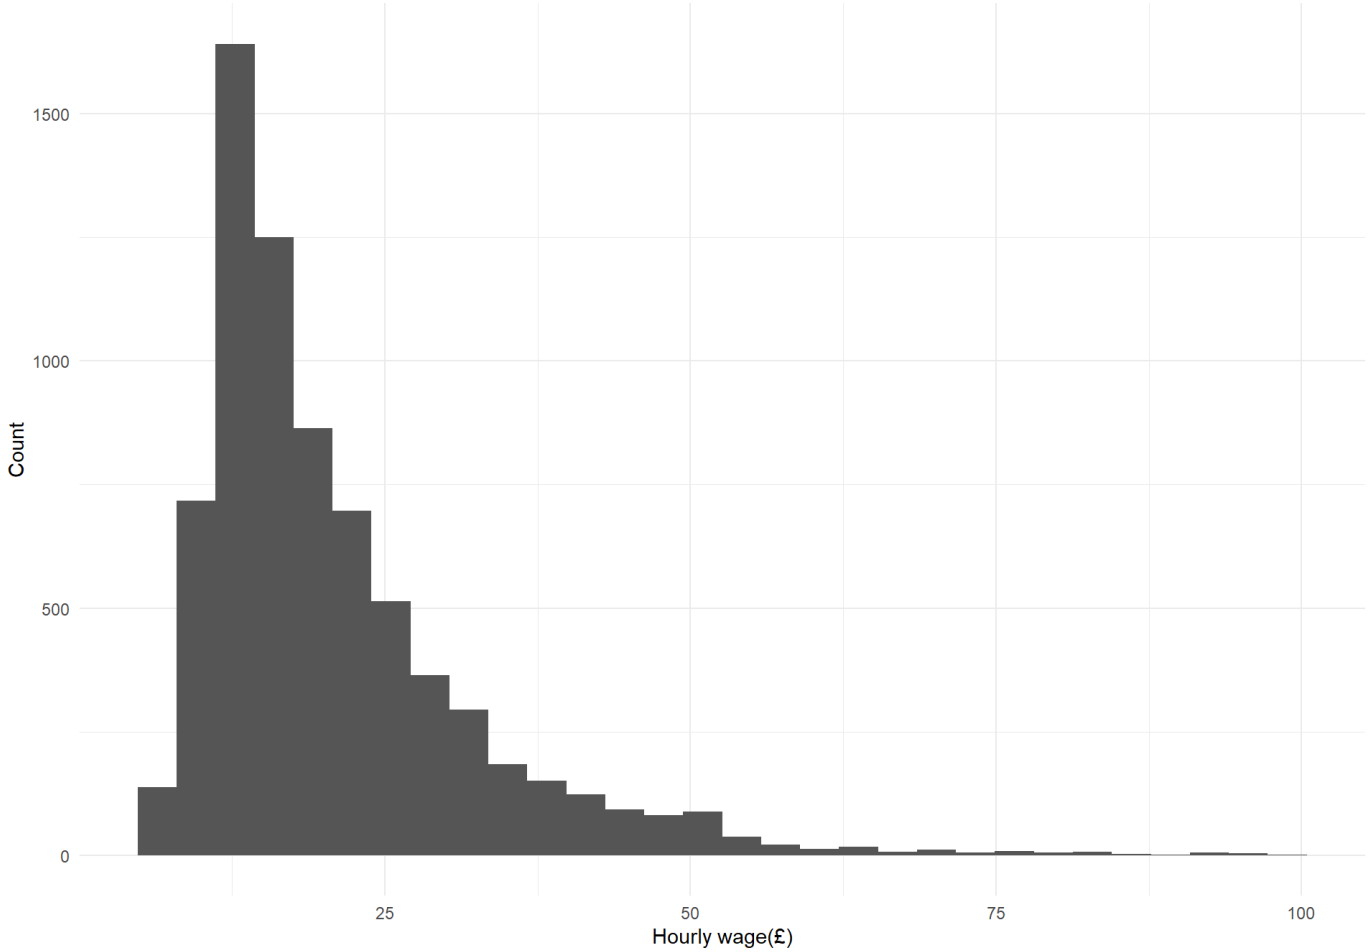
存在的问题

- 到目前为止，我们已经讨论了假设1和假设2的一部分。
- 有迹象表明模型设定存在问题，残差也未达到预期表现。
- 事实证明，对数变换可以帮助解决所有这些问题。
- 现在就试一试。

分布

- 注意，正态性假设针对的是残差，而不是原始变量。
- 不过，如果因变量偏斜，那么残差也很可能偏斜。
- 再看一看因变量的直方图。

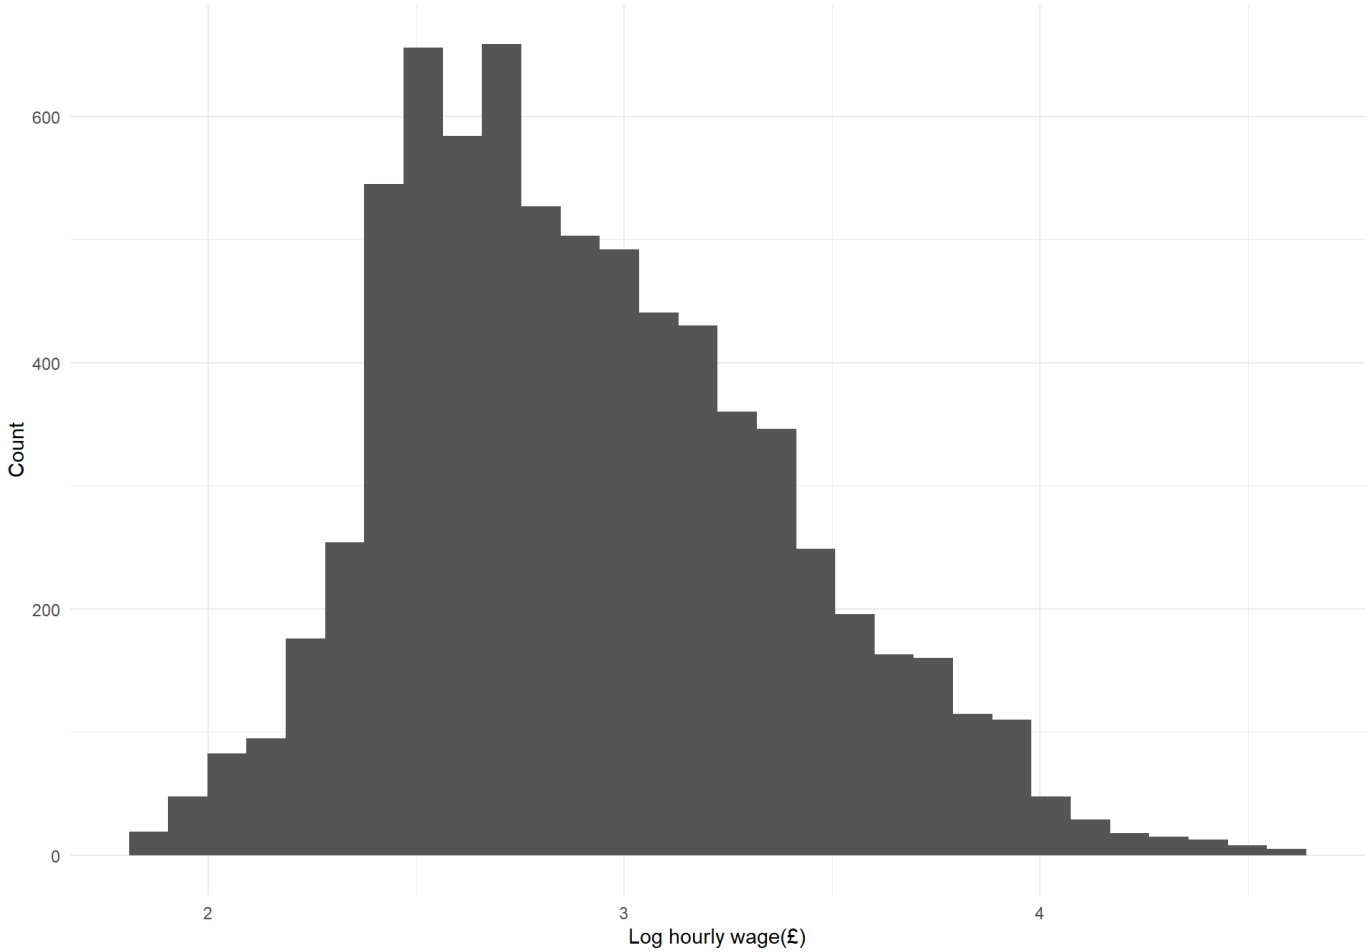
因变量的分布



结果解释

- 可以看出该变量分布偏斜。
- 事实上，它的偏斜形态与残差有些相似。
- 如果因变量像这样分布，就应当预料到残差可能不服从正态分布。
- 对数变换往往有帮助。

工资对数的分布



结果解释

- 这仍然不是正态分布。
- 但相比最初的分布，它已经更接近正态。
- 可以用半对数模型重新估计并看看结果。

如何处理零值?

- 注意，这种变换仅适用于没有零值的情况（我们的例子正是如此）。
- 如果存在零值，就不能直接做对数变换，因为零的对数没有定义。
- 可以考虑其他变换，如平方根变换，但会使结果更难解释。
- 也有人建议用较小的数替换零值，或者给所有值加上一个小数。
- 这种方法很流行，但可能引发问题，尤其当零值很多时。
- 另一个办法是排除零值，只对正数进行建模。
- 但这会限制模型结果的可推广性，也会改变结果解释。

半对数回归

```
lfs %>% mutate(log_wage = log(HOURPAY)) %>% lm(log_wage ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNRO2 + MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.) %>% summary
```

```
##
## Call:
## lm(formula = log_wage ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT +
##     EMPLEN + JOBTYP + MPNR02 + MARSTA + INDE07M + NSECMJ20 +
##     GOR9D, data = .)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.62055 -0.21109 -0.01861  0.19648  1.96285
##
## Coefficients:
##                                                    Estimate Std. Error
## (Intercept)                                       3.0115227  0.0744636
## SEXFemale                                        -0.0719738  0.0088949
## AGE                                               0.0041173  0.0004292
## HIQUL22DHigher education                         -0.1352929  0.0158525
## HIQUL22DA level or equivalent                    -0.1692705  0.0111238
## HIQUL22DGCSE A*-C or equivalent                  -0.2011436  0.0130428
## HIQUL22DOther qualitfication                     -0.1975554  0.0209636
## HIQUL22DNo Qualification                         -0.2873597  0.0258566
## FLEX22W6No                                        0.0567135  0.0295696
## FTPTPart-time                                    -0.0297625  0.0108578
## EMPLENThree months, less than 6                  -0.0151183  0.0321268
## EMPLEN6 months, less than 12                      0.0146695  0.0295457
## EMPLEN1 year, less than 2                         0.0065315  0.0269487
## EMPLEN2 years, less than 5                        0.0477627  0.0258684
## EMPLEN5 years, less than 10                       0.0642989  0.0264364
## EMPLEN10 years, less than 20                      0.0872838  0.0265202
## EMPLEN20 years or more                            0.1164016  0.0275700
## JOBTYPNot permanent in some way                   0.0104594  0.0236075
## MPNR0211-19                                       0.0111125  0.0175732
## MPNR0220-24                                       0.0178841  0.0228220
## MPNR02Don't know but under 25                    -0.0260251  0.0296457
## MPNR0225-49                                       0.0139941  0.0154129
## MPNR0250-249                                      0.0441019  0.0132299
## MPNR02250-499                                     0.0889228  0.0187895
## MPNR02Don't know but between 50 and 499           0.0365645  0.0219740
## MPNR02500 or more                                 0.1195901  0.0134575
## MARSTAMarried, living with spouse                 0.0579014  0.0096678
## MARSTAMarried separated from spouse               0.0358534  0.0277121
## MARSTADivorced                                    0.0675272  0.0172986
## MARSTAWidowed                                     0.0260218  0.0409994
## MARSTACurrently or previously in civil partnership  0.0012794  0.0396475
## INDE07MEnergy and water                           0.1886694  0.0655100
## INDE07MManufacturing                              0.1221503  0.0610133
## INDE07MConstruction                               0.1949621  0.0623280
## INDE07MDistribution, hotels and restaurants      -0.0073309  0.0604083
## INDE07MTransport and communication                0.1702397  0.0609278
```

```
## INDE07MBanking and finance                          0.1231448  0.0602697
## INDE07MPublic admin, education and health           0.0181740  0.0599948
## INDE07MOther services                              -0.0073582  0.0626015
## NSECMJ20Lower managerial and professional          -0.2150006  0.0110268
## NSECMJ20Intermediate occupations                   -0.4471331  0.0139022
## NSECMJ20Lower supervisory and technical            -0.4203188  0.0195287
## NSECMJ20Semi-routine occupations                   -0.5387646  0.0169187
## NSECMJ20Routine occupations                        -0.5727283  0.0177126
## NSECMJ20Never worked                               -0.4505182  0.0307417
## GOR9DYorkshire and The Humber                      -0.1609020  0.0191250
## GOR9DSouth West                                    -0.1249406  0.0191410
## GOR9DWest Midlands                                 -0.1123784  0.0205305
## GOR9DSouth East                                    -0.0892086  0.0176602
## GOR9DEast of England                               -0.0759118  0.0200910
## GOR9DEast Midlands                                 -0.1569061  0.0198246
## GOR9DNorth East                                    -0.1842434  0.0247838
## GOR9DNorth West                                    -0.1410464  0.0195823
## GOR9DWales                                         -0.1764938  0.0250278
## GOR9DNorthern Ireland                              -0.1800145  0.0214698
## GOR9DScotland                                      -0.1140573  0.0199441
##                                                    t value Pr(>|t|)
## (Intercept)                                         40.443  < 2e-16 ***
## SEXFemale                                           -8.092 6.85e-16 ***
## AGE                                                  9.594  < 2e-16 ***
## HIQUL22DHigher education                            -8.534  < 2e-16 ***
## HIQUL22DA level or equivalent                      -15.217  < 2e-16 ***
## HIQUL22DGCSE A*-C or equivalent                    -15.422  < 2e-16 ***
## HIQUL22DOther qualitfication                        -9.424  < 2e-16 ***
## HIQUL22DNo Qualification                           -11.114  < 2e-16 ***
## FLEX22W6No                                           1.918 0.055154 .
## FTPTPart-time                                       -2.741 0.006138 **
## EMPLENThree months, less than 6                     -0.471 0.637953
## EMPLEN6 months, less than 12                         0.497 0.619555
## EMPLEN1 year, less than 2                            0.242 0.808501
## EMPLEN2 years, less than 5                           1.846 0.064879 .
## EMPLEN5 years, less than 10                          2.432 0.015031 *
## EMPLEN10 years, less than 20                         3.291 0.001002 **
## EMPLEN20 years or more                               4.222 2.45e-05 ***
## JOBTYPNot permanent in some way                      0.443 0.657738
## MPNRO211-19                                          0.632 0.527174
## MPNRO220-24                                          0.784 0.433282
## MPNRO2Don't know but under 25                       -0.878 0.380042
## MPNRO225-49                                          0.908 0.363938
## MPNRO250-249                                         3.334 0.000862 ***
## MPNRO2250-499                                        4.733 2.26e-06 ***
## MPNRO2Don't know but between 50 and 499              1.664 0.096159 .
## MPNRO2500 or more                                    8.886  < 2e-16 ***
## MARSTAMarried, living with spouse                    5.989 2.21e-09 ***
```

```
## MARSTAMarried separated from spouse                    1.294 0.195781
## MARSTADivorced                                         3.904 9.56e-05 ***
## MARSTAWidowed                                          0.635 0.525652
## MARSTACurrently or previously in civil partnership     0.032 0.974259
## INDE07MEnergy and water                                2.880 0.003988 **
## INDE07MManufacturing                                   2.002 0.045319 *
## INDE07MConstruction                                    3.128 0.001767 **
## INDE07MDistribution, hotels and restaurants           -0.121 0.903413
## INDE07MTransport and communication                     2.794 0.005218 **
## INDE07MBanking and finance                             2.043 0.041066 *
## INDE07MPublic admin, education and health              0.303 0.761955
## INDE07MOther services                                 -0.118 0.906435
## NSECMJ20Lower managerial and professional            -19.498  < 2e-16 ***
## NSECMJ20Intermediate occupations                     -32.163  < 2e-16 ***
## NSECMJ20Lower supervisory and technical              -21.523  < 2e-16 ***
## NSECMJ20Semi-routine occupations                     -31.844  < 2e-16 ***
## NSECMJ20Routine occupations                          -32.334  < 2e-16 ***
## NSECMJ20Never worked                                 -14.655  < 2e-16 ***
## GOR9DYorkshire and The Humber                         -8.413  < 2e-16 ***
## GOR9DSouth West                                       -6.527 7.14e-11 ***
## GOR9DWest Midlands                                    -5.474 4.55e-08 ***
## GOR9DSouth East                                       -5.051 4.49e-07 ***
## GOR9DEast of England                                  -3.778 0.000159 ***
## GOR9DEast Midlands                                    -7.915 2.85e-15 ***
## GOR9DNorth East                                       -7.434 1.17e-13 ***
## GOR9DNorth West                                       -7.203 6.49e-13 ***
## GOR9DWales                                            -7.052 1.93e-12 ***
## GOR9DNorthern Ireland                                 -8.385  < 2e-16 ***
## GOR9DScotland                                         -5.719 1.11e-08 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.3402 on 7291 degrees of freedom
## Multiple R-squared:  0.483,  Adjusted R-squared:  0.4791
## F-statistic: 123.9 on 55 and 7291 DF,  p-value: < 2.2e-16
```

原始回归

```
lfs %>% lm(HOURPAY ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNRO2 + MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.) %>% summary
```

```
##
## Call:
## lm(formula = HOURPAY ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT +
##     EMPLEN + JOBTYP + MPNR02 + MARSTA + INDE07M + NSECMJ20 +
##     GOR9D, data = .)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -31.140  -5.101  -1.189   3.046  79.547
##
## Coefficients:
##                                                    Estimate Std. Error t value
## (Intercept)                                        25.78853    1.98215  13.010
## SEXFemale                                          -1.78189    0.23677  -7.526
## AGE                                                 0.10231    0.01142   8.956
## HIQUL22DHigher education                           -3.23076    0.42198  -7.656
## HIQUL22DA level or equivalent                      -3.85940    0.29611 -13.034
## HIQUL22DGCSE A*-C or equivalent                    -4.53640    0.34719 -13.066
## HIQUL22DOther qualitfication                       -4.44594    0.55803  -7.967
## HIQUL22DNo Qualification                           -6.14744    0.68828  -8.932
## FLEX22W6No                                          0.40302    0.78712   0.512
## FTPTPart-time                                      -0.07943    0.28902  -0.275
## EMPLENThree months, less than 6                    -0.39861    0.85519  -0.466
## EMPLEN6 months, less than 12                       -0.18981    0.78648  -0.241
## EMPLEN1 year, less than 2                          -0.30792    0.71735  -0.429
## EMPLEN2 years, less than 5                          0.34445    0.68859   0.500
## EMPLEN5 years, less than 10                         0.52264    0.70371   0.743
## EMPLEN10 years, less than 20                        1.06104    0.70594   1.503
## EMPLEN20 years or more                              1.57930    0.73389   2.152
## JOBTYPNot permanent in some way                     0.15802    0.62841   0.251
## MPNR0211-19                                         0.01830    0.46778   0.039
## MPNR0220-24                                         0.17017    0.60750   0.280
## MPNR02Don't know but under 25                      -1.01501    0.78914  -1.286
## MPNR0225-49                                         0.05431    0.41028   0.132
## MPNR0250-249                                        0.51390    0.35217   1.459
## MPNR02250-499                                       1.50815    0.50016   3.015
## MPNR02Don't know but between 50 and 499             0.65691    0.58493   1.123
## MPNR02500 or more                                   2.40393    0.35823   6.711
## MARSTAMarried, living with spouse                   1.44619    0.25735   5.620
## MARSTAMarried separated from spouse                 0.79898    0.73767   1.083
## MARSTADivorced                                      1.68799    0.46047   3.666
## MARSTAWidowed                                       1.62508    1.09137   1.489
## MARSTACurrently or previously in civil partnership -0.38073    1.05538  -0.361
## INDE07MEnergy and water                             3.70456    1.74382   2.124
## INDE07MManufacturing                                2.19235    1.62412   1.350
## INDE07MConstruction                                 3.84059    1.65911   2.315
## INDE07MDistribution, hotels and restaurants        -0.39967    1.60802  -0.249
## INDE07MTransport and communication                  3.64347    1.62184   2.246
```

```
## INDE07MBanking and finance                          2.61233    1.60432   1.628
## INDE07MPublic admin, education and health           -0.37672    1.59701  -0.236
## INDE07MOther services                               -0.61520    1.66640  -0.369
## NSECMJ20Lower managerial and professional           -5.89892    0.29352 -20.097
## NSECMJ20Intermediate occupations                   -10.52187    0.37006 -28.433
## NSECMJ20Lower supervisory and technical             -9.81153    0.51984 -18.874
## NSECMJ20Semi-routine occupations                   -11.54158    0.45036 -25.627
## NSECMJ20Routine occupations                        -12.49647    0.47149 -26.504
## NSECMJ20Never worked                                -8.66825    0.81832 -10.593
## GOR9DYorkshire and The Humber                       -4.31942    0.50909  -8.485
## GOR9DSouth West                                     -3.69832    0.50952  -7.258
## GOR9DWest Midlands                                  -3.25102    0.54650  -5.949
## GOR9DSouth East                                     -2.42283    0.47010  -5.154
## GOR9DEast of England                                -2.23360    0.53480  -4.176
## GOR9DEast Midlands                                  -4.01808    0.52771  -7.614
## GOR9DNorth East                                     -5.24307    0.65972  -7.947
## GOR9DNorth West                                     -4.00454    0.52126  -7.682
## GOR9DWales                                          -4.97962    0.66622  -7.474
## GOR9DNorthern Ireland                               -5.08488    0.57151  -8.897
## GOR9DScotland                                       -3.28323    0.53089  -6.184
##                                                    Pr(>|t|)
## (Intercept)                                         < 2e-16 ***
## SEXFemale                                          5.87e-14 ***
## AGE                                                 < 2e-16 ***
## HIQUL22DHigher education                           2.16e-14 ***
## HIQUL22DA level or equivalent                       < 2e-16 ***
## HIQUL22DGCSE A*-C or equivalent                     < 2e-16 ***
## HIQUL22DOther qualitfication                       1.87e-15 ***
## HIQUL22DNo Qualification                            < 2e-16 ***
## FLEX22W6No                                         0.608648
## FTPTPart-time                                      0.783459
## EMPLENThree months, less than 6                    0.641152
## EMPLEN6 months, less than 12                       0.809302
## EMPLEN1 year, less than 2                          0.667754
## EMPLEN2 years, less than 5                         0.616933
## EMPLEN5 years, less than 10                        0.457692
## EMPLEN10 years, less than 20                       0.132879
## EMPLEN20 years or more                             0.031434 *
## JOBTYPNot permanent in some way                    0.801461
## MPNRO211-19                                        0.968800
## MPNRO220-24                                        0.779394
## MPNRO2Don't know but under 25                      0.198407
## MPNRO225-49                                        0.894685
## MPNRO250-249                                       0.144539
## MPNRO2250-499                                      0.002576 **
## MPNRO2Don't know but between 50 and 499            0.261452
## MPNRO2500 or more                                  2.08e-11 ***
## MARSTAMarried, living with spouse                  1.98e-08 ***
```

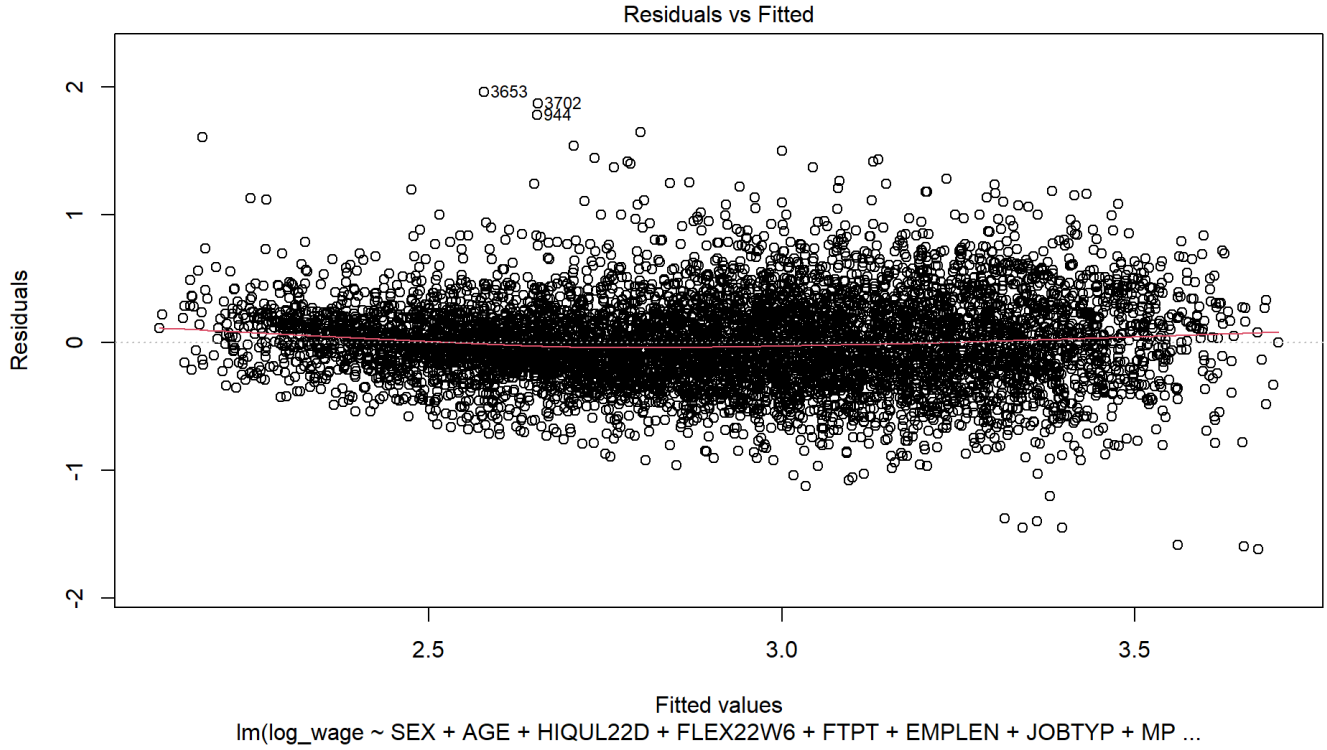
```
## MARSTAMarried separated from spouse                0.278795
## MARSTADivorced                                     0.000248 ***
## MARSTAWidowed                                      0.136521
## MARSTACurrently or previously in civil partnership 0.718297
## INDE07MEnergy and water                            0.033671 *
## INDE07MManufacturing                               0.177099
## INDE07MConstruction                                0.020649 *
## INDE07MDistribution, hotels and restaurants        0.803718
## INDE07MTransport and communication                 0.024702 *
## INDE07MBanking and finance                         0.103503
## INDE07MPublic admin, education and health          0.813522
## INDE07MOther services                              0.712006
## NSECMJ20Lower managerial and professional          < 2e-16 ***
## NSECMJ20Intermediate occupations                   < 2e-16 ***
## NSECMJ20Lower supervisory and technical            < 2e-16 ***
## NSECMJ20Semi-routine occupations                   < 2e-16 ***
## NSECMJ20Routine occupations                        < 2e-16 ***
## NSECMJ20Never worked                               < 2e-16 ***
## GOR9DYorkshire and The Humber                      < 2e-16 ***
## GOR9DSouth West                                    4.32e-13 ***
## GOR9DWest Midlands                                 2.83e-09 ***
## GOR9DSouth East                                    2.62e-07 ***
## GOR9DEast of England                               2.99e-05 ***
## GOR9DEast Midlands                                 2.99e-14 ***
## GOR9DNorth East                                    2.19e-15 ***
## GOR9DNorth West                                    1.77e-14 ***
## GOR9DWales                                         8.65e-14 ***
## GOR9DNorthern Ireland                              < 2e-16 ***
## GOR9DScotland                                      6.57e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 9.055 on 7291 degrees of freedom
## Multiple R-squared:  0.389,  Adjusted R-squared:  0.3844
## F-statistic: 84.41 on 55 and 7291 DF,  p-value: < 2.2e-16
```

半对数模型的RESET检验

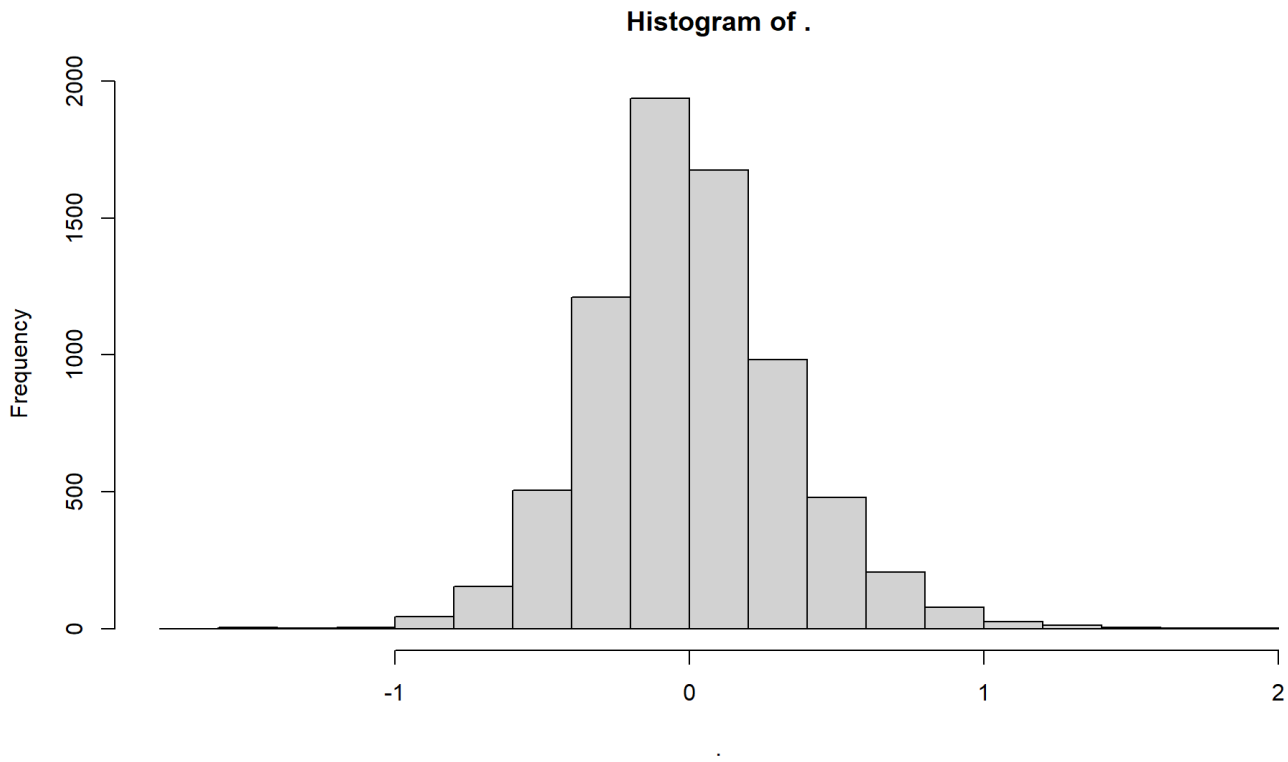
```
lfs %>% mutate(log_wage = log(HOURPAY)) %>% lm(log_wage ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNRO2 + MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.) %>% resettest()
```

```
##
##  RESET test
##
## data:  .
## RESET = 52.408, df1 = 2, df2 = 7289, p-value < 2.2e-16
```

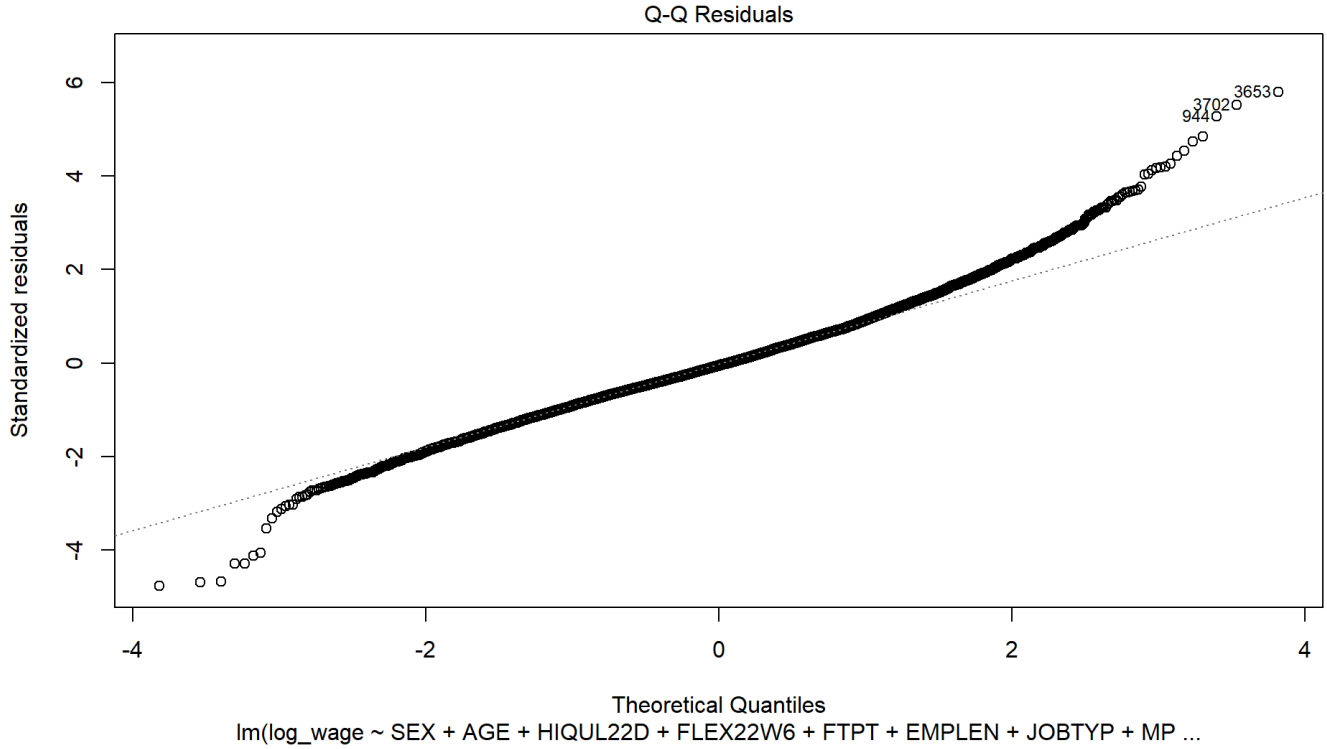
半对数模型的残差与拟合值图



半对数模型的残差直方图



半对数模型的QQ图



半对数模型的BP检验

```
lfs %>% mutate(log_wage = log(HOURPAY)) %>%
  lm(log_wage ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02 +
MARSTA + INDE07M + NSECMJ20 + GOR9D,
     data=.) %>%
  bptest()
```

```
##
##  studentized Breusch-Pagan test
##
## data:  .
## BP = 356.74, df = 55, p-value < 2.2e-16
```

一些思考

- 模型仍未通过设定检验。
- 但相比原始模型，已经好得多。
- 这也是为什么必须同时查看统计检验和诊断图。
- 我们往往无法将模型调整到完美状态。
- 我们的目标是让模型尽可能好。

总结

- 我们已经介绍了模型背后一些非常重要的假设。
- 学习了重要的诊断工具。
- 也开始了解如何修复部分问题。
- 下一讲将进一步改进模型，并继续讨论其他假设。