Lecture 9 | 对数变换、函数形式与回归诊断——R语言完全零基础逐行代码教程

> **课程**：URBAN5127 Quantitative Data Analysis | **来源**：`lecture9_notes.html`（课堂原始讲义）与对应中文版。
> **读者**：没有编程经验、正在学习R/RStudio的初学者。**方法**：保持讲义全部课堂R代码原样，逐行解释，再用独立标注的教学补充帮助理解。

〇、先认识这一讲：对数变换、函数形式与回归诊断

这一讲先使用内置mtcars数据集比较线性、半对数、双对数模型，然后回到LFS工资回归，演示RESET设定检验、BP异方差检验和残差QQ图。

读完应当会：

1. 自然对数及其定义域。
2. 水平-水平、对数-水平、对数-对数模型。
3. 残差-拟合值图。
4. RESET检验模型设定。
5. Breusch–Pagan异方差检验。
6. 残差QQ图与解释变量变换。

原始代码的覆盖范围

- 英文原始HTML中识别到 **16段真正的课堂R代码（`pre.r`）**；下文每一段完整按原顺序出现，**不省略或替换原始代码。**
- HTML中的黑色`## ...`控制台打印是**运行结果**，不能把它当成要重新输入的R命令；网页的JavaScript/CSS也不是本课R代码。
- 如果相同代码在不同位置重复出现，教程仍按原讲义顺序保留并解释其教学目的。

一、先修知识：即使从来没写过代码也能看懂

1.1 R / RStudio到底是什么?

R是一种用于统计分析的编程语言；RStudio是帮助你编辑、运行、检查R程序的工作界面。**R语言**决定代码含义，**RStudio**提供Source（脚本编辑器）、Console（即时运行）、Environment（查看对象）、Plots（看图）等窗口。
建议先创建一个`.R`脚本，将本教程中的每段原始代码逐段粘贴进去；在RStudio中选中一行或几行按Ctrl+Enter（Windows）或Cmd+Enter（macOS）运行。不要一次性运行全部章节：有些讲义代码依赖之前做过的数据处理。

1.2 把R代码当成一句完整的话来阅读

写法	初学者的读法	常见误解
`x <- ...`	把右边结果保存到x	以为`<-`是小于号
`f(x, y)`	调用函数f，把x和y作为参数	以为所有括号都在做数学乘法

写法	初学者的读法	常见误解
`data = lfs`	指定数据对象	以为这里是把变量赋值给lfs
`df$AGE`	从df里抽取AGE这一列	以为 `$` 有货币意义
`a %>% b()`	先做a，再把结果交给b	与ggplot的图层加号 `+` 混淆
`y ~ x1 + x2`	用x1、x2共同解释y	把公式中的 `+` 当成数值求和
`"Female"`	这是**字符串文字**	误以为是变量名
`TRUE` 与 `FALSE`	布尔值/逻辑值	与文字 `"TRUE"` 混淆
`# ...`	注释，对运行结果无影响	把注释当成一定会运行的代码
`<`、`==`	分别表示小于、是否相等	把 `==` 与赋值符混淆

如果一行很长，先找最外层函数，再拆成“传入的数据→做了什么→返回什么”；碰到多层括号，从**最里面的函数**开始理解。

1.3 第一次运行前，需要准备哪些包？

初学者先区分：**安装（install.packages）只需通常做一次，载入（library）在每次新R会话中可能要再执行。**下方是**教学补充**，不是原课件代码：

```
# 第一次使用且尚未安装时，去掉下面一行行首的 # 并运行
# install.packages(c("dplyr", "lmtest"))
library(dplyr)
library(lmtest)
```

这些包在本讲主要用于：

- `dplyr`：mutate以及%>%管道。
- `lmtest`：resettest、bptest。

`lm()`、`summary()`、`aov()`、`t.test()`、`cor()`、`cor.test()`和`plot()`等来自R基础/推荐自带组件，通常不需要为它们单独安装新包。

1.4 数据对象和运行顺序

- LFS示例中的`lfs`不是R预装对象。课程前几讲已完成**读取、筛选、清洗、因子转换**，这些步骤需要先执行；本教程不臆造文件路径或原始清洗代码。
- 第9讲还使用`mtcars`（R内置数据集）；第8讲第一段代码会创建虚构对象`fake_data`。
- 如果出现`object 'lfs' not found`，不是本行统计公式错了，而是尚未创建或读入`lfs`。
- 课堂输出与现在运行结果只有在使用同一份已清洗数据、相同函数设定、相容包版本时才可能完全一致。

1.5 这几类对象是什么?

- **向量（vector）**：一列同类型值，常由`c(...)`生成。
- **数据框（data.frame / tibble）**：像Excel表格，行对应观测、列对应变量。
- **函数（function）**：执行特定任务，如`mean()`求平均、`lm()`拟合回归。
- **参数（argument）**：括号里告诉函数如何工作的选项，例如`data = lfs`。
- **模型对象**：`lm(...)`运行后返回的结果，里面有系数、残差、拟合值等，不只是一个单独数字。
- **因子（factor）**：R记录分类变量的特殊类型，参照组决定类别回归系数的解释方式。

二、本讲课程代码：原文保留、逐段拆解

代码 01 | 水平-水平线性模型：mpg对车辆重量wt

原讲义位置：线性模型。

这段想做什么?

以mtcars数据集建立原始尺度的线性关系，作为之后两种对数模型的对照。

课堂原始R代码（完整保留）

```
mtcars %>% lm(mpg ~ wt, data=.) %>% summary
```

逐行讲解

1. **第1行** `mtcars %>% lm(mpg ~ wt, data=.) %>% summary`：从R内置`mtcars`汽车数据框开始管道流程。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.`中的`.`是管道传来的数据，**不是小数点或缺失值。** `~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 `lm()`拟合线性回归，括号内包括公式与数据来源。 `summary()`输出摘要；模型对象包括估计系数、标准误、t值、p值等。

把函数和统计概念拆开看

1. `mtcars`是R自带数据集，不需要先加载LFS文件。
2. `lm(mpg ~ wt, data=.)`预测燃油经济性mpg随车辆重量wt的线性变化。
3. `%>% summary`在R管道中传递模型给`summary()`方法；虽然末尾没有括号，作为右侧函数在magrittr管道中可成立。
4. 系数`wt`表示重量每增加1个mtcars重量单位（1000磅），预测mpg变化的数值。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
## Call:
## Residuals:
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  37.2851     1.8776  19.858  < 2e-16 ***
## Multiple R-squared:  0.7528, Adjusted R-squared:  0.7446
## F-statistic: 91.38 on 1 and 30 DF,  p-value: 1.294e-10
```

回归摘要读法：`Call`说明实际模型公式；`Coefficients`中`Estimate`是系数、`Std. Error`是标准误、`t value`是估计/标准误、`Pr(>|t|)`为显著性检验；`Multiple R-squared`是模型在当前因变量尺度下的解释比例。

初学者容易踩的坑 / 研究上的注意事项

保留原始代码。为方便初学者，常见等价写法是`summary(lm(mpg ~ wt, data = mtcars))`；也可以写`mtcars %>% lm(mpg ~ wt, data = .) %>% summary()`。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 02 | 半对数模型：对因变量mpg取自然对数

原讲义位置：半对数模型。

这段想做什么?

保持wt原尺度，只对mpg取对数，观察函数形式改变如何影响拟合。

课堂原始R代码（完整保留）

```
mtcars %>% mutate(log_mpg = log(mpg)) %>% lm(log_mpg ~ wt, data=.) %>% summary
```

逐行讲解

1. **第1行** `mtcars %>% mutate(log_mpg = log(mpg)) %>% lm(log_mpg ~ wt, data=.) %>% summary`：从R内置`mtcars`汽车数据框开始管道流程。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.`中的`.`是管道传来的数据，**不是小数点或缺失值。** `~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 `lm()`拟合线性回归，括号内包括公式与数据来源。 `summary()`输出摘要；模型对象包括估计系数、标准误、t值、p值等。 `mutate()`创建新数据列或覆盖现有列。 `log()`默认取自然对数；必须注意输入是否为0或负数。

把函数和统计概念拆开看

1. `mutate(log_mpg = log(mpg))`创建新列log_mpg；原数据集mtcars本身未被永久修改，因为没有赋值回去。
2. `log()`默认是自然对数（底数e），要求输入大于0。
3. `lm(log_mpg ~ wt, data=.)`解释的是**对数后的**mpg，而不是原始mpg。
4. 在半对数模型中，wt系数乘以100可近似理解为wt每增加1单位时mpg的百分比变化；更精确用`100*(exp(β)-1)`。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
## Call:
## Residuals:
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  3.83191    0.08396   45.64  < 2e-16 ***
## Multiple R-squared:  0.7976, Adjusted R-squared:  0.7908
## F-statistic: 118.2 on 1 and 30 DF,  p-value: 6.31e-12
```

回归摘要读法：`Call`说明实际模型公式；`Coefficients`中`Estimate`是系数、`Std. Error`是标准误、`t value`是估计/标准误、`Pr(>|t|)`为显著性检验；`Multiple R-squared`是模型在当前因变量尺度下的解释比例。

初学者容易踩的坑 / 研究上的注意事项

对不同尺度的因变量比较R^2要小心：对数模型的R^2解释的是log(mpg)的变异，不是原始mpg的变异。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 03 | 双对数模型：mpg和wt都取自然对数

原讲义位置：双对数模型。

这段想做什么?

把两侧变量都换到对数尺度，得到常称为log-log的模型。

课堂原始R代码（完整保留）

```
mtcars %>% mutate(log_mpg = log(mpg), log_wt = log(wt)) %>% lm(log_mpg ~ log_wt, data=.) %>% summary
```

逐行讲解

1. **第1行** `mtcars %>% mutate(log_mpg = log(mpg), log_wt = log(wt)) %>% lm(log_mpg ~ log_wt, data=.) %>% summary`：从R内置`mtcars`汽车数据框开始管道流程。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.`中的`.`是管道传来的数据，**不是小数点或缺失值。** `~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 `lm()`拟合线性回归，括号内包括公式与数据来源。 `summary()`输出摘要；模型对象包括估计系数、标准误、t值、p值等。 `mutate()`创建新数据列或覆盖现有列。 `log()`默认取自然对数；必须注意输入是否为0或负数。

把函数和统计概念拆开看

1. `mutate(log_mpg = log(mpg), log_wt = log(wt))`一次创建两列。
2. `lm(log_mpg ~ log_wt)`回归对数mpg对对数重量。
3. `log_wt`的斜率可以被理解为近似弹性：重量变动1%，mpg平均约变动β%。
4. 对数解释不能用于零值、负值；需要先理解数据编码。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
## Call:
## Residuals:
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  3.90181    0.08790   44.39  < 2e-16 ***
## Multiple R-squared:  0.8056, Adjusted R-squared:  0.7992
## F-statistic: 124.4 on 1 and 30 DF,  p-value: 3.406e-12
```

回归摘要读法：`Call`说明实际模型公式；`Coefficients`中`Estimate`是系数、`Std. Error`是标准误、`t value`是估计/标准误、`Pr(>|t|)`为显著性检验；`Multiple R-squared`是模型在当前因变量尺度下的解释比例。

初学者容易踩的坑 / 研究上的注意事项

“弹性”的百分比解读通常是局部近似；当变化较大时，可以使用模型的指数关系更精确计算。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答：“我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？”
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 04 | 观察原始线性模型的残差-拟合值图

原讲义位置：第一次回归的残差与拟合值图。

这段想做什么?

检验只用一条直线解释wt与mpg时是否仍有系统性的非线性。

课堂原始R代码（完整保留）

```
mtcars %>% lm(mpg ~ wt, data=.) %>% plot(which=1)
```

逐行讲解

1. **第1行** `mtcars %>% lm(mpg ~ wt, data=.) %>% plot(which=1)`：从R内置`mtcars`汽车数据框开始管道流程。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.`中的`.`是管道传来的数据，**不是小数点或缺失值。** `~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 `lm()`拟合线性回归，括号内包括公式与数据来源。 `plot(which=1)`为线性模型绘制残差—拟合值图。

把函数和统计概念拆开看

1. `lm(...)`先拟合模型；不能直接对原始数据框使用回归诊断`plot(which=1)`。
2. `plot(which=1)`调用lm对象的Residuals vs Fitted图。
3. 横轴是预测值、纵轴是观测值减预测值的残差。
4. 若点呈明显曲线或平滑线弯曲，说明线性形式可能漏掉结构。

课件输出怎样读?

这段课堂代码主要生成**图形**，并非打印一张数字表。应打开RStudio的Plots窗口，结合本节"逐项讲解"和"统计含义"观察坐标轴、点、曲线或Cook距离等信息。

初学者容易踩的坑 / 研究上的注意事项

某些点在零线上方表示实际mpg高于模型预测（低估）；零线下方则表示模型高估。图不能单独证明因果机制。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 05 | 观察半对数模型的残差-拟合值图

原讲义位置：第二次回归的残差与拟合值图。

这段想做什么?

在log(mpg)模型中检查残差是否比原始模型更接近没有明显结构的随机散点。

课堂原始R代码（完整保留）

```
mtcars %>% lm(log(mpg) ~ wt, data=.) %>% plot(which=1)
```

逐行讲解

1. **第1行** `mtcars %>% lm(log(mpg) ~ wt, data=.) %>% plot(which=1)`：从R内置`mtcars`汽车数据框开始管道流程。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.`中的`.`是管道传来的数据，**不是小数点或缺失值。** `~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 `lm()`拟合线性回归，括号内包括公式与数据来源。 `plot(which=1)`为线性模型绘制残差—拟合值图。 `log()`默认取自然对数；必须注意输入是否为0或负数。

把函数和统计概念拆开看

1. `log(mpg)`可直接写在公式左侧，而不一定先创建log_mpg列。
2. `lm(log(mpg) ~ wt)`拟合的是对数因变量模型。
3. `plot(which=1)`的纵轴残差现在是**对数尺度**的误差。
4. 与上一图比较形状可帮助选择更合理的函数形式。

课件输出怎样读?

这段课堂代码主要生成**图形**，并非打印一张数字表。应打开RStudio的Plots窗口，结合本节"逐项讲解"和"统计含义"观察坐标轴、点、曲线或Cook距离等信息。

初学者容易踩的坑 / 研究上的注意事项

同一张图更平坦只说明这一诊断维度可能改善，仍要检查异方差、数据异常及理论合理性。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 06 | 观察双对数模型的残差-拟合值图

原讲义位置：第三次回归的残差与拟合值图。

这段想做什么？

进一步比较对数-对数变换后的残差结构。

课堂原始R代码（完整保留）

```
mtcars %>% lm(log(mpg) ~ log(wt), data=.) %>% plot(which=1)
```

逐行讲解

1. **第1行** `mtcars %>% lm(log(mpg) ~ log(wt), data=.) %>% plot(which=1)`：从R内置`mtcars`汽车数据框开始管道流程。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.`中的`.`是管道传来的数据，**不是小数点或缺失值。** `~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 `lm()`拟合线性回归，括号内包括公式与数据来源。 `plot(which=1)`为线性模型绘制残差—拟合值图。 `log()`默认取自然对数；必须注意输入是否为0或负数。

把函数和统计概念拆开看

1. `log(wt)`直接放入公式右侧，无须创建新列。
2. 公式左侧和右侧都对数化后，残差/拟合值也在log(mpg)尺度。
3. `which=1`仍选择同一类型诊断图，便于结构比较。
4. 模型形式应结合理论、诊断及预测目标，而不只是某一张图是否美观。

课件输出怎样读？

这段课堂代码主要生成**图形**，并非打印一张数字表。应打开RStudio的Plots窗口，结合本节"逐项讲解"和"统计含义"观察坐标轴、点、曲线或Cook距离等信息。

初学者容易踩的坑 / 研究上的注意事项

双对数关系描述的是比例变化，不要把它写成"车辆增重1磅，mpg下降多少个单位"。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 07 | 对原始模型执行RESET函数形式检验

原讲义位置：线性模型的RESET检验。

这段想做什么?

用Ramsey RESET检验是否存在被线性式遗漏的系统结构。

课堂原始R代码（完整保留）

```
mtcars %>% lm(mpg ~ wt, data=.) %>% resettest()
```

逐行讲解

1. **第1行** `mtcars %>% lm(mpg ~ wt, data=.) %>% resettest()`：从R内置`mtcars`汽车数据框开始管道流程。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.`中的`.`是管道传来的数据，**不是小数点或缺失值。** `~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 `lm()`拟合线性回归，括号内包括公式与数据来源。 `resettest()`对已拟合模型作Ramsey RESET设定检验。

把函数和统计概念拆开看

1. `resettest()`来自`lmtest`包。
2. 它接收管道传来的lm模型对象。
3. 零假设大意为所使用的回归函数形式没有被该检验发现的设定偏误。
4. 输出包括RESET F统计量、自由度和p值。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
##
##  RESET test
##
## data:  .
## RESET = 5.1315, df1 = 2, df2 = 28, p-value = 0.01263
```

找`RESET`与`p-value`。若p<0.05，当前回归形式可能存在该检验能发现的设定问题；即使p>=0.05，也不等于"证明模型完全正确"。

初学者容易踩的坑 / 研究上的注意事项

原讲义的原始模型p值约0.01263，按常用0.05阈值拒绝零假设，提示原始线性形式存在值得调查的设定问题；它不直接告诉你必须用哪一种模型。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 08 | 对半对数模型执行RESET检验

原讲义位置：半对数模型的RESET检验。

这段想做什么?

检查转换因变量后，设定诊断是否改善。

课堂原始R代码（完整保留）

```
mtcars %>% mutate(log_mpg = log(mpg)) %>% lm(log_mpg ~ wt, data=.) %>%
resettest()
```

逐行讲解

1. **第1行** `mtcars %>% mutate(log_mpg = log(mpg)) %>% lm(log_mpg ~ wt, data=.) %>% resettest()`：从R内置`mtcars`汽车数据框开始管道流程。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.`中的`.`是管道传来的数据，**不是小数点或缺失值。** `~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 `lm()`拟合线性回归，括号内包括公式与数据来源。 `mutate()`创建新数据列或覆盖现有列。 `log()`默认取自然对数；必须注意输入是否为0或负数。 `resettest()`对已拟合模型作Ramsey RESET设定检验。

把函数和统计概念拆开看

1. `mutate(log_mpg = log(mpg))`先生成变换后的被解释变量。
2. 随后拟合`log_mpg ~ wt`。
3. `resettest()`检验新的回归，而非之前的模型。
4. 不同模型应比较检验及残差图，但记住因变量尺度也改变了。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
##
##  RESET test
##
## data:  .
## RESET = 1.2329, df1 = 2, df2 = 28, p-value = 0.3068
```

找`RESET`与`p-value`。若p<0.05，当前回归形式可能存在该检验能发现的设定问题；即使p>=0.05，也不等于"证明模型完全正确"。

初学者容易踩的坑 / 研究上的注意事项

讲义输出p=0.3068，不能在0.05显著性水平拒绝RESET零假设；这是"没有发现该类设定问题"的证据，不是证明模型绝对正确。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 09 | 对双对数模型执行RESET检验

原讲义位置：双对数模型的RESET检验。

这段想做什么?

检查对两个变量均取对数的模型是否呈现设定警讯。

课堂原始R代码（完整保留）

```
mtcars %>% mutate(log_mpg = log(mpg), log_wt = log(wt)) %>% lm(log_mpg ~ log_wt, data=.) %>% resettest()
```

逐行讲解

1. **第1行** `mtcars %>% mutate(log_mpg = log(mpg), log_wt = log(wt)) %>% lm(log_mpg ~ log_wt, data=.) %>% resettest()`：从R内置`mtcars`汽车数据框开始管道流程。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.`中的`.`是管道传来的数据，**不是小数点或缺失值。** `~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 `lm()`拟合线性回归，括号内包括公式与数据来源。 `mutate()`创建新数据列或覆盖现有列。 `log()`默认取自然对数；必须注意输入是否为0或负数。 `resettest()`对已拟合模型作Ramsey RESET设定检验。

把函数和统计概念拆开看

1. `mutate`同时得到log_mpg和log_wt。
2. `lm(log_mpg ~ log_wt)`在双对数尺度估计关系。
3. `resettest()`对该拟合执行设定检验。
4. 检验不显著意味着当前数据未提供足够证据拒绝相应零假设。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
##
##  RESET test
##
## data:  .
## RESET = 0.75605, df1 = 2, df2 = 28, p-value = 0.4789
```

找`RESET`与`p-value`。若p<0.05，当前回归形式可能存在该检验能发现的设定问题；即使p>=0.05，也不等于"证明模型完全正确"。

初学者容易踩的坑 / 研究上的注意事项

原讲义的双对数模型p=0.4789，也未在0.05水平拒绝零假设；并不能因此自动宣称双对数优于半对数。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 10 | 检验LFS原始工资多元模型的RESET

原讲义位置：RESET检验。

这段想做什么?

将mtcars学到的函数形式检验用于多个控制变量的LFS工资模型。

课堂原始R代码（完整保留）

```
lfs %>%
  lm(HOURPAY ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02
+ MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.) %>%
  resettest()
```

逐行讲解

1. **第1行** `lfs %>%`：从`lfs`数据框开始进入管道流程。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。
2. **第2行** `lm(HOURPAY ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02 + MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.) %>%`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.`中的`.`是管道传来的数据，**不是小数点或缺失值。** `~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 公式中的`+`表示**同时纳入**这些解释变量，并非对列做逐行算术加法。 `lm()`拟合线性回归，括号内包括公式与数据来源。
3. **第3行** `resettest()`：`resettest()`对已拟合模型作Ramsey RESET设定检验。

把函数和统计概念拆开看

1. `lfs %>%`先传入LFS数据。
2. `HOURPAY ~ SEX + AGE + ...`把性别、年龄、学历等变量纳入同一回归。
3. `data=.`使lm使用管道左边的数据。
4. `resettest()`在模型层面检查设定警讯。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
##
##  RESET test
##
## data:  .
## RESET = 123.33, df1 = 2, df2 = 7289, p-value < 2.2e-16
```

找`RESET`与`p-value`。若p<0.05，当前回归形式可能存在该检验能发现的设定问题；即使p>=0.05，也不等于"证明模型完全正确"。

初学者容易踩的坑 / 研究上的注意事项

讲义输出p值极小（小于2.2e-16），说明按该RESET检验拒绝相应零假设；不能仅凭小p值断定是哪一个解释变量出了问题。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 11 | 对LFS工资模型做Breusch–Pagan异方差检验

原讲义位置：检查模型是否存在异方差。

这段想做什么?

判断工资多元回归的残差方差是否随解释变量发生系统变化。

课堂原始R代码（完整保留）

```
lfs %>%
  lm(HOURPAY ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02
+ MARSTA + INDE07M + NSECMJ20 + GOR9D,
     data=.) %>%
 bptest()
```

逐行讲解

1. **第1行** `lfs %>%`：从`lfs`数据框开始进入管道流程。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。
2. **第2行** `lm(HOURPAY ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02 + MARSTA + INDE07M + NSECMJ20 + GOR9D,`：`~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 公式中的`+`表示**同时纳入**这些解释变量，并非对列做逐行算术加法。 `lm()`拟合线性回归，括号内包括公式与数据来源。
3. **第3行** `data=.) %>%`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.`中的`.`是管道传来的数据，**不是小数点或缺失值。**
4. **第4行** `bptest()`：`bptest()`对模型作Breusch–Pagan异方差检验。

把函数和统计概念拆开看

1. `bptest()`来自lmtest包，输入线性回归模型。
2. 零假设是同方差（残差方差恒定），对立是假设被解释变量相关的方差结构不恒定。
3. BP统计量和p值用于判断证据是否与同方差假设矛盾。
4. 由于此时RESET已经提示模型设定问题，需同时考虑函数形式和异方差。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
##
##  studentized Breusch-Pagan test
##
## data:  .
## BP = 390.68, df = 55, p-value < 2.2e-16
```

找`BP`和`p-value`。在常用5%显著性水平下，若p<0.05则拒绝"同方差"零假设，提示异方差；检验不告诉你具体修正哪一个变量。

初学者容易踩的坑 / 研究上的注意事项

原讲义BP=390.68且p值极小，提示明显异方差。异方差稳健标准误可改善常见的推断问题，但**不会自动修正函数形式错误。**

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 12 | 通过QQ图检查原始多元工资模型的残差分布

原讲义位置：残差QQ图。

这段想做什么?

查看模型残差的分位点是否接近正态分布对应的理论直线。

课堂原始R代码（完整保留）

```
lm(HOURPAY ~ SEX + AGE +  HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02 +
MARSTA + INDE07M + NSECMJ20 + GOR9D, data=lfs) %>% plot(which=2)
```

逐行讲解

1. **第1行** `lm(HOURPAY ~ SEX + AGE +  HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02 + MARSTA + INDE07M + NSECMJ20 + GOR9D, data=lfs) %>% plot(which=2)`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=lfs`明确指定从lfs表取变量。`~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 公式中的`+`表示**同时纳入**这些解释变量，并非对列做逐行算术加法。 `lm()`拟合线性回归，括号内包括公式与数据来源。 `plot(which=2)`为线性模型绘制Normal Q-Q正态分位数图。

把函数和统计概念拆开看

1. `plot(which=2)`调用lm对象的第二张内置诊断图（Normal Q-Q）。
2. 每个点比较标准化残差的经验分位点和正态分位点。
3. 偏离参考直线越明显，说明该区间越不符合简单正态分布形状。
4. QQ图显示的是分布诊断，而不是直接检验解释变量是否因果有效。

课件输出怎样读?

这段课堂代码主要生成**图形**，并非打印一张数字表。应打开RStudio的Plots窗口，结合本节"逐项讲解"和"统计含义"观察坐标轴、点、曲线或Cook距离等信息。

初学者容易踩的坑 / 研究上的注意事项

对于大样本回归，残差非正态不必然导致OLS系数不一致；推断可信度还取决于样本独立性、标准误估计和其他假设，应避免把"QQ图不直"与"所有结果无效"划等号。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 13 | 在LFS多元工资模型中拟合半对数回归

原讲义位置：半对数回归。

这段想做什么?

把因变量由工资改为log(工资)，检查变换后的模型输出。

课堂原始R代码（完整保留）

```
lfs %>% mutate(log_wage = log(HOURPAY)) %>% lm(log_wage ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02 + MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.) %>% summary
```

逐行讲解

1. **第1行** `lfs %>% mutate(log_wage = log(HOURPAY)) %>% lm(log_wage ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02 + MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.) %…`：从 `lfs` 数据框开始进入管道流程。 出现 `%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.` 中的 `.` 是管道传来的数据，**不是小数点或缺失值。** `~` 连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 公式中的 `+` 表示**同时纳入**这些解释变量，并非对列做逐行算术加法。 `lm()` 拟合线性回归，括号内包括公式与数据来源。 `summary()` 输出摘要；模型对象包括估计系数、标准误、t值、p值等。 `mutate()` 创建新数据列或覆盖现有列。 `log()` 默认取自然对数；必须注意输入是否为0或负数。

把函数和统计概念拆开看

1. `log(HOURPAY)` 使工资变为自然对数，必须排除或合理处理工资≤0的无效输入。
2. `mutate(log_wage = ...)` 在管道中的临时表生成新列。
3. `lm(log_wage ~ ...)` 将许多控制变量同时纳入模型。
4. `summary` 输出系数和模型诊断统计量；对数系数按百分比解释要注意是近似值。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
## Call:
## Residuals:
## Coefficients:
##                                                Estimate Std. Error
## (Intercept)                                   3.0115227  0.0744636
## SEXFemale                                    -0.0719738  0.0088949
## AGE                                           0.0041173  0.0004292
## HIQUL22DHigher education                     -0.1352929  0.0158525
## HIQUL22DA level or equivalent                -0.1692705  0.0111238
## HIQUL22DGCSE A*-C or equivalent              -0.2011436  0.0130428
## (Intercept)                                   40.443   < 2e-16 ***
## SEXFemale                                     -8.092 6.85e-16 ***
```

回归摘要读法：`Call`说明实际模型公式；`Coefficients`中`Estimate`是系数、`Std. Error`是标准误、`t value`是估计/标准误、`Pr(>|t|)`为显著性检验；`Multiple R-squared`是模型在当前因变量尺度下的解释比例。

初学者容易踩的坑 / 研究上的注意事项

原讲义半对数模型`SEXFemale`系数约-0.07197：在其它变量相同的线性模型语境下，该差值对应的工资水平比例约为`exp(-0.07197)-1`（约-6.9%）；这是关联分析，不自动等于因果效应。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 14 | 重新呈现原始工资尺度回归以进行比较

原讲义位置：原始回归。

这段想做什么?

老师把原始尺度模型与半对数模型并列，强调系数单位和模型评价不能混淆。

课堂原始R代码（完整保留）

```
lfs %>% lm(HOURPAY ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP +
MPNR02 + MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.) %>% summary
```

逐行讲解

1. **第1行** `lfs %>% lm(HOURPAY ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02 + MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.) %>% summary`：从`lfs`数据框开始进入管道流程。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。`data=.`中的`.`是管道传来的数据，**不是小数点或缺失值。** `~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 公式中的`+`表示**同时纳入**这些解释变量，并非对列做逐行算术加法。 `lm()`拟合线性回归，括号内包括公式与数据来源。 `summary()`输出摘要；模型对象包括估计系数、标准误、t值、p值等。

把函数和统计概念拆开看

1. `HOURPAY`没有取对数，因此系数以原始小时工资单位衡量。
2. 相同的`+`控制变量组合用于保证比较具有相近解释框架。
3. `summary`中R^2对应HOURPAY变异，与上一段log_wage的R^2不在相同因变量尺度上。
4. 输出的性别系数单位与log_wage模型不同，不能直接比较两者的数值绝对值。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
## Call:
## Residuals:
## Coefficients:
##                                                 Estimate Std. Error t
value
## (Intercept)                                     25.78853    1.98215
13.010
## SEXFemale                                       -1.78189    0.23677
-7.526
## AGE                                              0.10231    0.01142
8.956
## HIQUL22DHigher education                        -3.23076    0.42198
-7.656
## HIQUL22DA level or equivalent                   -3.85940    0.29611
-13.034
## HIQUL22DGCSE A*-C or equivalent                 -4.53640    0.34719
-13.066
## (Intercept)                                     < 2e-16 ***
## SEXFemale                                      5.87e-14 ***
```

回归摘要读法：`Call`说明实际模型公式；`Coefficients`中`Estimate`是系数、`Std. Error`是标准误、`t value`是估计/标准误、`Pr(>|t|)`为显著性检验；`Multiple R-squared`是模型在当前因变量尺度下的解释比例。

初学者容易踩的坑 / 研究上的注意事项

LFS原始模型与半对数模型的R^2差异不意味着可以在不同因变量尺度上直接按大小选赢家；要结合目标、诊断和预测评价。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答：“我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？”
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 15 | 对LFS半对数模型执行RESET检验

原讲义位置：半对数模型的RESET检验。

这段想做什么?

判断在工资取对数后，先前的函数形式警讯是否完全消失。

课堂原始R代码（完整保留）

```
lfs %>% mutate(log_wage = log(HOURPAY)) %>% lm(log_wage ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02 + MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.) %>% resettest()
```

逐行讲解

1. **第1行** `lfs %>% mutate(log_wage = log(HOURPAY)) %>% lm(log_wage ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02 + MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.) %…`：从 `lfs` 数据框开始进入管道流程。 出现 `%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.` 中的 `.` 是管道传来的数据，**不是小数点或缺失值。** `~` 连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 公式中的 `+` 表示**同时纳入**这些解释变量，并非对列做逐行算术加法。 `lm()` 拟合线性回归，括号内包括公式与数据来源。 `mutate()` 创建新数据列或覆盖现有列。 `log()` 默认取自然对数；必须注意输入是否为0或负数。 `resettest()` 对已拟合模型作Ramsey RESET设定检验。

把函数和统计概念拆开看

1. `mutate(log_wage = log(HOURPAY))` 构造对数工资。
2. `lm(log_wage ~ ...)` 是半对数多元模型。
3. `resettest()` 继续检验设定。
4. p值比较应注意样本量大时很小的偏差也可能被检出。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
##
##  RESET test
##
## data:  .
## RESET = 52.408, df1 = 2, df2 = 7289, p-value < 2.2e-16
```

找 `RESET` 与 `p-value`。若p<0.05，当前回归形式可能存在该检验能发现的设定问题；即使p>=0.05，也不等于"证明模型完全正确"。

初学者容易踩的坑 / 研究上的注意事项

课件p值仍小于2.2e-16，所以半对数变换虽然可能改善某些残差特征，却**没有通过本次RESET检验。**

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 16 | 对LFS半对数模型执行BP异方差检验

原讲义位置：半对数模型的BP检验。

这段想做什么?

看工资取对数后异方差是否仍存在。

课堂原始R代码（完整保留）

```
lfs %>% mutate(log_wage = log(HOURPAY)) %>%
  lm(log_wage ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02
+ MARSTA + INDE07M + NSECMJ20 + GOR9D,
     data=.) %>%
  bptest()
```

逐行讲解

1. **第1行** `lfs %>% mutate(log_wage = log(HOURPAY)) %>%`：从 `lfs` 数据框开始进入管道流程。出现 `%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `mutate()` 创建新数据列或覆盖现有列。 `log()` 默认取自然对数；必须注意输入是否为0或负数。
2. **第2行** `lm(log_wage ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02 + MARSTA + INDE07M + NSECMJ20 + GOR9D,`：`~` 连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 公式中的 `+` 表示**同时纳入**这些解释变量，并非对列做逐行算术加法。 `lm()` 拟合线性回归，括号内包括公式与数据来源。
3. **第3行** `data=.) %>%`：出现 `%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.` 中的 `.` 是管道传来的数据，**不是小数点或缺失值。**
4. **第4行** `bptest()`：`bptest()` 对模型作Breusch–Pagan异方差检验。

把函数和统计概念拆开看

1. `mutate()` 先生成对数工资。
2. `lm(...)` 拟合多变量半对数模型。
3. `bptest()` 检验残差方差是否恒定。
4. 对数变换可能降低异方差程度，但不保证完全消除。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
##
##  studentized Breusch-Pagan test
##
## data:  .
## BP = 356.74, df = 55, p-value < 2.2e-16
```

找 `BP` 和 `p-value`。在常用5%显著性水平下，若p<0.05则拒绝“同方差”零假设，提示异方差；检验不告诉你具体修正哪一个变量。

初学者容易踩的坑 / 研究上的注意事项

课件BP=356.74，p值仍小于2.2e-16，提示该模型仍拒绝同方差零假设；接下来第10讲继续修改模型并讨论稳健标准误。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答：“我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？”

- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

三、按课堂顺序串起来：这一讲完整分析流程

三类回归形式（逐个变量理解）

1. **水平—水平（level-level）**：`y ~ x`。β表示x增加1单位时，y的预测值变化β个**原单位**。
2. **对数—水平（log-level）**：`log(y) ~ x`。x增加1单位，y的比例变化精确为`exp(β)-1`，百分比为`100*(exp(β)-1)`；β较小时约为`100*β%`。
3. **对数—对数（log-log）**：`log(y) ~ log(x)`。β是局部弹性：x增加约1%，y变化约β%。
4. **R^2不可跨不同因变量尺度直接比大小**：模型解释`y`还是`log(y)`，总变异不同。
5. **检验问题不同**：`resettest()`找某些设定偏误；`bptest()`检验残差异方差；`plot(which=2)`观察正态分位数偏离。三者不能互相代替。
6. **对数定义域**：`log(0)=-Inf`，负数取log在实数范围无定义。正式清洗时要记录删去或重新定义的样本，不要偷偷用`log(y+1)`改变研究对象。

需要记住的完整逻辑

1. 先比较汽车数据的三种尺度：原始、半对数、双对数。
2. 通过残差图了解为何一种函数形式可能更符合数据。
3. 用RESET检查设定问题，使用BP检验异方差。
4. 返回LFS工资多元模型，尝试对数变换、QQ图和再次检验。
5. 区分“诊断有所改善”和“模型所有假设都满足”。

四、函数与参数速查表

函数/运算符	用来做什么	使用时先检查什么
`lm()`	拟合普通最小二乘线性回归模型	输入是什么类型？缺失值和参考组怎么处理？
`summary()`	根据对象类型给出统计摘要；lm对象显示系数、标准误、p值和拟合统计量	输入是什么类型？缺失值和参考组怎么处理？
`plot()`	根据输入对象类型绘制图形；用于lm时有内置回归诊断图	输入是什么类型？缺失值和参考组怎么处理？
`log()`	默认计算自然对数ln(x)，仅对正数有有限实数值	输入是什么类型？缺失值和参考组怎么处理？
`mutate()`	对数据框添加新列或修改已有列	输入是什么类型？缺失值和参考组怎么处理？
`resettest()`	Ramsey RESET模型设定检验，来自lmtest	输入是什么类型？缺失值和参考组怎么处理？
`bptest()`	Breusch–Pagan异方差检验，来自lmtest	输入是什么类型？缺失值和参考组怎么处理？

函数/运算符	用来做什么	使用时先检查什么
`%>%`	管道符：把左边结果交给右边函数，便于从左到右阅读操作顺序	这里是回归公式、比较表达式还是普通计算？
`~`	模型/检验公式分隔符：在回归中通常左边是结果变量，右边是解释变量	这里是回归公式、比较表达式还是普通计算？
`+`	回归公式里的加号表示**纳入多个解释变量**，不是把它们逐行数值相加	这里是回归公式、比较表达式还是普通计算？
`data=.`	点号`.`指管道前一步传过来的对象；明确告诉回归函数用哪个数据框	这里是回归公式、比较表达式还是普通计算？

五、本讲用到的变量：名字不是它们的中文意思

原变量名	根据本系列讲义能够确认/需要核对的含义
`HOURPAY`	小时工资（此系列课程LFS示例中的因变量）
`SEX`	性别分组
`AGE`	年龄（数值变量）
`HIQUL22D`	最高资格 / 学历水平（分类变量）
`FLEX22W6`	灵活工作安排相关变量（准确类别见数据字典）
`FTPT`	全职 / 兼职
`EMPLEN`	就业年限或工作持续时间相关变量（按数据字典核实）
`JOBTYP`	工作类型
`MPNR02`	LFS其他解释变量（请以原始数据字典确认编码含义）
`MARSTA`	婚姻状况
`INDE07M`	行业分类
`NSECMJ20`	社会经济分类
`GOR9D`	地理区域分组
`log_wage`	小时工资的自然对数
`mtcars`	R自带的汽车示例数据集
`mpg`	每加仑燃油可行驶的英里数
`wt`	车辆重量（mtcars数据集中的单位是1000磅）
`log_mpg`	每加仑英里数的自然对数
`log_wt`	汽车重量的自然对数

> **避免误译**：LFS数据的编码与变量类别需以课程使用的变量说明、元数据和预处理后的`levels()`为准。上表中对含义不明确的字段明确提示了"需要数据字典核实"，没有强行猜测。

六、初学者常见错误与排查顺序

1. **object not found（对象不存在）**：确认是否先创建了`lfs`或`fake_data`，或前一步的`select()`是否把变量删掉。
2. **could not find function（找不到函数）**：确认是否安装并`library()`了相应包。
3. **unexpected symbol / unexpected end of input（语法错误）**：检查括号、引号、逗号和前一行末尾的`%>%`是否完整。
4. **missing values / NA / -Inf**：统计函数遇到`NA`或`log(0)`会出问题，正式分析需遵循数据字典及清洗记录。
5. **contrasts can be applied only to factors with 2 or more levels**：筛选样本后某个分类变量可能只剩一类，需要检查`table()`或`levels()`。
6. **课程输出与自己不同**：先比较数据版本、样本行数、变量类型、参考组、缺失处理和包版本，不要立即修改统计模型去"凑数"。
7. **统计显著误当成因果关系**：观察数据中的关联仍可能受未观测因素影响，报告必须诚实描述限制。

七、课后练习：自己独立运行，别只看解释

练习 1 | 模型形式

写出水平—水平、半对数、双对数三种公式，解释系数单位。

建议提交的自查结果：贴上所运行的代码、关键输出，并用自己的中文解释观察到的变化。

练习 2 | 诊断检验

把mtcars三个RESET的p值整理成三行表，并注意"不拒绝"不等于"模型已证实正确"。

建议提交的自查结果：贴上所运行的代码、关键输出，并用自己的中文解释观察到的变化。

练习 3 | 对数限制

在玩具数据`c(10, 0, -1)`上运行`log()`，解释输出与为什么必须提前清洗。

建议提交的自查结果：贴上所运行的代码、关键输出，并用自己的中文解释观察到的变化。

八、读完本讲，能否回答下面5个问题?

1. 上面的课堂代码中，哪些是**原始数据框**，哪些是处理后产生的新对象?
2. `%>%`、`~`、`data=.`分别在代码中起什么作用?
3. 这讲最重要的**模型或统计检验的原假设**是什么？输出中哪个部分告诉你结果?
4. 如果你只把一个参数改掉，图形/估计会如何变化？为什么?
5. 这个方法能不能直接证明因果关系？若不能，还需要什么研究设计或额外前提?

编写说明：教程中的"课堂原始R代码"均直接提取自`lecture9_notes.html`；数值输出摘录也来自该文件，未声称重新计算。对语法、注意事项和练习的解释属于**额外教学补充。**这不是翻译版课件的替代品；建议并排打开本教程和`lecture9_notes_中文版.html`核对原始图表、文字与结果。