Lecture 10 | VIF多重共线性、模型迭代、分类重编码及稳健标准误——R语言完全零基础逐行代码教程

> **课程**：URBAN5127 Quantitative Data Analysis | **来源**：`lecture10_notes.html`（课堂原始讲义）与对应中文版。
> **读者**：没有编程经验、正在学习R/RStudio的初学者。**方法**：保持讲义全部课堂R代码原样，逐行解释，再用独立标注的教学补充帮助理解。

〇、先认识这一讲：VIF多重共线性、模型迭代、分类重编码及稳健标准误

这一讲从前一讲的LFS多元工资回归继续，检查共线性、设定及异方差，逐步删减和重编码变量，并改用异方差稳健标准误进行推断。

读完应当会：

1. VIF与GVIF。
2. 比较不同模型的RESET与BP检验。
3. 模型变量删减。
4. case_when分类重编码。
5. 因子参照组的更换。
6. coeftest与vcovHC稳健标准误。

原始代码的覆盖范围

- 英文原始HTML中识别到 **12段真正的课堂R代码（`pre.r`）**；下文每一段完整按原顺序出现，**不省略或替换原始代码。**
- HTML中的黑色 `## ...` 控制台打印是**运行结果**，不能把它当成要重新输入的R命令；网页的JavaScript/CSS也不是本课R代码。
- 如果相同代码在不同位置重复出现，教程仍按原讲义顺序保留并解释其教学目的。

一、先修知识：即使从来没写过代码也能看懂

1.1 R / RStudio到底是什么?

R是一种用于统计分析的编程语言；RStudio是帮助你编辑、运行、检查R程序的工作界面。**R语言**决定代码含义，**RStudio**提供Source（脚本编辑器）、Console（即时运行）、Environment（查看对象）、Plots（看图）等窗口。
建议先创建一个`.R`脚本，将本教程中的每段原始代码逐段粘贴进去；在RStudio中选中一行或几行按Ctrl+Enter（Windows）或Cmd+Enter（macOS）运行。不要一次性运行全部章节：有些讲义代码依赖之前做过的数据处理。

1.2 把R代码当成一句完整的话来阅读

写法	初学者的读法	常见误解
`x <- ...`	把右边结果保存到x	以为 `<-` 是小于号
`f(x, y)`	调用函数f，把x和y作为参数	以为所有括号都在做数学乘法
`data = lfs`	指定数据对象	以为这里是把变量赋值给lfs
`df$AGE`	从df里抽取AGE这一列	以为 `$` 有货币意义
`a %>% b()`	先做a，再把结果交给b	与ggplot的图层加号 `+` 混淆
`y ~ x1 + x2`	用x1、x2共同解释y	把公式中的 `+` 当成数值求和
`"Female"`	这是**字符串文字**	误以为是变量名
`TRUE` 与 `FALSE`	布尔值/逻辑值	与文字 `"TRUE"` 混淆
`# ...`	注释，对运行结果无影响	把注释当成一定会运行的代码
`<`、`==`	分别表示小于、是否相等	把 `==` 与赋值符混淆

如果一行很长，先找最外层函数，再拆成“传入的数据→做了什么→返回什么”；碰到多层括号，从**最里面的函数**开始理解。

1.3 第一次运行前，需要准备哪些包?

初学者先区分：**安装（install.packages）只需通常做一次，载入（library）在每次新R会话中可能要再执行。**下方是**教学补充**，不是原课件代码：

```
# 第一次使用且尚未安装时，去掉下面一行行首的 # 并运行
# install.packages(c("dplyr", "car", "lmtest", "sandwich"))
library(dplyr)
library(car)
library(lmtest)
library(sandwich)
```

这些包在本讲主要用于：

- `dplyr`：mutate、case_when、relevel用base::stats、%>%管道。
- `car`：vif。
- `lmtest`：resettest、bptest、coeftest。
- `sandwich`：vcovHC。

`lm()`、`summary()`、`aov()`、`t.test()`、`cor()`、`cor.test()`和`plot()`等来自R基础/推荐自带组件，通常不需要为它们单独安装新包。

1.4 数据对象和运行顺序

- LFS示例中的`lfs`不是R预装对象。课程前几讲已完成**读取、筛选、清洗、因子转换**，这些步骤需要先执行；本教程不臆造文件路径或原始清洗代码。
- 第9讲还使用`mtcars`（R内置数据集）；第8讲第一段代码会创建虚构对象`fake_data`。
- 如果出现`object 'lfs' not found`，不是本行统计公式错了，而是尚未创建或读入`lfs`。
- 课堂输出与现在运行结果只有在使用同一份已清洗数据、相同函数设定、相容包版本时才可能完全一致。

1.5 这几类对象是什么?

- **向量（vector）**：一列同类型值，常由`c(...)`生成。
- **数据框（data.frame / tibble）**：像Excel表格，行对应观测、列对应变量。
- **函数（function）**：执行特定任务，如`mean()`求平均、`lm()`拟合回归。
- **参数（argument）**：括号里告诉函数如何工作的选项，例如`data = lfs`。
- **模型对象**：`lm(...)`运行后返回的结果，里面有系数、残差、拟合值等，不只是一个单独数字。
- **因子（factor）**：R记录分类变量的特殊类型，参照组决定类别回归系数的解释方式。

二、本讲课程代码：原文保留、逐段拆解

代码 01 | 估计多元工资模型的广义方差膨胀因子GVIF

原讲义位置：模型的VIF值。

这段想做什么?

通过car包的`vif()`检查多个解释变量是否存在较严重的线性相关性问题。

课堂原始R代码（完整保留）

```
lfs %>% mutate(log_wage = log(HOURPAY)) %>%
  lm(log_wage ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02
+ MARSTA + INDE07M + NSECMJ20 + GOR9D,
     data=.) %>%
 vif()
```

逐行讲解

1. **第1行** `lfs %>% mutate(log_wage = log(HOURPAY)) %>%`：从`lfs`数据框开始进入管道流程。出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `mutate()`创建新数据列或覆盖现有列。 `log()`默认取自然对数；必须注意输入是否为0或负数。
2. **第2行** `lm(log_wage ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02 + MARSTA + INDE07M + NSECMJ20 + GOR9D,`：`~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 公式中的`+`表示**同时纳入**这些解释变量，并非对列做逐行算术加法。 `lm()`拟合线性回归，括号内包括公式与数据来源。
3. **第3行** `data=.) %>%`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.`中的`.`是管道传来的数据，**不是小数点或缺失值**。
4. **第4行** `vif()`：`vif()`计算（广义）方差膨胀因子，检视解释变量共线性。

把函数和统计概念拆开看

1. `mutate(log_wage = log(HOURPAY))` 建立对数工资。
2. `lm(...)` 拟合包括性别、年龄、教育、地区等的多元线性回归。
3. `vif()` 来自 `car` 包，对连续项通常显示VIF，对多自由度分类项往往显示GVIF及调整指标。
4. `GVIF^(1/(2*Df))` 用于对不同自由度的因子项进行尺度调整；不能直接把原始GVIF与简单VIF的阈值机械比较。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
##              GVIF Df GVIF^(1/(2*Df))
## SEX      1.249367  1        1.117751
## AGE      1.682555  1        1.297133
## HIQUL22D 1.609476  5        1.048741
## FLEX22W6 1.124745  1        1.060540
## FTPT     1.266411  1        1.125349
## EMPLEN   1.431578  7        1.025958
## JOBTYP   1.122614  1        1.059535
## MPNR02   1.269364  8        1.015019
## MARSTA   1.432800  5        1.036618
## INDE07M  1.668301  8        1.032505
## NSECMJ20 2.151890  6        1.065946
## GOR9D    1.190306 11        1.007950
```

观察多自由度因子项时优先看 `Df` 与调整后的 `GVIF^(1/(2*Df))`，不要把不同维数的原始GVIF数字直接机械比大小。

初学者容易踩的坑 / 研究上的注意事项

课件讲到VIF=1表示没有方差膨胀、5和10是常见经验参照，但不是严格定律。看共线性要结合系数标准误、理论、变量编码和研究目的。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 02 | 重新检验原始工资模型的RESET

原讲义位置：RESET检验。

这段想做什么?

作为模型修改之前的函数形式基线测试。

课堂原始R代码（完整保留）

```
lfs %>%
  lm(HOURPAY ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02
+ MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.) %>%
  resettest()
```

逐行讲解

1. **第1行** `lfs %>%`：从`lfs`数据框开始进入管道流程。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。
2. **第2行** `lm(HOURPAY ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02 + MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.) %>%`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.`中的`.`是管道传来的数据，**不是小数点或缺失值。** `~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 公式中的`+`表示**同时纳入**这些解释变量，并非对列做逐行算术加法。 `lm()`拟合线性回归，括号内包括公式与数据来源。
3. **第3行** `resettest()`：`resettest()`对已拟合模型作Ramsey RESET设定检验。

把函数和统计概念拆开看

1. 因变量仍是`HOURPAY`。
2. 解释变量包含`EMPLEN`以及一系列分类和连续控制变量。
3. `resettest()`对这一具体模型运行，任何调整模型形式都要重新检验。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
##
##  RESET test
##
## data:  .
## RESET = 123.33, df1 = 2, df2 = 7289, p-value < 2.2e-16
```

找`RESET`与`p-value`。若p<0.05，当前回归形式可能存在该检验能发现的设定问题；即使p>=0.05，也不等于"证明模型完全正确"。

初学者容易踩的坑 / 研究上的注意事项

输出RESET=123.33、p值极小；提示原始回归设定需要重新审视。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 03 | 重新检验原始工资模型的BP异方差

原讲义位置：BP检验。

这段想做什么?

建立修改之前的异方差检验基线。

课堂原始R代码（完整保留）

```
lfs %>%
  lm(HOURPAY ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02
+ MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.) %>%
  bptest()
```

逐行讲解

1. **第1行** `lfs %>%`：从`lfs`数据框开始进入管道流程。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。
2. **第2行** `lm(HOURPAY ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02 + MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.) %>%`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.`中的`.`是管道传来的数据，**不是小数点或缺失值。** `~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 公式中的`+`表示**同时纳入**这些解释变量，并非对列做逐行算术加法。 `lm()`拟合线性回归，括号内包括公式与数据来源。
3. **第3行** `bptest()`： `bptest()`对模型作Breusch–Pagan异方差检验。

把函数和统计概念拆开看

1. `bptest()`用回归残差进行同方差检验。
2. `BP`越大通常对零假设越不利，但判断必须结合自由度/p值。
3. 同一模型的RESET和BP针对不同假设，两种p值不能混为一谈。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
##
##  studentized Breusch-Pagan test
##
## data:  .
## BP = 390.68, df = 55, p-value < 2.2e-16
```

找`BP`和`p-value`。在常用5%显著性水平下，若p<0.05则拒绝“同方差”零假设，提示异方差；检验不告诉你具体修正哪一个变量。

初学者容易踩的坑 / 研究上的注意事项

输出BP=390.68、p值极小，原模型出现异方差警讯。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。

- 用一句话回答：“我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？”
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 04 | 半对数工资模型的RESET复查

原讲义位置：RESET检验。

这段想做什么？

把原始工资换成对数工资，重新检测模型设定。

课堂原始R代码（完整保留）

```
lfs %>%
  mutate(log_wage = log(HOURPAY)) %>%
  lm(log_wage ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02
+ MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.)  %>%
  resettest()
```

逐行讲解

1. **第1行** `lfs %>%`：从`lfs`数据框开始进入管道流程。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。
2. **第2行** `mutate(log_wage = log(HOURPAY)) %>%`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `mutate()`创建新数据列或覆盖现有列。 `log()`默认取自然对数；必须注意输入是否为0或负数。
3. **第3行** `lm(log_wage ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02 + MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.)  %>%`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.`中的`.`是管道传来的数据，**不是小数点或缺失值**。 `~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 公式中的`+`表示**同时纳入**这些解释变量，并非对列做逐行算术加法。 `lm()`拟合线性回归，括号内包括公式与数据来源。
4. **第4行** `resettest()`： `resettest()`对已拟合模型作Ramsey RESET设定检验。

把函数和统计概念拆开看

1. `log_wage`是由`log(HOURPAY)`生成的**新因变量**。
2. 控制变量组合此时尚未删减。
3. `resettest()`检验的是该半对数形式，不是原始工资形式。

课件输出怎样读？

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
##
##  RESET test
##
## data:  .
## RESET = 52.408, df1 = 2, df2 = 7289, p-value < 2.2e-16
```

找`RESET`与`p-value`。若p<0.05，当前回归形式可能存在该检验能发现的设定问题；即使p>=0.05，也不等于“证明模型完全正确”。

初学者容易踩的坑 / 研究上的注意事项

输出RESET=52.408、p值极小：统计量数值下降并不自动证明“设定已解决”，因为仍显著。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答：“我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？”
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 05 | 半对数工资模型的BP复查

原讲义位置：BP检验。

这段想做什么?

检测原始全变量半对数模型的异方差。

课堂原始R代码（完整保留）

```
lfs %>%
  mutate(log_wage = log(HOURPAY)) %>%
  lm(log_wage ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02
+ MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.)  %>%
  bptest()
```

逐行讲解

1. **第1行** `lfs %>%`：从`lfs`数据框开始进入管道流程。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。
2. **第2行** `mutate(log_wage = log(HOURPAY)) %>%`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `mutate()`创建新数据列或覆盖现有列。 `log()`默认取自然对数；必须注意输入是否为0或负数。
3. **第3行** `lm(log_wage ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + EMPLEN + JOBTYP + MPNR02 + MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.)  %>%`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.`中的`.`是管道传来的数据，**不是小数点或缺失值。** `~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 公式中的`+`表示**同时纳入**这些解释变量，并非对列做逐行算术加法。 `lm()`拟合线性回归，括号内包括公式与数据来源。
4. **第4行** `bptest()`： `bptest()`对模型作Breusch–Pagan异方差检验。

把函数和统计概念拆开看

1. `bptest()`检验同方差原假设。
2. 样本量和模型项可能影响检验统计量，因此不宜仅比较BP数值大小。
3. 变换后的工资系数与原始模型单位不同。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
##
##  studentized Breusch-Pagan test
##
## data:  .
## BP = 356.74, df = 55, p-value < 2.2e-16
```

找`BP`和`p-value`。在常用5%显著性水平下，若p<0.05则拒绝"同方差"零假设，提示异方差；检验不告诉你具体修正哪一个变量。

初学者容易踩的坑 / 研究上的注意事项

输出BP=356.74、p值极小：仍提示异方差。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 06 | 删除EMPLEN之后的半对数模型RESET

原讲义位置：RESET检验。

这段想做什么?

观察移除一项解释变量后的设定检验结果。

课堂原始R代码（完整保留）

```
lfs %>%
  mutate(log_wage = log(HOURPAY)) %>%
  lm(log_wage ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + JOBTYP + MPNR02 + MARSTA
+ INDE07M + NSECMJ20 + GOR9D, data=.)  %>%
  resettest()
```

逐行讲解

1. **第1行** `lfs %>%`：从`lfs`数据框开始进入管道流程。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。
2. **第2行** `mutate(log_wage = log(HOURPAY)) %>%`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `mutate()`创建新数据列或覆盖现有列。 `log()`默认取自然对数；必须注意输入是否为0或负数。
3. **第3行** `lm(log_wage ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + JOBTYP + MPNR02 + MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.)  %>%`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.`中的`.`是管道传来的数据，**不是小数点或缺失值。** `~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 公式中的`+`表示**同时纳入**这些解释变量，并非对列做逐行算术加法。 `lm()`拟合线性回归，括号内包括公式与数据来源。
4. **第4行** `resettest()`：`resettest()`对已拟合模型作Ramsey RESET设定检验。

把函数和统计概念拆开看

1. 与前一组模型比较，回归公式中**移除了**`EMPLEN`。

2. 其余控制变量继续保留。
3. 重新拟合后通过管道对新对象进行RESET检验。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
##
##  RESET test
##
## data:  .
## RESET = 52.253, df1 = 2, df2 = 7296, p-value < 2.2e-16
```

找`RESET`与`p-value`。若p<0.05，当前回归形式可能存在该检验能发现的设定问题；即使p>=0.05，也不等于"证明模型完全正确"。

初学者容易踩的坑 / 研究上的注意事项

输出RESET=52.253、p值仍极小：删减一个变量不意味着模型必然改善。删减应有理论或诊断依据，注意遗漏变量偏误。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 07 | 删除EMPLEN之后的BP检验

原讲义位置：BP检验。

这段想做什么?

观察删减模型对残差异方差诊断的影响。

课堂原始R代码（完整保留）

```
lfs %>%
  mutate(log_wage = log(HOURPAY)) %>%
  lm(log_wage ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + JOBTYP + MPNR02 + MARSTA
+ INDE07M + NSECMJ20 + GOR9D, data=.)  %>%
  bptest()
```

逐行讲解

1. **第1行** `lfs %>%`：从`lfs`数据框开始进入管道流程。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。
2. **第2行** `mutate(log_wage = log(HOURPAY)) %>%`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `mutate()`创建新数据列或覆盖现有列。 `log()`默认取自然对数；必须注意输入是否为0或负数。

3. **第3行** `lm(log_wage ~ SEX + AGE + HIQUL22D + FLEX22W6 + FTPT + JOBTYP + MPNR02 + MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.) %>%`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。`data=.`中的`.`是管道传来的数据，**不是小数点或缺失值。**`~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 公式中的`+`表示**同时纳入**这些解释变量，并非对列做逐行算术加法。`lm()`拟合线性回归，括号内包括公式与数据来源。
4. **第4行** `bptest()`：`bptest()`对模型作Breusch–Pagan异方差检验。

把函数和统计概念拆开看

1. 回归里仍然没有`EMPLEN`。
2. `bptest()`在新拟合残差上运行。
3. BP输出自由度和上一个全变量模型可能不同，因为自变量项变化。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
##
##  studentized Breusch-Pagan test
##
## data:  .
## BP = 341.84, df = 48, p-value < 2.2e-16
```

找`BP`和`p-value`。在常用5%显著性水平下，若p<0.05则拒绝"同方差"零假设，提示异方差；检验不告诉你具体修正哪一个变量。

初学者容易踩的坑 / 研究上的注意事项

输出BP=341.84、p值仍极小，同方差假设仍被拒绝。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 08 | 把婚姻状况重编码成更少类别

原讲义位置：创建新变量。

这段想做什么?

合并婚姻状况类别，学习`case_when()`如何从原变量生成新变量并设置参考组。

课堂原始R代码（完整保留）

```r
lfs <- lfs %>%
  mutate(new_MARSTA = case_when(
    MARSTA == "Married, living with spouse" ~ "Married",
    MARSTA == "Divorced" ~ "Divorced",
    TRUE ~ "Other") %>%
      factor() %>%
      relevel(ref = "Other")
    )
```

逐行讲解

1. **第1行** `lfs <- lfs %>%`：赋值：用`<-`将右侧结果保存到`lfs`。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。
2. **第2行** `mutate(new_MARSTA = case_when(`：`mutate()`创建新数据列或覆盖现有列。`case_when()`按条件顺序给每行数据指定新类别。 `new_MARSTA`是前面重编码后的婚姻状况，执行前要确认它已存在。
3. **第3行** `MARSTA == "Married, living with spouse" ~ "Married",`：`==`判断原始婚姻状态是否**等于**某一标签，`~`右侧是满足条件时的输出标签。
4. **第4行** `MARSTA == "Divorced" ~ "Divorced",`：`==`判断原始婚姻状态是否**等于**某一标签，`~`右侧是满足条件时的输出标签。
5. **第5行** `TRUE ~ "Other") %>%`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。`TRUE ~ "Other"`兜底：没有匹配前面条件的观测将标为Other。
6. **第6行** `factor() %>%`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。`factor()`将文字类别转换为R的因子类型。
7. **第7行** `relevel(ref = "Other")`：`relevel()`将指定因子水平设为参考类别，影响回归系数相对谁计算。
8. **第8行** `)`：本行继续或结束上一行的函数参数/括号；R通过括号判断完整表达式。

把函数和统计概念拆开看

1. `lfs <- lfs %>%`会把处理后的数据框**赋值回**lfs（真正改变当前对象）。
2. `case_when()`按条件从上往下匹配，输出字符串“Married”“Divorced”“Other”。
3. `MARSTA == "..."`中`==`是比较是否相等，不是赋值。
4. `TRUE ~ "Other"`是兜底分支，匹配之前所有未符合条件的行，包括可能需要另行核查的缺失或未知编码。
5. `factor()`把字符串组变成分类因子；`relevel(ref = "Other")`把Other设为基准类别。

课件输出怎样读?

此代码主要**创建/修改对象**，默认可能不打印结果。可运行`names(lfs)`、`head(lfs)`或`str(fake_data)`（根据本段对象）检查执行效果。

初学者容易踩的坑 / 研究上的注意事项

讲义文字提到减少至两级，但实际代码生成**三个类别**（Married、Divorced、Other），应以代码为准。新变量会改变参照组和回归系数解释，不能无记录地改变变量定义。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。

- 用一句话回答：“我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？”
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 09 | 重新设置行业变量INDE07M的参照类别

原讲义位置：更改行业变量的参照组。

这段想做什么？

将行业因子的参考类别改成“Public admin, education and health”。

课堂原始R代码（完整保留）

```
lfs <- lfs %>%
  mutate(INDE07M = relevel(INDE07M, ref = "Public admin, education and health"))
```

逐行讲解

1. **第1行** `lfs <- lfs %>%`：赋值：用`<-`将右侧结果保存到`lfs`。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。
2. **第2行** `mutate(INDE07M = relevel(INDE07M, ref = "Public admin, education and health"))`：`mutate()`创建新数据列或覆盖现有列。 `relevel()`将指定因子水平设为参考类别，影响回归系数相对谁计算。

把函数和统计概念拆开看

1. `mutate(INDE07M = ...)`覆盖当前数据框中同名的INDE07M列。
2. `relevel()`仅适用于因子；如果当前变量是字符型，应先`factor()`。
3. `ref = "Public admin, education and health"`要求该字符串与实际因子水平**完全一致**。
4. 改变参照组会改变截距和各分类系数的比较对象，一般不会改变同一模型的总体拟合值。

课件输出怎样读？

此代码主要**创建/修改对象**，默认可能不打印结果。可运行`names(lfs)`、`head(lfs)`或`str(fake_data)`（根据本段对象）检查执行效果。

初学者容易踩的坑 / 研究上的注意事项

课件说明原先行业参考组过小，所以改用一个更合适、更容易解释的行业类别；这属于可解释性调整，不意味着统计结果凭空更可信。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答：“我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？”
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 10 | 使用年龄组AGES与重编码婚姻状态的新回归做RESET

原讲义位置：RESET检验。

这段想做什么?

在模型中用`AGES`而不是连续`AGE`，加入`new_MARSTA`，并对新的控制变量组合做设定检验。

课堂原始R代码（完整保留）

```
lfs %>%
  mutate(log_wage = log(HOURPAY)) %>%
  lm(log_wage ~ SEX + AGES + HIQUL22D + FTPT + JOBTYP + MPNR02 + new_MARSTA +
INDE07M + NSECMJ20 + GOR9D, data=.) %>%
  resettest()
```

逐行讲解

1. **第1行** `lfs %>%`：从`lfs`数据框开始进入管道流程。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。
2. **第2行** `mutate(log_wage = log(HOURPAY)) %>%`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `mutate()`创建新数据列或覆盖现有列。 `log()`默认取自然对数；必须注意输入是否为0或负数。
3. **第3行** `lm(log_wage ~ SEX + AGES + HIQUL22D + FTPT + JOBTYP + MPNR02 + new_MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.) %>%`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.`中的`.`是管道传来的数据，**不是小数点或缺失值。** `~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 公式中的`+`表示**同时纳入**这些解释变量，并非对列做逐行算术加法。 `lm()`拟合线性回归，括号内包括公式与数据来源。 `AGES`是年龄分组变量，不应与连续年龄`AGE`等同。 `new_MARSTA`是前面重编码后的婚姻状况，执行前要确认它已存在。
4. **第4行** `resettest()`：`resettest()`对已拟合模型作Ramsey RESET设定检验。

把函数和统计概念拆开看

1. 公式内从`AGE`改为`AGES`：需要确认`AGES`在数据中已存在并是期望的类型。
2. 婚姻状态使用第8段新生成的`new_MARSTA`。
3. 模型不再含`EMPLEN`和`FLEX22W6`，但保留其他变量。
4. `resettest()`检查改进后模型是否仍存在整体设定警讯。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
##
##  RESET test
##
## data:  .
## RESET = 90.25, df1 = 2, df2 = 7292, p-value < 2.2e-16
```

找`RESET`与`p-value`。若p<0.05，当前回归形式可能存在该检验能发现的设定问题；即使p>=0.05，也不等于"证明模型完全正确"。

初学者容易踩的坑 / 研究上的注意事项

课件输出RESET=90.25、p值仍极小；注意模型样本、变量维数变化可能影响数值，不能只比较统计量大小下结论。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 11 | 对包含AGES与new_MARSTA的模型做BP检验

原讲义位置：BP检验。

这段想做什么?

检验最新模型残差是否同方差。

课堂原始R代码（完整保留）

```
lfs %>%
  mutate(log_wage = log(HOURPAY)) %>%
  lm(log_wage ~ SEX + AGES + HIQUL22D + FTPT + JOBTYP + MPNR02 + new_MARSTA +
INDE07M + NSECMJ20 + GOR9D, data=.)  %>%
  bptest()
```

逐行讲解

1. **第1行** `lfs %>%`：从`lfs`数据框开始进入管道流程。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。
2. **第2行** `mutate(log_wage = log(HOURPAY)) %>%`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `mutate()`创建新数据列或覆盖现有列。 `log()`默认取自然对数；必须注意输入是否为0或负数。
3. **第3行** `lm(log_wage ~ SEX + AGES + HIQUL22D + FTPT + JOBTYP + MPNR02 + new_MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.)  %>%`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.`中的`.`是管道传来的数据，**不是小数点或缺失值。** `~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 公式中的`+`表示**同时纳入**这些解释变量，并非对列做逐行算术加法。 `lm()`拟合线性回归，括号内包括公式与数据来源。 `AGES`是年龄分组变量，不应与连续年龄`AGE`等同。 `new_MARSTA`是前面重编码后的婚姻状况，执行前要确认它已存在。
4. **第4行** `bptest()`： `bptest()`对模型作Breusch–Pagan异方差检验。

把函数和统计概念拆开看

1. 模型和上一个RESET的回归变量集合相同。
2. 仅末尾从`resettest()`换为`bptest()`，表示原假设已变成"同方差"。
3. 必须分别报告两项检验，不可把BP显著当成函数形式必然有问题。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
##
##  studentized Breusch-Pagan test
##
## data:  .
## BP = 331.69, df = 52, p-value < 2.2e-16
```

找`BP`和`p-value`。在常用5%显著性水平下，若p<0.05则拒绝"同方差"零假设，提示异方差；检验不告诉你具体修正哪一个变量。

初学者容易踩的坑 / 研究上的注意事项

输出BP=331.69、p值仍极小：继续提示异方差。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 12 | 计算异方差稳健标准误并重新进行系数检验

原讲义位置：稳健标准误。

这段想做什么?

用lmtest的`coeftest()`和sandwich的`vcovHC()`，保持原回归系数、更新标准误和t检验。

课堂原始R代码（完整保留）

```
lfs %>%
  mutate(log_wage = log(HOURPAY)) %>%
  lm(log_wage ~ SEX + AGES + HIQUL22D + FTPT + JOBTYP + MPNR02 + new_MARSTA +
INDE07M + NSECMJ20 + GOR9D, data=.) %>%
coeftest(., vcov = vcovHC(.))
```

逐行讲解

1. **第1行** `lfs %>%`：从`lfs`数据框开始进入管道流程。 出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。
2. **第2行** `mutate(log_wage = log(HOURPAY)) %>%`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `mutate()`创建新数据列或覆盖现有列。 `log()`默认取自然对数；必须注意输入是否为0或负数。
3. **第3行** `lm(log_wage ~ SEX + AGES + HIQUL22D + FTPT + JOBTYP + MPNR02 + new_MARSTA + INDE07M + NSECMJ20 + GOR9D, data=.) %>%`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `data=.`中的`.`是管道传来的数据，**不是小数点或缺失值。** `~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 公式中的`+`表示**同时纳入**这些解释变量，并非对列做逐行算术加法。 `lm()`拟合线性回归，括号内包括公式与数据来源。 `AGES`是年龄分组变量，不应与连续年龄`AGE`等同。 `new_MARSTA`是前面重编码后的婚姻状况，执行前要确认它已存在。
4. **第4行** `coeftest(., vcov = vcovHC(.))`：`coeftest()`列出系数估计及依据指定协方差矩阵计算的检验结果。 `vcovHC(.)`依据当前模型计算异方差稳健系数协方差矩阵。

把函数和统计概念拆开看

1. `coeftest()` 接受拟合好的模型对象，并重新计算系数检验。
2. `vcovHC(.)` 基于管道传入的模型计算异方差稳健的协方差矩阵；点号指该模型。
3. `vcov = vcovHC(.)` 用新的方差协方差矩阵替代默认估计，以更新Std. Error、t值和p值。
4. 稳健标准误通常不改变OLS系数点估计值（Estimate），但可改变显著性判断。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
##                                          Estimate Std. Error  t value
## (Intercept)                             3.0713766  0.0413786  74.2262
## SEXFemale                              -0.0779263  0.0090922  -8.5707
## HIQUL22DHigher education               -0.1242005  0.0158922  -7.8152
## HIQUL22DA level or equivalent          -0.1533249  0.0111090 -13.8018
## HIQUL22DGCSE A*-C or equivalent        -0.1894577  0.0126873 -14.9329
## HIQUL22DOther qualitfication           -0.2013098  0.0206791  -9.7349
## HIQUL22DNo Qualification               -0.2759178  0.0220550 -12.5104
## (Intercept)                            < 2.2e-16 ***
## SEXFemale                              < 2.2e-16 ***
```

比较Estimate与默认lm模型：**系数点估计一般保持不变**，改变的是基于稳健协方差计算的标准误及其t检验、p值。

初学者容易踩的坑 / 研究上的注意事项

课件示例 `SEXFemale` 点估计仍约-0.07793，但稳健标准误约0.00909。稳健SE针对常见异方差推断问题，**不是**对遗漏变量、测量误差、内生性或模型设定偏误的修复。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

三、按课堂顺序串起来：这一讲完整分析流程

"模型变好"要分清三件不同的事

- **识别问题**：VIF/GVIF检验解释变量间的冗余程度；RESET检验设定；BP检验异方差；这些指标回答的问题不同。
- **改变模型**：移除 `EMPLEN`、将年龄从 `AGE` 改为 `AGES`、重编码婚姻变量、重新设置行业参照组；这些操作改变了研究假设和系数含义，应逐项记录依据。
- **改变推断方式**：`coeftest(..., vcov = vcovHC(...))` 在同一OLS系数上采用另一种标准误估计方式；不等于重新拟合一个能解决所有偏误的模型。
- **敏感性比较**：每改一次模型，记录样本量、变量集合、拟合形式、关键系数、标准误、诊断检验以及选择理由。
- **注意讲义内表述与代码的差异**：重新编码婚姻状态的代码产生三组，而不是讲解文字口头提及的两组。

需要记住的完整逻辑

1. 用GVIF查看变量间冗余。
2. 对原始模型、半对数模型、删减模型分别进行RESET/BP检验。
3. 重编码婚姻状态、调整行业参照组、调整年龄表示和解释变量。
4. 对修改后的OLS回归采用异方差稳健标准误，不把它误当成重构因果模型。

四、函数与参数速查表

函数/运算符	用来做什么	使用时先检查什么
`lm()`	拟合普通最小二乘线性回归模型	输入是什么类型？缺失值和参考组怎么处理？
`log()`	默认计算自然对数ln(x)，仅对正数有有限实数值	输入是什么类型？缺失值和参考组怎么处理？
`mutate()`	对数据框添加新列或修改已有列	输入是什么类型？缺失值和参考组怎么处理？
`resettest()`	Ramsey RESET模型设定检验，来自lmtest	输入是什么类型？缺失值和参考组怎么处理？
`bptest()`	Breusch–Pagan异方差检验，来自lmtest	输入是什么类型？缺失值和参考组怎么处理？
`vif()`	计算方差膨胀因子或广义VIF，来自car	输入是什么类型？缺失值和参考组怎么处理？
`case_when()`	按照给定条件依次决定输出的分类标签	输入是什么类型？缺失值和参考组怎么处理？
`factor()`	把数据转换成类别因子，供分类变量分析和模型编码使用	输入是什么类型？缺失值和参考组怎么处理？
`relevel()`	为分类因子重新指定参考水平	输入是什么类型？缺失值和参考组怎么处理？
`coeftest()`	根据指定系数协方差矩阵报告系数检验，来自lmtest	输入是什么类型？缺失值和参考组怎么处理？
`vcovHC()`	为回归模型计算异方差稳健协方差矩阵，来自sandwich	输入是什么类型？缺失值和参考组怎么处理？
`%>%`	管道符：把左边结果交给右边函数，便于从左到右阅读操作顺序	这里是回归公式、比较表达式还是普通计算？
`<-`	赋值符：把右边得到的值保存到左边对象或变量名	这里是回归公式、比较表达式还是普通计算？
`~`	模型/检验公式分隔符：在回归中通常左边是结果变量，右边是解释变量	这里是回归公式、比较表达式还是普通计算？

函数/运算符	用来做什么	使用时先检查什么
`==`	比较两个值是否相等，返回TRUE/FALSE；与赋值`<-`完全不同	这里是回归公式、比较表达式还是普通计算?
`<`	比较运算符：小于；`age < 40`就是只保留40以下	这里是回归公式、比较表达式还是普通计算?
`+`	回归公式里的加号表示**纳入多个解释变量**，不是把它们逐行数值相加	这里是回归公式、比较表达式还是普通计算?
`data=.`	点号`.`指管道前一步传过来的对象；明确告诉回归函数用哪个数据框	这里是回归公式、比较表达式还是普通计算?

五、本讲用到的变量：名字不是它们的中文意思

原变量名	根据本系列讲义能够确认/需要核对的含义
`HOURPAY`	小时工资（此系列课程LFS示例中的因变量）
`SEX`	性别分组
`AGE`	年龄（数值变量）
`HIQUL22D`	最高资格 / 学历水平（分类变量）
`FLEX22W6`	灵活工作安排相关变量（准确类别见数据字典）
`FTPT`	全职 / 兼职
`EMPLEN`	就业年限或工作持续时间相关变量（按数据字典核实）
`JOBTYP`	工作类型
`MPNR02`	LFS其他解释变量（请以原始数据字典确认编码含义）
`MARSTA`	婚姻状况
`INDE07M`	行业分类
`NSECMJ20`	社会经济分类
`GOR9D`	地理区域分组
`AGES`	年龄分类变量
`new_MARSTA`	经case_when重编码后的婚姻状态
`log_wage`	小时工资的自然对数

> **避免误译**：LFS数据的编码与变量类别需以课程使用的变量说明、元数据和预处理后的`levels()`为准。上表中对含义不明确的字段明确提示了“需要数据字典核实”，没有强行猜测。

六、初学者常见错误与排查顺序

1. **object not found（对象不存在）**：确认是否先创建了`lfs`或`fake_data`，或前一步的`select()`是否把变量删掉。
2. **could not find function（找不到函数）**：确认是否安装并`library()`了相应包。
3. **unexpected symbol / unexpected end of input（语法错误）**：检查括号、引号、逗号和前一行末尾的`%>%`是否完整。
4. **missing values / NA / -Inf**：统计函数遇到`NA`或`log(0)`会出问题，正式分析需遵循数据字典及清洗记录。
5. **contrasts can be applied only to factors with 2 or more levels**：筛选样本后某个分类变量可能只剩一类，需要检查`table()`或`levels()`。
6. **课程输出与自己不同**：先比较数据版本、样本行数、变量类型、参考组、缺失处理和包版本，不要立即修改统计模型去"凑数"。
7. **统计显著误当成因果关系**：观察数据中的关联仍可能受未观测因素影响，报告必须诚实描述限制。

七、课后练习：自己独立运行，别只看解释

练习 1 | VIF

解释为什么`HIQUL22D`等多自由度因子输出的是GVIF而不是只看某个单一VIF。

建议提交的自查结果：贴上所运行的代码、关键输出，并用自己的中文解释观察到的变化。

练习 2 | 重编码

运行`table(lfs$new_MARSTA, useNA="ifany")`（完成重编码之后），数一数实际生成多少个类别。

建议提交的自查结果：贴上所运行的代码、关键输出，并用自己的中文解释观察到的变化。

练习 3 | 稳健SE

对比`summary(lm(...))`与`coeftest(..., vcov=vcovHC(...))`中系数是否变化，以及标准误如何变化。

建议提交的自查结果：贴上所运行的代码、关键输出，并用自己的中文解释观察到的变化。

八、读完本讲，能否回答下面5个问题?

1. 上面的课堂代码中，哪些是**原始数据框**，哪些是处理后产生的新对象?
2. `%>%`、`~`、`data=.`分别在代码中起什么作用?
3. 这讲最重要的**模型或统计检验的原假设**是什么？输出中哪个部分告诉你结果?
4. 如果你只把一个参数改掉，图形/估计会如何变化？为什么?
5. 这个方法能不能直接证明因果关系？若不能，还需要什么研究设计或额外前提?

编写说明：教程中的"课堂原始R代码"均直接提取自`lecture10_notes.html`；数值输出摘录也来自该文件，未声称重新计算。对语法、注意事项和练习的解释属于**额外教学补充**。这不是翻译版课件的替代品；建议并排打开本教程和`lecture10_notes_中文版.html`核对原始图表、文字与结果。