第11讲笔记

定量数据分析

引言

- 现在，我们已经把模型调整到相当不错的状态。
- 最初的版本不太理想，因此我们做了一些修改。
- 模型还依赖另外几项需要讨论的假设。
- 这些假设更多地涉及分析的概念设计。

模型假设

我们将讨论以下假设（引自Peter Kennedy的《计量经济学指南》）：

1. 模型设定正确。
2. 残差方差相同，并且彼此独立。
3. 自变量之间不存在完全线性关系。
4. 自变量是固定的，且测量没有误差。
5. 残差的期望为零。

残差的分布假设

- 我们已经讨论过残差应当：
    - 服从正态分布。
    - 具有恒定的方差。
- 另一项假设是残差彼此独立。
- 也就是说，知道某个残差的具体取值，不应有助于预测另一个残差。
- 如果数据中存在模型没有考虑到的结构，就可能违反这一假设。
- 这一问题从分析设计和数据收集阶段就需要考虑。

我们的数据

- 数据中的每一条观测代表一个人。
- 阅读季度劳动力调查的文档会发现，调查以家庭为抽样单位，并访谈家庭中的每个成员。
- 同一家庭的人可能共享某些特征，而模型未必控制了这些因素。
- 这可能使同一家庭成员的残差相关。

- 它对假设检验的影响与异方差问题类似。

如何处理这一问题?

- 我认为这可能不是一个严重的问题。
- 样本包含大量家庭，而且每个家庭的人数相对较少。
- 有几种方法可以解决。
- 我建议使用一种简单方法：聚类稳健标准误。
- 我们允许同一组内的残差相关（组别由我们指定），但假定不同组之间独立。
- 可以使用miceadds包中的lm.cluster函数估计这样的模型。

聚类稳健标准误

- 在我们的数据中，HSERIALP变量标识每个人所属的家庭。
- 此前我们从数据中排除了这一字段，因此需要把它重新加入select调用，然后重新加载、处理数据。
- select函数现在应该类似于：

```
lfs <- select(lfs,SEX,HOURPAY,AGE,GOR9D,EMPLEN,FLEX22W6,FTPT,HIQUL22D,
              INDE07M,JOBTYP,MPNRO2,MARSTA,NSECMJ20,BUSHR,AGES,HSERIALP)
```

估计模型

```
lfs %>%
  mutate(log_wage = log(HOURPAY)) %>%
  lm.cluster(data = .,
             log_wage ~ SEX + AGE + HIQUL22D + FTPT + JOBTYP + MPNRO2 + new_MARSTA
+ INDE07M + NSECMJ20 + GOR9D,
             cluster = "HSERIALP") %>%
  summary()
```

稳健标准误

```
## R^2= 0.4778
##
##                                                Estimate   Std. Error
## (Intercept)                                 3.086969836 0.0296716506
## SEXFemale                                  -0.072477892 0.0087970859
## AGE                                         0.005483362 0.0004040354
## HIQUL22DHigher education                   -0.130678763 0.0161689068
## HIQUL22DA level or equivalent              -0.164029502 0.0111998679
## HIQUL22DGCSE A*-C or equivalent            -0.195033719 0.0127509367
## HIQUL22DOther qualitfication               -0.193790968 0.0209412890
## HIQUL22DNo Qualification                   -0.276496850 0.0216695497
## FTPTPart-time                              -0.030869597 0.0111997894
## JOBTYPNot permanent in some way            -0.028515091 0.0237512786
## MPNRO211-19                                 0.011543459 0.0188647187
## MPNRO220-24                                 0.014039373 0.0233277255
## MPNRO2Don't know but under 25              -0.030033657 0.0262168296
## MPNRO225-49                                 0.013993771 0.0159845052
## MPNRO250-249                                0.047566994 0.0143197227
## MPNRO2250-499                               0.093715926 0.0194921359
## MPNRO2Don't know but between 50 and 499     0.033404114 0.0232499766
## MPNRO2500 or more                           0.128853612 0.0148288868
## new_MARSTADivorced                          0.058736532 0.0171760497
## new_MARSTAMarried                           0.055448064 0.0094543158
## INDEO7MAgriculture, forestry and fishing   -0.018376968 0.0632075627
## INDEO7MEnergy and water                     0.169203697 0.0296419911
## INDEO7MManufacturing                        0.102229644 0.0155157579
## INDEO7MConstruction                         0.174390187 0.0225424207
## INDEO7MDistribution, hotels and restaurants -0.030962240 0.0124965536
## INDEO7MTransport and communication          0.148729700 0.0171128999
## INDEO7MBanking and finance                  0.100527666 0.0131197524
## INDEO7MOther services                      -0.028134161 0.0222887708
## NSECMJ2OLower managerial and professional  -0.214972397 0.0125205321
## NSECMJ2OIntermediate occupations           -0.453634835 0.0141048643
## NSECMJ2OLower supervisory and technical    -0.425015381 0.0200819205
## NSECMJ2OSemi-routine occupations           -0.552923764 0.0160407046
## NSECMJ2ORoutine occupations                -0.590493898 0.0174408853
## NSECMJ2ONever worked                       -0.463865298 0.0322067267
## GOR9DYorkshire and The Humber              -0.155682125 0.0222713437
## GOR9DSouth West                            -0.123554215 0.0222382017
## GOR9DWest Midlands                         -0.110846706 0.0240530451
## GOR9DSouth East                            -0.089018724 0.0216909469
## GOR9DEast of England                       -0.075017907 0.0237355383
## GOR9DEast Midlands                         -0.153178997 0.0229611700
## GOR9DNorth East                            -0.180706389 0.0254060203
## GOR9DNorth West                            -0.137984041 0.0225070443
## GOR9DWales                                 -0.170684127 0.0253828135
## GOR9DNorthern Ireland                      -0.166344748 0.0229327215
## GOR9DScotland                              -0.110272913 0.0233079479
```

```
##                                                t value      Pr(>|t|)
## (Intercept)                                104.0376850  0.000000e+00
## SEXFemale                                   -8.2388523  1.738704e-16
## AGE                                         13.5714885  5.910932e-42
## HIQUL22DHigher education                    -8.0821026  6.365952e-16
## HIQUL22DA level or equivalent              -14.6456640  1.435916e-48
## HIQUL22DGCSE A*-C or equivalent            -15.2956386  8.175496e-53
## HIQUL22DOther qualitfication                -9.2540134  2.162180e-20
## HIQUL22DNo Qualification                   -12.7596952  2.752761e-37
## FTPTPart-time                               -2.7562659  5.846546e-03
## JOBTYPNot permanent in some way             -1.2005708  2.299177e-01
## MPNRO211-19                                  0.6119073  5.405991e-01
## MPNRO220-24                                  0.6018320  5.472859e-01
## MPNRO2Don't know but under 25               -1.1455869  2.519661e-01
## MPNRO225-49                                  0.8754585  3.813245e-01
## MPNRO250-249                                 3.3217818  8.944462e-04
## MPNRO2250-499                                4.8078839  1.525363e-06
## MPNRO2Don't know but between 50 and 499      1.4367375  1.507926e-01
## MPNRO2500 or more                            8.6893651  3.644707e-18
## new_MARSTADivorced                           3.4196764  6.269566e-04
## new_MARSTAMarried                            5.8648416  4.495617e-09
## INDEO7MAgriculture, forestry and fishing    -0.2907400  7.712502e-01
## INDEO7MEnergy and water                      5.7082433  1.141482e-08
## INDEO7MManufacturing                         6.5887625  4.435075e-11
## INDEO7MConstruction                          7.7360896  1.025212e-14
## INDEO7MDistribution, hotels and restaurants -2.4776623  1.322462e-02
## INDEO7MTransport and communication           8.6910869  3.589883e-18
## INDEO7MBanking and finance                   7.6623143  1.826121e-14
## INDEO7MOther services                       -1.2622572  2.068563e-01
## NSECMJ2OLower managerial and professional  -17.1695896  4.485805e-66
## NSECMJ2OIntermediate occupations           -32.1615880 6.082501e-227
## NSECMJ2OLower supervisory and technical    -21.1640805  2.047165e-99
## NSECMJ2OSemi-routine occupations           -34.4700421 2.255790e-260
## NSECMJ2ORoutine occupations                -33.8568764 2.874888e-251
## NSECMJ2ONever worked                       -14.4027458  4.972793e-47
## GOR9DYorkshire and The Humber               -6.9902439  2.744087e-12
## GOR9DSouth West                             -5.5559445  2.761146e-08
## GOR9DWest Midlands                          -4.6084271  4.057265e-06
## GOR9DSouth East                             -4.1039575  4.061421e-05
## GOR9DEast of England                        -3.1605732  1.574590e-03
## GOR9DEast Midlands                          -6.6712192  2.536871e-11
## GOR9DNorth East                             -7.1127389  1.137624e-12
## GOR9DNorth West                             -6.1307047  8.749069e-10
## GOR9DWales                                  -6.7243975  1.763205e-11
## GOR9DNorthern Ireland                       -7.2535982  4.058428e-13
## GOR9DScotland                               -4.7311292  2.232744e-06
```

一些思考

- 正如预期，结果没有发生太大变化。
- 不过还是值得检查，因为它有可能改变我们的结论。
- 地理层面也可能存在聚类，例如不同城市或地区。
- 我们的数据只包含相当宽泛的地区类别，也可以考虑用它们进行处理。
- 我们已经控制了地区间差异。

可能违反独立性假设的原因

- 模型设定错误。
- 数据具有层级结构。
- 对同一单位进行重复的时间观测。
- 数据中存在地理空间关系。

检验

- 检验独立性假设是否被违反，超出了本课程的范围。
- 课程开始时，我要求大家选择横截面数据，就是因为它们相对不容易出现这一问题。
- 仍然应该考虑数据中是否有某种结构可能带来麻烦。
- 至少可以把它写成研究局限性和 / 或未来研究方向。

假设5

- 第五项假设比较抽象，实际上不太需要我们额外操作。
- 假设有以下理论模型：

$$y_i = \beta_0 + \beta_1 \cdot x_{1i} + u_i$$

- 运行OLS模型并估计所有参数。

假设5

- 假设我们判断错了，实际上我们不知道的正确理论模型是：

$$y_i = \beta_0 + \beta_1 \cdot x_{1i} + \beta_2 \cdot x_{2i} + u_i$$

- 如果x_1与x_2不相关，就可以避免遗漏变量偏差，β_1的估计是无偏的。
- 然而，β_0的估计会有偏，因为它包含了被排除变量x_2的均值。
- 我们几乎从不解释模型截距，因此对此不必太担心。

- 在模型中包含β_0，可确保残差u的估计均值为零。

对当前模型的思考

- 我们已经估计、检验并改进了模型。
- 虽然不完美，但我认为它比较稳健。
- 我们最初想估计性别工资差距。
- 最终模型发现，女性每小时工资比男性低约11%。
- 模型所控制的因素无法解释这一差异。

构建稳健模型

- 我们已经讨论了构建稳健模型需要考虑的事项。
- 学习了如何建模，也讨论了模型背后的假设。
- 现在我想回顾一些要点，并提供额外建议。

构建稳健模型

- 从一般到具体
    - 从所有变量和完整样本开始。
    - 按需要缩减并完善模型。
- 从具体到一般
    - 从少数变量和特定样本开始。
    - 逐步扩展并完善模型。
- 不同学科和研究者对哪种方法合适有不同观点。
- 只要充分检验模型，两种方法都可以成立。

从一般到具体的建模方法

1. 理论
2. 设计理想的回归模型
3. 数据收集
4. 一般模型
5. 诊断检查与改进
6. 具体模型
7. 是否修订理论？
8. 展示最终模型

理论

- 先从理论出发，可以来自定量或定性研究。

- 最有可能发挥作用的机制是什么？
- 什么因素使一个变量随另一变量变化？
- 尽量考虑所有可能的决定因素。
- 尽可能明确需要检验的具体假设。

一般模型

- 尝试估计第一个回归模型。
- 在正式开始诊断和调整前，先进行明显必要的修改。
- 查看残差图。
- 执行诊断检验，例如RESET检验、异方差检验。

潜在问题

- 系数符号不符合预期：
  - 检查多重共线性。
  - 尝试非线性变换。
  - 考虑创建交互项。
- 调整后的$\bar{R}^2$异常偏低：
  - 变换变量。
  - 删除无关变量。
  - 考虑加入变量。

具体模型

- 应该表现良好：
  - 稳定。
  - 尽可能通过模型设定检验。
- 回归系数应具有实际意义：
  - 结果合理吗？
  - 它们与理论和直觉有什么关系？
  - 是否存在其他解释或理解方式？
- 看到结果后，是否需要修订理论？
- 有时只有开始实证研究，才能真正理解所采用的理论。

形成最终模型

- 获得稳健模型既是一门科学，也是一门艺术。
- 通常需要大量实践才能掌握。
- 尝试运行不同回归，查看不同的诊断结果。

- 请记住，一开始如何设定模型可能才是最重要的环节。
- 每次展示模型前，都应确保它足够稳健。
- 说明进行了哪些检验，以及还有哪些未解决的问题。
- 网上有很多关于模型稳健性检验的优质指南。
- 相关主题也有许多好书。

超越OLS

- 学习新的定量方法，可以花费整整一生。
- 本课程提供了扎实的入门基础，帮助你进一步学习新方法。
- 最后我想简要介绍其他几种常见回归方法。
- 我不要求你在课程作业中使用它们。
- 使用这些方法不会获得额外分数，而且我不希望在你的课程作业中看到它们。

计数数据

- 第一讲说过，事物的计数是离散变量的例子。
- 我们提到一个经验法则：如果计数的平均值小于10，就不应该使用OLS。
- 当计数平均值低于10时，可以考虑泊松回归或负二项回归。
- 这些模型明确考虑了数据的计数性质。
- 它们不会预测不可能的取值，例如负数。
- 它们提供适当的标准误，从而支持稳健的假设检验。

二元因变量

- 假设某件事情要么发生、要么不发生，或者某个判断要么真、要么假。
- 例如，一个人是否拥有汽车？
- 我们可能想研究哪些因素决定汽车拥有情况。
- 可以考虑Probit模型或Logistic逻辑回归模型。

分类变量

- 有时因变量是分类变量，例如通勤采用的交通方式。
- 常见建模方式是多项逻辑回归，也称多项Logit模型。
- 还有适用于特殊情况的变体，例如嵌套Logit模型。

有序变量

- 有序变量可以当作分类变量，通过多项Logit模型分析。
- 在特定假设下，可以使用有序Logit或有序Probit模型获得更有效率的估计。

面板数据

- 有时我们会对同一横截面单位重复观察。
- 有时可以使用OLS分析，但通常不太合适。
- 另一种方法是使用面板数据模型，例如固定效应或随机效应模型。
- 这些模型具有一些优势，例如可以考虑无法直接观察的异质性。
- 它们也支持在此类数据上开展稳健的假设检验。
- 针对不同的因变量类型，还有线性、逻辑回归等多种版本。

时间序列数据

- 有时我们收集随时间变化的数据，例如GDP、失业率、通货膨胀等。
- 这些数据有时可以使用OLS建模，但也存在专门的模型。
- 对于单变量时间序列，有自回归综合移动平均（ARIMA）模型、广义自回归条件异方差（GARCH）模型等。
- 对于多变量分析，有向量自回归（VAR）模型和向量误差修正（VECM）模型等。

空间计量经济学

- 这类模型适用于具有空间位置参考的数据。
- 部分模型与OLS回归很相似，但会考虑空间邻近造成的独立性假设违反问题。
- 常见模型包括空间误差模型、空间滞后模型和空间杜宾模型。

课程结束

- 现在，你已经具备了扎实的定量数据分析基础。
- 除此之外，还有更多方法、路径和不同学术观点。
- 即使以后不使用这些方法，你现在也应能够理解和批判性评价他人的研究。