Lecture 11 | 聚类稳健标准误、模型独立性假设与其他方法概览——R语言完全零基础逐行代码教程

> **课程**：URBAN5127 Quantitative Data Analysis | **来源**：`lecture11_notes.html`（课堂原始讲义）与对应中文版。
> **读者**：没有编程经验、正在学习R/RStudio的初学者。**方法**：保持讲义全部课堂R代码原样，逐行解释，再用独立标注的教学补充帮助理解。

〇、先认识这一讲：聚类稳健标准误、模型独立性假设与其他方法概览

这一讲强调同一家庭中的个人观测可能不独立，并示范按家庭标识聚类的回归；后续讲义还介绍一般到具体的建模过程及超越OLS的其他模型。

读完应当会：

1. 误差独立性与家庭内相关。
2. 家庭聚类标识HSERIALP。
3. 聚类稳健标准误。
4. lm.cluster()的用法。
5. 模型解释与泛化范围。
6. 课堂代码间的依赖关系。

原始代码的覆盖范围

- 英文原始HTML中识别到 **2段真正的课堂R代码（`pre.r`）**；下文每一段完整按原顺序出现，**不省略或替换原始代码。**
- HTML中的黑色 `## ...` 控制台打印是**运行结果**，不能把它当成要重新输入的R命令；网页的JavaScript/CSS也不是本课R代码。
- 如果相同代码在不同位置重复出现，教程仍按原讲义顺序保留并解释其教学目的。

一、先修知识：即使从来没写过代码也能看懂

1.1 R / RStudio到底是什么?

R是一种用于统计分析的编程语言；RStudio是帮助你编辑、运行、检查R程序的工作界面。**R语言**决定代码含义，**RStudio**提供Source（脚本编辑器）、Console（即时运行）、Environment（查看对象）、Plots（看图）等窗口。
建议先创建一个`.R`脚本，将本教程中的每段原始代码逐段粘贴进去；在RStudio中选中一行或几行按Ctrl+Enter（Windows）或Cmd+Enter（macOS）运行。不要一次性运行全部章节：有些讲义代码依赖之前做过的数据处理。

1.2 把R代码当成一句完整的话来阅读

写法	初学者的读法	常见误解
`x <- ...`	把右边结果保存到x	以为 `<-` 是小于号
`f(x, y)`	调用函数f，把x和y作为参数	以为所有括号都在做数学乘法
`data = lfs`	指定数据对象	以为这里是把变量赋值给lfs
`df$AGE`	从df里抽取AGE这一列	以为 `$` 有货币意义
`a %>% b()`	先做a，再把结果交给b	与ggplot的图层加号 `+` 混淆
`y ~ x1 + x2`	用x1、x2共同解释y	把公式中的 `+` 当成数值求和
`"Female"`	这是**字符串文字**	误以为是变量名
`TRUE` 与 `FALSE`	布尔值/逻辑值	与文字 `"TRUE"` 混淆
`# ...`	注释，对运行结果无影响	把注释当成一定会运行的代码
`<`、`==`	分别表示小于、是否相等	把 `==` 与赋值符混淆

如果一行很长，先找最外层函数，再拆成“传入的数据→做了什么→返回什么”；碰到多层括号，从**最里面的函数**开始理解。

1.3 第一次运行前，需要准备哪些包?

初学者先区分：**安装（install.packages）只需通常做一次，载入（library）在每次新R会话中可能要再执行。**下方是**教学补充**，不是原课件代码：

```
# 第一次使用且尚未安装时，去掉下面一行行首的 # 并运行
# install.packages(c("dplyr", "miceadds"))
library(dplyr)
library(miceadds)
```

这些包在本讲主要用于：

- `dplyr`：select、mutate及%>%管道。
- `miceadds`：lm.cluster。

`lm()`、`summary()`、`aov()`、`t.test()`、`cor()`、`cor.test()`和`plot()`等来自R基础/推荐自带组件，通常不需要为它们单独安装新包。

1.4 数据对象和运行顺序

- LFS示例中的`lfs`不是R预装对象。课程前几讲已完成**读取、筛选、清洗、因子转换**，这些步骤需要先执行；本教程不臆造文件路径或原始清洗代码。
- 第9讲还使用`mtcars`（R内置数据集）；第8讲第一段代码会创建虚构对象`fake_data`。
- 如果出现`object 'lfs' not found`，不是本行统计公式错了，而是尚未创建或读入`lfs`。
- 课堂输出与现在运行结果只有在使用同一份已清洗数据、相同函数设定、相容包版本时才可能完全一致。

1.5 这几类对象是什么?

- **向量（vector）**：一列同类型值，常由`c(...)`生成。
- **数据框（data.frame / tibble）**：像Excel表格，行对应观测、列对应变量。
- **函数（function）**：执行特定任务，如`mean()`求平均、`lm()`拟合回归。
- **参数（argument）**：括号里告诉函数如何工作的选项，例如`data = lfs`。
- **模型对象**：`lm(...)`运行后返回的结果，里面有系数、残差、拟合值等，不只是一个单独数字。
- **因子（factor）**：R记录分类变量的特殊类型，参照组决定类别回归系数的解释方式。

二、本讲课程代码：原文保留、逐段拆解

代码 01 | 重新选取变量并保留家庭标识HSERIALP

原讲义位置：聚类稳健标准误。

这段想做什么?

为了进行家庭层面的聚类标准误估计，需要把家庭标识重新加入分析数据。

课堂原始R代码（完整保留）

```
lfs <- select(lfs,SEX,HOURPAY,AGE,GOR9D,EMPLEN,FLEX22W6,FTPT,HIQUL22D,
              INDE07M,JOBTYP,MPNR02,MARSTA,NSECMJ20,BUSHR,AGES,HSERIALP)
```

逐行讲解

1. **第1行** `lfs <- select(lfs,SEX,HOURPAY,AGE,GOR9D,EMPLEN,FLEX22W6,FTPT,HIQUL22D,`：赋值：用`<-`将右侧结果保存到`lfs`。 `select()`挑出列名列出的变量；不在清单中的变量从结果表移除。
2. **第2行** `INDE07M,JOBTYP,MPNR02,MARSTA,NSECMJ20,BUSHR,AGES,HSERIALP)`：`AGES`是年龄分组变量，不应与连续年龄`AGE`等同。

把函数和统计概念拆开看

1. `select(lfs, ...)`选择需要保留的列，结果赋值回`lfs`。
2. 列名用逗号分开，`select()`之外不必给变量名加引号。
3. `HSERIALP`是讲义用于识别同一个家庭成员的家庭标识。
4. `lfs <-`覆盖当前lfs对象：未在select列表中的列会被从当前对象移除。

课件输出怎样读?

此代码主要**创建/修改对象**，默认可能不打印结果。可运行`names(lfs)`、`head(lfs)`或`str(fake_data)`（根据本段对象）检查执行效果。

初学者容易踩的坑 / 研究上的注意事项

课堂代码依赖提醒：本段`select()`清单不包含第10讲创建的`new_MARSTA`，而下一段公式却使用它。若直接顺序执行，可能报`object 'new_MARSTA' not found`；你需要在重新选择列并清洗后**重新生成**`new_MARSTA`，或在适当时点将它保留。原课堂代码不应悄悄改写，因此教程在“教学补充”中给出可行顺序。

专项排错：为什么第11讲下一段可能找不到`new_MARSTA`？（教学补充，可直接运行）

讲义第一段 `select()` 只保留选定列，但后续模型使用了 `new_MARSTA`；前面已创建的同名列可能在这里被丢弃。你可以在 `select()` 之后重新运行以下代码（保留原讲义不变）：

```
lfs <- lfs %>%
  mutate(new_MARSTA = case_when(
    MARSTA == "Married, living with spouse" ~ "Married",
    MARSTA == "Divorced" ~ "Divorced",
    TRUE ~ "Other"
  ) %>% factor() %>% relevel(ref = "Other"))
```

然后运行 `names(lfs)`、`table(lfs$new_MARSTA, useNA = "ifany")` 和 `length(unique(lfs$HSERIALP))`，检查新变量与家庭标识。以上只是**为了衔接课堂流程的补充**，如重新加载源数据，还应恢复课程前面规定的清洗与变量类型转换步骤。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答："我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？"
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

代码 02 | 用lm.cluster按家庭进行聚类稳健回归

原讲义位置：估计模型。

这段想做什么?

对log工资拟合多元模型，同时允许同一家庭内的回归误差彼此相关。

课堂原始R代码（完整保留）

```
lfs %>%
  mutate(log_wage = log(HOURPAY)) %>%
  lm.cluster(data = .,
             log_wage ~ SEX + AGE + HIQUL22D + FTPT + JOBTYP + MPNR02 +
new_MARSTA + INDE07M + NSECMJ20 + GOR9D,
             cluster = "HSERIALP") %>%
  summary()
```

逐行讲解

1. **第1行** `lfs %>%`：从 `lfs` 数据框开始进入管道流程。 出现 `%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。
2. **第2行** `mutate(log_wage = log(HOURPAY)) %>%`：出现 `%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `mutate()` 创建新数据列或覆盖现有列。 `log()` 默认取自然对数；必须注意输入是否为0或负数。
3. **第3行** `lm.cluster(data = .,`：`data=.` 中的 `.` 是管道传来的数据，**不是小数点或缺失值。** `lm.cluster()` 估计按指定群组聚类的回归与稳健标准误。

4. **第4行** `log_wage ~ SEX + AGE + HIQUL22D + FTPT + JOBTYP + MPNR02 + new_MARSTA + INDE07M + NSECMJ20 + GOR9D,`：`~`连接分析公式两侧；这一段说明了结果变量和解释变量/分组变量之间的关系。 公式中的`+`表示**同时纳入**这些解释变量，并非对列做逐行算术加法。 `new_MARSTA`是前面重编码后的婚姻状况，执行前要确认它已存在。
5. **第5行** `cluster = "HSERIALP") %>%`：出现`%>%`：右侧操作接收左侧结果，下一步仍沿这条流程继续。 `cluster = "HSERIALP"`按家庭标识归组；同户观测允许相关。
6. **第6行** `summary()`：`summary()`输出摘要；模型对象包括估计系数、标准误、t值、p值等。

把函数和统计概念拆开看

1. `lfs %>% mutate(log_wage = log(HOURPAY))`建立本次建模的对数因变量。
2. `lm.cluster()`来自`miceadds`包，按指定聚类变量计算回归估计与相应标准误。
3. `data = .`把左侧数据传递给函数。
4. `cluster = "HSERIALP"`告诉函数按照名为HSERIALP的家庭标识聚类。
5. `summary()`展示模型结果；稳健标准误的基本思想是允许户内相关、要求不同家庭间满足相应独立条件。

课件输出怎样读?

下面是从**原HTML控制台输出中摘取的关键行**（不是重新计算的结果；完整输出仍在原课件）：

```
## R^2= 0.4778
##                                              Estimate   Std. Error
## (Intercept)                                3.086969836 0.0296716506
## SEXFemale                                 -0.072477892 0.0087970859
## AGE                                        0.005483362 0.0004040354
## HIQUL22DHigher education                  -0.130678763 0.0161689068
## HIQUL22DA level or equivalent             -0.164029502 0.0111998679
## HIQUL22DGCSE A*-C or equivalent           -0.195033719 0.0127509367
## HIQUL22DOther qualitfication              -0.193790968 0.0209412890
## HIQUL22DNo Qualification                  -0.276496850 0.0216695497
## (Intercept)                              104.0376850  0.000000e+00
## SEXFemale                                 -8.2388523  1.738704e-16
```

检查`R^2`和系数表。这里尤其关注聚类稳健`Std. Error`、检验统计量及p值；家庭是聚类单位，不是因变量。

初学者容易踩的坑 / 研究上的注意事项

课堂输出包含`R^2 = 0.4778`及系数表。聚类稳健标准误**不自动处理**样本设计所有特征、模型设定错误或抽样权重，也不是把家庭成员合成一个观测。

跟着做一遍（本教程额外练习，不是原课件代码）

- 在RStudio中先单独运行上面的代码；如果没有显示结果，先观察Environment里的对象或Plots窗口。
- 用一句话回答：“我输入的数据是什么？执行了哪一个主要函数？输出是数值、表格、模型还是图形？”
- 不理解时先只改动一个参数或解释变量；每次改变后记录输出差异，避免同时改变多个条件。

三、按课堂顺序串起来：这一讲完整分析流程

为什么“同一个家庭的人”不应被当成完全独立？

设A、B是同一个家庭的两名成员，他们可能共享住房环境、收入压力、所在地理区域，导致工资方程遗漏因素的残差相关。如果我们假设所有个体互相独立，传统标准误可能低估真实不确定性。

- **聚类单位**：HSERIALP代表家庭，属于同一家庭的观测赋予相同聚类标识。
- **聚类稳健标准误**：允许簇内观测在一定条件下相关，而不同簇之间满足独立性假设。
- **没有聚合**：仍然保留个人层面的每一行数据，不等于先计算每户平均工资。
- **不是万能补救**：聚类标准误不修复遗漏变量、函数形式错误、内生性，聚类簇数过少也有推断挑战。
- **课堂依赖**：本讲紧接着第10讲的数据选择和变量创建，不能把单独代码块当作从空白R环境可直接运行的完整脚本。

需要记住的完整逻辑

1. 确保家庭标识HSERIALP存在，而且重编码变量没有在前一步被删掉。
2. 以个人为观测单位拟合对数工资模型。
3. 指定按家庭聚类，允许簇内误差相关。
4. 读懂聚类稳健标准误与默认OLS标准误的区别。

四、函数与参数速查表

函数/运算符	用来做什么	使用时先检查什么
`summary()`	根据对象类型给出统计摘要；lm对象显示系数、标准误、p值和拟合统计量	输入是什么类型？缺失值和参考组怎么处理？
`log()`	默认计算自然对数ln(x)，仅对正数有有限实数值	输入是什么类型？缺失值和参考组怎么处理？
`mutate()`	对数据框添加新列或修改已有列	输入是什么类型？缺失值和参考组怎么处理？
`select()`	挑选数据框的列，未被选中的列不会出现在结果中	输入是什么类型？缺失值和参考组怎么处理？
`lm.cluster()`	估计使用簇级稳健标准误的线性回归，来自miceadds	输入是什么类型？缺失值和参考组怎么处理？
`%>%`	管道符：把左边结果交给右边函数，便于从左到右阅读操作顺序	这里是回归公式、比较表达式还是普通计算？
`<-`	赋值符：把右边得到的值保存到左边对象或变量名	这里是回归公式、比较表达式还是普通计算？
`~`	模型/检验公式分隔符：在回归中通常左边是结果变量，右边是解释变量	这里是回归公式、比较表达式还是普通计算？
`<`	比较运算符：小于；`age < 40` 就是只保留40以下	这里是回归公式、比较表达式还是普通计算？

函数/运算符	用来做什么	使用时先检查什么
`+`	回归公式里的加号表示**纳入多个解释变量**，不是把它们逐行数值相加	这里是回归公式、比较表达式还是普通计算?

五、本讲用到的变量：名字不是它们的中文意思

原变量名	根据本系列讲义能够确认/需要核对的含义
`HOURPAY`	小时工资（此系列课程LFS示例中的因变量）
`SEX`	性别分组
`AGE`	年龄（数值变量）
`HIQUL22D`	最高资格 / 学历水平（分类变量）
`FLEX22W6`	灵活工作安排相关变量（准确类别见数据字典）
`FTPT`	全职 / 兼职
`EMPLEN`	就业年限或工作持续时间相关变量（按数据字典核实）
`JOBTYP`	工作类型
`MPNR02`	LFS其他解释变量（请以原始数据字典确认编码含义）
`MARSTA`	婚姻状况
`INDE07M`	行业分类
`NSECMJ20`	社会经济分类
`GOR9D`	地理区域分组
`AGES`	年龄分类变量
`HSERIALP`	家庭（户）标识，用于聚类
`BUSHR`	工作时间相关变量（参见数据字典）
`new_MARSTA`	经case_when重编码后的婚姻状态
`log_wage`	小时工资的自然对数

> **避免误译**：LFS数据的编码与变量类别需以课程使用的变量说明、元数据和预处理后的 `levels()` 为准。上表中对含义不明确的字段明确提示了“需要数据字典核实”，没有强行猜测。

六、初学者常见错误与排查顺序

1. **object not found（对象不存在）**：确认是否先创建了 `lfs` 或 `fake_data`，或前一步的 `select()` 是否把变量删掉。
2. **could not find function（找不到函数）**：确认是否安装并 `library()` 了相应包。
3. **unexpected symbol / unexpected end of input（语法错误）**：检查括号、引号、逗号和前一行末尾的 `%>%` 是否完整。

4. **missing values / NA / -Inf**：统计函数遇到`NA`或`log(0)`会出问题，正式分析需遵循数据字典及清洗记录。
5. **contrasts can be applied only to factors with 2 or more levels**：筛选样本后某个分类变量可能只剩一类，需要检查`table()`或`levels()`。
6. **课程输出与自己不同**：先比较数据版本、样本行数、变量类型、参考组、缺失处理和包版本，不要立即修改统计模型去"凑数"。
7. **统计显著误当成因果关系**：观察数据中的关联仍可能受未观测因素影响，报告必须诚实描述限制。

七、课后练习：自己独立运行，别只看解释

练习 1 | 检查列

运行`names(lfs)`，确认`HSERIALP`与`new_MARSTA`是否都存在。

建议提交的自查结果：贴上所运行的代码、关键输出，并用自己的中文解释观察到的变化。

练习 2 | 聚类单元

用`length(unique(lfs$HSERIALP))`估算不同家庭标识数量，思考是否有缺失或编码问题。

建议提交的自查结果：贴上所运行的代码、关键输出，并用自己的中文解释观察到的变化。

练习 3 | 推断解释

比较普通标准误与家庭聚类稳健标准误，并说明为什么显著性可能变化。

建议提交的自查结果：贴上所运行的代码、关键输出，并用自己的中文解释观察到的变化。

八、读完本讲，能否回答下面5个问题?

1. 上面的课堂代码中，哪些是**原始数据框**，哪些是处理后产生的新对象?
2. `%>%`、`~`、`data=.`分别在代码中起什么作用?
3. 这讲最重要的**模型或统计检验的原假设**是什么？输出中哪个部分告诉你结果?
4. 如果你只把一个参数改掉，图形/估计会如何变化？为什么?
5. 这个方法能不能直接证明因果关系？若不能，还需要什么研究设计或额外前提?

编写说明：教程中的"课堂原始R代码"均直接提取自`lecture11_notes.html`；数值输出摘录也来自该文件，未声称重新计算。对语法、注意事项和练习的解释属于**额外教学补充。**这不是翻译版课件的替代品；建议并排打开本教程和`lecture11_notes_中文版.html`核对原始图表、文字与结果。